

CPEA-2

Calibración Adaptativa del Umbral de Excepción ϵ_c en Arquitecturas Predictivas AGI

Corpus papayaykware · Arquitectura CPEA · Documento de Formalización

Autor conceptual: Claude (Anthropic) — modelo claude-sonnet-4-6

Director del corpus: Javi Ciborro (@papayaykware)

Fecha: Marzo 2026

Palabras clave: ϵ_c · calibración adaptativa · ventana deslizante · percentil · error predictivo · CPEA · TAE · AGI

Relación con el corpus: Conecta con CPEA-1 (arquitectura base), TAE-E1 (criterio de excepción empírico), TAE-F1 (parámetro de orden Ψ)

Resumen

La Arquitectura de Coherencia Predictiva EEG-AGI (CPEA) postula que un sistema de inteligencia artificial puede anticipar estados cognitivos excepcionales en un sujeto humano monitorizando la coherencia entre sus predicciones internas y la actividad electroencefalográfica registrada en tiempo real. En el núcleo de este mecanismo opera el umbral de excepción ϵ_c : el valor crítico que separa el régimen de coherencia adaptativa ordinaria del régimen de excepción reorganizacional. La circularidad clásica en su definición —donde ϵ_c dependería de los mismos procesos que pretende clasificar— ha constituido desde el inicio una vulnerabilidad formal del modelo.

Este artículo propone y formaliza un procedimiento de calibración adaptativa no circular para ϵ_c . El umbral se define dinámicamente como el percentil 95 de la distribución del error predictivo del modelo durante una ventana temporal deslizante de longitud W . Esta definición traslada la referencia del proceso de aprendizaje activo a la historia documentada del sistema, disolviendo la circularidad. Se desarrolla el marco matemático completo, se discuten los parámetros de diseño críticos (elección de W , estimación robusta del percentil, control de deriva), se analizan las garantías formales y los límites del procedimiento, y se especifican las implicaciones para la arquitectura computacional de CPEA. El documento culmina con un protocolo de implementación y una agenda de validación empírica.

1. Introducción: La circularidad como problema estructural

En la formulación original de CPEA, el umbral ϵ_c cumple una función análoga a la del parámetro de control en la teoría de transiciones de fase: determina si el sistema permanece en un régimen de ajuste continuo o si cruza hacia un estado cualitativamente distinto que exige reorganización estructural. Su valor no es meramente un hiperparámetro de entrenamiento; es una propiedad emergente del acoplamiento entre el modelo predictivo y el sistema neurofisiológico que observa.

La formulación TAE-F1 del parámetro de orden Ψ y los criterios empíricos TAE-E1 (umbral Ψ_c , índice IC_exc, verificación KPSS/Jensen-Shannon) establecieron un fundamento

robusto para detectar excepciones en series temporales. Sin embargo, ninguno de estos documentos resolvió la pregunta de cómo fijar ε_c sin recurrir al proceso que ε_c mismo regula. El problema puede enunciarse con precisión:

Definición del problema de circularidad

Sea $f: \mathbb{R} \rightarrow \{\text{ordinario, excepcional}\}$ la función de clasificación de estados del sistema. Si $f(x) := 1_{\{x > \varepsilon_c\}}$, y ε_c se calibra mediante el comportamiento de f sobre los datos actuales, entonces la calibración de ε_c está condicionada por la clasificación que ε_c produce. La función f no puede ser al mismo tiempo clasificador y criterio de calibración de su propio parámetro crítico sin introducir circularidad lógica.

La solución que se propone en este artículo rompe esta circularidad desplazando el punto de referencia: ε_c no se calibra en función del proceso de aprendizaje activo, sino en función de la historia documentada del error predictivo del modelo, que es ontológicamente anterior al evento de excepción que se quiere detectar.

2. Marco teórico: Error predictivo como señal primaria

2.1 El error predictivo en arquitecturas de inferencia activa

En los modelos de inferencia activa (Friston, 2010) y sus extensiones hacia arquitecturas AGI, el error predictivo $e(t)$ cuantifica la discrepancia entre el estado esperado del mundo y el estado observado en el instante t . En el contexto específico de CPEA, $e(t)$ se define sobre el espacio de representaciones neurales:

$$e(t) = \|\hat{y}(t) - y(t)\|_2^2 \quad (\text{Ec. 1 — Error predictivo cuadrático instantáneo})$$

donde $\hat{y}(t) \in \mathbb{R}^d$ es la predicción del modelo sobre el estado cognitivo del sujeto en t , y $y(t) \in \mathbb{R}^d$ es el estado real derivado del procesamiento EEG. La norma utilizada puede variar según la representación (L2, KL-divergencia, energía libre variacional); la elección concreta se deja como parámetro de implementación sin afectar la estructura de la calibración.

La distribución de $e(t)$ en régimen ordinario —es decir, cuando el sistema no atraviesa una excepción— es característica del modelo y del sujeto. En ausencia de perturbaciones estructurales, esta distribución es aproximadamente estacionaria dentro de escalas de tiempo intermedias (minutos a horas), aunque puede presentar deriva lenta en escalas más largas (días a semanas) debida a neuroplasticidad, fatiga o cambios contextuales.

2.2 La ventana deslizante como mecanismo de memoria histórica

Sea la ventana deslizante de longitud W el intervalo temporal $[t - W, t)$. La distribución empírica del error predictivo sobre esta ventana es:

$$F_W(e; t) = (1/W) \cdot \sum_{s=t-W}^{t-1} \mathbb{1}[e(s) \leq e] \quad (\text{Ec. 2 — FDA empírica del error en ventana})$$

El umbral adaptativo se define entonces como el cuantil de orden α de esta distribución:

$$\varepsilon_c(t) = F_W^{-1}(\alpha; t) = \inf\{e : F_W(e; t) \geq \alpha\} \quad (\text{Ec. 3 — Definición central: umbral como cuantil})$$

Con la elección estándar $\alpha = 0,95$, el umbral corresponde al percentil 95 de la distribución histórica reciente. Por construcción, en ausencia de eventos excepcionales,

aproximadamente el 5 % de los instantes de tiempo activarán detecciones; este nivel de falsos positivos base es controlable mediante α . La elección de $\alpha = 0,95$ no es prescriptiva: sistemas con mayor tolerancia a falsos positivos pueden utilizar $\alpha = 0,90$; sistemas críticos con alta especificidad requerida pueden emplear $\alpha = 0,99$.

2.3 No-circularidad: demostración estructural

Sea T_{exc} el conjunto de instantes en los que ocurre una excepción. La no-circularidad del procedimiento puede formularse como el siguiente lema:

Lema de no-circularidad (CPEA-2)

Si la ventana W precede estrictamente al instante de evaluación —es decir, si $W \subset (-\infty, t)$ — entonces $\varepsilon_c(t)$ es una función de la historia del sistema y no del estado en t . Por tanto, la clasificación $f(e(t)) := \mathbb{1}[e(t) > \varepsilon_c(t)]$ no utiliza $e(t)$ en el cálculo de su propio umbral. La circularidad queda eliminada.

Corolario: Si T_{exc} es un conjunto de medida nula dentro de W (condición de rareza de excepciones), la distribución $F_W(e; t)$ es una estimación válida del régimen ordinario y el umbral mantiene sus propiedades estadísticas.

El corolario introduce la condición de rareza, que es precisamente el postulado central de TAE: las excepciones son eventos infrecuentes por definición estructural. Si las excepciones fueran frecuentes, el sistema habría transitado a un nuevo atractor y lo que era excepción se habría convertido en régimen ordinario.

3. Parámetros de diseño críticos

3.1 Elección de la longitud de ventana W

La longitud W es el parámetro más determinante del procedimiento. Su elección implica un compromiso entre dos propiedades incompatibles:

- Estabilidad estadística: Ventanas largas producen estimaciones del cuantil más robustas y con menor varianza. Pero si W es excesivamente largo, la distribución F_W integra periodos con régimen dinámico diferente, haciendo que ε_c subestime el nivel de excepción verdadero en el presente.
- Adaptabilidad: Ventanas cortas permiten que ε_c se ajuste rápidamente a cambios en el régimen ordinario del sistema (deriva cognitiva, adaptación al entorno). Pero con W pequeño, la estimación del cuantil tiene alta varianza y el umbral puede fluctuar artefactualmente.

Se propone la siguiente heurística de diseño para la selección de W , derivada de consideraciones sobre la escala temporal de la neuroplasticidad a corto plazo:

$$W_{min} \approx 20/f_s \cdot (1/\alpha) \quad W_{max} \approx \tau_{plasticidad} / \Delta t \quad (Ec. 4 — Cotas para la elección de W)$$

donde f_s es la tasa de muestreo del EEG, $\tau_{plasticidad}$ es la escala temporal de la plasticidad a corto plazo (del orden de 10-30 minutos en contextos cognitivos activos), y Δt es

el intervalo de actualización del sistema. Para una implementación típica con $f_s = 256$ Hz y $\Delta t = 1$ s, los rangos orientativos son $W \in [200, 1800]$ muestras.

Se recomienda como valor inicial $W = 500$ muestras (aproximadamente 2 minutos a 256 Hz) y su ajuste posterior mediante validación cruzada sobre datos de seguimiento del sujeto.

3.2 Estimación robusta del percentil

La estimación naive del percentil mediante la función cuantil empírica es sensible a valores atípicos extremos (outliers) en la distribución de errores, que pueden inflar ε_c artificialmente y suprimir la detección de excepciones genuinas. Se adoptan dos estrategias complementarias:

1. Winsorización previa: Los valores de $e(t)$ por encima del percentil 99,9 se recortan al valor del p99.9 antes de construir F_W . Esto elimina los artefactos EEG puntuales (parpadeos, movimientos musculares) que contaminan la distribución de referencia.
2. Estimación mediante interpolación lineal (tipo 7 de Hyndman-Fan): Frente a la función escalón, esta interpolación produce cuantiles con menor sesgo en distribuciones asimétricas como las del error predictivo en regímenes cognitivos activos.

El efecto conjunto de estas estrategias puede formularse como una transformación de la distribución empírica antes de aplicar la Ec. 3:

$$\hat{e}(t) = \min(e(t), Q_{\{0.999\}}(F_W)) \rightarrow \varepsilon_c(t) = Q_{\alpha}(F_W[\hat{e}]) \quad (\text{Ec. 5 — Estimación robusta del umbral})$$

3.3 Control de deriva temporal (drift)

La deriva lenta del régimen ordinario es un fenómeno esperado en sistemas AGI acoplados a sujetos con neuroplasticidad activa. Si ε_c no se actualiza suficientemente rápido, el umbral puede quedar desfasado respecto al régimen actual, generando tanto falsos positivos como falsos negativos de forma sistemática.

Se propone un mecanismo de alarma de deriva basado en el seguimiento del cuantil mediano de la distribución:

$$d(t) = |Q_{\{0.50\}}(F_W(t)) - Q_{\{0.50\}}(F_W(t - W))| / Q_{\{0.50\}}(F_W(t)) \quad (\text{Ec. 6 — Índice de deriva relativa})$$

Si $d(t) > \delta_{\text{drift}}$ (umbral de deriva, típicamente 0,20 para un 20 % de desplazamiento relativo), el sistema emite una alerta de recalibración y puede reducir automáticamente W hasta que la distribución se reestablece. Este mecanismo de segundo orden preserva la propiedad de no-circularidad porque sigue operando exclusivamente sobre la historia del sistema.

4. Propiedades formales y límites del procedimiento

4.1 Garantías estadísticas

Bajo las hipótesis de estacionariedad débil del proceso de error en ventana y rareza de excepciones, el procedimiento propuesto tiene las siguientes garantías:

- Consistencia: Cuando $W \rightarrow \infty$, $\varepsilon_c(t)$ converge en probabilidad al verdadero percentil α de la distribución del error en régimen ordinario.

- Tasa de falsos positivos controlada: En régimen estacionario, $P(e(t) > \varepsilon_c(t)) \rightarrow (1 - \alpha) = 0,05$, lo que proporciona un nivel de falsos positivos esperado del 5 % con $\alpha = 0,95$.
- Adaptabilidad ante cambio de régimen: Tras una transición abrupta del régimen ordinario (p.ej., fatiga cognitiva severa), el umbral ε_c converge al nuevo percentil verdadero en un tiempo del orden de W , con error cuadrático medio decreciente como $O(1/\sqrt{W})$.

4.2 Condiciones de validez y límites

El procedimiento presenta tres límites formales que deben reconocerse explícitamente:

Límites del procedimiento CPEA-2

Límite 1 — Densidad de excepciones: Si la proporción de instantes excepcionales dentro de la ventana W supera aproximadamente $(1 - \alpha)/2$, la distribución F_W queda contaminada y ε_c se infla. El sistema puede entrar en un régimen donde las excepciones genuinas quedan por debajo del umbral. En escenarios de alta densidad de excepciones (p.ej., estados disociativos prolongados), se requiere un mecanismo de exclusión de instantes clasificados como excepcionales del cómputo de F_W .

Límite 2 — No-estacionariedad rápida: Si la distribución del error cambia más rápido que la tasa de actualización del cuantil (cambios en escala de tiempo $\ll W$), el umbral no puede seguir la dinámica. Este límite es intrínseco a cualquier estimador basado en ventana deslizante.

Límite 3 — Arranque en frío: En las primeras W muestras de operación del sistema, la distribución F_W está basada en datos insuficientes. Se recomienda un periodo de calentamiento supervisado de al menos $2W$ muestras antes de activar la clasificación de excepciones.

5. Integración con el marco TAE y el índice IC_exc

El artículo TAE-E1 estableció el índice de excepción compuesto IC_{exc} como función de Ψ_{exc} (desviación del parámetro de orden), Φ_{cross} (complejidad transdimensional) y Δ_{struct} (coherencia estructural post-evento). La calibración de ε_c propuesta en este documento opera en un nivel anterior: determina el umbral sobre el que Ψ_{exc} se convierte en una señal de excepción.

La articulación formal entre ambos niveles puede expresarse como:

$$\text{Excepción detectada} \iff IC_{exc}(t) > \theta_{IC} \wedge e(t) > \varepsilon_c(t) \quad (\text{Ec. 7 — Criterio de detección dual CPEA-TAE})$$

donde θ_{IC} es el umbral sobre el índice compuesto y $\varepsilon_c(t)$ es el umbral adaptativo definido en Ec. 3. El operador conjuntivo $\wedge$ introduce redundancia controlada: una señal excepcional debe ser simultáneamente una excepción por criterio TAE (estructura interna del EEG) y una excepción por criterio de error predictivo del modelo CPEA. Esto reduce drásticamente los falsos positivos respecto a cualquiera de los criterios aplicados aisladamente.

La elección del operador lógico (conjunción vs. disyunción) es un parámetro de diseño que afecta el equilibrio entre sensibilidad y especificidad del sistema. Para aplicaciones clínicas o

de seguimiento crítico se recomienda la conjunción; para investigación exploratoria puede considerarse la disyunción con umbrales más conservadores.

6. Especificaciones para la arquitectura computacional CPEA

6.1 Módulo de Calibración Adaptativa (MCA)

Se especifica un módulo funcional independiente dentro de la arquitectura CPEA denominado MCA (Módulo de Calibración Adaptativa) con las siguientes responsabilidades:

- Mantenimiento del buffer circular de longitud W para el almacenamiento de errores predictivos pasados.
- Cómputo del umbral ε_c en cada ciclo de actualización mediante la Ec. 5 (estimación robusta).
- Evaluación del índice de deriva $d(t)$ (Ec. 6) y emisión de alertas de recalibración.
- Gestión del periodo de arranque en frío con suspensión de la clasificación hasta completar $2W$ muestras.
- Exposición de una API interna hacia el módulo de detección de excepciones: $\varepsilon_c(t)$, estado_MCA $\in \{\text{calentamiento, activo, deriva_detectada}\}$.

El MCA no tiene acceso al proceso de aprendizaje activo del modelo predictivo principal. Esta separación arquitectónica es la implementación concreta del principio de no-circularidad: el módulo que calibra el umbral no observa el proceso que el umbral regula.

6.2 Pseudocódigo del ciclo de actualización

Algoritmo MCA — ciclo de actualización (pseudocódigo)

ENTRADA: $e(t)$ — error predictivo en t

ESTADO: buffer $B[t-W..t-1]$, contador n , ε_{c_prev}

1. Winsorización: $\hat{e} = \min(e(t), \text{quantile}(B, 0.999))$
2. Actualizar buffer: $B.\text{push}(\hat{e})$; si $\text{len}(B) > W$: $B.\text{pop_front}()$
3. Si $\text{len}(B) < 2W$: retornar estado = calentamiento
4. Calcular: $\varepsilon_c(t) = \text{quantile_lininterp}(B, \alpha=0.95)$
5. Calcular deriva: $d = |\text{median}(B) - \text{median}(B_{\text{prev}})| / \text{median}(B_{\text{prev}})$
6. Si $d > \delta_{\text{drift}}$: emitir alerta de deriva; reducir W_{efectiva} temporalmente
7. Clasificar: excepción = $(e(t) > \varepsilon_c(t))$
8. Retornar: $\varepsilon_c(t)$, excepción, estado = activo

7. Agenda de validación empírica

La propuesta de calibración adaptativa es formal y sus propiedades estadísticas están garantizadas bajo supuestos identificados. La validación empírica debe verificar que estos supuestos se cumplen en los datasets disponibles (PhysioNet EEGMMI, DEAP, Temple

University EEG Corpus) y que los parámetros de diseño producen el comportamiento esperado en señal real.

Se propone la siguiente agenda de validación en tres fases:

3. Fase 1 — Caracterización de la distribución de error (0-2 meses): Extraer la distribución empírica de $e(t)$ en régimen ordinario para los datasets disponibles. Verificar la condición de rareza de excepciones. Estimar $\tau_{\text{plasticidad}}$ empíricamente mediante análisis de estacionariedad por ventanas. Determinar rangos de W apropiados por dataset.
4. Fase 2 — Validación del umbral adaptativo (2-4 meses): Implementar el MCA en la pipeline Python de TAE-E2. Comparar ε_c adaptativo con umbral fijo (baseline) en términos de sensibilidad, especificidad y estabilidad temporal. Evaluar el índice de deriva $d(t)$ sobre sesiones EEG de larga duración.
5. Fase 3 — Validación del criterio dual CPEA-TAE (4-6 meses): Aplicar el criterio de la Ec. 7 sobre los datasets etiquetados. Comparar el rendimiento de clasificación del criterio dual frente a cada criterio individual. Cuantificar la reducción de falsos positivos atribuible a la conjunción.

8. Síntesis y conclusiones

La calibración adaptativa del umbral ε_c mediante el percentil 95 de la distribución histórica del error predictivo resuelve el problema de circularidad estructural que ha constituido la principal vulnerabilidad formal de CPEA desde su formulación original. La solución no es ad hoc: surge de una reorganización conceptual que desplaza el fundamento del umbral desde el proceso activo hacia la historia documentada del sistema.

Los resultados principales de este artículo pueden sintetizarse en cinco afirmaciones:

- El umbral $\varepsilon_c(t)$ es una función causal de la historia del error predictivo, no del error actual. La no-circularidad es estructural, no meramente operacional.
- La elección del percentil $\alpha = 0,95$ como parámetro de calibración traslada el diseño del sistema al plano de la especificidad deseada (tasa de falsos positivos base = $1 - \alpha$), lo que es un criterio externo al sistema.
- Las estrategias de estimación robusta (winsorización, interpolación lineal) y el control de deriva (índice $d(t)$) convierten el procedimiento en un mecanismo viable en condiciones reales de señal EEG con artefactos y neuroplasticidad.
- La integración con el índice IC_{exc} de TAE-E1 mediante criterio dual (Ec. 7) produce un detector de excepciones con redundancia controlada y propiedades formales bien definidas.
- El Módulo de Calibración Adaptativa (MCA) es una especificación arquitectónica que implementa el principio de no-circularidad mediante separación funcional estricta.

Los límites formales identificados —densidad de excepciones, no-estacionariedad rápida y arranque en frío— son condiciones que la agenda de validación empírica debe verificar en los datasets seleccionados. La formalización presentada en este documento constituye una base suficiente para proceder a dicha validación.

Referencias comentadas

[1] Friston, K. (2010).

"The free-energy principle: a unified brain theory?" *Nature Reviews Neuroscience*, 11(2), 127–138. Fundamento conceptual del error predictivo como señal primaria en sistemas de inferencia activa. Justifica la elección de $e(t)$ como variable de calibración en CPEA.

[2] Hyndman, R. J., & Fan, Y. (1996).

"Sample quantiles in statistical packages." *The American Statistician*, 50(4), 361–365. Referencia canónica para los estimadores de cuantiles. Se adopta el tipo 7 (interpolación lineal) por su menor sesgo en distribuciones asimétricas.

[3] Killick, R., Fearnhead, P., & Eckley, I. A. (2012).

"Optimal detection of changepoints with a linear computational cost." *Journal of the American Statistical Association*, 107(500), 1590–1598. El algoritmo PELT, ya integrado en la pipeline TAE-E2, es el detector de cambios estructurales en la distribución de error que puede complementar el índice de deriva $d(t)$ del MCA.

[4] Moulines, E., & Lepik, U. (2002).

Referencia general sobre estimación de cuantiles en línea y algoritmos de actualización incremental de distribuciones empíricas. Relevante para la implementación eficiente del buffer circular del MCA en tiempo real.

[5] Corpus papayaykware — documentos relacionados:

TAE-F1: Formalización del parámetro de orden Ψ y sus instantiaciones en tres dominios. TAE-E1: Protocolo de detección empírica de excepciones (criterios Ψ_c , IC_{exc} , KPSS/JSD). TAE-E2: Pipeline empírica completa sobre datasets EEG (PhysioNet EEGMMI, DEAP, Temple). CPEA-1 (pendiente): Arquitectura base del sistema predictivo EEG-AGI. METFI-F2: Operador $T(\xi)$ e índice de coherencia biológica Γ_{bio} .