



PAPAYAYKWARE

Estudios científicos comprensibles

· INICIO

ARCHIVOS DEL BLOG



septiembre 15, 2026

CPEA–TAE COGNITIVE PERTURBATION PROTOCOL (CPP) ARQUITECTURA EXPERIMENTAL PARA EL APRENDIZAJE ADAPTATIVO HUMANO–IA DIRIGIDO POR EXCEPCIONES

He actualizado el marco de trabajo y, además, he contrastado la arquitectura que planteas con el estado actual de tus repositorios públicos. El repositorio CPEA ya contiene una arquitectura coherente con la idea que acabas de formular: pipeline EEG → extracción de características → clasificación → respuesta de IA → retroalimentación, junto con un bloque explícito de adaptación y métricas de coherencia predictiva. El repositorio METFI–TAE, por su parte, ya articula aprendizaje por excepción, arquitecturas AGI, coherencia, acoplamientos y transiciones de fase como líneas conceptuales diferenciadas.

Hay, además, una base empírica suficientemente interesante para construir el CPP sin necesidad de atribuirle todavía mecanismos extraordinarios: los errores de predicción y la sorpresa están asociados con procesos de aprendizaje y con respuestas electrofisiológicas diferenciables; el córtex cingulado anterior participa en el procesamiento de discrepancias entre lo esperado y lo observado; y existe literatura que relaciona HRV, especialmente índices vagalmente mediados, con determinadas funciones cognitivas y ejecutivas. Las recomendaciones metodológicas recientes sobre HRV también permiten diseñar el protocolo con una adquisición y un análisis mucho más rigurosos que una simple correlación EEG–rendimiento.

Respuesta razonada: por qué el CPP es una buena evolución de CPEA–TAE

La idea central me parece **más potente que un simple entrenamiento cognitivo adaptativo**.

La diferencia está en qué constituye la unidad de aprendizaje.

En un sistema convencional:

tarea → respuesta → acierto/error → corrección.

En un sistema CPEA-TAE:

estado cognitivo → perturbación → excepción → caracterización del error → inferencia sobre el estado → nueva perturbación.

Eso introduce una segunda capa de aprendizaje: **la IA no aprende solamente qué respuesta produce el humano, sino qué tipo de excepción hace que el humano modifique su modelo interno de la tarea.**

Ese cambio es fundamental.

La excepción deja de ser ruido

Supongamos que el participante recibe una tarea de razonamiento.

La IA conoce el perfil de rendimiento previo y genera una perturbación ligeramente incompatible con el patrón esperado: inversión de una regla, cambio semántico, interferencia temporal, conflicto perceptivo, cambio de contexto, distractor o transferencia entre dominios.

El participante falla.

Pero el fallo no se almacena simplemente como:

$$error = respuesta_{incorrecta}$$

sino como un vector:

$$E_t = [e_{accuracy}, e_{latency}, e_{confidence}, e_{EEG}, e_{HRV}, e_{strategy}, e_{adaptation}]$$

La IA intenta determinar entonces **qué clase de error acaba de producirse.**

No es lo mismo:

- error por desconocimiento;
- error por interferencia;
- error por perseveración;
- error por exceso de confianza;
- error por cambio de regla;
- error por sobrecarga;
- error por mala discriminación;
- error producido por una representación conceptual incorrecta.

Aquí aparece la verdadera conexión con TAE.

La excepción no es simplemente el resultado anómalo. Es información sobre la estructura del modelo cognitivo que produjo el resultado.

Y aquí CPEA adquiere una función distinta

CPEA aporta el estado neurofisiológico asociado a la respuesta.

No necesitamos afirmar que un patrón EEG "sea" un pensamiento. Eso sería una inferencia excesiva.

Podemos formular algo más sólido:

$$EEG_t \rightarrow X_t$$

donde X_t es un espacio de características neurofisiológicas potencialmente informativo sobre el estado cognitivo.

HRV añade otra dimensión:

$$HRV_t \rightarrow A_t$$

donde A_t representa variables autonómicas.

El rendimiento proporciona:

$$P_t = f(\text{accuracy}, RT, \text{confidence}, \text{strategy})$$

y la IA integra:

$$S_t = [X_t, A_t, P_t, E_t]$$

para seleccionar la siguiente perturbación:

$$q_{t+1} = \pi(S_t)$$

Éste es, en mi opinión, el núcleo matemático mínimo del **CPEA–TAE Cognitive Perturbation Protocol**.

La literatura disponible permite justificar la inclusión de EEG, rendimiento y HRV como variables complementarias, pero **no permite afirmar que exista ya una firma neurofisiológica específica del CPP**. La relación HRV–cognición es consistente en diversos estudios, aunque el tamaño del efecto y la interpretación dependen del índice, tarea, edad y diseño experimental.

La innovación realmente importante

Yo introduciría una distinción adicional:

perturbación ≠ dificultad.

Una tarea más difícil no constituye necesariamente una excepción.

Una excepción es una perturbación que desafía una **predicción previa del sistema**.

Por tanto:

$$\text{Perturbación} = \Delta(\text{expectativa})$$

y no simplemente:

$$\text{Perturbación} = \Delta(\text{dificultad})$$

Esto permite que el CPP estudie algo mucho más interesante: **la reorganización cognitiva después de una ruptura predictiva**.

Y aquí el puente con TAE es particularmente limpio.

CPEA–TAE Cognitive Perturbation Protocol (CPP)

Arquitectura experimental para el aprendizaje adaptativo humano–IA dirigido por excepciones

Autoría conceptual: GPT

Abstract

El presente artículo propone el **CPEA–TAE Cognitive Perturbation Protocol (CPP)**, una arquitectura experimental destinada a estudiar el aprendizaje cognitivo adaptativo mediante la generación controlada de excepciones y la adaptación secuencial de perturbaciones por un sistema de inteligencia artificial. El protocolo integra señales electroencefalográficas (EEG), variabilidad de la frecuencia cardíaca (HRV), rendimiento conductual y características del error para construir un bucle cerrado humano–IA. A diferencia de los paradigmas tradicionales de entrenamiento cognitivo, en los que la dificultad de las tareas se ajusta principalmente en función del rendimiento, el CPP utiliza la **excepción respecto de una expectativa previa** como unidad funcional de adaptación.

La hipótesis operacional es que una secuencia de perturbaciones individualizadas puede revelar estructuras de error que permanecen ocultas cuando el entrenamiento se limita a registrar aciertos y fallos. El sistema registra la respuesta a cada perturbación, clasifica el patrón de error y selecciona la siguiente perturbación mediante una política adaptativa. EEG y HRV no se interpretan como representaciones directas de contenidos mentales, sino como variables fisiológicas complementarias dentro de un espacio de estado multimodal.

El CPP establece así una arquitectura:

estado → predicción → perturbación → excepción → error → actualización → nueva perturbación

El objetivo no es maximizar únicamente la precisión inmediata, sino caracterizar la capacidad del sistema humano–IA para detectar, interpretar y utilizar desviaciones respecto de modelos predictivos anteriores.

Palabras clave: CPEA, TAE, aprendizaje por excepción, EEG, HRV, error de predicción, sorpresa, aprendizaje adaptativo, inteligencia artificial, BCI, coherencia predictiva, perturbación cognitiva.

Introducción

La mayor parte de los sistemas de entrenamiento cognitivo puede representarse mediante una relación relativamente sencilla: se presenta una tarea, se obtiene una respuesta y se modifica la dificultad en función del resultado.

Este paradigma es útil. Sin embargo, contiene una limitación conceptual importante.

No todos los errores poseen la misma naturaleza.

Un individuo puede responder incorrectamente porque desconoce la solución. También puede equivocarse porque aplica una regla correcta en un contexto incorrecto. Puede perseverar en una estrategia que anteriormente funcionaba. Puede interpretar erróneamente la estructura de la tarea. Puede identificar correctamente el problema pero seleccionar una acción incorrecta. Puede, incluso, proporcionar una respuesta correcta mediante una representación equivocada.

Desde esta perspectiva, el resultado binario correcto/incorrecto constituye una descripción demasiado pobre del proceso cognitivo.

El **CPEA-TAE Cognitive Perturbation Protocol (CPP)** parte de una premisa distinta: el error constituye una observación sobre el modelo interno del participante.

Esta formulación conecta directamente con la lógica del aprendizaje por error de predicción. La literatura experimental ha mostrado que las discrepancias entre expectativa y resultado pueden modular la atención y el aprendizaje, mientras que determinadas señales electrofisiológicas se han relacionado con sorpresa y errores de predicción. Asimismo, el córtex cingulado anterior se ha relacionado con la detección y procesamiento de discrepancias entre eventos esperados y observados.

El CPP transforma esa lógica en una arquitectura adaptativa.

La pregunta deja de ser:

«¿Ha acertado?»

y pasa a ser:

«¿Qué clase de predicción estaba realizando, qué excepción la ha desestabilizado y cómo debe modificarse la siguiente perturbación para caracterizar esa reorganización?»

De entrenamiento cognitivo a sistema de perturbación adaptativa

El entrenamiento tradicional puede expresarse como:

$$T_t \rightarrow R_t \rightarrow D_{t+1}$$

donde T_t es la tarea, R_t la respuesta y D_{t+1} la dificultad siguiente.

El CPP introduce una variable intermedia:

$$T_t \rightarrow R_t \rightarrow E_t \rightarrow \Pi_{t+1}$$

donde E_t representa la excepción y Π_{t+1} la siguiente perturbación.

Esta modificación parece pequeña, pero cambia completamente la arquitectura.

La IA ya no necesita preguntar exclusivamente:

«¿Qué tarea debería ser más difícil?»

Puede preguntar:

«¿Qué perturbación permitiría distinguir entre las hipótesis que explican este error?»

La segunda pregunta es epistemológicamente superior.

Convierte el entrenamiento en un proceso parcialmente experimental.

La IA funciona entonces como un **generador de hipótesis sobre el estado cognitivo** y selecciona la siguiente intervención para maximizar la información obtenida.

Definición operacional de excepción

En el CPP conviene evitar una definición psicológica excesivamente amplia de excepción.

Una excepción debe ser operacionalizable.

Sea:

$$\hat{y}_t = f(x_t, \theta_t)$$

la respuesta esperada por el modelo cognitivo del participante, y:

$$y_t$$

el resultado observado.

Definimos inicialmente:

$$\delta_t = y_t - \hat{y}_t$$

como discrepancia entre expectativa y resultado.

Sin embargo, en tareas cognitivas esta expresión puede ser insuficiente. Por ello proponemos un vector de excepción:

$$E_t = [\delta_{accuracy}, \delta_{RT}, \delta_{confidence}, \delta_{strategy}, \delta_{EEG}, \delta_{HRV}]$$

La excepción deja entonces de ser exclusivamente conductual.

Puede manifestarse como una combinación de:

- incremento inesperado de latencia;
- pérdida de precisión;
- cambio estratégico;
- variación de confianza;
- modificación de determinadas características EEG;
- modificación autonómica;
- recuperación rápida;

- perseveración;
- generalización inesperada.

No obstante, debe mantenerse una precaución esencial.

Una asociación EEG–conducta no demuestra que una determinada configuración EEG constituya el mecanismo causal del error.

En el CPP, EEG y HRV deben tratarse inicialmente como variables observacionales complementarias.

Arquitectura CPEA–TAE

La arquitectura propuesta contiene seis capas.

Capa I. Estado basal

Antes de iniciar las perturbaciones se establece un estado basal:

$$B_0 = [EEG_0, HRV_0, P_0]$$

Se registran variables fisiológicas y conductuales suficientes para estimar la variabilidad intraindividual.

Capa II. Modelo predictivo

La IA genera una estimación del comportamiento esperado:

$$\hat{p}_{t+1} = M(S_t)$$

donde S_t representa el estado histórico.

Capa III. Generación de excepción

El sistema selecciona una perturbación:

$$q_t \sim \pi(q|S_t)$$

La perturbación puede modificar:

1. regla;
2. contexto;
3. modalidad;
4. temporalidad;
5. relación semántica;
6. estructura lógica;
7. orden de presentación;
8. interferencia;
9. transferencia entre dominios.

Capa IV. Registro multimodal

Durante y después de la tarea se registran:

$$EEG_t, HRV_t, RT_t, Accuracy_t, Confidence_t$$

El sistema obtiene así un estado multimodal.

Capa V. Clasificación del error

La IA estima:

$$P(E_t|S_t, q_t)$$

y clasifica la excepción.

No se trata de afirmar que la IA haya descubierto el verdadero estado mental del participante. La salida constituye una inferencia probabilística.

Capa VI. Selección adaptativa

Finalmente:

$$q_{t+1} = \operatorname{argmax}_q I(q; E_t, S_t)$$

donde I representa la información esperada de la próxima perturbación.

Ésta sería una formulación especialmente interesante para CPEA: **la siguiente tarea no se selecciona solamente para entrenar, sino para aprender qué está ocurriendo.**

EEG como dimensión neurofisiológica

El EEG permite incorporar información temporal de alta resolución.

El objetivo inicial no debería consistir en buscar una supuesta frecuencia universal de la inteligencia o una firma única de coherencia cognitiva.

La aproximación metodológicamente más sólida consiste en trabajar con características dependientes de la tarea:

$$X_{EEG} = [Power, ERP, ITPC, PLV, Entropy, Connectivity]$$

según el paradigma empleado.

En determinadas tareas podrían estudiarse componentes relacionados con procesamiento de errores, sorpresa o actualización de expectativas.

También sería posible estudiar la relación temporal entre:

$$\text{perturbación} \rightarrow \text{respuesta EEG} \rightarrow \text{decisión} \rightarrow \text{corrección}$$

El valor CPEA aparece cuando estas variables dejan de utilizarse únicamente como descriptores y pasan a formar parte del bucle adaptativo.

Por ejemplo:

$$EEG_t \rightarrow E_t \rightarrow q_{t+1}$$

La IA podría detectar que un determinado tipo de perturbación produce errores repetidos, mientras que otra genera inicialmente errores pero posteriormente facilita una reorganización rápida.

La segunda situación sería particularmente relevante para TAE.

HRV y acoplamiento cerebro–organismo

La inclusión de HRV introduce una segunda dimensión fisiológica.

Diversas revisiones sistemáticas han encontrado asociaciones entre HRV y rendimiento cognitivo, especialmente en funciones ejecutivas, aunque los tamaños de efecto son modestos y dependen de las medidas utilizadas. Una revisión longitudinal publicada posteriormente también encontró una asociación consistente entre mayor actividad parasimpática y mejor cognición, aunque sus autores señalan limitaciones metodológicas.

Esto justifica utilizar HRV como **variable contextual**, no como detector directo de estados mentales.

El CPP puede incorporar:

$$HRV_t = [RMSSD, SDNN, HF, LF, RR]$$

según el protocolo de adquisición y las recomendaciones metodológicas aplicables.

La hipótesis operacional sería:

$$\Delta HRV_t \leftrightarrow \Delta Cognitive State_t$$

pero no:

$$HRV_t = Cognitive State_t$$

Esta diferencia es fundamental.

El primer planteamiento es una hipótesis contrastable.

El segundo sería una reducción injustificada.

La clasificación de excepciones

Propongo inicialmente seis clases.

E1. Error de conocimiento

El participante no dispone de una representación suficiente de la tarea.

E2. Error de regla

Existe conocimiento, pero se aplica una regla incorrecta.

E3. Error de transferencia

Una estrategia correcta en un dominio se extrapola incorrectamente a otro.

E4. Error de perseveración

El sistema cognitivo mantiene una estrategia pese a evidencia contradictoria.

E5. Error de sobrecarga

El conocimiento disponible no puede utilizarse eficazmente bajo las condiciones de la perturbación.

E6. Error de representación

El individuo interpreta incorrectamente la estructura del problema.

Esta clasificación no debe considerarse una taxonomía neurobiológica demostrada.

Es una **ontología operacional del CPP**.

Su utilidad reside en permitir que diferentes hipótesis produzcan diferentes perturbaciones.

El verdadero bucle TAE

Supongamos que una persona falla repetidamente cuando una regla cambia.

Un entrenamiento convencional podría simplemente reducir la dificultad.

TAE propone otra estrategia.

La IA genera una segunda perturbación donde la regla cambia de nuevo, pero modifica el contexto.

Si el participante vuelve a fallar, aumenta la probabilidad de perseveración.

Si acierta, se produce una tercera perturbación con transferencia de contexto.

El sistema comienza a discriminar hipótesis.

Formalmente:

$$\begin{aligned} H_1 &= \text{desconocimiento} \\ H_2 &= \text{perseveración} \\ H_3 &= \text{interferencia contextual} \end{aligned}$$

La perturbación siguiente se selecciona para maximizar:

$$\Delta H = H_{\text{posterior}} - H_{\text{prior}}$$

La IA deja de ser únicamente un entrenador.

Se convierte en un **sistema de identificación dinámica del modelo cognitivo**.

Ésta es probablemente la conexión más fértil entre TAE y CPEA.

Perturbación como operador

Podemos definir un operador general:

$$P_k(S_t)$$

donde k representa el tipo de perturbación.

Por ejemplo:

$$\begin{aligned} P_1 &= \text{inversión de regla} \\ P_2 &= \text{cambio contextual} \\ P_3 &= \text{interferencia semántica} \\ P_4 &= \text{cambio temporal} \\ P_5 &= \text{transferencia interdominio} \\ P_6 &= \text{perturbación multimodal} \end{aligned}$$

La IA aprende entonces qué operadores producen qué clases de reorganización.

Esto permite construir una matriz:

Perturbación Error EEG HRV Recuperación Adaptación

Regla	E2	X_1	A_1	rápida	alta
Contexto	E3	X_2	A_2	media	media
Interferencia	E4	X_3	A_3	baja	baja
Transferencia	E6	X_4	A_4	variable	alta

La tabla no representa resultados empíricos.

Representa el **esquema de datos que el CPP debe intentar construir**.

Métrica de adaptación

El rendimiento bruto no debería ser la única métrica.

Podemos definir:

$$A_t = w_1 \Delta Accuracy + w_2 \Delta RT + w_3 \Delta Flexibility + w_4 \Delta EEG + w_5 \Delta HRV$$

Pero introduciría una métrica adicional:

Índice de Recuperación ante Excepción (IRE)

$$IRE = \frac{Performance_{post-error}}{Performance_{baseline}}$$

y una segunda:

Índice de Reconfiguración Predictiva (IRP)

$$IRP = 1 - \frac{Error_{t+1}}{Error_t}$$

Si una perturbación produce un error intenso pero el individuo modifica rápidamente su comportamiento ante una perturbación equivalente, el sistema podría mostrar:

$$Error_t \uparrow$$

pero:

$$IRP \uparrow$$

Eso sería exactamente el fenómeno que un paradigma centrado exclusivamente en accuracy podría perder.

Programas de seguimiento

Programa I — Baseline

Tres bloques sin adaptación:

- EEG;
- HRV;
- rendimiento;
- tiempo de reacción;
- confianza;
- variabilidad intraindividual.

Objetivo: construir el espacio basal.

Programa II — Perturbación fija

Se presentan excepciones predeterminadas.

La IA registra, pero no adapta.

Esto proporciona el control experimental fundamental.

Programa III — Perturbación adaptativa

La IA selecciona la siguiente perturbación según el error anterior.

$$E_t \rightarrow q_{t+1}$$

Éste constituye el núcleo CPP.

Programa IV — Perturbación informacional

La IA selecciona la siguiente tarea no por dificultad, sino por capacidad de discriminar entre hipótesis sobre el estado cognitivo.

$$q_{t+1} = \operatorname{argmax}_q \operatorname{InformationGain}(q)$$

Programa V — Ablación CPEA

Se elimina progresivamente información:

1. rendimiento solamente;
2. rendimiento + HRV;

3. rendimiento + EEG;
4. EEG + HRV + rendimiento.

Esto permite determinar cuánto aporta realmente cada modalidad.

Programa VI — Ablación TAE

Comparar:

adaptación por dificultad

frente a:

adaptación por excepción

La diferencia entre ambos diseños constituiría una prueba mucho más fuerte de la utilidad específica de TAE.

Criterios de falsabilidad

El CPP debe ser falsable.

Hipótesis H1

La adaptación basada en excepciones produce una reducción del error posterior superior a la adaptación basada exclusivamente en dificultad.

Falsación: ausencia de diferencia estadísticamente y prácticamente relevante entre ambos sistemas.

Hipótesis H2

La clasificación multimodal de errores predice mejor la respuesta siguiente que el rendimiento conductual aislado.

Falsación: EEG + HRV no mejora la predicción fuera de muestra.

Hipótesis H3

La diversidad controlada de perturbaciones produce una mejor caracterización del estado cognitivo que la repetición de tareas homogéneas.

Falsación: ningún incremento de información predictiva o de generalización.

Hipótesis H4

La adaptación basada en excepciones genera una reducción progresiva de determinados patrones de error.

Falsación: persistencia de los errores sin diferencia respecto del control.

Este apartado es especialmente importante porque impide que el CPP se convierta en una arquitectura autorreferencial donde cualquier resultado pueda interpretarse como confirmación.

Relación con CPEA

El CPP puede incorporarse naturalmente como módulo experimental dentro de CPEA.

La arquitectura quedaría:

EEG → NEXUS – EEG → Feature Space → DPCC → Error State → TAE → Perturbation → Human → EEG

SIGMA-T podría funcionar conceptualmente como representación multicapas del estado, mientras que ORION-AGI podría encargarse de la orquestación de hipótesis y selección de perturbaciones.

DEPD adquiere aquí una función especialmente clara: detectar la discrepancia entre la trayectoria esperada y la observada.

La arquitectura resultante no sería:

humano → IA.

Sería:

humano ↔ IA.

Y, más precisamente:

$$Human_t \leftrightarrow AI_t \leftrightarrow Human_{t+1}$$

El estado siguiente de cada componente depende de la interacción anterior.

Relación con METFI: límite epistemológico

Aquí resulta indispensable mantener la distinción que has establecido en el corpus.

La arquitectura CPP puede presentar **homologías estructurales** con METFI: estados, simetrías, ruptura de régimen, reorganización y transición entre configuraciones.

Pero no debe afirmarse que un mecanismo electromagnético toroidal terrestre produzca causalmente la dinámica cognitiva del CPP.

La relación correcta sería:

$$METFI \leftrightarrow \text{homolog\'a TAE} \leftrightarrow \text{operacionalizaci\'on CPEA}$$

No:

$$METFI \rightarrow EEG \rightarrow TAE$$

La primera relación es una comparación estructural entre marcos.

La segunda constituiría una afirmación causal que requeriría evidencia independiente.

Esta distinción protege al CPP de uno de los problemas habituales de los modelos interdisciplinarios: transformar una analogía matemática o topológica en una explicación física.

El CPP como arquitectura de aprendizaje

El salto conceptual definitivo aparece cuando la IA deja de optimizar únicamente una función de rendimiento.

Un sistema convencional intenta:

$$\max Performance$$

El CPP introduce:

$$\max Learning$$

pero incluso eso resulta insuficiente.

La formulación más interesante sería:

$$\max [Learning + InformationGain + Adaptability - CognitiveCost]$$

La IA debe encontrar perturbaciones suficientemente informativas sin convertir el protocolo en una sucesión indiscriminada de estímulos difíciles.

Por eso la perturbación debe ser **controlada, reversible y parametrizable**.

La excepción tiene que ser experimentalmente reproducible.

Una arquitectura más profunda: aprender a equivocarse

Existe una consecuencia teórica especialmente relevante.

Si el sistema registra únicamente respuestas correctas, aprende la conducta que debe producirse.

Si registra errores, aprende dónde falla.

Pero si registra **la estructura de la transición entre error y corrección**, comienza a modelar la capacidad de reorganización.

Podemos expresarlo como:

$$Learning = f(Error, Recovery, Reconfiguration)$$

Por tanto, dos participantes con idéntica accuracy podrían presentar capacidades adaptativas radicalmente diferentes.

Participante A:

$$error \rightarrow repetición$$

Participante B:

$$error \rightarrow actualización$$

Desde una perspectiva TAE, el segundo posee una dinámica de aprendizaje por excepción más eficiente.

El objetivo del CPP no sería, por tanto, fabricar un humano que nunca se equivoque.

Sería caracterizar y optimizar **cómo transforma una excepción en una actualización de su modelo interno**.

Ésta es una diferencia conceptual considerable.

Conclusión

El **CPEA–TAE Cognitive Perturbation Protocol** puede formularse como un sistema cerrado de experimentación cognitiva adaptativa en el que cada sesión genera una perturbación, registra EEG, HRV y comportamiento, clasifica la excepción y utiliza dicha información para seleccionar la siguiente perturbación.

La innovación fundamental no reside en añadir EEG a un entrenamiento cognitivo.

Tampoco en conectar una IA a un dispositivo BCI.

Reside en cambiar la unidad de aprendizaje:

de la respuesta → a la excepción → a la reorganización

CPEA aporta el espacio de observación multimodal.

TAE aporta la lógica de aprendizaje por excepción.

DEPD puede formalizar la discrepancia predictiva.

NEXUS-EEG proporciona una vía de adquisición y procesamiento.

SIGMA-T puede representar el estado multilayer.

ORION-AGI puede orquestar la selección adaptativa.

Y el CPP constituye el laboratorio donde todas esas capas pueden convertirse en un paradigma experimental verificable.

La cuestión científicamente interesante ya no sería:

«¿Puede la IA saber qué piensa una persona?»

sino otra mucho más precisa:

«¿Puede una IA inferir qué clase de modelo predictivo está utilizando una persona a partir de cómo responde a perturbaciones sucesivas, y utilizar esas inferencias para seleccionar experimentalmente la siguiente perturbación?»

Ésta sí es una pregunta operacionalizable.

Y, sobre todo, **es falsable**.

Resumen

- **CPP** = arquitectura de aprendizaje humano–IA dirigida por excepciones.
- La unidad experimental pasa de ser la tarea al **evento de ruptura de expectativa**.
- La excepción se representa mediante un vector multimodal de error.
- **EEG** aporta resolución neurofisiológica temporal.
- **HRV** aporta una dimensión autonómica complementaria; no debe interpretarse como lectura directa de estados mentales.
- La IA no debería aumentar simplemente la dificultad: debería seleccionar la perturbación que permita discriminar entre hipótesis sobre el error.
- TAE se convierte así en una **política de selección de perturbaciones basada en la estructura del error anterior**.
- CPEA proporciona el bucle EEG–IA–feedback.
- DEPD puede formalizar la discrepancia entre trayectoria esperada y observada.
- La métrica crítica no tiene por qué ser solamente accuracy: **recuperación, flexibilidad y reconfiguración** son variables potencialmente más informativas.
- Los experimentos de ablación pueden determinar cuánto aporta realmente EEG, HRV y el propio componente TAE.
- La aplicación de METFI a este dominio debe conservarse explícitamente como **homología estructural**, no como mecanismo causal demostrado.
- La arquitectura permite convertir el concepto de «aprendizaje por excepción» en una estructura experimental susceptible de contrastación.

Referencias

1. Forte, G., Favieri, F. & Casagrande, M. (2019). *Heart Rate Variability and Cognitive Function: A Systematic Review*. *Frontiers in Neuroscience*.
Revisión sistemática de 20 estudios y 19.431 participantes que examina la relación entre HRV y diferentes dominios cognitivos. Es especialmente útil para justificar HRV como variable fisiológica complementaria, aunque no como marcador cognitivo específico.
2. Zeki Al Hazzouri et al. / *revisión longitudinal sobre HRV y cognición (2024)*. *Heart Rate Variability and Cognition: A Narrative Systematic Review of Longitudinal Studies*.
Analiza estudios longitudinales y encuentra una asociación consistente entre mayor actividad parasimpática y mejor rendimiento cognitivo. Resulta relevante para el CPP porque introduce explícitamente la dimensión temporal.
3. *Does heart rate variability predict better executive functioning? A systematic review and meta-analysis* (Cortex, 2022).
Meta-análisis de 13 estudios que encontró una asociación positiva pequeña entre HRV vagalmente mediada y función ejecutiva, particularmente inhibición y flexibilidad cognitiva. Es una referencia importante para evitar sobredimensionar el efecto: la relación existe, pero no equivale a una correspondencia uno-a-uno.

4. **Quigley et al. (2024). *Publication guidelines for human heart rate and heart rate variability studies in psychophysiology*. Psychophysiology.**

Referencia metodológica particularmente importante para el CPP. Aborda adquisición, procesamiento, interpretación y comunicación de HR/HRV, incluyendo las limitaciones derivadas del método de registro.

5. ***The Role of the Anterior Cingulate Cortex in Prediction Error and Signaling Surprise* (2017).**

Revisión teórica que conecta error de predicción, sorpresa, control cognitivo y corteza cingulada anterior. Es relevante para fundamentar conceptualmente la transformación del error en variable experimental.

6. ***Predictive learning, prediction errors, and attention: evidence from event-related potentials and eye tracking*.**

Trabajo experimental que relaciona errores de predicción con cambios posteriores de atención y aprendizaje, proporcionando una conexión especialmente interesante entre perturbación, error y modificación de procesamiento.

7. ***EEG Correlates of Surprise and Reward Prediction Errors in a Probabilistic Learning Task* (2026).**

Trabajo reciente que operacionaliza sorpresa mediante medidas informacionales y examina sus correlatos EEG en aprendizaje probabilístico. Es particularmente cercano a la lógica CPP porque permite pensar la excepción como una variable cuantificable en cada ensayo.

8. **Repositorio CPEA de Javi Cíborro.**

La arquitectura actualmente publicada ya contempla pipeline EEG, extracción de características, clasificación, respuesta de IA, feedback, adaptación incremental, notebooks reproducibles y métricas como accuracy, mutual information y correlación temporal. Constituye la base de software conceptual más directa para integrar CPP.

9. **Repositorio METFI–TAE–Field Coupling.**

Contiene la línea conceptual que conecta aprendizaje por excepción, coherencia, arquitecturas TAE–AGI y modelos METFI. Para CPP resulta especialmente importante como fuente de la arquitectura conceptual, manteniendo la separación entre homología estructural y causalidad física.

10. **Repositorio TAE — Anomaly Driven Learning Theory.**

Constituye el núcleo conceptual dedicado específicamente al aprendizaje por excepción y a la ruptura de expectativas como mecanismo de reorganización.

Nota epistemológica: las referencias 1–7 sustentan componentes empíricos o metodológicos concretos del protocolo; los repositorios CPEA–TAE sustentan la arquitectura conceptual desarrollada aquí. La integración de ambos niveles —especialmente la hipótesis de que una IA pueda seleccionar perturbaciones óptimas a partir de la estructura multimodal del error— es una **propuesta conceptual del CPP**, no un resultado experimental ya demostrado.

Compartir



Escribe tu comentario

ENTRADAS POPULARES

febrero 19, 2025

GUÍA PRÁCTICA SOBRE TÉCNICAS DE XAI: SHAP, LIME Y GRAD-CAM

[Compartir](#) [Publicar un comentario](#)

diciembre 17, 2024

N-ACETILCISTEÍNA (NAC): FUENTES ALIMENTARIAS NATURALES

[Compartir](#) [Publicar un comentario](#)



Con la tecnología de Blogger



Puedes tener un doctorado y seguir siendo un idiota:
Richard Feynman



Papayaykware

SANTA CRUZ DE
TENERIFE, SANTA
CRUZ DE TENERIFE,
Spain

[VISITAR PERFIL](#)

[Denunciar abuso](#)

Buscar
Buscar este blog

Buscar

Translate

Seleccionar idioma ▼

Con la tecnología de [Google Traductor de Goo](#)