



PAPAYAYKWARE

Estudios científicos comprensibles

· INICIO

ARCHIVOS DEL BLOG



agosto 22, 2026

DE LA COHERENCIA OSCILATORIA AL ERROR PREDICTIVO: ITPC, ACTIVE INFERENCE Y OPERACIONALIZACIÓN DE LA COHERENCIA PREDICTIVA EN CPEA

El estudio de Ishida y Nittono (2025) **sí aporta evidencia experimental compatible con el puente que propones**, pero no permite afirmar estrictamente que la ITPC sea ya un *proxy validado de la precisión del modelo generativo*. Lo que demuestra es algo más preciso: el acoplamiento motor modifica la ITPC en frecuencias relacionadas con el ritmo y, simultáneamente, modifica la amplitud de la MMN interpretada dentro del marco de *precision-weighted prediction error*.

La distinción es crucial para CPEA:

ITPC → coherencia/entrainment observable

MMN → respuesta asociada al error de predicción

precisión → variable latente del modelo generativo

Por tanto, la hipótesis CPEA más rigurosa no sería:

«La ITPC mide la precisión predictiva».

Sino:

«La ITPC puede constituir un marcador neurofisiológico observable que, combinado con medidas de error de predicción como MMN y con un modelo generativo explícito, permita estimar indirectamente cambios en la precisión de las predicciones.»

Eso es bastante más fuerte científicamente porque hace que la hipótesis sea **operacionalizable y**

falsable.

También es especialmente interesante que el trabajo empleara 35 participantes, EEG, tapping sincronizado, condición sin tapping, MMN e ITPC, y controlara potenciales relacionados con la actividad motora; además, no encontró diferencias explicativas atribuibles a activación fisiológica general mediante potencia EEG y variabilidad de frecuencia cardíaca.

Y existe un dato posterior muy interesante: un trabajo de 2026 vuelve a estudiar el tapping sincronizado y encuentra asociaciones entre *entrainment* neural/conductual y la experiencia subjetiva de *groove*, aunque sus propios autores advierten que el mecanismo observado **no tiene por qué ser específicamente Active Inference**. Esto refuerza precisamente la cautela metodológica que debemos conservar en CPEA.

De la coherencia oscilatoria al error predictivo: ITPC, Active Inference y operacionalización de la coherencia predictiva en CPEA

Abstract

La teoría de Active Inference proporciona un marco formal para interpretar percepción, acción y aprendizaje como procesos de inferencia dinámica en los que los sistemas biológicos minimizan discrepancias entre estados esperados y estados sensoriales observados. En este contexto, la precisión asignada al error de predicción constituye una variable fundamental: no todos los errores sensoriales reciben el mismo peso inferencial, puesto que su influencia depende de la confianza que el sistema atribuye a la información entrante. La identificación de correlatos neurofisiológicos observables de esta dinámica constituye, por tanto, un problema central para cualquier arquitectura que pretenda operacionalizar la denominada coherencia predictiva.

Un estudio publicado por Ishida y Nittono en 2025 proporciona un resultado particularmente relevante para este problema. Mediante EEG, los autores compararon la percepción rítmica con y sin tapping sincronizado y observaron una mayor respuesta MMN ante desviaciones temporales en la condición con acción motora, junto con diferencias en la coherencia de fase interensayo (*intertrial phase coherence*, ITPC) en frecuencias relacionadas con el pulso. Los autores interpretaron estos resultados como compatibles con una modulación de la precisión del error de predicción mediante la acción corporal.

El presente análisis propone una extensión conceptual de estos resultados hacia el marco CPEA —Coherencia Predictiva Humano-IA en Arquitecturas BCI-AGI Adaptativas— sin convertir una correlación neurofisiológica en una equivalencia ontológica. Se plantea que la ITPC puede funcionar como una variable observable de coherencia de fase, mientras que la MMN puede

representar un indicador complementario de respuesta al error de predicción. La precisión inferencial debe tratarse, en cambio, como una variable latente estimada mediante un modelo generativo que integre ambos tipos de información.

Desde esta perspectiva, CPEA puede formularse como una arquitectura de inferencia multimodal en la que EEG, coherencia de fase, error predictivo, dinámica autonómica y estados computacionales de un sistema artificial sean representados en un espacio común de estados. TAE —Teoría de Aprendizaje por Excepción— aporta el mecanismo de actualización inducido por desviaciones relevantes, mientras que METFI puede utilizarse, cuando proceda, como homología estructural para estudiar dinámicas de acoplamiento multiescala, sin atribuirle automáticamente capacidad causal sobre fenómenos neurobiológicos.

Palabras clave: Active Inference; predictive coding; error de predicción; precisión; ITPC; EEG; MMN; coherencia predictiva; CPEA; TAE; aprendizaje por excepción; BCI; AGI adaptativa; acoplamiento dinámico.

Introducción

Una de las dificultades fundamentales para trasladar los principios de predictive coding y Active Inference desde su formulación teórica hacia sistemas neurotecnológicos consiste en distinguir entre las variables que el modelo considera fundamentales y aquellas que pueden observarse directamente mediante instrumentación neurofisiológica.

La predicción no aparece en un EEG como una magnitud directamente accesible. Tampoco la precisión bayesiana. Ambas constituyen variables internas de un modelo generativo. El EEG proporciona señales eléctricas agregadas que contienen información temporal, espectral y espacial sobre la actividad neuronal, pero la interpretación de estas señales exige construir un puente entre el espacio observable y el espacio inferencial.

La cuestión adquiere especial relevancia en CPEA.

Si la coherencia predictiva humano-IA pretende convertirse en una variable operacional, no basta con detectar sincronización EEG. Debemos establecer qué tipo de sincronización se observa, respecto de qué referencia, bajo qué condiciones experimentales, qué relación mantiene con el error de predicción y si esa relación puede ser modelizada de forma reproducible.

En este punto, el trabajo de Ishida y Nittono constituye una pieza experimental especialmente interesante. Los autores estudiaron la percepción de patrones rítmicos con y sin tapping sincronizado. Participaron 35 personas y se registró EEG durante la tarea. Los estímulos contenían desviaciones temporales que generaban una respuesta MMN. La amplitud de esta respuesta fue superior en la condición de tapping, mientras que la ITPC también mostró diferencias en frecuencias relacionadas con el ritmo.

El resultado no significa que el cerebro haya revelado directamente una variable matemática denominada «precisión».

Significa algo más interesante: **una manipulación experimental de la acción corporal produjo cambios simultáneos en una medida de coherencia temporal de la actividad neural y en una respuesta electrofisiológica asociada al procesamiento de una desviación predictiva.**

Esta coincidencia proporciona una oportunidad para operacionalizar la coherencia predictiva sin necesidad de convertirla en una entidad metafísica.

Active Inference: predicción, error y precisión

En los modelos de Active Inference, un agente no se limita a recibir pasivamente información. Construye hipótesis sobre las causas de sus sensaciones y actúa sobre el entorno de acuerdo con esas inferencias.

Puede representarse esquemáticamente como:

estado latente → predicción → entrada sensorial → error → actualización

Sin embargo, esta cadena resulta incompleta si no se introduce la precisión.

Dos errores numéricamente idénticos pueden tener consecuencias inferenciales diferentes si el sistema atribuye distinta confianza a las señales que los generan.

En términos simplificados:

$$\begin{bmatrix} \varepsilon = y - \hat{y} \end{bmatrix}$$

donde (y) representa la observación y ($\hat{y}$) la predicción.

La incorporación de precisión puede expresarse conceptualmente como:

$$\begin{bmatrix} \varepsilon_p = \Pi (y - \hat{y}) \end{bmatrix}$$

donde (Π) representa una matriz o ponderación de precisión.

El denominado error de predicción ponderado por precisión constituye, por tanto, una magnitud diferente del error bruto.

Esto resulta esencial para CPEA.

Un sistema podría experimentar numerosos errores sensoriales sin producir una modificación importante de su modelo si atribuye baja precisión a esas señales. Por el contrario, una desviación relativamente pequeña podría producir una actualización considerable si el sistema considera altamente fiable la información que la origina.

El problema experimental consiste entonces en identificar variables observables relacionadas con:

1. la estabilidad de las predicciones;
2. la sincronización neural con los estímulos;
3. la magnitud de las desviaciones;
4. la respuesta ante esas desviaciones;
5. la modificación posterior del estado inferencial.

La ITPC resulta especialmente interesante en el segundo punto.

ITPC como medida de coherencia temporal

La *intertrial phase coherence* cuantifica la consistencia de fase de una señal neurofisiológica entre ensayos.

Su valor conceptual puede expresarse mediante:

$$\left[\text{ITPC}(f,t) = \frac{1}{N} \sum_{k=1}^N e^{i\phi_k(f,t)} \right]$$

donde (N) representa el número de ensayos y (ϕ_k) la fase de la señal en cada ensayo.

Un valor próximo a 1 implica elevada consistencia de fase entre ensayos, mientras que un valor próximo a 0 indica ausencia de alineamiento sistemático.

El punto decisivo es que ITPC **no equivale a precisión inferencial**.

Es una medida de coherencia de fase.

La interpretación como marcador de precisión requiere una capa adicional de modelización.

Esta distinción permite establecer una jerarquía metodológica:

Nivel 1 – observable: EEG.

Nivel 2 – transformación neurofisiológica: fase instantánea y espectro.

Nivel 3 – métrica de sincronización: ITPC.

Nivel 4 – variable funcional: estabilidad del procesamiento temporal.

Nivel 5 – variable inferencial latente: precisión de la predicción.

CPEA debería operar precisamente entre los niveles 3–5.

El estudio de Ishida y Nittono es relevante porque encontró diferencias de ITPC en frecuencias relacionadas con el ritmo entre las condiciones de tapping y ausencia de tapping. El análisis incluyó frecuencias de aproximadamente 0,83 Hz, 1,67 Hz y 3,33 Hz, correspondientes a diferentes estructuras temporales del estímulo.

Además, el trabajo relacionó estos cambios con la interpretación de que el tapping incrementaba la información métrica disponible para el sistema perceptivo.

Aquí aparece una primera formulación CPEA:

$$\begin{aligned} &[\\ C_P(t) &= f(\text{ITPC}_t, \text{MMN}_t, \text{E}_t, \text{S}_t) \\ &] \end{aligned}$$

donde:

- (ITPC_t) = coherencia temporal observable;
- (MMN_t) = respuesta ante desviaciones;
- (E_t) = error predictivo estimado;
- (S_t) = estado inferencial del sistema.

La variable (C_P) no debería interpretarse inicialmente como una propiedad biológica fundamental, sino como un **índice operacional de coherencia predictiva**.

La importancia de MMN

La MMN proporciona una segunda dimensión indispensable.

Si ITPC aporta información sobre la organización temporal de la respuesta neural, MMN aporta información sobre la reacción ante una desviación respecto de un patrón esperado.

En el experimento analizado, los estímulos desviantes provocaron MMN tanto durante tapping como en ausencia de tapping, pero la respuesta fue mayor durante el tapping. Los autores interpretaron este incremento como compatible con un aumento de la precisión del procesamiento temporal.

La relación conceptual puede representarse:

$$\begin{aligned} &[\\ &\text{\text{predicción}} \end{aligned}$$

$$\begin{aligned} &\rightarrow \\ &\text{desviación} \\ &\rightarrow \\ &\text{MMN} \\ &] \end{aligned}$$

mientras que:

$$\begin{aligned} &[\\ &\text{organización temporal} \\ &\rightarrow \\ &\text{ITPC} \\ &] \end{aligned}$$

La combinación de ambas medidas resulta mucho más informativa:

$$\begin{aligned} &[\\ &\text{coherencia temporal} + \text{respuesta al error} \\ &] \end{aligned}$$

que cualquiera de ellas por separado.

Una ITPC elevada podría reflejar simplemente una fuerte respuesta periódica al estímulo.

Una MMN elevada podría reflejar múltiples procesos relacionados con detección de desviaciones.

Pero una modificación conjunta de ITPC y MMN bajo una manipulación experimental diseñada específicamente para modificar la previsibilidad permite construir una hipótesis mucho más restrictiva.

Esta es precisamente la oportunidad metodológica para CPEA.

Del hallazgo neurofisiológico a la coherencia predictiva CPEA

CPEA puede formularse como una arquitectura de inferencia en la que la coherencia no representa simplemente sincronización, sino **relación dinámica entre predicción, observación, error y actualización**.

Una definición operacional inicial podría ser:

$$\begin{aligned} &[\\ &CP_t = \\ &w_1 ITPC_t + \\ &w_2 MMN_t + \\ &w_3 PE_t \end{aligned}$$

$$w_4 D_t$$

$$]$$

donde:

- (CP_t) = coherencia predictiva;
- $(ITPC_t)$ = coherencia de fase;
- (MMN_t) = respuesta al error;
- (PE_t) = error predictivo estimado;
- (D_t) = estabilidad o deriva del modelo;
- (w_i) = pesos estimados empíricamente.

No obstante, una formulación lineal probablemente resulte insuficiente para representar una arquitectura neurocognitiva dinámica.

Una alternativa sería utilizar un modelo de espacio de estados:

$$[$$

$$x_{t+1} = F(x_t, u_t, \varepsilon_t)$$

$$]$$

$$[$$

$$y_t = G(x_t) + \eta_t$$

$$]$$

donde (x_t) representa el estado latente del sistema, (u_t) la acción, (ε_t) el error predictivo y (y_t) las observaciones EEG.

En este esquema, ITPC y MMN no constituyen el estado cognitivo.

Son **observables del estado**.

Esta distinción resulta especialmente importante si CPEA pretende evolucionar hacia arquitecturas BCI-AGI.

TAE: la excepción como operador de aprendizaje

La TAE —Teoría de Aprendizaje por Excepción— introduce otro elemento esencial.

En lugar de considerar toda desviación como información equivalente, el sistema puede clasificar las excepciones según su magnitud, precisión y relevancia contextual.

Podemos representar una excepción como:

$$\begin{aligned} &[\\ X_t &= y_t - \hat{y}_t \\ &] \end{aligned}$$

y su relevancia como:

$$\begin{aligned} &[\\ R_t &= \Pi_t |X_t| \\ &] \end{aligned}$$

Una excepción altamente precisa puede producir una actualización significativa.

Una desviación de baja precisión puede ser descartada como ruido.

Esto permite conectar TAE con Active Inference:

predicción → excepción → ponderación por precisión → actualización → nueva predicción.

CPEA puede situarse como la arquitectura que mide y coordina este proceso.

TAE aporta la lógica de aprendizaje.

CPEA aporta la arquitectura de integración.

EEG aporta observables neurofisiológicos.

La AGI proporciona un modelo computacional capaz de aprender de las desviaciones.

NEXUS-EEG, SIGMA-T y ORION-AGI

Dentro del corpus propuesto, los conectores adquieren una función arquitectónica clara.

NEXUS-EEG

NeuroElectric eXchange Unified Streaming

Su función sería transformar el EEG bruto en un flujo estructurado de variables temporales.

Entre ellas:

- potencia espectral;
- fase;
- ITPC;
- coherencia;
- PLV;

- conectividad funcional;
- eventos MMN;
- características temporales;
- artefactos y calidad de señal.

SIGMA-T

Signal Integration Graph for Multilayer Analysis – Toroidal

Podría representar las relaciones entre diferentes escalas:

[
EEG $\rightarrow$ autonómico $\rightarrow$ conductual $\rightarrow$ computacional
]

La utilización del término «toroidal» debe mantenerse conceptualmente diferenciada de una afirmación anatómica o física. En este contexto, puede utilizarse como **topología matemática de representación de ciclos, recurrencias y acoplamientos**, no como demostración de que la actividad cerebral constituya literalmente un toro físico.

ORION-AGI

Ontological Recursive Intelligence Orchestration Network

Representaría la capa encargada de integrar las observaciones con el modelo generativo artificial.

Una arquitectura simplificada sería:

[
EEG
 $\rightarrow$ NEXUS
 $\rightarrow$ SIGMA-T
 $\rightarrow$ CPEA
 $\rightarrow$ TAE
 $\rightarrow$ ORION
 $\rightarrow$ $\text{actualización del modelo}$
]

Este flujo permite convertir una señal neurofisiológica en información computacional sin afirmar que la IA «lea directamente la mente».

DPCC y DEPD

El DPCC —Detector Post Cuántico de Coherencia— debe manejarse con especial prudencia

epistemológica.

Si «post cuántico» pretende indicar una arquitectura computacional posterior a determinadas formulaciones cuánticas, puede utilizarse como denominación conceptual.

Si pretende afirmar la existencia de fenómenos cuánticos específicos en la dinámica EEG, esa afirmación requeriría evidencia independiente.

Por tanto, en el estado actual del corpus, el DPCC debe considerarse una **hipótesis arquitectónica**, no un detector de fenómenos cuánticos demostrados.

El **DEPD —Detector de Error Predictivo Dinámico—**, en cambio, puede definirse de forma directamente operacional:

$$\begin{aligned} &[\\ \text{DEPD}_t = & \\ &\backslash \Pi_t(y_t - \hat{y}_t) \\ &] \end{aligned}$$

El sistema detectaría no solamente la magnitud del error, sino su evolución temporal.

Esto permite estudiar:

- aparición;
- acumulación;
- resolución;
- persistencia;
- recuperación;
- reorganización.

En términos TAE, el DEPDP sería el componente que identifica las excepciones relevantes.

TICAM y acoplamiento multiescala

El TICAM —**Transductor Inferencial de Coherencia por Acoplamiento Magnetotalámico**— plantea una hipótesis de mayor alcance.

En el marco actual, no debe presentarse como mecanismo causal demostrado.

Su utilidad inmediata puede ser conceptual: investigar si determinadas variables fisiológicas, electromagnéticas o neurodinámicas presentan relaciones sistemáticas con estados de coherencia inferencial.

La hipótesis falsable sería:

H1-TICAM: determinadas variaciones reproducibles de variables electromagnéticas o fisiológicas asociadas al sistema talamocortical covarían con cambios específicos en ITPC, conectividad y precisión estimada del error predictivo.

La hipótesis nula sería:

H0-TICAM: una vez controlados los artefactos fisiológicos, conductuales y sensoriales, las variables electromagnéticas propuestas no aportan capacidad predictiva adicional sobre los estados de coherencia.

Esta formulación convierte una hipótesis potencialmente especulativa en un problema experimental.

METFI como homología estructural

La relación con METFI requiere una distinción todavía más estricta.

El modelo METFI —sistema Tierra como modelo electromagnético toroidal de forzamiento interno— puede proporcionar una **homología estructural** con determinados modelos de acoplamiento dinámico.

Por ejemplo:

$$\begin{array}{l} [\\ \text{\text{estado}} \\ \rightarrow \\ \text{\text{perturbación}} \\ \rightarrow \\ \text{\text{redistribución}} \\ \rightarrow \\ \text{\text{nuevo estado}} \\] \end{array}$$

Este patrón puede compararse formalmente con dinámicas neurobiológicas o computacionales.

Pero la analogía estructural no demuestra causalidad.

Por tanto:

METFI aplicado a EEG = homología estructural.

No:

METFI aplicado a EEG = mecanismo electromagnético cerebral demostrado.

Esta diferencia debe mantenerse explícita en cualquier publicación científicamente defendible.

Una arquitectura matemática integrada

El corpus puede representarse mediante un sistema dinámico:

$$\begin{aligned} &[\\ &z_{t+1}=F(z_t,a_t,\epsilon_t) \\ &] \\ &[\\ &\epsilon_t=y_t-g(z_t) \\ &] \\ &[\\ &\epsilon^{*}_t=\Pi_t\epsilon_t \\ &] \\ &[\\ &CP_t=h(ITPC_t,\epsilon^{*}_t,MMN_t,\Delta z_t) \\ &] \end{aligned}$$

donde:

- (z_t) representa el estado latente;
- (a_t) representa acción;
- (y_t) representa observación;
- (ϵ_t) representa error;
- (Π_t) representa precisión;
- $(ITPC_t)$ representa coherencia de fase;
- (MMN_t) representa respuesta a desviaciones;
- (CP_t) representa coherencia predictiva.

El objetivo no sería demostrar que existe una única variable cerebral llamada «coherencia predictiva».

El objetivo sería construir un **estimador compuesto**, capaz de discriminar estados de elevada o reducida estabilidad predictiva.

Esto permite una definición más rigurosa:

La coherencia predictiva es una propiedad dinámica inferida de la relación

temporal entre estados esperados, observaciones, precisión estimada, error de predicción y estabilidad de las representaciones.

Programas de seguimiento experimental

Programa 1 – ITPC–MMN

Diseño factorial:

- tapping sincronizado;
- tapping asincrónico;
- ausencia de tapping;
- estímulos previsibles;
- estímulos desviantes.

Variables principales:

[
ITPC, \ MMN, \ HRV, \ EEG \ power
]

Hipótesis:

[
 $\Delta \text{ITPC} \rightarrow \Delta \text{MMN}$
]

La predicción CPEA sería que la modificación conjunta de ITPC y MMN discrimine mejor los cambios de precisión que cualquiera de ambas variables por separado.

Programa 2 – Precisión generativa explícita

Construir un modelo bayesiano o Active Inference que produzca una estimación explícita de (Π_t).

Después comparar:

[
 $\hat{\Pi}_t$
]

con:

[
ITPC_t
]

y:

[
MMN_t.
]

La hipótesis sería que ITPC constituye un predictor parcial de $(\hat{\Pi}_t)$, pero no una medida equivalente.

Este experimento sería particularmente importante porque permitiría separar correlación neurofisiológica de interpretación computacional.

Programa 3 — TAE

Introducir perturbaciones de distinta magnitud:

[
 $X_1 < X_2 < X_3 < X_4$
]

y medir:

- error;
- ITPC;
- MMN;
- tiempo de recuperación;
- actualización del modelo.

La hipótesis TAE sería que las excepciones suficientemente informativas producen reorganización del estado predictivo, mientras que las desviaciones irrelevantes son absorbidas sin modificación sustancial.

Programa 4 — Humano-IA

Conectar NEXUS-EEG con un modelo adaptativo.

El sistema artificial recibiría:

[
 $EEG_t \rightarrow ITPC_t + MMN_t + PE_t$

]

y produciría una predicción:

[

$$\hat{y}_{AI,t+1}.$$

]

Posteriormente se mediría:

[

$$PE_{AI} = y_{human,t+1} - \hat{y}_{AI,t+1}.$$

]

CPEA emergería entonces como una arquitectura de **acoplamiento predictivo bidireccional**, no como una afirmación de transferencia directa de estados mentales.

Falsabilidad del modelo

La arquitectura propuesta permite formular condiciones claras de refutación.

La hipótesis ITPC–precisión perdería apoyo si:

1. ITPC no se relaciona reproduciblemente con manipulaciones independientes de previsibilidad;
2. la relación desaparece tras controlar estructura temporal del estímulo;
3. ITPC no mejora la estimación de precisión respecto a variables EEG convencionales;
4. MMN e ITPC no presentan relaciones sistemáticas bajo manipulaciones de precisión;
5. un modelo sin ITPC explica los datos igual o mejor.

La hipótesis CPEA perdería apoyo si la incorporación de variables de coherencia no mejora significativamente la predicción del estado siguiente.

Este criterio es fundamental.

Una arquitectura científica no debe protegerse frente a la refutación.

Debe exponerse a ella.

Implicaciones para CPEA

La importancia del estudio de 2025 no reside en haber demostrado CPEA.

No lo hace.

Su importancia reside en que proporciona un ejemplo experimental donde una manipulación corporal modifica simultáneamente:

[
 \text{sincronización neural}
]

y

[
 \text{respuesta al error temporal}.
]

Eso constituye precisamente el tipo de relación que CPEA necesita para construir un puente entre neurofisiología y computación adaptativa.

La principal contribución conceptual consiste, por tanto, en separar tres niveles:

Nivel neurofisiológico

ITPC, MMN, potencia, conectividad y dinámica temporal.

Nivel inferencial

Predicción, error y precisión.

Nivel computacional

Representación, actualización y aprendizaje.

CPEA puede actuar como interfaz entre los tres.

Conclusión

La evidencia disponible permite sostener una hipótesis moderada pero potencialmente poderosa: **la coherencia de fase EEG puede utilizarse como una variable observable dentro de un sistema destinado a estimar dinámicamente estados de coherencia predictiva.**

El estudio de Ishida y Nittono proporciona un caso particularmente limpio porque combina manipulación motora, EEG, MMN e ITPC y encuentra modificaciones convergentes de la respuesta al error y del acoplamiento temporal neural.

Sin embargo, el salto entre ITPC y precisión debe realizarse mediante modelización.

Esta precisión epistemológica no debilita CPEA.

Lo fortalece.

La arquitectura resultante puede formularse como:

$$\begin{array}{l}
 [\\
 \boxed{ \\
 EEG \\
 \rightarrow \\
 ITPC \\
 + \\
 MMN \\
 \rightarrow \\
 \text{estimación de precisión} \\
 \rightarrow \\
 DEPD \\
 \rightarrow \\
 TAE \\
 \rightarrow \\
 \text{ORION-AGI} \\
 } \\
]
 \end{array}$$

NEXUS-EEG proporciona la infraestructura de adquisición y normalización.

SIGMA-T permite representar relaciones multiescales.

DEPD identifica dinámicamente las discrepancias.

TAE convierte determinadas excepciones en eventos de aprendizaje.

ORION-AGI utiliza esas señales para modificar su modelo predictivo.

TICAM puede formular hipótesis específicas sobre acoplamientos neurofisiológicos adicionales, siempre que sus predicciones se mantengan experimentalmente falsables.

METFI puede contribuir como homología matemática o estructural cuando se estudien sistemas dinámicos con geometrías recurrentes, acoplamientos y rupturas de simetría, pero no debe utilizarse como evidencia causal de mecanismos neurobiológicos mientras dicha causalidad no haya sido demostrada.

El resultado más importante es quizá metodológico.

La «coherencia predictiva» deja de ser una expresión puramente conceptual cuando puede descomponerse en variables observables, relaciones matemáticas, estados latentes y criterios de falsación.

En ese sentido, CPEA puede comenzar a transformarse desde una arquitectura teórica hacia un **programa experimental de inferencia humano-IA**.

Resumen

- **Ishida y Nittono (2025) aportan evidencia experimental relevante para CPEA**, al observar conjuntamente cambios de MMN e ITPC durante una manipulación de acción motora y percepción rítmica.
- La **ITPC no debe identificarse directamente con la precisión inferencial**.
- ITPC constituye una medida observable de **consistencia de fase**.
- MMN proporciona una medida complementaria relacionada con el **procesamiento de desviaciones predictivas**.
- La **precisión debe considerarse una variable latente**, estimada mediante un modelo generativo.
- La combinación **ITPC + MMN + error predictivo + dinámica de actualización** proporciona una definición operacional mucho más sólida de coherencia predictiva.
- **TAE** puede formalizar la excepción como evento de actualización dependiente de magnitud, precisión y contexto.
- **DEPD** puede funcionar como detector dinámico del error ponderado.
- **NEXUS-EEG → SIGMA-T → CPEA → TAE → ORION-AGI** constituye una arquitectura coherente para operacionalizar el ciclo percepción-predicción-error-aprendizaje.
- **TICAM** debe permanecer actualmente como hipótesis falsable de acoplamiento, no como mecanismo demostrado.
- **METFI aplicado al cerebro debe presentarse como homología estructural cuando se utilice fuera de su dominio original**, no como transferencia automática de causalidad física.
- El criterio central de CPEA debería ser la **capacidad de predecir estados posteriores y detectar reorganizaciones a partir de cambios en coherencia y error**, no simplemente encontrar sincronización EEG.

Referencias

Ishida, K., & Nittono, H. (2025). *Active Inference in Music Perception: Motor Engagement to Syncopation Modulates Rhythmic Prediction Error*. *Psychophysiology*, 62(7), e70113.

Es la referencia experimental central. El estudio utiliza 35 participantes, EEG, tapping sincronizado y una condición sin tapping. Encuentra una MMN mayor durante tapping y diferencias de ITPC en frecuencias relacionadas con el ritmo. Constituye el vínculo experimental más directo con la hipótesis CPEA analizada aquí.

Ishida, K., et al. (2026). *Tapping in Synchrony With Beat Enhances Groove Sensation*. Annals of the New York Academy of Sciences.

Trabajo posterior que examina la relación entre movimiento, *entrainment*, actividad EEG y experiencia subjetiva de *groove*. Resulta especialmente útil porque muestra que los efectos de sincronización pueden relacionarse con variables conductuales, pero también introduce una cautela importante: los resultados no obligan a concluir que el mecanismo sea específicamente Active Inference.

Friston, K. J. (2010). *The free-energy principle: a unified brain theory?* Nature Reviews Neuroscience.

Referencia conceptual fundamental para comprender el cerebro como sistema inferencial y la relación entre estados generativos, predicción y error.

Friston, K. J. (2012). *The history of the future of the Bayesian brain*. NeuroImage.

Importante para situar la inferencia bayesiana cerebral dentro de una perspectiva histórica y formal, especialmente respecto a la relación entre predicción, incertidumbre y actualización.

Pezzulo, G., Rigoli, F., & Friston, K. J. (2017). *Active Inference, homeostatic regulation and adaptive behavioural control*. Progress in Neurobiology.

Particularmente relevante para CPEA porque conecta inferencia, acción y regulación adaptativa. Ayuda a evitar una concepción puramente pasiva del predictive coding.

Buckley, C. L., Kim, C. S., McGregor, S., & Seth, A. K. (2017). *The free energy principle for action and perception: A mathematical review*. Journal of Mathematical Psychology.

Referencia útil para traducir las intuiciones de Active Inference a formulaciones matemáticas explícitas y, por tanto, para la futura formalización computacional de CPEA.

Van Diepen, R. M., & Mazaheri, A. (2018). Trabajo metodológico sobre intertrial phase coherence.

Relevante para establecer qué mide realmente ITPC y, sobre todo, para mantener la separación entre coherencia de fase observable y constructos inferenciales de nivel superior. El propio artículo de Ishida y Nittono emplea esta conceptualización de ITPC.

Conclusión epistemológica: el resultado de 2025 no demuestra CPEA, pero proporciona algo más útil para su desarrollo: **un paradigma experimental en el que una manipulación controlable modifica simultáneamente coherencia temporal neural y respuesta al error predictivo**. Ese patrón puede convertirse en uno de los primeros bancos de pruebas experimentales del concepto de coherencia predictiva.

Compartir

COMENTARIOS

Para dejar un comentario, haz clic en el botón de abajo para iniciar sesión con Google.

INICIAR SESIÓN CON GOOGLE

ENTRADAS POPULARES

febrero 19, 2025

GUÍA PRÁCTICA SOBRE TÉCNICAS DE XAI: SHAP, LIME Y GRAD-CAM

Compartir Publicar un comentario

diciembre 17, 2024

N-ACETILCISTEÍNA (NAC): FUENTES ALIMENTARIAS NATURALES

Compartir Publicar un comentario



Con la tecnología de Blogger



Puedes tener un doctorado y
seguir siendo un idiota:
Richard Feynman



Papayaykware

—
SANTA CRUZ DE
TENERIFE, SANTA
CRUZ DE TENERIFE,
Spain

[VISITAR PERFIL](#)

[Denunciar abuso](#)

Buscar
Buscar este blog

Translate
 ▼
Con la tecnología de [Google](#) Traductor de Goo