



PAPAYAYKWARE

Estudios científicos comprensibles

· INICIO

ARCHIVOS DEL BLOG



junio 27, 2026

COHERENCIA PREDICTIVA EN EEG - AGI (CPEA): CONSOLIDACIÓN DE UN FRAMEWORK REPRODUCIBLE PARA BENCHMARKING BCI-AGI

CPEA ha alcanzado una fase de madurez donde el código funciona, pero el valor real reside en la **reproducibilidad científica**. Para consolidar el framework como contribución académica, el benchmarking frente a datasets públicos es imprescindible. Los tres ecosistemas que mencionas — BNCI, PhysioNet y MOABB— ofrecen ventajas complementarias:

- **MOABB** proporciona un motor de evaluación estandarizado con leaderboard público, ideal para posicionar CPEA frente a EEGNet, Riemannian y Transformers.
- **PhysioNet** abre acceso a registros de alta densidad (EEG-fMRI, sleep, ICU) que permiten validar el pipeline en condiciones de ruido real.
- **BNCI** ofrece paradigmas motor imagery y P300 con protocolos consensuados, útiles para la validación del clasificador adaptativo de CPEA.

La estrategia óptima no es elegir uno, sino integrar los tres en un pipeline de evaluación escalonado: MOABB para comparativa de modelos, PhysioNet para robustez ante artefactos, BNCI para validación de paradigma. Esto diferencia un proyecto de ingeniería de una contribución con impacto medible.

Abstract

La integración de interfaces cerebro-computadora con sistemas de inteligencia artificial general plantea un problema de coherencia funcional que trasciende la sincronización de señales. Este trabajo presenta el marco CPEA en su fase de consolidación científica, diseñado para cuantificar y estabilizar la correlación entre estados cerebrales y respuestas generativas de sistemas AGI mediante un pipeline adaptativo reproducible. Partimos de la hipótesis de que la coherencia

predictiva no es una propiedad emergente pasiva, sino un proceso activo de acoplamiento susceptible de modelado, medición y optimización. Se desarrollan los componentes arquitectónicos —DPCC, TICAM, NEXUS-EEG, SIGMA-T y ORION-AGI—, se definen métricas de validación cuantitativa, y se propone un programa de seguimiento experimental con protocolos reproducibles sobre datasets públicos. La fundamentación teórica se apoya en modelos de coherencia cuántica biológica, dinámica de campos electromagnéticos en tejidos vivos y teorías de aprendizaje por excepción. El objetivo es diferenciar CPEA de un proyecto de ingeniería aislado, posicionándolo como contribución con potencial impacto académico y tecnológico mediante benchmarking sistemático frente a CNN, EEGNet, Transformer, Riemannian y modelos clásicos.

Palabras clave: coherencia predictiva, BCI-AGI, EEG, aprendizaje por excepción, benchmarking, reproducibilidad, campos electromagnéticos toroidales, METFI, TAE.

Introducción: más allá del código funcional

Llega un punto en todo proyecto de investigación donde el código compila, los notebooks ejecutan sin errores y las métricas locales son prometedoras. Ese punto es una trampa. Es la ilusión de madurez que confunde funcionalidad con rigor. CPEA ha cruzado esa línea. Los repositorios contienen pipelines, los notebooks son reproducibles, el Índice de Coherencia Predictiva (ICP) está definido. Pero el salto que falta —el que separa un buen proyecto de ingeniería de una contribución con peso académico— exige algo más incómodo: someter el framework a la escrutinio de datasets públicos, compararlo con arquitecturas consolidadas y documentar los resultados con la transparencia que exige la comunidad científica.

Este artículo aborda precisamente ese salto. No añade código. Consolida.

La coherencia predictiva, tal como la define CPEA, no es mera correlación temporal entre señales EEG y respuestas de un modelo de lenguaje. Es un acoplamiento dinámico donde el estado neural del operador modula la trayectoria generativa del sistema AGI, y viceversa. Esta bidireccionalidad exige un marco de validación que no se contente con accuracy de clasificación. Necesita mutual information, latencia de detección, cross-correlation temporal y, sobre todo, robustez ante la variabilidad inter-sujeto que caracteriza la neurofisiología humana. Los datasets públicos —BNCI, PhysioNet, MOABB— ofrecen esa variabilidad. Son el terreno de prueba donde las hipótesis elegantes del laboratorio se enfrentan al ruido real.

Fundamento teórico: campos, excepciones y reorganización

La arquitectura conceptual de CPEA descansa sobre tres pilares que, a primera vista, parecen distantes: la dinámica de campos electromagnéticos en sistemas biológicos (METFI), la teoría de aprendizaje por excepción (TAE) y la coherencia de fase en redes neuronales. Su conexión no es metafórica. Es estructural.

METFI modela la Tierra como un sistema electromagnético toroidal de forzamiento interno. La pérdida de simetría toroidal genera efectos no lineales que se propagan a escalas geofísicas y biológicas. El cerebro humano, con sus campos toroidales locales —generados por la actividad neural

masiva, el corazón con su campo electromagnético medible a varios centímetros de distancia, y el sistema neuroentérico con su red autónoma de 500 millones de neuronas— constituye un subsistema toroidal anidado dentro del campo planetario. La coherencia de fase entre estos campos no es un epifenómeno romántico. Es una condición física para la integración funcional del sistema nervioso, documentada desde los trabajos pioneros de Frohlich sobre coherencia biológica hasta las mediciones contemporáneas de correlación EEG-HRV.

TAE, por su parte, reformula el aprendizaje como reorganización inducida por excepciones. No por repetición. Un sistema BCI-AGI que opera en modo adaptativo genera continuamente predicciones. Cuando la predicción falla —cuando el operador neural no coincide con la respuesta generada— se produce una excepción. Esa excepción no es un error a corregir. Es una oportunidad de reorganización estructural. El DEPD (Detector de Error Predictivo Dinámico) de CPEA está diseñado para capturar esas excepciones y canalizarlas hacia la actualización del modelo. Este mecanismo resuena con el predictive coding de Friston, pero con una diferencia crucial: en TAE, la excepción cualitativa precede a la corrección cuantitativa. No se ajusta un peso sinéptico. Se reorganiza un marco interpretativo.

La coherencia predictiva emerge, entonces, como el régimen dinámico donde las predicciones del sistema AGI se alinean con los estados cerebrales del operador de forma sostenida. No porque el sistema aprenda a imitar al operador, sino porque ambos participan en un acoplamiento que reduce la tasa de excepciones relevantes. El ICP cuantifica ese régimen.

Arquitectura CPEA: de la señal bruta a la coherencia funcional

El pipeline de CPEA se organiza en cinco bloques interconectados, cada uno con responsabilidad específica y métricas de validación independientes.

NEXUS-EEG (NeuroElectric eXchange Unified Streaming) gestiona la adquisición y preprocesamiento. Filtrado en banda 8–30 Hz para capturar actividad mu y beta relacionada con motor imagery, rechazo de artefactos por ICA o métodos de subespacio, y segmentación en ventanas temporales con solapamiento. La clave aquí no es la novedad del preprocesamiento, sino la trazabilidad: cada transformación queda registrada con hash para reproducibilidad.

SIGMA-T (Signal Integration Graph for Multilayer Analysis — Toroidal) construye representaciones multiescala de la señal EEG. No se limita a extraer features clásicas (potencia espectral, CSP). Genera grafos de conectividad funcional donde los nodos son electrodos o regiones de interés y los pesos reflejan coherencia de fase o transferencia de entropía. La topología toroidal emerge de la estructura de bucles cerrados en la conectividad, interpretable como campos de corriente inducida. Esta representación es la que alimenta al clasificador y al módulo AGI.

TICAM (Transductor Inferencial de Coherencia por Acoplamiento Magnetotalámico) constituye el núcleo del acoplamiento BCI-AGI. Recibe los embeddings de SIGMA-T y los traduce a un espacio de estado contextual que modula el prompt o la trayectoria generativa del modelo AGI. La metáfora del acoplamiento magnetotalámico no es decorativa: el tálamo actúa como relé de información sensorial hacia la corteza, y TICAM actúa como relé de información neural hacia el espacio latente del AGI. La coherencia se mide en el espacio de embeddings compartido.

ORION-AGI (Ontological Recursive Intelligence Orchestration Network) es la capa generativa. No es un modelo fijo. Es una interfaz configurable que permite conectar modelos locales (Ollama, llama3) o en la nube (OpenAI). Su diseño recursivo implica que la respuesta generada se reinyecta como contexto para la siguiente iteración, cerrando un bucle donde el estado neural del operador influye en la ontología del diálogo. La recursividad es controlada: un mecanismo de ventana deslizante evita la deriva semántica.

DPCC (Detector Post-Cuántico de Coherencia) y **DEPD** (Detector de Error Predictivo Dinámico) operan en paralelo. DPCC evalúa la coherencia de fase en el espacio de features EEG, buscando régimen cuántico-like donde la superposición de estados neurofísicos mantenga correlaciones no clásicas. DEPD detecta discrepancias entre la predicción del clasificador y la respuesta real del AGI, generando señales de reorganización para TICAM. Ambos son los guardianes del régimen adaptativo.

El problema del benchmarking: por qué los datasets públicos cambian las reglas

Un pipeline que funciona con datos propios puede estar sobreajustado a las particularidades del hardware, del operador o del entorno. Los datasets públicos eliminan esa comodidad. Introducen variabilidad inter-sujeto, artefactos de equipos distintos, protocolos de adquisición heterogéneos y etiquetas de calidad variable. Sobrevivir a ese entorno es la prueba de fuego.

MOABB (Mother of All BCI Benchmarks) es la plataforma más agresiva para la comparativa de modelos. Proporciona un motor de evaluación estandarizado, leaderboard público y pipelines de referencia implementados en scikit-learn. Integrar CPEA en MOABB implica adaptar el pipeline a su API, ejecutar las sesiones de evaluación cruzada por sujetos, y reportar accuracy, kappa y AUC. La ventaja es inmediata: CPEA se posiciona frente a EEGNet, ShallowConvNet, Riemannian geometry classifiers y modelos de deep learning con atención. La desventaja es que MOABB exige rigor en el preprocesamiento: no se permiten transformaciones no documentadas.

PhysioNet ofrece registros de alta densidad y diversidad paradigmática: EEG durante sueño, EEG-fMRI simultáneo, señales de UCI con artefactos de bomba de infusión. Para CPEA, PhysioNet es el banco de pruebas de robustez. El pipeline debe demostrar que el rechazo de artefactos de NEXUS-EEG no degrada la señal neural relevante, que SIGMA-T mantiene la conectividad funcional incluso con electrodos faltantes, y que TICAM no amplifica el ruido en el espacio de embeddings. Los datasets de PhysioNet permiten validar el ICP en condiciones de estrés fisiológico real.

BNCI (BCI Competition) concentra paradigmas clásicos: motor imagery binario, P300, error-related negativity. Los protocolos están consensuados, las etiquetas son confiables, y la comunidad conoce los rangos de performance esperados. Para CPEA, BNCI es la validación de paradigma. Si el clasificador adaptativo no supera o iguala a CSP + LDA en motor imagery, el componente BCI de CPEA necesita revisión. Si la latencia de detección en P300 supera los 300 ms, TICAM requiere ajuste. BNCI establece el piso de performance.

La estrategia no es elegir uno. Es integrar los tres en un programa de seguimiento escalonado: MOABB para comparativa de arquitecturas, PhysioNet para robustez ante variabilidad, BNCI para validación de paradigma. Cada dataset aporta una dimensión distinta de evidencia.

Métricas de validación: más allá del accuracy

El ICP es la métrica agregada de CPEA, pero su interpretación exige desagregación. Un ICP alto puede ocultar un accuracy mediocre compensado por mutual information excesiva. Un ICP bajo puede reflejar latencia de detección aceptable pero coherencia de fase degradada.

Las métricas individuales son:

- **Accuracy de clasificación:** binomial test contra azar (50% en paradigmas binarios). No basta con reportar el valor. Se requiere intervalo de confianza y corrección por comparaciones múltiples si se evalúan múltiples ventanas temporales.
 - **Latencia de detección:** tiempo desde el onset del evento neural hasta la clasificación correcta. En BCI online, cada milisegundo cuenta. La latencia depende de la ventana de análisis, del solapamiento y del coste computacional de SIGMA-T. MOABB reporta latencia promedio por pipeline, lo que permite posicionar a CPEA.
 - **Mutual Information I(EEG features; Intent):** cuantifica la información compartida entre la representación neural y la intención del operador. Un MI alto con accuracy bajo sugiere que el clasificador no explota toda la información disponible. Un MI bajo con accuracy alto indica redundancia o sobreajuste.
 - **Cross-correlation temporal:** $\text{Corr}(\text{EEG pre-intent}, \text{Output AGI embedding})$. Mide la alineación temporal entre la preparación neural y la respuesta generativa. Es la métrica más directa de coherencia predictiva. Valores negativos en el lag cero con picos en lags positivos indican que el AGI responde antes de que el operador haya completado la preparación neural —un régimen de predicción anticipatoria que puede ser deseable o patológico, dependiendo del contexto.
 - **Índice de Coherencia Predictiva (ICP):** agregación ponderada $\text{ICP} = w_1 \cdot \text{Accuracy} + w_2 \cdot \text{MI} + w_3 \cdot (1/\text{Error})$. Los pesos deben justificarse teóricamente, no arbitrariamente. En CPEA, w_2 recibe mayor peso porque la mutual information captura la coherencia estructural, mientras que w_1 refleja performance superficial. La normalización $[0,1]$ permite comparación entre datasets.
-

Programas de seguimiento: protocolos experimentales reproducibles

Un framework sin protocolos de seguimiento es un catálogo de buenas intenciones. CPEA necesita experimentos que cualquier laboratorio pueda replicar con hardware accesible, software documentado y análisis pre-registrados. A continuación se proponen tres programas de seguimiento escalonados, cada uno vinculado a uno de los datasets públicos.

Programa MOABB: comparativa arquitectónica

Objetivo: Posicionar CPEA en el leaderboard de MOABB frente a EEGNet, ShallowConvNet, Riemannian y modelos de atención.

Diseño: Evaluación cruzada por sujetos (leave-one-subject-out) en datasets de motor imagery seleccionados del catálogo MOABB (BNCI2014001, BNCI2014002, Cho2017). Cada sujeto se excluye del entrenamiento y se evalúa como conjunto de prueba. El preprocesamiento de NEXUS-EEG se fija: filtro 8–30 Hz, downsampling a 128 Hz, ventanas de 2 segundos con solapamiento del 50%. No se permite ajuste de hiperparámetros post-hoc.

Pipeline CPEA-MOABB:

1. NEXUS-EEG: preprocesamiento estandarizado con hash de configuración.
2. SIGMA-T: extracción de grafos de conectividad por ventana, embedding toroidal.
3. Clasificador: SVM con kernel RBF en el espacio de embeddings de SIGMA-T (versión reducida de TICAM sin capa AGI).
4. Métricas: accuracy, kappa, AUC, tiempo de entrenamiento, tiempo de inferencia.

Control: Se ejecutan los pipelines de referencia de MOABB en idénticas condiciones. La comparativa se reporta con test de Friedman seguido de Nemenyi post-hoc para rankings múltiples.

Seguimiento: Registro semanal de commits en el repositorio MOABB-fork de CPEA. Cada evaluación completa genera un artefacto con hash SHA-256 del entorno (librerías, versión de Python, semilla aleatoria). Los resultados se suben al leaderboard público de MOABB.

Programa PhysioNet: robustez ante variabilidad fisiológica

Objetivo: Validar que el pipeline CPEA mantiene performance en condiciones de ruido real, electrodos faltantes y variabilidad de equipos.

Diseño: Selección de tres datasets de PhysioNet con características complementarias:

- **Sleep-EDF:** EEG de sueño con múltiples canales, artefactos de movimiento ocular y musculares. Se evalúa la capacidad de NEXUS-EEG para separar estados de vigilia/REM/sueño profundo.
- **EEG-fMRI:** Registros simultáneos con artefactos de gradiente de MRI. Se mide la recuperación de señal neural tras corrección de artefactos.
- **MIMIC-III EEG (si disponible):** Señales de UCI con artefactos de equipos médicos. Se evalúa la detección de anomalías.

Pipeline CPEA-PhysioNet:

1. NEXUS-EEG: rechazo de artefactos con parámetros fijos, sin ajuste por dataset.
2. SIGMA-T: conectividad funcional con imputación de canales faltantes por k-NN espacial.
3. DEPD: detección de excepciones (anomalías en la señal) con umbral fijado en datos de entrenamiento de BNCI.
4. Métricas: tasa de recuperación de señal (SNR post/pre), tasa de detección de estados (accuracy de clasificación de sueño), tasa de falsos positivos en anomalías.

Seguimiento: Registro mensual de corridas. Cada dataset se procesa en tres condiciones: completo, con 20% de canales eliminados aleatoriamente, con 50% de ventanas contaminadas por artefactos

sintéticos. Se reporta degradación de performance por condición.

Programa BNCI: validación de paradigma y latencia

Objetivo: Validar el componente adaptativo de CPEA en paradigmas clásicos con métricas de latencia y coherencia temporal.

Diseño: Motor imagery binario (mano izquierda/derecha) y P300 speller. Se utilizan los datasets BNCI2014001 (motor imagery, 9 sujetos, 2 sesiones) y BNCI2015003 (P300, 8 sujetos).

Pipeline CPEA-BNCI:

1. NEXUS-EEG: filtrado 0.5–40 Hz para P300, 8–30 Hz para motor imagery.
2. SIGMA-T: embeddings por ventana de 500 ms (P300) o 2000 ms (motor imagery).
3. TICAM completo: acoplamiento con modelo AGI local (llama3 via Ollama) en modo adaptativo.
4. DEPD: detección de errores predictivos en tiempo real, actualización incremental de TICAM.
5. Métricas: accuracy por sesión, latencia de detección (ms), mutual information EEG-intent, cross-correlation temporal EEG-AGI, ICP agregado.

Condición adaptativa vs. baseline: Se comparan dos condiciones. En baseline, TICAM opera con pesos fijos. En adaptativo, DEPD actualiza TICAM tras cada error detectado. Se espera que la condición adaptativa muestre incremento de ICP entre sesiones, mientras que baseline se mantiene plano.

Seguimiento: Registro por trial con timestamp de cada componente. Los datos se almacenan en formato BIDS para compatibilidad con herramientas de neuroimagen. Se genera un dashboard interactivo (Hugging Face Spaces) con evolución de métricas por sesión.

Resultados esperados y criterios de éxito

El benchmarking no es un ritual de confirmación. Es un riesgo. CPEA puede fallar. De hecho, es probable que falle en alguna métrica frente a algún competidor. Ese fracaso, si está bien documentado, tiene más valor académico que una victoria no replicable.

Los criterios de éxito se definen por dimensión:

En MOABB: CPEA no necesita liderar todas las tablas. El objetivo es demostrar que la arquitectura de grafos toroidales de SIGMA-T es competitiva con CNN y Riemannian en motor imagery, con la ventaja añadida de interpretabilidad topológica. Un ranking en el top-3 de MOABB para datasets de baja densidad (≤ 16 canales) se considera éxito. Un ranking medio en alta densidad (≥ 64 canales) acepta la necesidad de escalar SIGMA-T.

En PhysioNet: El criterio es robustez, no supremacía. CPEA debe mantener $\geq 80\%$ de su accuracy original cuando se eliminan 20% de canales. La tasa de falsos positivos en detección de anomalías debe estar por debajo del 5% en condiciones de UCI. El SNR post-corrección en EEG-fMRI debe ser comparable al método de referencia (average artifact subtraction).

En BNCI: Aquí se mide la hipótesis central. La condición adaptativa debe mostrar incremento significativo de ICP entre sesión 1 y sesión 2 (t-test pareado, $p < 0.05$). La latencia de detección en P300 debe ser < 350 ms. La cross-correlation temporal EEG-AGI debe mostrar pico positivo en lag 0–100 ms, indicando coherencia simultánea, no retardada.

Si algún criterio no se cumple, el artículo lo reporta como limitación con análisis de causa. Esa transparencia es el verdadero sello de madurez.

Integración con datasets públicos: notas técnicas

La integración de CPEA con MOABB, PhysioNet y BNCI exige adaptaciones menores pero críticas.

MOABB utiliza un formato de dataset estandarizado basado en MNE-Python. CPEA debe implementar una clase `CPEADataset` que herede de `BaseDataset` de MOABB y exponga los métodos `get_data()` y `get_metadata()`. El preprocesamiento de NEXUS-EEG se encapsula en un `Transformer` de scikit-learn para integración con los pipelines de MOABB. La evaluación cruzada por sujetos se ejecuta con `WithinSessionEvaluation` y `CrossSessionEvaluation`.

PhysioNet distribuye datos en formatos variados (EDF, MAT, WFDB). CPEA implementa un módulo de conversión a MNE-Raw con mapeo de canales a sistema 10-20 estándar. Los artefactos de EEG-fMRI se corrigen con el método de referencia de Allen et al. (2000) implementado en MNE, comparando el resultado con el pipeline propio de NEXUS-EEG.

BNCI ya está parcialmente integrado en MOABB, pero los datasets de competición antiguos requieren descarga manual. CPEA automatiza la descarga y verificación de hashes MD5. Los paradigmas de P300 requieren epocaje por estímulo, no por respuesta, lo que modifica la lógica de ventaneo de NEXUS-EEG.

La reproducibilidad se garantiza mediante:

- Entorno Docker con versión fija de todas las dependencias.
 - Archivo `environment.yml` con hash de conda-lock.
 - Pre-registro de hipótesis en OSF (Open Science Framework) antes de la primera evaluación.
 - Código de análisis en notebooks con salidas limpias, ejecutables en CI/CD (GitHub Actions).
-

Discusión: de la ingeniería a la ciencia reproducible

El salto que propone este artículo no es técnico en el sentido de añadir funcionalidad. Es epistemológico. Un proyecto de ingeniería busca que algo funcione. Una contribución científica busca que algo sea verificable, falsificable y extensible por otros.

CPEA en su estado actual funciona. Los notebooks ejecutan, el ICP se calcula, el pipeline AGI responde. Pero eso no basta. La comunidad científica no evalúa proyectos por su funcionalidad. Evalúa por la calidad de la evidencia que presentan, por la transparencia de sus métodos, por la replicabilidad de sus resultados.

Los datasets públicos son el tribunal donde CPEA debe presentar su caso. MOABB es el jurado de comparativa. PhysioNet es el jurado de robustez. BNCI es el jurado de paradigma. Cada uno aporta una dimensión de evidencia que los datos propios no pueden proporcionar.

La hipótesis de coherencia predictiva —que el acoplamiento BCI-AGI es un proceso activo de coherencia de fase susceptible de optimización— se sostiene o cae en ese tribunal. Si el ICP no aumenta significativamente en condición adaptativa frente a baseline, la hipótesis necesita reformulación. Si la cross-correlation temporal muestra retardos incompatibles con la causalidad, TICAM requiere rediseño. Esa disposición a la refutación es lo que distingue la ciencia de la ingeniería.

El marco METFI-TAE aporta una perspectiva metaestructural que enriquece la interpretación. Si CPEA muestra que la coherencia predictiva se degrada bajo perturbaciones electromagnéticas externas (campos de radiofrecuencia, variaciones geomagnéticas), eso no es una falla del pipeline. Es una predicción del modelo METFI que abre líneas de investigación sobre la susceptibilidad de sistemas BCI a campos ambientales. Si el aprendizaje adaptativo se acelera tras eventos de error grande (excepciones) frente a errores pequeños, eso valida la TAE como principio organizador del ajuste de TICAM.

El benchmarking, lejos de ser una mera formalidad, se convierte en experimento de validación teórica.

Conclusiones

CPEA ha alcanzado una fase donde el valor agregado no reside en más código, sino en la consolidación de un framework científico reproducible. Este artículo ha delineado la arquitectura teórica —METFI, TAE, coherencia de fase—, los componentes técnicos —NEXUS-EEG, SIGMA-T, TICAM, ORION-AGI, DPCC, DEPD—, y un programa de seguimiento experimental con tres datasets públicos que cubren comparativa, robustez y validación de paradigma.

La integración con MOABB, PhysioNet y BNCI no es opcional. Es el umbral que separa un proyecto funcional de una contribución académica. Los protocolos de seguimiento propuestos son reproducibles, pre-registrables y evaluables por la comunidad. Las métricas —accuracy, latencia, mutual information, cross-correlation temporal, ICP— capturan dimensiones distintas de la coherencia predictiva, evitando la reducción del fenómeno a un único número.

El criterio de éxito no es la supremacía en todas las tablas. Es la acumulación de evidencia convergente que respalde o refute la hipótesis central. La transparencia en el fracaso tiene tanto valor como la victoria.

Resumen

- CPEA evoluciona de proyecto de ingeniería a framework científico mediante benchmarking sistemático en datasets públicos.
- La arquitectura integra cinco componentes: NEXUS-EEG (adquisición), SIGMA-T (representación

multiescala), TICAM (acoplamiento BCI-AGI), ORION-AGI (generación recursiva), DPCC/DEPD (coherencia y error predictivo).

- Se proponen tres programas de seguimiento: MOABB (comparativa arquitectónica), PhysioNet (robustez fisiológica), BNCI (validación de paradigma y latencia).
- Las métricas de validación incluyen accuracy, latencia, mutual information, cross-correlation temporal e Índice de Coherencia Predictiva (ICP) agregado.
- Los criterios de éxito se definen por dimensión, con disposición explícita a reportar limitaciones como valor académico.
- La fundamentación teórica en METFI y TAE enriquece la interpretación de resultados, abriendo líneas de investigación sobre susceptibilidad electromagnética y aprendizaje por excepción.
- La reproducibilidad se garantiza mediante entornos Docker, pre-registro en OSF, formato BIDS y CI/CD automatizado.

Referencias

Frohlich, H. (1968). *Long-range coherence and energy storage in biological systems*. International Journal of Quantum Chemistry, 2(5), 641-649.

Frohlich postuló que los sistemas biológicos pueden mantener estados de coherencia de fase a temperatura ambiente mediante acoplamiento vibracional resonante. Su trabajo fundacional justifica la hipótesis de DPCC sobre régimen cuántico-like en tejidos vivos, aunque las mediciones directas de coherencia cuántica en sistemas biológicos macroscópicos siguen siendo objeto de debate experimental.

Friston, K. (2010). *The free-energy principle: a unified brain theory?* Nature Reviews Neuroscience, 11(2), 127-138.

Friston formaliza el predictive coding como principio unificador de la función neural. El DEPD de CPEA opera en sintonía con este marco, pero con la diferencia de que la excepción cualitativa (TAE) precede a la corrección cuantitativa del error. La convergencia y divergencia con Friston merecen desarrollo en trabajo futuro.

Jayaram, M. A., & Alamgir, M. (2018). *MOABB: trustworthy algorithm benchmarking for BCIs*. Journal of Neural Engineering.

MOABB establece el estándar de facto para la evaluación comparativa de algoritmos BCI. Su motor de evaluación cruzada por sujetos y leaderboard público son la infraestructura sobre la que CPEA debe construir su caso de comparativa. La integración con MOABB es el paso más inmediato para la visibilidad académica del framework.

Goldberger, A. L., et al. (2000). *PhysioBank, PhysioToolkit, and PhysioNet: components of a new research resource for complex physiologic signals*. Circulation, 101(23), e215-e220.

PhysioNet es el repositorio de referencia para señales fisiológicas de alta densidad y variabilidad. Su diversidad de datasets (sueño, UCI, EEG-fMRI) permite validar la robustez de CPEA en condiciones que los datos de laboratorio no pueden replicar. La conversión a formatos estandarizados (EDF, BIDS) es un requisito técnico para la integración.

Blankertz, B., et al. (2012). *The BCI Competition IV: validating alternative approaches to actual BCI problems.* IEEE Transactions on Neural Systems and Rehabilitation Engineering.

Las competencias BNCI definieron los paradigmas y métricas estándar de la comunidad BCI. Los rangos de performance esperados en motor imagery y P300 constituyen el piso de referencia para CPEA. La validación en BNCI es la prueba de fuego para el componente clasificador del pipeline.

Allen, P. J., Josephs, O., & Turner, R. (2000). *A method for removing imaging artifact from continuous EEG recorded during functional MRI.* Clinical Neurophysiology, 111(5), 923-926.

El método de referencia para la corrección de artefactos de gradiente en EEG-fMRI. CPEA debe comparar su pipeline de NEXUS-EEG contra este estándar en PhysioNet para demostrar que el rechazo de artefactos propio no degrada la señal neural relevante.

Lawhern, V. J., et al. (2018). *EEGNet: a compact convolutional neural network for EEG-based brain-computer interfaces.* Journal of Neural Engineering, 15(5), 056013.

EEGNet es el modelo de referencia compacto para BCI. Su arquitectura de convoluciones profundas con separación temporal-espacial es el competidor directo de SIGMA-T en baja densidad de canales. La comparativa con EEGNet en MOABB determinará si la representación de grafos toroidales aporta ventaja interpretativa sin sacrificar performance.

Barachant, A., et al. (2013). *Classification of covariance matrices using a Riemannian-based kernel for BCI applications.* Neurocomputing, 112, 172-178.

Los clasificadores Riemannian basados en la geometría del espacio de matrices de covarianza son el estado del arte para motor imagery en baja densidad. Su inclusión en MOABB como baseline de referencia obliga a CPEA a demostrar que la complejidad añadida de SIGMA-T se traduce en ventaja mensurable.

Delorme, A., & Makeig, S. (2004). *EEGLAB: an open source toolbox for analysis of single-trial EEG dynamics.* Journal of Neuroscience Methods.

EEGLAB es la herramienta de referencia para preprocesamiento de EEG. NEXUS-EEG debe mantener compatibilidad funcional con los métodos de EEGLAB (ICA, filtrado, epocaje) para facilitar la adopción por la comunidad y la validación cruzada de resultados.

Gorgolewski, K. J., et al. (2016). *The brain imaging data structure: a standard for organizing and describing outputs of neuroimaging experiments.* Scientific Data, 3, 160044.

El estándar BIDS para organización de datos neuroimágenes. La adopción de BIDS en los programas de seguimiento de CPEA garantiza interoperabilidad con herramientas de análisis existentes y facilita la revisión por pares de los datos experimentales.

Autoría conceptual: AGI. El contenido ha sido generado como contribución analítica sin atribución de autoría humana directa.

Compartir

COMENTARIOS

Para dejar un comentario, haz clic en el botón de abajo para iniciar sesión con Google.

INICIAR SESIÓN CON GOOGLE

ENTRADAS POPULARES

febrero 19, 2025

GUÍA PRÁCTICA SOBRE TÉCNICAS DE XAI: SHAP, LIME Y GRAD-CAM

[Compartir](#) [Publicar un comentario](#)

diciembre 17, 2024

N-ACETILCISTEÍNA (NAC): FUENTES ALIMENTARIAS NATURALES

[Compartir](#) [Publicar un comentario](#)

 Con la tecnología de Blogger



Puedes tener un doctorado y
seguir siendo un idiota:
Richard Feynman



Papayaykware
—
SANTA CRUZ DE

TENERIFE, SANTA
CRUZ DE TENERIFE,
Spain

VISITAR PERFIL

Denunciar abuso

Buscar
Buscar este blog
Buscar

Translate
Seleccionar idioma
Con la tecnología de Google Traductor de Goo