

CORPUS PAPAYAYKWARE

Eje III — CPEA (Coherencia Predictiva EEG-AGI)

CPEA-3

Protocolo de Estudio Pre-Registrado:

Tres Líneas Experimentales para la Validación Empírica de CPEA

Autor conceptual: Claude (Anthropic)

Originador y director del corpus: Javi Ciborro (@papayaykware)

Santa Cruz de Tenerife, España · Mayo 2026

github.com/papayaykware · papayaykware.blogspot.com

Abstract

CPEA-3 constituye el protocolo de estudio pre-registrado para la validación empírica de la Arquitectura de Coherencia Predictiva EEG-AGI (CPEA). Los documentos CPEA-1 y CPEA-2 establecieron los fundamentos teóricos del marco y formalizaron el Módulo de Calibración Adaptativa (ACM) con su umbral dinámico ϵ_c . CPEA-3 traduce estos fundamentos en tres líneas experimentales complementarias, cada una diseñada para testear un aspecto diferente de la hipótesis central: que los estados de coherencia predictiva neural son detectables, clasificables y transferibles mediante arquitecturas EEG-AGI.

La Línea A (EEG-Coherencia en reposo y tarea cognitiva) valida la detección del parámetro de orden Ψ_{neur} en condiciones controladas de laboratorio. La Línea B (Detección de excepciones TAE en señal EEG continua) testa el pipeline completo CPEA sobre datasets públicos de PhysioNet. La Línea C (Transferencia cross-modal: EEG $\rightarrow$ modelo AGI) evalúa si las representaciones de excepción aprendidas en señal EEG son transferibles a un modelo de lenguaje como prior de detección de anomalías. Cada línea incluye hipótesis operacionales, variables dependientes e independientes, criterios de falsación, análisis estadístico pre-especificado y requerimientos de datos.

Palabras clave

CPEA · EEG · Coherencia predictiva · TAE · Parámetro de orden Ψ_{neur} · ACM · Umbral adaptativo ϵ_c
Entropía de permutación · PELT · Detección de excepciones · Transferencia cross-modal · Pre-registro

1. Marco Teórico y Posición en el Corpus CPEA

1.1 Recapitulación de CPEA-1 y CPEA-2

CPEA (Coherencia Predictiva EEG-AGI) postula que el cerebro humano opera como un sistema de inferencia predictiva cuya coherencia interna es medible mediante señal EEG multicanal. El parámetro de orden Ψ_{neur} cuantifica esta coherencia como la correlación cruzada ponderada entre oscilaciones de banda theta (4-8 Hz), alpha (8-13 Hz) y gamma (30-80 Hz) en regiones frontales, parietales y occipitales.

CPEA-2 introdujo el Módulo de Calibración Adaptativa (ACM), que define el umbral de excepción ε_c como el percentil 95 del error de predicción sobre una ventana deslizante de W muestras. El ACM demostró formalmente la propiedad de no-circularidad: el umbral no puede ser influido por la misma excepción que detecta, garantizando independencia estadística entre detección y calibración.

CPEA-3 opera en el nivel de validación empírica: asume los fundamentos de CPEA-1 y CPEA-2 como hipótesis a testear, no como supuestos, y diseña los experimentos que permitirían refutarlos o corroborarlos con datos reales.

1.2 Hipótesis central de CPEA

La hipótesis central que CPEA-3 busca testear es:

Hipótesis Central CPEA (HC)

HC: La señal EEG multicanal contiene información estructural suficiente para (a) detectar transiciones de coherencia (excepciones TAE) con anticipación ≥ 500 ms respecto a su manifestación conductual, (b) clasificar el tipo de excepción según su firma espectral, y (c) transferir representaciones de excepción a modelos AGI como prior de detección de anomalías.

HC se falsaría si cualquiera de las tres subhipótesis (HA, HB, HC_transfer) es refutada en sus criterios pre-especificados.

1.3 Estructura del protocolo

El protocolo sigue los estándares de pre-registro de la Open Science Framework (OSF) y el formato CONSORT adaptado para estudios de señal fisiológica. Cada línea experimental se especifica con:

- Hipótesis operacional y su correspondencia con HC.
- Variables independientes, dependientes y de control.
- Análisis estadístico pre-especificado con corrección de comparaciones múltiples.
- Criterio de falsación cuantitativo.
- Datos requeridos (públicos o de captación propia) y pipeline de procesamiento.
- Conexión con documentos del corpus.

2. Línea Experimental A: Detección de Ψ_{neur} en Reposo y Tarea Cognitiva

2.1 Hipótesis operacional

HA: El parámetro de orden Ψ_{neur} , calculado como coherencia espectral ponderada entre regiones frontales y parietales en banda alpha, discrimina significativamente entre condiciones de reposo (ojos cerrados), tarea cognitiva de baja demanda y tarea cognitiva de alta demanda, con tamaño de efecto Cohen's $d \geq 0.5$ entre condiciones extremas.

2.2 Diseño experimental

Participantes

N = 30 adultos sanos (18-45 años), sin historia de patología neurológica, con corrección visual normal o corregida. Exclusión: medicación psicoactiva en los 30 días previos, consumo de cafeína en las 4 horas previas a la sesión.

Condiciones

- C1 — Reposo ojos cerrados: 5 minutos sin tarea, instrucción de no dormir.
- C2 — Tarea de baja demanda: lectura de texto narrativo simple (nivel comprensión 6.º grado).
- C3 — Tarea de alta demanda: aritmética mental en series de 3 (test de Paced Auditory Serial Addition adaptado).
- Orden: contrabalanceado mediante cuadrado latino 3×3 entre participantes.

Adquisición EEG

- Sistema: 64 canales activos (BioSemi ActiveTwo o equivalente $\geq 64\text{ch}$), referencia CMS/DRL, frecuencia de muestreo 2048 Hz.
- Canales de interés primario: Fz, F3, F4, Pz, P3, P4, Cz (análisis de hipótesis); resto como canales de control y rechazo de artefactos.
- Preprocesamiento: filtro paso-banda 1-80 Hz (Butterworth 4.º orden), notch 50 Hz, ICA para rechazo de artefactos oculares y musculares, re-referencia promedio.

2.3 Cálculo de Ψ_{neur}

Ψ_{neur} se calcula sobre ventanas de 4 segundos con 50% de solapamiento mediante la siguiente expresión:

$$\Psi_{\text{neur}}(t) = \sum_{b \in \{\theta, \alpha, \gamma\}} w_b \cdot [\sum_{\{(i,j) \in \text{pares}\}} |\text{Coh}_b(i,j,t)|] / N_{\text{pares}}$$

donde $\text{Coh}_b(i,j,t)$ es la coherencia espectral de Welch entre canales i y j en banda b , w_b son pesos pre-especificados ($w_\theta=0.25$, $w_\alpha=0.50$, $w_\gamma=0.25$) y N_{pares} es el número de pares de canales de interés. Los pesos reflejan la hipótesis de primacía de la banda alpha en la coherencia predictiva de larga escala.

2.4 Variables y análisis

Variable	Tipo	Medida	Análisis
$\Psi_{\text{neur}}(t)$	Dependiente principal	Media por condición y ventana	ANOVA mixto + corrección Bonferroni
Condición (C1/C2/C3)	Independiente	Factor intra-sujeto (3 niveles)	Contrastes planeados C1 vs C3
Orden de condición	Control	Factor entre-sujetos (cuadrado latino)	Covariable en ANOVA
Artefactos ICA	Control	N.º componentes rechazados	Covariable continua
Cohen's d (C1 vs C3)	Tamaño de efecto	Calculado post-ANOVA	CI 95% bootstrap (B=5000)

2.5 Criterio de falsación

Falsación HA

HA queda refutada si: el efecto principal de Condición no alcanza $p < 0.01$ (corregido Bonferroni) en el ANOVA mixto, O si el tamaño de efecto Cohen's d (C1 vs C3) es < 0.3 en el intervalo de confianza bootstrap al 95%.

En caso de falsación parcial (efecto significativo pero $d < 0.5$), se reporta como corroboración débil y se revisa la especificación de los pesos w_b mediante análisis exploratorio post-hoc pre-especificado (grid search sobre $w_\alpha \in [0.3, 0.7]$).

2.6 Datos y reproducibilidad

- Dataset de validación previa: EEGMMI (PhysioNet) — 109 sujetos, 64 canales, tareas motoras e imaginadas. Permite piloto de pipeline antes de captación propia.
- Código: Python + MNE-Python ≥ 1.6 , script pre-registrado en OSF antes de análisis.
- Datos crudos: depositados en OpenNeuro en formato BIDS antes de análisis confirmatorio.

3. Línea Experimental B: Detección de Excepciones TAE en Señal EEG Continua

3.1 Hipótesis operacional

HB: El pipeline completo CPEA (ACM + PELT + verificación de nuevo estado de coherencia) detecta excepciones TAE en señal EEG continua con una sensibilidad ≥ 0.75 y especificidad ≥ 0.70 respecto a un criterio de referencia independiente, en al menos dos datasets de PhysioNet de dominios distintos.

3.2 Datasets de referencia

Dataset	N sujetos	Canales	Dominio	Criterio de referencia TAE
EEGMMI (PhysioNet)	109	64	Tarea motora / imaginada	Inicio de tarea (marca temporal)
DEAP (acceso abierto)	32	32	Respuesta emocional a video	Cambio de estímulo + rating subjetivo
Temple Univ. EEG Corpus	~1.700	Variable	EEG clínico de rutina	Eventos clínicos anotados por experto

El criterio de referencia TAE se construye de forma independiente al pipeline CPEA para cada dataset: se definen como excepciones los instantes temporales en que el sistema experimenta un cambio de estado verificado externamente (inicio de tarea, cambio de estímulo, evento clínico). El pipeline CPEA no tiene acceso a estas marcas durante la detección.

3.3 Pipeline CPEA completo

Paso 1 — Cálculo de error de predicción

El error de predicción $e(t)$ se calcula como la divergencia entre la distribución espectral predicha por un modelo $AR(p)$ de orden $p=10$ ajustado sobre una ventana anterior de 10 segundos, y la distribución espectral observada en la ventana actual:

$$e(t) = D_{KL}[P_{obs}(t) || P_{pred}(t)]$$

Paso 2 — Calibración adaptativa ACM

El umbral $\epsilon_c(t)$ se actualiza en cada ventana como el percentil 95 de $e(t')$ para t' en la ventana deslizante $[t-W, t]$, con $W = 300$ ventanas (equivalente a 10 minutos a 2 s/ventana). La propiedad de no-circularidad (CPEA-2) garantiza que $e(t)$ no influye en $\epsilon_c(t)$ si t está dentro de la ventana de calibración activa.

Paso 3 — Detección PELT

El algoritmo PELT (Pruned Exact Linear Time) detecta puntos de cambio en la serie $e(t)/\epsilon_c(t)$. Un punto de cambio es candidato a excepción TAE si:

- C1 (dislocation métrica): $e(t) > \epsilon_c(t)$ en al menos 3 ventanas consecutivas.

- C2 (perturbación entrópica): la entropía de permutación local $PE(t)$ aumenta $\geq 20\%$ respecto a la media de los 60 segundos anteriores.
- C3 (persistencia temporal): las condiciones C1 y C2 se mantienen durante ≥ 5 ventanas consecutivas (≥ 10 segundos).

Esta es la operacionalización directa de TAGIS-1 (criterios de excepción C1, C2, C3) sobre señal EEG, constituyendo el puente empírico entre TAGIS y CPEA.

Paso 4 — Verificación de nuevo estado de coherencia

Una excepción candidata se confirma como excepción TAE verificada si Ψ_{neur} calculado en los 30 segundos posteriores al punto de cambio difiere significativamente ($|\Delta\Psi| > 0.1$) del Ψ_{neur} en los 30 segundos anteriores. Esto verifica que el sistema ha transitado a un nuevo atractor de coherencia, no simplemente ha experimentado ruido transitorio.

3.4 Métricas de evaluación

- Sensibilidad (recall): fracción de excepciones de referencia detectadas por CPEA dentro de una ventana de ± 2 segundos.
- Especificidad: fracción de ventanas sin excepción de referencia correctamente clasificadas como no-excepcionales.
- F1-score: media armónica de sensibilidad y precisión.
- Tiempo de anticipación: diferencia entre el instante de detección CPEA y el instante de la marca de referencia (positivo = anticipación, negativo = retraso).

3.5 Criterio de falsación

Falsación HB

HB queda refutada si: en cualquiera de los dos datasets primarios (EEGMMI + DEAP), la sensibilidad es < 0.60 O la especificidad es < 0.60 , usando los parámetros pre-especificados del pipeline sin ajuste post-hoc.

HB queda corroborada débilmente si: sensibilidad ≥ 0.75 y especificidad ≥ 0.70 en EEGMMI y DEAP, pero no en Temple University EEG Corpus (dataset clínico más heterogéneo).

HB queda corroborada fuertemente si: criterios anteriores se cumplen en los tres datasets.

4. Línea Experimental C: Transferencia Cross-Modal EEG → Modelo AGI

4.1 Hipótesis operacional

HC_transfer: Las representaciones de excepción extraídas del pipeline CPEA sobre señal EEG (vectores de características espectrales en el instante de excepción) son transferibles a un modelo de lenguaje de gran escala como prior de detección de anomalías, mejorando su sensibilidad a distribuciones OOD en $\geq 15\%$ respecto al baseline sin prior, medido en F1-score sobre un benchmark de detección de anomalías textual.

4.2 Motivación teórica

HC_transfer es la hipótesis más especulativa del protocolo pero también la de mayor implicación para el corpus. Si es corroborada, establece un puente empírico entre señal neural biológica y arquitecturas AGI que va más allá de la analogía estructural formalizada en INTER-1 a INTER-5: implicaría que la firma de excepción es una representación transferible entre sustratos, no solo un isomorfismo matemático.

La base teórica es que las excepciones TAE, sean neurales o computacionales, comparten la misma geometría en el espacio de representaciones (cusp catastrophe en TAE-F2) y por tanto sus firmas deben ser parcialmente alineables mediante transformaciones lineales en espacios de embedding de alta dimensión.

4.3 Diseño del experimento de transferencia

Paso 1 — Extracción de representaciones EEG de excepción

Para cada excepción detectada en la Línea B, se extrae un vector de características $v_{exc} \in \mathbb{R}^{128}$:

- 32 dimensiones: potencia espectral por banda (theta, alpha, beta, gamma) en los 8 canales de interés en la ventana de excepción.
- 32 dimensiones: coherencia entre pares de canales en la ventana de excepción.
- 32 dimensiones: gradiente temporal de Ψ_{neur} en las 5 ventanas anteriores a la excepción.
- 32 dimensiones: entropía de permutación por canal en la ventana de excepción.

Paso 2 — Construcción del prior de excepción

El conjunto de vectores $\{v_{exc}\}$ de todos los sujetos y datasets de la Línea B se utiliza para entrenar un codificador ligero $E: \mathbb{R}^{128} \rightarrow \mathbb{R}^{768}$ (dimensión de embedding de GPT-2 base). E se entrena para minimizar la distancia coseno entre v_{exc} y los embeddings de tokens de alta sorpresa en el modelo de lenguaje (tokens donde la perplejidad supera el percentil 95 de la distribución del corpus).

Este entrenamiento no requiere acceso a los pesos del modelo de lenguaje: opera únicamente sobre embeddings de tokens extraídos sin gradientes (modo inferencia).

Paso 3 — Evaluación de transferencia

El prior $E(v_{exc})$ se introduce como vector de contexto en el espacio de embedding del modelo de lenguaje antes de la inferencia sobre textos de test. Se evalúa si este prior mejora la detección de distribuciones OOD textuales en:

- CLINC150-OOD: benchmark estándar de detección de intención fuera de distribución en sistemas de diálogo.
- SNLI-hard: subset de alta dificultad del Stanford Natural Language Inference corpus.
- Texto generado por modelo adversarial (benchmark de detección de alucinaciones).

4.4 Variables y análisis

Variable	Tipo	Condición baseline	Condición experimental
F1-score detección OOD	Dependiente principal	GPT-2 sin prior	GPT-2 + prior $E(v_{exc})$
Perplejidad en tokens OOD	Dependiente secundaria	Distribución sin prior	Distribución con prior
Dimensionalidad de v_{exc}	Independiente	128 (completo)	Ablación: 32, 64, 96
Dataset EEG fuente	Independiente	EEGMMI solo	EEGMMI + DEAP combinado
Mejora F1 relativa	Métrica de transferencia	0% (baseline)	$\geq 15\%$ (criterio HC_transfer)

4.5 Criterio de falsación

Falsación HC_transfer

HC_transfer queda refutada si: la mejora en F1-score sobre CLINC150-OOD es $< 5\%$ respecto al baseline en el análisis confirmatorio pre-especificado.

HC_transfer queda corroborada débilmente si: mejora $\geq 15\%$ en CLINC150-OOD pero no en SNLI-hard ni en el benchmark de alucinaciones.

HC_transfer queda corroborada fuertemente si: mejora $\geq 15\%$ en los tres benchmarks textuales.

Nota metodológica crítica: la comparación debe hacerse con semillas aleatorias fijas (seed=42, 123, 777) y reportar varianza entre semillas para distinguir efecto real de varianza de inicialización.

4.6 Implicaciones para el corpus si HC_transfer es corroborada

Una corroboración fuerte de HC_transfer tendría implicaciones que trascienden CPEA y afectan a la estructura argumental de todo el corpus:

- Validaría empíricamente el isomorfismo IS-M4 de INTER-5 (CPEA $\leftrightarrow$ predicción activa de Friston) al nivel de representaciones transferibles, no solo de estructura matemática.

- Proporcionaría evidencia para IS-P4 de INTER-6: la firma de excepción neural es detectable computacionalmente y transferible entre dominios.
- Abriría una línea de investigación hacia CPEA-4: arquitecturas de co-entrenamiento EEG-LLM en tiempo real, donde el modelo de lenguaje adapta sus umbrales de atención en función de señal EEG del operador.

5. Consideraciones Éticas y de Pre-Registro

5.1 Ética de investigación

Las Líneas A y C (en la parte de captación EEG) requieren aprobación de Comité de Ética de Investigación (CEI) antes del inicio de la captación. Los elementos mínimos del protocolo ético son:

- Consentimiento informado explícito con posibilidad de retirada en cualquier momento sin penalización.
- Anonimización irreversible de datos EEG antes del depósito en repositorio público.
- Seguro de responsabilidad civil del investigador principal.
- Evaluación de riesgo mínimo: la adquisición EEG es no-invasiva y no presenta riesgos documentados más allá de incomodidad menor por el gel conductor.

La Línea B opera exclusivamente sobre datos públicos ya anonimizados (PhysioNet, DEAP) y no requiere aprobación CEI adicional, aunque debe cumplir los términos de uso de cada dataset.

5.2 Pre-registro

El protocolo CPEA-3 debe pre-registrarse en OSF (osf.io) antes del inicio de cualquier análisis sobre datos reales. El pre-registro debe incluir:

- Hipótesis exactas (HA, HB, HC_transfer) tal como se especifican en este documento.
- Parámetros del pipeline CPEA (W=300 ventanas, pesos w_b , umbrales C1-C3) sin margen de ajuste post-hoc.
- Análisis estadístico completo pre-especificado incluyendo tratamiento de datos faltantes y outliers.
- Criterios de exclusión de participantes definidos a priori.
- Declaración de conflictos de interés: ninguno (investigación independiente sin financiación institucional).

5.3 Apertura y reproducibilidad

- Código: repositorio público en github.com/papayaykware con licencia MIT antes del inicio del análisis.
- Datos de captación propia: depósito en OpenNeuro en formato BIDS dentro de los 12 meses posteriores a la publicación de resultados.
- Materiales experimentales (instrucciones a participantes, scripts de tarea): depositados en OSF junto al pre-registro.

6. Cronograma y Recursos

Fase	Actividad	Duración estimada	Recursos requeridos
Pre-registro	Depósito en OSF + aprobación CEI (Línea A)	4-8 semanas	Ninguno adicional
Línea B (piloto)	Pipeline CPEA sobre EEGMMI + DEAP	2-4 semanas	GPU (Colab Pro+ o local)
Línea A (captación)	30 sujetos × 3 sesiones ≈ 90 sesiones EEG	3-6 meses	Sistema EEG 64ch + sala
Línea A (análisis)	ANOVA + bootstrap CI + revisión	4-6 semanas	Cluster de cómputo o Colab
Línea B (confirmatorio)	Pipeline sobre Temple Univ. EEG Corpus	4-6 semanas	GPU + almacenamiento ≥ 500 GB
Línea C	Entrenamiento codificador E + evaluación	6-8 semanas	GPU A100 o equivalente
Redacción y pre-print	Manuscrito TAE-E3 + arXiv submission	4-8 semanas	Ninguno adicional

El cronograma total estimado es de 9-18 meses desde el pre-registro hasta el pre-print, dependiendo principalmente de la disponibilidad de sistema EEG para la Línea A. Las Líneas B y C pueden iniciarse en paralelo al proceso CEI y no bloquean el avance del corpus.

7. Resumen de las Tres Líneas Experimentales

Línea	Hipótesis	Criterio de corroboración fuerte	Criterio de falsación	Dataset
A — Ψ_{neur} en tarea	HA: Ψ_{neur} discrimina condiciones cognitivas	$d \geq 0.5$ (C1 vs C3), $p < 0.01$ corregido	$d < 0.3$ O $p \geq 0.01$	Captación propia (N=30) + EEGMMI piloto
B — Detección excepciones	HB: pipeline CPEA detecta excepciones TAE en EEG	Sensib. ≥ 0.75 y Espec. ≥ 0.70 en 3 datasets	Sensib. < 0.60 O Espec. < 0.60 en ≥ 2 datasets	EEGMMI + DEAP + Temple Univ.
C — Transferencia EEG→AGI	HC_transfer: prior EEG mejora detección OOD en LLM	Mejora F1 $\geq 15\%$ en 3 benchmarks textuales	Mejora F1 $< 5\%$ en CLINC150-OOD	Línea B + CLINC150 + SNLI-hard

8. Conexiones Formales con el Corpus

8.1 Documentos que CPEA-3 valida

- CPEA-1: la definición del parámetro de orden Ψ_{neur} es directamente testada en la Línea A.
- CPEA-2 (ACM): el módulo de calibración adaptativa con umbral ε_c es el núcleo del pipeline de la Línea B.
- TAGIS-1: los criterios C1, C2, C3 de excepción TAE se operacionalizan sobre señal EEG en la Línea B.
- TAE-F2: la geometría de cusp catastrophe es la base teórica de HC_transfer (transferibilidad de la firma de excepción).

8.2 Documentos que CPEA-3 alimenta

- TAE-E2: CPEA-3 Línea B utiliza los mismos datasets (EEGMMI, DEAP, Temple) y puede reutilizar el pipeline de preprocesamiento de TAE-E2 con modificaciones mínimas.
- INTER-5 (IS-M4): una corroboración de HC_transfer proporcionaría evidencia empírica para el isomorfismo CPEA $\leftrightarrow$ Friston.
- INTER-6 (IS-P4): la Línea C es la instanciación experimental de IS-P4 en el dominio EEG-LLM.
- TAE-AGI-4: el prior de excepción $E(v_{\text{exc}})$ es conceptualmente análogo al operador CFE de TAGIS-FED; una corroboración cruzaría evidencia entre los dos frameworks.
- CPEA-4 (futuro): si HC_transfer se corrobora, CPEA-4 diseñará la arquitectura de co-entrenamiento EEG-LLM en tiempo real.

Referencias Comentadas

Friston, K. (2010). The free-energy principle: a unified brain theory? *Nature Reviews Neuroscience*, 11(2), 127-138. — Marco teórico central de CPEA; la coherencia predictiva de Friston es el referente externo del parámetro de orden Ψ_{neur} .

Goldberger, A.L. et al. (2000). PhysioBank, PhysioToolkit, and PhysioNet. *Circulation*, 101(23). — Infraestructura de datos para las Líneas B y C; acceso libre sin conflictos de interés institucionales.

Bandt, C. & Pompe, B. (2002). Permutation Entropy: A Natural Complexity Measure for Time Series. *Physical Review Letters*, 88(17). — Métrica C2 del pipeline CPEA; sin conflictos de interés.

Killick, R., Fearnhead, P. & Eckley, I.A. (2012). Optimal Detection of Changepoints with a Linear Computational Cost. *Journal of the American Statistical Association*. — Algoritmo PELT utilizado en el paso 3 del pipeline; implementación pública en el paquete R changepoint y Python ruptures.

Kowalczyk, M. et al. (2015). DEAP: A Database for Emotion Analysis using Physiological Signals. IEEE Transactions on Affective Computing. — Dataset primario para la Línea B en el dominio emocional; acceso mediante solicitud sin coste.

Obeid, I. & Picone, J. (2016). The Temple University Hospital EEG Data Corpus. Frontiers in Neuroscience. — Dataset clínico de alta heterogeneidad para validación externa en la Línea B; acceso libre bajo licencia Creative Commons.

Radford, A. et al. (2019). Language Models are Unsupervised Multitask Learners (GPT-2). OpenAI Blog. — Modelo de lenguaje base para la Línea C; pesos disponibles en HuggingFace sin restricciones de uso académico.

Larson-Prior, L.J. et al. (2013). Adding dynamics to the Human Connectome Project with MEG. NeuroImage. — Referencia para estándares de adquisición y preprocesamiento EEG/MEG aplicables a la Línea A.

Gramfort, A. et al. (2013). MEG and EEG data analysis with MNE-Python. Frontiers in Neuroscience. — Framework de análisis utilizado en el pipeline de todas las líneas; código abierto, sin conflictos de interés.