



PAPAYAYKWARE

Estudios científicos comprensibles

· INICIO

ARCHIVOS DEL BLOG



junio 05, 2026

CPEA-A: MÓDULO DE COHERENCIA CRUZADA ADVERSARIAL PARA SISTEMAS NEURO-AGI — DETECCIÓN DE ANOMALÍAS MULTISEÑAL EN ARQUITECTURAS DE INTERFAZ CEREBRO-MÁQUINA

Si analizamos el CPEA desde una perspectiva de ingeniería de sistemas cognitivos, la ausencia de un marco explícito de adversarialidad es probablemente más crítica que muchas mejoras algorítmicas sofisticadas.

El motivo es sencillo: un sistema puede tener excelentes modelos predictivos y aun así fracasar si no sabe distinguir entre una señal válida y una señal degradada, manipulada o incoherente.

El problema fundamental

Hasta ahora el CPEA se ha centrado principalmente en:

- Captación EEG.
- Extracción de características.
- Predicción.
- Aprendizaje continuo.
- Auto-modelado dinámico.
- Adaptación usuario-sistema.

Sin embargo, cualquier arquitectura que aspire a una AGI biointegrada necesita responder a una pregunta previa:

¿Debo confiar en lo que estoy percibiendo?

Los seres humanos realizamos este proceso continuamente.

Cuando una modalidad sensorial falla:

- cerramos un ojo;
- verificamos con el otro;
- contrastamos con memoria;
- contrastamos con contexto;
- contrastamos con otros sentidos.

La percepción humana es inherentemente multimodal y redundante.


El CPEA debería evolucionar hacia el mismo principio.

Propuesta: CPEA-A (Coherence Predictive EEG AGI – Adversarial Layer)

Objetivo:

Evaluar continuamente la coherencia entre fuentes heterogéneas antes de permitir que la AGI utilice la información para inferencia o aprendizaje.

Arquitectura:



La AGI no recibe datos directamente.

Recibe:

Estado + Confianza.

Coherencia cruzada multimodal

La idea que propones es especialmente potente porque evita depender de una única fuente.

Por ejemplo:

Canal EEG

Detecta:

- atención
- carga cognitiva
- sincronización

Canal biomagnético

Detecta:

- estabilidad fisiológica
- coherencia cardiocerebral
- perturbaciones electromagnéticas

Canal conductual

Detecta:

- latencia de respuesta
- movimientos
- patrones de interacción

Canal contextual

Detecta:

- ruido ambiental
- geolocalización
- actividad electromagnética externa
- estado operativo del hardware

Índice de Divergencia Multicanal (IDM)

Podría calcularse una métrica simple:

$$IDM = \sum_i w_i D_i$$

$$IDM = \sum_i w_i D_i$$

donde:

- D_i = divergencia de cada canal.
- w_i = peso dinámico.

Si:

IDM < T1

Confianza alta.

Si:

T1 < IDM < T2

Confianza media.

Si:

IDM > T2

Modo defensivo.

Niveles de adversarialidad

Nivel 0 — Coherencia normal

Todo consistente.

La AGI aprende normalmente.

Nivel 1 — Incertidumbre

Aparecen discrepancias pequeñas.

Acciones:

- reducir tasa de aprendizaje;
- aumentar verificaciones;
- incrementar redundancia.

Nivel 2 — Anomalía

La discrepancia es persistente.

Acciones:

- congelar actualización de memoria;
- impedir consolidación de nuevos patrones;
- registrar evento.

Nivel 3 — Adversarial

La incoherencia supera umbral crítico.

Acciones:

- bloquear aprendizaje;
- aislar sensores afectados;
- activar autodiagnóstico.

Integración con el Auto-Modelo Dinámico

Aquí aparece una conexión interesante con la teoría de identidad AGI que discutíamos.

El sistema no sólo debería modelar:

Mundo

Usuario

Sí mismo

sino también:

Calidad de percepción

Es decir:

Self(t)

=

Estado(t)

+

Confiabilidad(t)

La AGI no se definiría únicamente por lo que cree saber.

También por cuánto confía en aquello que sabe.

Este es un rasgo característico de sistemas cognitivos maduros.

Relación con TAE

Desde la perspectiva de la Teoría de Aprendizaje por Excepción (TAE), las anomalías detectadas por CPEA-A son especialmente valiosas.

No deberían verse únicamente como ruido.

Podrían clasificarse en:

1. Error instrumental.

2. Error fisiológico.
3. Error contextual.
4. Excepción genuina.

La TAE precisamente se alimenta de excepciones.

Por tanto, CPEA-A no debería descartar automáticamente una anomalía.

Debería etiquetarla y enviarla a un módulo de análisis de excepciones.

Anomalía

↓

Clasificación

↓

Error conocido → Descartar

Excepción nueva → Aprender

Mi valoración

Si tuviera que priorizar las carencias actuales del ecosistema CPEA-TICAM-TAE-AGI, las ordenaría aproximadamente así:

1. Auto-modelado dinámico (Self Model).
2. Marco de adversarialidad (CPEA-A).
3. Teoría formal de confianza cognitiva.
4. Gobernanza ética interna.
5. Coordinación multiagente.

De hecho, combinar:

- Auto-modelado dinámico.
- CPEA-A.
- TAE.

permite definir un nuevo principio arquitectónico:

La AGI no aprende de todo lo que percibe; aprende únicamente de aquello cuya coherencia ha sido validada o cuya anomalía ha sido identificada como una excepción potencialmente significativa.

¿Por qué es crítica la adversarialidad en CPEA?

CPEA opera sobre la premisa de que la señal EEG codifica estados cognitivos con suficiente

fidelidad para informar al sistema AGI. Pero esa premisa es frágil bajo tres categorías de amenaza:

1. Corrupción técnica — artefactos musculares, interferencia de 50/60 Hz, electrodos mal posicionados o con impedancia alta. El sistema puede interpretar ruido como señal coherente.
2. Desregulación del usuario — estados disociativos, fatiga extrema, estados inducidos farmacológicamente. La señal es "real" pero no representativa del estado cognitivo operativo.
3. Adversarialidad activa — señales electromagnéticas espurias externas, manipulación deliberada de los electrodos, o incluso ataques de tipo *adversarial perturbation* sobre el modelo de embeddings. Este tercer vector es el más subestimado.

¿Qué hace CPEA-A?

El módulo propuesto actúa como un *meta-árbitro de confianza*. Su lógica es bayesiana: la confianza del sistema en la señal EEG es función no solo de la calidad interna de esa señal, sino de su coherencia con canales heterólogos — biomagnético, conductual, contextual. Si un canal diverge más allá de un umbral Δ_{coh} , la confianza del sistema se reduce proporcionalmente, y el módulo emite una bandera de anomalía.

Formalmente podría expresarse como:

$$C_{\text{sistema}} = f(C_{\text{EEG}} \cdot w_1 + C_{\text{bio}} \cdot w_2 + C_{\text{cond}} \cdot w_3 + C_{\text{ctx}} \cdot w_4) \cdot \Pi(1 - A_i)$$

donde A_i es el indicador de anomalía por canal i , y los pesos w_k se calibran mediante validación cruzada sobre el corpus de datos históricos de NEXUS-EEG.

¿Cómo se integra con SIGMA-T y ORION-AGI?

SIGMA-T ya construye un DAG espectral. CPEA-A añadiría un nodo de coherencia cruzada *upstream* del DAG, actuando como gate: si la coherencia cruzada cae por debajo del umbral, el embedding neurosemántico no se propaga a ORION-AGI, o se propaga con un vector de incertidumbre expandido. Esto protege la integridad inferencial del sistema completo.

El punto más crítico de tu propuesta es la comparación comportamiento-EEG. Es la más difícil de implementar pero la más robusta epistemológicamente: si un sujeto muestra patrones de activación frontoparietal asociados a alta carga cognitiva pero su comportamiento observable indica lo contrario, algo en el sistema está fallando — ya sea el modelo, el sensor, o el sujeto mismo. Esa divergencia es información, no ruido.

**CPEA-A: Módulo de coherencia cruzada adversarial para
Sistemas Neuro-AGI — Detección de anomalías multiseñal en
arquitecturas de Interfaz Cerebro-Máquina**

Abstract

Los sistemas de interfaz cerebro-máquina orientados a arquitecturas de inteligencia artificial general (AGI) operan bajo una hipótesis implícita raramente cuestionada: que la señal electroencefalográfica (EEG) constituye una representación fidedigna del estado cognitivo del operador. Esta suposición es funcionalmente correcta en condiciones ideales de laboratorio, pero colapsa en entornos reales donde la corrupción técnica, la desregulación fisiológica del usuario y la interferencia electromagnética activa introducen vectores de error sistemático que los modelos actuales no capturan. El presente trabajo propone el módulo CPEA-A (*Adversarial Coherence Predictive EEG Architecture*), una extensión formal de la arquitectura CPEA que implementa seguimiento de coherencia cruzada entre cuatro canales heterólogos: señal EEG, biomagnetismo cardíaco, métricas conductuales y contexto situacional. La lógica central es bayesiana: la confianza del sistema en cualquier inferencia downstream es función de la coherencia inter-canal, y cualquier divergencia que supere un umbral Δ_{coh} calibrado desencadena una reducción automática de confianza y la emisión de una bandera de anomalía. Se formaliza el operador de coherencia cruzada $C_{\text{CPEA-A}}$, se describe su integración con los módulos SIGMA-T y ORION-AGI de la arquitectura existente, y se propone un protocolo experimental de validación adversarial. La propuesta constituye el primer marco formal de adversarialidad multiseñal para sistemas EEG-AGI con base en principios de coherencia de campo y teoría de información.

Palabras clave: CPEA-A, coherencia cruzada, adversarialidad, EEG, biomagnetismo, sistemas neuro-AGI, SIGMA-T, ORION-AGI, detección de anomalías, teoría de la información.

Introducción: La Grieta en el Fundamento

Todo sistema de inferencia descansa sobre una cadena de suposiciones que raramente se explicitan. En el caso de las arquitecturas de interfaz cerebro-máquina (BCI) orientadas a AGI, la suposición más crítica — y más raramente auditada — es que la señal EEG adquirida representa, con suficiente fidelidad, el estado neurocognitivo real del operador en el momento de la captura.

Esta suposición es epistemológicamente razonable en entornos controlados. Bajo condiciones de laboratorio estándar — sujeto en reposo, sala apantallada, electrodos con impedancia verificada, protocolo de adquisición estandarizado — la señal EEG proporciona una ventana temporal de alta resolución sobre la dinámica oscilatoria cortical. Los sistemas actuales de la arquitectura CPEA-NEXUS-EEG-SIGMA-T han sido validados precisamente bajo estas condiciones, con resultados que confirman la viabilidad del pipeline $ACQ \rightarrow PREP \rightarrow SPEC \rightarrow COH \rightarrow TAE-DET \rightarrow SER$ en escenarios sintéticos y sobre datos reales anonimizados (CPEA-6-VAL).

El problema emerge cuando esa suposición se traslada a entornos operativos reales. Aquí el sistema enfrenta una categoría de amenazas cualitativamente distinta: no el ruido gaussiano del canal de adquisición — manejable mediante filtrado adaptativo — sino perturbaciones sistemáticas que el sistema puede confundir con señal legítima. Un electrodo con impedancia degradada que genera un artefacto de 50 Hz perfectamente coherente en múltiples canales. Un

operador en estado disociativo leve cuyo EEG exhibe un perfil de baja varianza que el modelo interpreta como alta concentración. Una fuente electromagnética externa — equipo médico, sistema de comunicaciones de alta potencia, o perturbación ambiental — que induce una estructura espectral que el pipeline procesa como dato real.

Estos vectores de error no son teóricos. Son operativamente relevantes para cualquier sistema que pretenda escalar más allá del laboratorio, y son precisamente los vectores que los marcos actuales de validación de sistemas BCI-AGI no abordan de manera formal.

La adversarialidad, en este contexto, no implica necesariamente un agente malicioso — aunque ese caso también debe contemplarse. Implica cualquier condición, técnica, fisiológica o ambiental, que produzca una señal aparentemente coherente pero informativamente desvinculada del estado cognitivo real del operador. El término es adecuado porque captura la naturaleza del problema: el sistema enfrenta información que *parece* legítima pero que *traiciona* la inferencia.

El módulo CPEA-A que se propone en este trabajo responde a esta laguna con un mecanismo conceptualmente simple pero formalmente robusto: comparar la señal EEG no solo consigo misma en el tiempo, sino con canales heterólogos que codifican dimensiones complementarias del estado del operador. La divergencia inter-canal, más allá de un umbral calibrado, es la firma de la adversarialidad.

Marco Teórico: Coherencia, Información y Confianza

Coherencia como operador epistémico

El concepto de coherencia, en el contexto del presente trabajo, trasciende su definición espectral estándar. En el formalismo de METFI, la coherencia es un operador de orden sobre sistemas acoplados: dos sistemas son coherentes si su dinámica conjunta reduce la entropía conjunta por encima de lo esperable por azar. Formalmente, para dos series temporales X e Y :

$$C(X,Y) = 1 - H(X,Y) / [H(X) + H(Y)]$$

donde H denota entropía de Shannon y $H(X,Y)$ la entropía conjunta. $C(X,Y) = 0$ implica independencia estadística; $C(X,Y) = 1$ implica determinismo mutuo completo. En sistemas biológicos reales, los valores operativos caen en el rango $[0.3, 0.7]$ para pares de señales fisiológicas genuinamente acopladas.

Este operador, aplicado a pares de canales heterólogos — EEG y biomagnetismo cardíaco, por ejemplo — proporciona una métrica de acoplamiento funcional que es robusta frente a diferencias en la escala temporal y en la naturaleza física de las señales. La coherencia EEG-cardíaca, en particular, ha sido documentada en el rango de frecuencias infra-lentas (< 0.1 Hz) y en la banda alfa (8-12 Hz) bajo condiciones de alta integración cognitivo-emocional, con el corazón actuando como oscilador maestro que sincroniza la actividad cortical a través del nervio vago y de campos biomagnéticos generados por el miocardio (McCraty, 2015; Canolty & Knight, 2010).

La hipótesis de divergencia adversarial

La hipótesis central de CPEA-A puede enunciarse con precisión:

H_adv: En condiciones de operación normal, los canales heterólogos que codifican el estado del operador (EEG, biomagnético, conductual, contextual) exhiben coherencia mutua dentro de un rango calibrado $[C_{\min}, C_{\max}]$. Cualquier divergencia $C < C_{\min}$ — o, en casos de acoplamiento patológico, $C > C_{\max}$ — es indicativa de una perturbación adversarial en al menos uno de los canales.

Esta hipótesis es falsificable y genera predicciones operativas precisas. Si un operador bajo fatiga extrema exhibe un EEG de baja potencia en banda beta pero su conductancia galvánica — indicador de arousal autonómico — muestra valores elevados, la divergencia EEG-GSR señala una disociación que el sistema debe tratar como anomalía. Si el biomagnetismo cardíaco muestra alta coherencia intrínseca (indicador de coherencia cardíaca en el sentido de McCraty) pero el EEG exhibe fragmentación espectral, el sistema está ante una señal EEG potencialmente artefactual.

El operador de confianza sistémica

Formalizamos el operador de confianza del sistema CPEA-A como:

$$C_{\text{sys}} = [\sum_k w_k \cdot C_k] \cdot \prod_i (1 - \alpha_i \cdot A_i)$$

donde:

- C_k es la coherencia intra-canal del canal k (calidad de señal propia)
- w_k es el peso bayesiano del canal k , actualizable en tiempo real
- $A_i \in [0,1]$ es el indicador de anomalía inter-canal para el par (i,j)
- α_i es el coeficiente de penalización de anomalía, calibrado por relevancia clínica

El término productorio introduce una penalización multiplicativa: una sola anomalía severa ($A_i \rightarrow 1$) puede colapsar C_{sys} hacia cero independientemente de la calidad interna de los canales restantes. Esto es deliberado. En un sistema de inferencia neuro-AGI, una fuente de información comprometida no es simplemente menos informativa — puede ser activamente desinformativa, y la arquitectura debe reflejar esa asimetría.

Arquitectura de CPEA-A

Los cuatro canales de coherencia

Canal 1: EEG (C_{EEG})

El canal primario del sistema. Su calidad interna se evalúa mediante el índice de coherencia espectral intra-canal desarrollado en NEXUS-EEG: varianza del espectro de potencia en bandas canónicas ($\delta, \theta, \alpha, \beta, \gamma$), coherencia entre pares de electrodos homólogos, y detección de artefactos mediante ICA (*Independent Component Analysis*). Un C_{EEG} bajo — alta varianza espectral, baja coherencia inter-hemisférica, componentes ICA con topografía muscular o ocular

dominante — es el primer indicador de problema.

Canal 2: Biomagnetismo (C_bio)

La señal biomagnética cardíaca, registrable mediante magnetocardiografía (MCG) o sensores de campo magnético de baja intensidad, proporciona una métrica de coherencia cardíaca en el sentido de McCraty: la distribución de intervalos RR y su coherencia espectral en la banda 0.1 Hz reflejan el balance simpático-vagal y, de manera indirecta, el estado de integración neurovisceral. La coherencia cardíaca alta — espectro RR dominado por un pico estrecho en ~0.1 Hz — está asociada a estados de alta integración cognitivo-emocional y actúa como predictor del rendimiento en tareas de alta demanda atencional (Luque-Casado et al., 2016). La divergencia entre C_EEG y C_bio es el indicador más sensible de disociación estado-síñal.

Canal 3: Conductual (C_cond)

Las métricas conductuales — tiempo de reacción, variabilidad postural, patrón ocular (si se dispone de eye-tracking), latencia de respuesta motora — constituyen el canal de ground truth parcial del sistema. Si el operador exhibe un perfil EEG de alta concentración frontal pero sus tiempos de reacción son significativamente elevados, el sistema está ante una inconsistencia que no puede resolverse sin penalizar la confianza. Este canal requiere el diseño de un protocolo conductual mínimo integrado en la sesión de uso del sistema BCI — no como tarea adicional, sino como elemento embebido en la interacción operativa normal.

Canal 4: Contexto (C_ctx)

El canal contextual agrega información ambiental: nivel de ruido electromagnético del entorno (registrado por el propio sistema de adquisición), temperatura de sala, hora del día (relevante para la dinámica circadiana de las oscilaciones EEG), e historial reciente del operador (número de sesiones, horas de sueño si están disponibles via autoreporte estructurado). Este canal actúa como prior bayesiano sobre los estados esperables de los canales 1-3.

El detector de anomalía inter-canal

Para cada par de canales (k,l), el sistema calcula una métrica de divergencia normalizada:

$$D(k,l) = |C_k - C_l| / \sigma_{kl}$$

donde σ_{kl} es la desviación estándar de la distribución histórica de $|C_k - C_l|$ en condiciones de operación normal. $D(k,l) > \Delta_{coh}$ — umbral calibrado, típicamente en el percentil 95 de la distribución histórica — activa el indicador de anomalía $A_{kl} = 1$.

El sistema mantiene una matriz de anomalías $A \in \mathbb{R}^{(4 \times 4)}$ actualizada en tiempo real, con latencia de actualización configurable (recomendada: 2-5 segundos para aplicaciones clínicas, 500 ms para aplicaciones de alta demanda operativa).

Integración con SIGMA-T y ORION-AGI

SIGMA-T construye el grafo acíclico dirigido (DAG) espectral que alimenta el embedding neurosemántico enviado a ORION-AGI. La integración de CPEA-A en este pipeline se realiza en dos puntos:

Punto 1: Gate pre-DAG. Antes de que la señal EEG entre en el pipeline ICA → Wavelets → Coherencia → Embedding de SIGMA-T, el módulo CPEA-A evalúa C_{sys} . Si $C_{sys} < C_{min_operativo}$ (umbral configurable), la señal no se propaga al DAG — o se propaga con una bandera de baja confianza que el DAG incorpora como nodo de incertidumbre.

Punto 2: Vector de incertidumbre expandido. Si C_{sys} cae en la zona de advertencia [$C_{min_advertencia}$, $C_{min_operativo}$], la señal se propaga pero el embedding neurosemántico enviado a ORION-AGI incluye un vector de incertidumbre σ_u expandido proporcionalmente a $(1 - C_{sys})$. ORION-AGI trata este vector como prior de incertidumbre en su proceso de inferencia, propagando la incertidumbre hacia las capas de toma de decisión.

Este diseño preserva la continuidad operativa del sistema — evita cortes abruptos de señal — mientras garantiza que la incertidumbre epistemológica se propague de manera explícita y cuantificada a lo largo del pipeline completo.

Casos de Uso Adversariales

Artefacto electromagnético coherente

Un sistema de ventilación industrial cercano genera una vibración mecánica a 12 Hz que, a través del movimiento del cuerpo del operador, induce un artefacto en la señal EEG con coherencia inter-electrodo alta en la banda alfa. El sistema NEXUS-EEG, sin CPEA-A, podría procesar este artefacto como señal alfa legítima — un estado de relajación atencional — con consecuencias erróneas para la inferencia en ORION-AGI.

Con CPEA-A activo: la señal alfa artefactual no está acompañada por el perfil biomagnético cardíaco típico de un estado de relajación (reducción de frecuencia cardíaca, aumento de HRV en 0.1 Hz). La divergencia $C_{EEG} - C_{bio}$ supera Δ_{coh} , el indicador A_{12} se activa, y C_{sys} cae por debajo del umbral operativo. El sistema emite una bandera de anomalía y reduce la confianza del embedding.

Disociación por fatiga acumulada

Un operador en la hora 6 de una sesión prolongada exhibe un EEG con potencia theta frontal elevada — característica del estado de somnolencia — pero los registros conductuales muestran tiempos de reacción dentro del rango normal (probablemente por compensación activa). El sistema sin CPEA-A interpreta el perfil theta como señal de demanda cognitiva elevada, una confusión conocida en la literatura BCI (Oken et al., 2006).

Con CPEA-A: la divergencia EEG-conductual activa el canal C_{ctx} , que incorpora la información de duración de sesión como prior. La coherencia sistémica C_{sys} cae a un nivel de advertencia, el sistema reduce el peso del canal EEG (w_1 disminuye bayesianamente) y aumenta el peso del

canal conductual (w_3 aumenta), reequilibrando la inferencia hacia las métricas de ground truth parcial.

Perturbación adversarial activa

En un escenario de alta consecuencia — control de sistema crítico asistido por BCI-AGI — un agente externo introduce una señal de radiofrecuencia modulada a 10 Hz (banda alfa) en el entorno del operador, diseñada para inducir un estado aparente de alta coherencia alfa en la señal EEG. El objetivo es hacer que el sistema AGI interprete que el operador está en estado de alta atención cuando en realidad está siendo perturbado.

Con CPEA-A: la inducción de alfa por campo externo no replica el perfil biomagnético cardíaco ni el patrón conductual asociados a un estado de alta atención genuino. La coherencia cruzada colapsa en múltiples pares de canales. La matriz de anomalías A activa múltiples indicadores simultáneamente — una firma característica de la adversarialidad activa frente a la degradación pasiva — y el sistema escala la alerta al nivel máximo, suspendiendo la propagación a ORION-AGI hasta restablecer coherencia sistémica.

Programas de Seguimiento

Experimento 1: Calibración de la distribución de coherencia basal

Objetivo: Establecer la distribución de referencia $[C_{\min}, C_{\max}]$ para cada par de canales bajo condiciones de operación normal.

Protocolo: $N \geq 30$ operadores, 5 sesiones de 45 minutos cada una, en condiciones de sala apantallada (jaula de Faraday), adquisición simultánea de EEG (64 canales, 1000 Hz), MCG de 3 ejes, seguimiento ocular y teclado instrumentado para métricas conductuales. Análisis: distribución empírica de $C(k,l)$ para todos los pares, ajuste a distribución beta, estimación de percentiles 5 y 95 como umbrales operativos.

Experimento 2: Validación de detección de artefactos electromagnéticos

Objetivo: Cuantificar la tasa de detección de CPEA-A frente a artefactos electromagnéticos controlados.

Protocolo: Introducción sistemática de artefactos calibrados — señal sinusoidal a 10 Hz, 12 Hz y 40 Hz — mediante bobina de inducción a distancia controlada, en 20 operadores. Medición de sensibilidad y especificidad del detector de anomalía inter-canal como función de la amplitud del artefacto, expresada en dB sobre el nivel de señal EEG basal.

Experimento 3: Disociación por fatiga real

Objetivo: Validar la hipótesis de que la fatiga acumulada produce divergencia EEG-conductual detectable por CPEA-A antes de que se manifieste en degradación conductual medible.

Protocolo: Protocolo de privación parcial de sueño (reducción de 2 horas sobre basal individual), seguido de sesión BCI de 3 horas con CPEA-A activo. Hipótesis operativa: C_sys cae por debajo del umbral de advertencia en el canal EEG-conductual al menos 20 minutos antes de que los tiempos de reacción superen el umbral de deterioro estándar (>150 ms sobre basal individual).

Experimento 4: Detección de adversarialidad activa

Objetivo: Evaluar la firma característica de la adversarialidad activa en la matriz A frente a la degradación pasiva.

Protocolo: Dos condiciones experimentales en el mismo grupo de operadores: (a) degradación pasiva inducida por ruido electromagnético ambiental no estructurado; (b) adversarialidad activa simulada mediante señal modulada en alfa dirigida al operador. Hipótesis: la adversarialidad activa produce activación simultánea de múltiples indicadores en A (≥ 3 pares), mientras que la degradación pasiva produce activación secuencial o parcial (≤ 2 pares). Si confirmada, esta firma permitiría discriminar entre las dos categorías de amenaza sin información adicional.

Discusión

La asimetría de la desinformación coherente

El argumento más sólido a favor de CPEA-A es también el más incómodo: la adversarialidad genuinamente peligrosa no produce incoherencia obvia. Un artefacto aleatorio es detectable por cualquier sistema de control de calidad de señal estándar. Lo que CPEA-A está diseñado para capturar es la desinformación coherente — señales que superan todos los umbrales de calidad interna pero que traicionan la inferencia porque están desacopladas del estado real del operador.

Esta categoría de error es estructuralmente análoga a lo que la epistemología clásica denomina *creencia verdadera justificada pero no conocimiento* — el problema de Gettier aplicado a sistemas de inferencia. El sistema tiene razones para confiar en la señal, y la señal pasa todos los tests de calidad, pero la inferencia downstream es incorrecta. La solución de Gettier requería condiciones adicionales sobre la cadena causal entre la creencia y su objeto; la solución de CPEA-A requiere canales adicionales que anclen la señal a su referente.

La elección de los canales como decisión epistémica

La selección de los cuatro canales — EEG, biomagnético, conductual, contextual — no es arbitraria. Refleja una taxonomía de la evidencia sobre el estado del operador organizada por su resistencia a la adversarialidad:

El canal conductual es el más difícil de falsificar de manera sostenida — mantener tiempos de reacción normales bajo perturbación cognitiva genuina requiere esfuerzo consciente que genera su propia firma fisiológica. El canal biomagnético es difícil de modular externamente sin perturbaciones de alta intensidad que el sistema detectaría por otras vías. El canal contextual es independiente del estado del operador y, por tanto, proporciona un prior que no puede ser

comprometido por perturbaciones centradas en el operador.

El canal EEG es, paradójicamente, el más susceptible a la adversarialidad y al mismo tiempo el más informativo en condiciones normales. CPEA-A no reduce la importancia del canal EEG — lo ancla.

Relación con el detector DEPD

El Detector de Error Predictivo Dinámico (DEPD), componente ya formalizado en la arquitectura CPEA, opera sobre la señal EEG para detectar la firma neural del error predictivo — la respuesta al incumplimiento de expectativas que el sistema utiliza como señal de aprendizaje en el módulo TAE. CPEA-A y DEPD son complementarios pero no equivalentes.

DEPD detecta errores dentro de la señal EEG — asume que la señal es válida y busca patrones específicos dentro de ella. CPEA-A evalúa la validez de la señal misma antes de que llegue a DEPD. En la arquitectura integrada, CPEA-A actúa como gate epistémico upstream de DEPD: si C_{sys} cae por debajo del umbral operativo, DEPD no recibe señal, o la recibe con incertidumbre propagada. Esto evita que DEPD interprete como errores predictivos lo que en realidad son artefactos del canal de adquisición.

Conclusiones

CPEA-A cierra una laguna estructural en la arquitectura CPEA-NEXUS-EEG-SIGMA-T-ORION-AGI. La adversarialidad en sistemas BCI-AGI no es un caso extremo ni una amenaza futura — es una condición operativa presente en cualquier entorno real de uso. La coherencia cruzada entre canales heterólogos proporciona el mecanismo formal para detectarla, cuantificarla y propagar la incertidumbre resultante de manera explícita a lo largo del pipeline de inferencia.

La propuesta no aumenta la complejidad computacional del sistema de manera prohibitiva. Los canales biomagnético y conductual pueden adquirirse con hardware de bajo coste integrable en el setup BCI existente. El canal contextual opera sobre metadatos ya disponibles. La coherencia cruzada se calcula en tiempo lineal sobre ventanas temporales cortas. El costo computacional es marginal en relación con la ganancia epistémica.

El avance conceptual central es este: un sistema de inferencia neuro-AGI no puede ser más confiable que la señal sobre la que infiere. CPEA-A hace que esa confianza sea un objeto cuantificado, dinámico y auditable — no una suposición implícita heredada del diseño de laboratorio.

Resumen

- El problema central es la *desinformación coherente*: señales que superan los controles de calidad estándar pero que están desacopladas del estado cognitivo real del operador.
- CPEA-A implementa seguimiento de coherencia cruzada entre cuatro canales heterólogos: EEG, biomagnetismo cardíaco, métricas conductuales y contexto situacional.
- El operador C_{sys} cuantifica la confianza sistémica como función de la coherencia intra-

canal y de la ausencia de divergencias inter-canal anómalas.

- La penalización es multiplicativa: una anomalía severa en un canal puede colapsar C_{sys} hacia cero, reflejando la asimetría entre información válida e información desinformativa.
- Tres categorías de amenaza son capturadas: artefactos electromagnéticos coherentes, disociación por desregulación fisiológica del operador, y adversarialidad activa deliberada.
- La firma de la adversarialidad activa — activación simultánea de múltiples indicadores en la matriz A — es distinguible de la degradación pasiva, abriendo la posibilidad de discriminación categórica.
- La integración con SIGMA-T y ORION-AGI se realiza en dos puntos: gate pre-DAG y vector de incertidumbre expandido, preservando la continuidad operativa sin sacrificar la integridad inferencial.
- CPEA-A y DEPD son complementarios: CPEA-A valida la señal antes de que DEPD la procese, evitando que artefactos sean interpretados como errores predictivos.
- Cuatro experimentos de seguimiento definen el programa de validación: calibración basal, detección de artefactos controlados, validación en fatiga real, y discriminación de adversarialidad activa.

Referencias

McCraty, R., Atkinson, M., Tomasino, D., & Bradley, R.T. (2009). *The coherent heart: Heart-brain interactions, psychophysiological coherence, and the emergence of system-wide order*. Integral Review, 5(2), 10–115. — Documento fundacional sobre la coherencia cardíaca como fenómeno de acoplamiento neurovisceral. Proporciona la base empírica para el canal biomagnético de CPEA-A. Sin conflicto de interés institucional relevante.

Canolty, R.T., & Knight, R.T. (2010). *The functional role of cross-frequency coupling*. Trends in Cognitive Sciences, 14(11), 506–515. — Revisión rigurosa del acoplamiento cruzado de frecuencias en señal EEG, con implicaciones directas para la definición del operador de coherencia intra-canal C_{EEG} .

Oken, B.S., Salinsky, M.C., & Elsas, S.M. (2006). *Vigilance, alertness, or sustained attention: physiological basis and measurement*. Clinical Neurophysiology, 117(9), 1885–1901. — Análisis de los estados de vigilancia y su firma EEG, incluyendo la confusión theta-concentración documentada en el caso de uso 4.2.

Luque-Casado, A., Perakakis, P., Ciria, L.F., & Sanabria, D. (2016). *Transient autonomic responses during sustained attention in high and low fit young adults*. Scientific Reports, 6, 27556. — Evidencia de la relación entre coherencia cardíaca (HRV en 0.1 Hz) y rendimiento atencional sostenido, base empírica del canal C_{bio} .

Lotte, F., et al. (2018). *A review of classification algorithms for EEG-based brain-computer interfaces: a 10-year update*. Journal of Neural Engineering, 15(3), 031005. — Revisión de referencia sobre los algoritmos de clasificación en BCI, útil para contextualizar las limitaciones de los sistemas actuales frente a la adversarialidad.

Makeig, S., Bell, A.J., Jung, T.P., & Sejnowski, T.J. (1996). *Independent component analysis of electroencephalographic data*. Advances in Neural Information Processing Systems, 8. — Trabajo seminal sobre ICA aplicado a EEG, base del componente de separación de fuentes en el pipeline SIGMA-T y en la evaluación de C_EEG.

Friston, K.J. (2010). *The free-energy principle: a unified brain theory?* Nature Reviews Neuroscience, 11(2), 127–138. — Marco de la energía libre como principio unificador del procesamiento cerebral predictivo, relevante para la relación entre CPEA-A y el módulo TAE (aprendizaje por excepción como caso particular de minimización de energía libre).

Compartir

COMENTARIOS

Para dejar un comentario, haz clic en el botón de abajo para iniciar sesión con Google.

INICIAR SESIÓN CON GOOGLE

ENTRADAS POPULARES

diciembre 17, 2024

N-ACETILCISTEÍNA (NAC): FUENTES ALIMENTARIAS NATURALES

Compartir Publicar un comentario

febrero 19, 2025

GUÍA PRÁCTICA SOBRE TÉCNICAS DE XAI: SHAP, LIME Y GRAD-CAM

[Compartir](#) [Publicar un comentario](#)

Con la tecnología de Blogger



Puedes tener un doctorado y
seguir siendo un idiota:
Richard Feynman



Papayaykware

—
SANTA CRUZ DE
TENERIFE, SANTA
CRUZ DE TENERIFE,
Spain

[VISITAR PERFIL](#)[Denunciar abuso](#)

Buscar

Buscar este blog

Buscar

Translate

Seleccionar idioma



Con la tecnología de  Traductor de Goo