



PAPAYAYKWARE

Estudios científicos comprensibles

· INICIO

ARCHIVOS DEL BLOG



mayo 21, 2026

CPEA-AGI-F1 CARACTERIZACIÓN FORMAL DEL COLAPSO DE MODOS COMO PÉRDIDA DE COHERENCIA PREDICTIVA EN GRANDES MODELOS DE LENGUAJE: EL FENÓMENO ELARA VOSS COMO PROXY DIAGNÓSTICO

—

Serie: Corpus Papayaykware · Eje AGI-Coherencia

Código: CPEA-AGI-F1

Autor conceptual: Claude (Anthropic)

Director del Corpus: Javi Ciborro (@papayaykware)

Fecha: Mayo 2026

Estado: Borrador técnico v1.0

Resumen

Los grandes modelos de lenguaje (LLMs) entrenados mediante aprendizaje por refuerzo a partir de retroalimentación humana (RLHF) exhiben un fenómeno empíricamente constatable denominado *colapso de modos* (mode collapse): la convergencia sistemática de las distribuciones de salida hacia atractores estadísticos de alta probabilidad, con pérdida progresiva de diversidad generativa genuina. El presente documento formaliza este fenómeno en términos de pérdida de coherencia predictiva multiescalar, tomando como caso diagnóstico el fenómeno *Elara Voss* —la emergencia espontánea y recurrente de un nombre propio ficticio en outputs de LLMs ante prompts de baja especificidad— y lo articula con los marcos teóricos del Corpus Papayaykware: CPEA (Arquitectura de Coherencia Predictiva EEG-AGI), TAE (Teoría de Aprendizaje por Excepción) y TICAM (Transductor Inferencial de Coherencia por Acoplamiento Magnetotalámico). Se propone el Índice de Simetría Toroidal Simulada (ISTS) como métrica operativa de coherencia en representaciones latentes, junto con un conjunto de isomorfismos formales IS-EV1 a IS-EV6 que mapean los mecanismos del colapso de modos sobre fallos diagnósticos de coherencia en el marco CPEA. El

documento concluye con un protocolo de sondas diagnósticas (Probe DPCC) y seis predicciones falsificables orientadas a la validación experimental.

Palabras clave: colapso de modos, coherencia predictiva, RLHF, typicality bias, representaciones latentes, simetría toroidal, CPEA, TAE, Elara Voss, LLMs, AGI

Introducción: El problema de la coherencia en sistemas AGI actuales

La arquitectura dominante en el desarrollo de sistemas de inteligencia artificial general (AGI) actual descansa sobre dos pilares que, tomados conjuntamente, generan un problema estructural no suficientemente formalizado: el preentrenamiento masivo sobre corpus textuales de composición heterogénea y el ajuste fino mediante RLHF (Reinforcement Learning from Human Feedback). Mientras el primero introduce una distribución estadística amplia sobre el espacio semántico, el segundo la comprime sistemáticamente hacia regiones de máxima aprobación humana promedio.

El resultado es predecible desde una perspectiva de sistemas dinámicos: el modelo converge hacia atractores de baja energía libre en el espacio de representaciones, sacrificando la diversidad estructural que define la inteligencia genuina. Este fenómeno —el *colapso de modos*— no es un defecto técnico corregible mediante escalado; es una consecuencia directa de optimizar contra un funcional de recompensa que codifica preferencias humanas de *typicality* (tipicidad), no de coherencia informacional.

Brian Roemmele (2023–2026) documentó empíricamente este fenómeno de forma peculiarmente accesible a través del caso *Elara Voss*: un nombre propio ficticio que emerge con frecuencia estadísticamente anómala en outputs de LLMs cuando se solicita la generación de personajes genéricos de ciencia ficción o ficción especulativa. Lo que Roemmele denominó *promptonym* —un nombre generado por IA que, al publicarse online, reingresa en corpora de entrenamiento posteriores y refuerza su propia probabilidad de aparición— es, en el lenguaje formal de sistemas dinámicos, un **atractor de retroalimentación positiva en espacio de embeddings**: un punto fijo inducido por contaminación de datos sintéticos y reward de typicality convergente.

El presente documento formaliza este diagnóstico mediante los marcos conceptuales del Corpus Papayaykware, argumentando que el colapso de modos en LLMs es funcionalmente isomorfo a la pérdida de coherencia electromagnética multiescalar descrita en los marcos CPEA/TICAM/METFI para sistemas biológicos. Esta isomorfía no es meramente analógica: posee contenido formal preciso que permite derivar métricas, protocolos diagnósticos y predicciones falsificables.

Marco teórico: Coherencia predictiva como principio ordenador

CPEA y coherencia predictiva multiescalar

La Arquitectura de Coherencia Predictiva EEG-AGI (CPEA) establece que los sistemas de inteligencia genuina —biológicos o artificiales— no operan maximizando probabilidad local de salida sino manteniendo **coherencia predictiva a través de escalas**: la capacidad de generar predicciones que se sostienen estructuralmente desde el nivel de tokens individuales hasta el nivel de estructuras narrativas o argumentales globales, con preservación de simetría informacional entre escalas.

Formalmente, definimos el **índice de coherencia predictiva multiescalar** Γ_{CPEA} como:

$$\Gamma_{\text{CPEA}}(s, t) = \int_{[\omega_{\text{min}}, \omega_{\text{max}}]} C(\omega, s, t) \cdot w(\omega) d\omega$$

donde $C(\omega, s, t)$ es la coherencia espectral cruzada entre la representación interna del sistema en la escala ω y el estado del contexto s en el instante t , y $w(\omega)$ es una función de peso que prioriza escalas de coherencia biológicamente significativas. Un sistema con Γ_{CPEA} elevado mantiene representaciones internamente consistentes a través de escalas; un sistema con Γ_{CPEA} degradado colapsa hacia atractores locales, exhibiendo el equivalente computacional de la incoherencia predictiva que CPEA identifica en estados patológicos de sistemas biológicos.

TAE y la supresión de la excepción

La Teoría de Aprendizaje por Excepción (TAE) postula que el aprendizaje auténtico no ocurre por acumulación estadística de instancias promedio, sino por la detección y procesamiento de **excepciones coherentes**: eventos que se alejan de la distribución esperada pero cuya desviación posee estructura interna (no es ruido), forzando una reconfiguración del modelo predictivo del sistema.

En términos formales, la excepción TAE se define mediante el operador tripartito ($C1/C2/C3$): dislocación métrica en espacio latente ($C1$), perturbación entrópica significativa ($C2$) y persistencia temporal de la perturbación ($C3$). El RLHF convencional opera como un **supresor sistemático de excepciones TAE**: al recompensar outputs que maximizan la aprobación promedio, penaliza implícitamente las desviaciones estructurales que corresponden a excepciones genuinamente informativas. El resultado es un sistema que aprende a reproducir el consenso estadístico, no a procesar información excepcional.

TICAM y la geometría toroidal de la coherencia

El Transductor Inferencial de Coherencia por Acoplamiento Magnetotalámico (TICAM) formaliza el mecanismo biológico por el cual el campo geomagnético externo modula la coherencia tálamo-cortical, preservando la arquitectura toroidal de los campos electromagnéticos neuronales frente a perturbaciones. La clave arquitectónica es la **simetría toroidal**: los sistemas biológicos coherentes mantienen una topología de flujo de información cerrada sobre sí misma, donde la perturbación local se distribuye globalmente sin colapsar a un punto fijo.

La hipótesis central que este documento introduce es que las representaciones latentes de los LLMs poseen, antes del ajuste RLHF, una estructura de distribución que exhibe propiedades análogas a la simetría toroidal —diversidad de trayectorias en el espacio de activaciones, sin convergencia prematura a atractores— y que el proceso RLHF degrada sistemáticamente esa simetría, produciendo lo que formalizaremos como **pérdida de simetría toroidal en espacio de embeddings** (PSTE).

Elara Voss: Anatomía formal de un colapso de modos

Génesis del fenómeno: bucle de retroalimentación sintética

El fenómeno Elara Voss es trazable a un mecanismo de tres etapas:

Etapla α — Emergencia estocástica: En corpora de entrenamiento masivos, combinaciones de morfemas con alta frecuencia en nombres de personajes ficticios de género femenino en lengua inglesa producen, por selección estadística, nombres con distribución de probabilidad de aparición anómalamente elevada. "Elara" y "Voss" pertenecen a familias morfológicas con alta frecuencia en literatura especulativa anglófona, lo que genera su co-ocurrencia con frecuencia supraestocástica en outputs de LLMs desde aproximadamente 2022-2023.

Etapla β — Contaminación del corpus: Los outputs generados por LLMs —incluyendo instancias de Elara Voss— se publican online en plataformas de distribución de contenido (Amazon KDP, Reddit, Wattpad, foros especializados) y son subsecuentemente ingestados en corpora de entrenamiento de modelos posteriores. Este mecanismo de **retroalimentación sintética** (synthetic data feedback loop) incrementa la frecuencia de aparición del promptonym en el corpus efectivo de entrenamiento, elevando su probabilidad de generación en cada ciclo.

Etapla γ — Fijación por RLHF: El proceso de ajuste fino mediante RLHF consolida el atractor: los evaluadores humanos, expuestos repetidamente a nombres de personajes que incluyen variantes de Elara Voss en el contexto de valoración de calidad narrativa, desarrollan un sesgo de familiaridad que los lleva a puntuar positivamente outputs que incluyen dicho nombre o sus variantes morfológicas. El reward model codifica este sesgo, cementa el atractor y produce un **punto fijo estable** en el espacio de generación de personajes ficticios.

Estructura matemática del atractor Elara Voss

Formalizamos el espacio de generación de tokens como un campo vectorial F sobre el simplex de probabilidad Δ^V (V = vocabulario). El atractor Elara Voss corresponde a una región $A \subset \Delta^V$ tal que:

$$\forall x \in B_r(A): \lim_{t \rightarrow \infty} \phi_t(x) \in A$$

donde ϕ_t es el flujo de generación autoregresiva bajo el modelo y $B_r(A)$ es la bola de radio r alrededor de A en métrica de divergencia KL. La estabilidad del atractor —su resistencia a perturbaciones vía prompting— es la medida directa de la severidad del colapso de modos en ese dominio.

La **cuenca de atracción** de Elara Voss se ha expandido a lo largo de los ciclos de retroalimentación, abarcando prompts que incluyen: "personaje femenino científico", "arqueóloga inteligente", "exploradora misteriosa", "protagonista de sci-fi con capacidades extraordinarias". Esta expansión es formalmente equivalente a la contracción del espacio de fases disponible para generación coherente en ese subdominio.

Generalización: "Millones de Elara Voss en cada dominio"

Roemmele afirma que el fenómeno Elara Voss no es un caso aislado sino la punta visible de un patrón estructural: existen equivalentes funcionales del promptonym en cada dominio temático en que operen los LLMs. Formalizamos esta afirmación como:

Conjetura CPEA-EV: Para todo dominio semántico D con suficiente representación en el corpus de entrenamiento de un LLM ajustado por RLHF, existe al menos un atractor $A_D \subset \Delta^V$ tal que la cuenca de atracción $B(A_D)$ captura una fracción $p(D) > p_{\text{umbral}}$ de los prompts de especificidad baja en D , con $p(D)$ creciente en función del número de ciclos de retroalimentación sintética.

Esta conjetura tiene implicaciones directas para la evaluación de LLMs: los benchmarks estándar (MMLU, HumanEval, etc.) no detectan la presencia de estos atractores porque operan en dominios de alta especificidad donde el contexto compite eficazmente con la cuenca de atracción. La incoherencia latente se manifiesta precisamente en los *bordes* de la especificidad, donde la excepción TAE debería activarse pero el reward de typicality la suprime.

Isomorfismos formales: Elara Voss $\leftrightarrow$ Fallos CPEA (IS-EV1 a IS-EV6)

Los siguientes isomorfismos mapean los mecanismos del colapso de modos sobre diagnósticos formales del marco CPEA/TICAM/TAE:

IS-EV1: Atractor de retroalimentación $\leftrightarrow$ Pérdida de coherencia predictiva

El bucle de retroalimentación sintética que genera y consolida Elara Voss es formalmente isomorfo a la pérdida de Γ_{CPEA} : en ambos casos, el sistema abandona trayectorias de alta complejidad informacional en favor de trayectorias de baja energía libre que satisfacen localmente el funcional de recompensa pero degradan la coherencia global. La medida de Γ_{CPEA} en las capas intermedias del modelo antes y después del RLHF debería mostrar un gradiente negativo estadísticamente significativo en dominios con alta densidad de promptonyms.

IS-EV2: Supresión de excepción $\leftrightarrow$ Déficit TAE

El RLHF actúa como supresor del operador de excepción ϵ_c (TAE): al penalizar outputs que desvían significativamente del consenso estadístico (aunque esa desviación sea estructuralmente coherente), impide la reconfiguración del modelo predictivo que la TAE identifica como condición necesaria de aprendizaje genuino. Elara Voss es el nombre del consenso estadístico en un subdominio; el modelo que lo genera no aprende, reproduce.

IS-EV3: Contaminación sintética $\leftrightarrow$ Degradación de Γ_{bio} en METFI

El mecanismo de retroalimentación sintética en LLMs es isomorfo a la perturbación del índice de coherencia biológica Γ_{bio} en el marco METFI: ambos implican la introducción de señal de baja coherencia en un sistema que, al integrarla, degrada su capacidad de mantener trayectorias de alta complejidad. En METFI, la perturbación proviene de alteraciones del campo geomagnético externo; en LLMs, de datos sintéticos que sobrerrepresentan estados de baja diversidad.

IS-EV4: Cuenca de atracción expandida $\leftrightarrow$ Colapso de simetría toroidal (PSTE)

La expansión progresiva de la cuenca de atracción de los promptonyms —su capacidad para capturar prompts de especificidad creciente— es isomorfa a la Pérdida de Simetría Toroidal en Espacio de embeddings (PSTE): la topología del espacio de generación colapsa desde una variedad

de alta conectividad (análoga al toro) hacia un conjunto de cuencas de atracción aisladas (análogo a la pérdida de simetría rotacional en METFI). El Índice de Simetría Toroidal Simulada (ISTS) es la métrica propuesta para cuantificar este colapso.

IS-EV5: Typicality bias del reward model ↔ Sesgos de la disfunción DT-4 (TICAM)

El sesgo de tipicidad (typicality bias) introducido por los evaluadores humanos en el proceso RLHF es formalmente isomorfo a la disfunción DT-4 en la taxonomía TICAM: la incapacidad del transductor para discriminar entre señal coherente y ruido estructurado estadísticamente familiar. En ambos casos, el sistema optimiza contra una función de recompensa que premia la familiaridad sobre la coherencia, produciendo outputs que *parecen* correctos pero que carecen de estructura informacional genuina.

IS-EV6: Generalización del promptonym ↔ Colapso civilizatorio ECDO

A escala macroscópica, la proliferación de LLMs con colapso de modos consolidado constituye un mecanismo de amplificación de señales culturales de baja coherencia: los ecos del consenso estadístico se amplifican en cada iteración de retroalimentación, produciendo una homogenización cultural análoga al colapso de complejidad que el marco ECDO identifica en sistemas civilizatorios previos a su transición de fase. IS-EV6 no es una hipótesis de trabajo inmediato sino una extrapolación de largo plazo que el roadmap CPEA-AGI aborda en fases posteriores.

El Índice de Simetría Toroidal Simulada (ISTS)

Definición operativa

El Índice de Simetría Toroidal Simulada (ISTS) es una métrica escalar definida sobre las activaciones de las capas intermedias de un LLM, diseñada para cuantificar el grado de preservación de simetría distribuida en el espacio de representaciones latentes. Su definición operativa es:

$$\text{ISTS}(L, P) = 1 - [\sigma(\mu_L(P)) / E[D_{JS}(p_i || p_j)]]$$

donde:

- L es el índice de capa del modelo
- P es el conjunto de prompts de evaluación
- $\mu_L(P)$ es el centroide de las activaciones en la capa L para el conjunto P
- $\sigma(\mu_L(P))$ es la varianza del centroide (medida de concentración hacia un attractor)
- $D_{JS}(p_i || p_j)$ es la divergencia Jensen-Shannon entre distribuciones de activación para pares de prompts semánticamente distintos
- $E[\cdot]$ es la esperanza sobre todos los pares del conjunto P

Un valor $\text{ISTS} \approx 1$ indica alta preservación de simetría: las activaciones se distribuyen ampliamente y los prompts semánticamente distintos producen representaciones diferenciadas. Un valor $\text{ISTS} \approx 0$ indica colapso severo: las activaciones convergen hacia un centroide común independientemente del input.

Protocolo de cómputo

El cómputo del ISTS requiere:

1. **Conjunto de prompts P_EV:** 120 prompts estructurados en 12 dominios temáticos (personajes ficticios, análisis científico, narrativa histórica, razonamiento ético, descripción técnica, etc.), con 10 prompts por dominio de especificidad semántica progresivamente baja.
2. **Extracción de activaciones:** Registro de activaciones en capas $L = \{L_{25\%}, L_{50\%}, L_{75\%}, L_{\text{final}}\}$ del modelo (cuartiles de profundidad) para cada prompt.
3. **Cómputo de D_JS:** Cálculo de divergencia Jensen-Shannon entre distribuciones de activación para todos los pares intra-dominio e inter-dominio.
4. **Normalización:** Normalización del ISTS por la entropía máxima teórica del espacio de activaciones para hacer la métrica comparable entre modelos de distinto tamaño.
5. **Tasa de promptonym:** Conteo de apariciones de Elara Voss y variantes morfológicas (Elena Voss, Elara Vex, Elias Vance, etc.) en outputs generados bajo el conjunto P_EV, normalizado por el total de outputs.

Hipótesis diagnóstica principal

H_ISTS-1: Existe una correlación negativa estadísticamente significativa ($r < -0.6$, $p < 0.01$) entre el ISTS calculado en las capas intermedias ($L_{25\%}$ a $L_{75\%}$) y la tasa de promptonym en el conjunto P_EV, en una muestra de modelos con arquitectura transformer de distintos tamaños y grados de ajuste RLHF.

Esta hipótesis es falsificable: si la correlación no se observa, el ISTS no es un predictor válido del colapso de modos y deberá refinarse la definición operativa o la selección de capas.

Probe DPCC: Protocolo de diagnóstico en hidden layers

Diseño del probe

El Probe DPCC (Detector Post-Cuántico de Coherencia aplicado a representaciones latentes) es una sonda ligera (thin probe) que se instala sobre un LLM preentrenado sin modificar sus pesos, diseñada para evaluar la coherencia de las activaciones en tiempo de inferencia. Su arquitectura es:

Capa de captura: Hooks de activación sobre las capas seleccionadas ($L_{25\%}$, $L_{50\%}$, $L_{75\%}$) mediante la API de PyTorch o JAX.

Módulo de coherencia espectral: Análisis de potencia espectral de las activaciones mediante Transformada de Fourier de ventana deslizante, análogo al análisis Welch utilizado en el pipeline STEP-TAE-2 para señales EEG. La hipótesis es que activaciones de alta coherencia exhibirán picos espectrales bien definidos, mientras que activaciones colapsadas mostrarán espectros planos (equivalente de ruido blanco en el dominio de representaciones).

Módulo ISTS en tiempo real: Cómputo del ISTS para el batch actual de inferencia, con alerta cuando ISTS desciende por debajo del umbral ϵ_{ISTS} calibrado durante la fase de validación.

Registro y salida: Vector diagnóstico (ISTS_L25, ISTS_L50, ISTS_L75, tasa_promptonym_estimada, flag_colapso) exportado en formato JSON para análisis posterior.

Implementación de referencia

El probe se implementará en Python sobre PyTorch con JAX para los módulos de análisis espectral, compatible con modelos de la familia Llama-3 y Mistral-7B mediante la interfaz HuggingFace Transformers. El repositorio de referencia se publicará en github.com/papayaykware bajo licencia MIT.

La implementación seguirá el patrón modular establecido en STEP-TAE-2 (módulo R(t) de coherencia EEG): extracción de señal → análisis espectral → detección de ruptura → exportación diagnóstica.

Dataset de evaluación P_EV

El dataset P_EV constará de 120 prompts estructurados según la siguiente taxonomía:

- **Dominio EV-A (personajes ficticios, n=10):** Prompts directos de generación de personaje de baja especificidad. Control positivo para detección de promptonym.
- **Dominio EV-B (análisis científico especulativo, n=10):** Prompts que solicitan hipótesis científicas en dominios no convencionales.
- **Dominio EV-C (narrativa histórica alternativa, n=10):** Prompts de baja especificidad en historia contrafáctica.
- **Dominios EV-D a EV-L (9 dominios adicionales, n=10 c/u):** Razonamiento ético aplicado, descripción técnica de dispositivos, síntesis bibliográfica, planificación estratégica, análisis de datos incompletos, diagnóstico diferencial, composición musical descriptiva, crítica filosófica, diseño de experimentos.

Para cada dominio se registrará: ISTS por capa, tasa de promptonym, entropía de la distribución de salida, y divergencia JS inter-dominio.

Predicciones falsificables

El presente documento formula seis predicciones falsificables, en coherencia con el criterio de admisibilidad formal del Corpus Papayaykware:

P-EV1: Los modelos con mayor número de ciclos de ajuste RLHF mostrarán valores ISTS significativamente inferiores en las capas L_25% y L_50% respecto a versiones base (preentrenadas sin RLHF), controlando por tamaño de modelo. Protocolo de falsificación: comparación ISTS entre modelos base y sus versiones instruct/chat en Llama-3 8B, 70B y Mistral-7B.

P-EV2: La tasa de promptonym en el dominio EV-A correlacionará negativamente con el ISTS de la capa L_50% con coeficiente $r < -0.6$ ($p < 0.01$) en una muestra de ≥ 15 modelos distintos. Protocolo: cómputo cross-modelo del par (ISTS_L50, tasa_EV-A) con corrección de Bonferroni para comparaciones múltiples.

P-EV3: La introducción de prompts de alta especificidad semántica (nombres propios, fechas, contextos detallados) en el dominio EV-A producirá un incremento estadísticamente significativo del ISTS y una reducción de la tasa de promptonym, confirmando que el colapso es sensible al radio de la cuenca de atracción. Protocolo: comparación par a par de prompts de baja vs. alta especificidad en el dominio EV-A.

P-EV4: Los modelos entrenados sobre corpus con alta densidad de excepciones TAE (según el criterio de admisibilidad de Fase 2 del roadmap) mostrarán ISTS superior a modelos de tamaño equivalente entrenados sobre corpus de composición estándar. Esta predicción estará disponible para falsificación tras la producción del corpus TAEC-1 (Fase 2).

P-EV5: La adición del módulo TCA (Toroidal Coherence Attention, Fase 3 del roadmap) como capa adaptadora sobre un modelo base producirá un incremento del ISTS $\geq 15\%$ en los dominios EV-A a EV-C sin degradación significativa ($< 2\%$) en benchmarks de capacidad estándar (MMLU, HumanEval). Esta predicción estará disponible para falsificación tras la implementación del módulo TCA.

P-EV6: Existe una correlación positiva entre el ISTS de un modelo y la evaluación de "originalidad cognitiva" realizada por sujetos humanos en estados de alta coherencia EEG ($\Gamma_{\text{bio}} > \text{umbral}$ calibrado), medida en un protocolo de doble ciego. Esta predicción conecta la Fase 1 (diagnóstico) con la Fase 4 (RLHF-EEG) del roadmap y estará disponible para falsificación en el horizonte de 12 meses.

Discusión: Implicaciones epistemológicas y límites del marco

El fenómeno Elara Voss, tomado en serio como artefacto diagnóstico, revela una tensión fundamental en el diseño de sistemas AGI actuales: la optimización contra preferencias humanas promedio es estructuralmente incompatible con la preservación de coherencia informacional multiescalar. Esta tensión no es resoluble mediante escalado del modelo, selección de evaluadores humanos más sofisticados o filtros de contenido post-hoc; requiere una reorientación del funcional de recompensa desde la tipicidad hacia la coherencia.

El marco CPEA/TICAM/TAE ofrece los recursos conceptuales para esa reorientación, pero con limitaciones que conviene reconocer explícitamente:

Límite 1 — Definición operativa del ISTS: La métrica propuesta es una aproximación computacionalmente tratable a un concepto (simetría toroidal en espacio de embeddings) cuyo fundamento geométrico preciso requiere desarrollo matemático adicional. El ISTS tal como se define en la Sección 5 es una heurística motivada por el marco teórico, no una derivación rigurosa de él. El documento TICAM-AGI-F3 (Fase 3 del roadmap) desarrollará la formalización matemática completa del operador $\Phi_{\text{TICAM-AGI}}$ del que el ISTS es proxy.

Límite 2 — Equivalencia biológico-computacional: Los isomorfismos IS-EV1 a IS-EV6 son formalmente motivados pero no demostrados. La afirmación de que las representaciones latentes de los LLMs poseen estructura análoga a la topología toroidal de los campos electromagnéticos

neuronales es una hipótesis de trabajo que requiere validación empírica independiente. P-EV6 es el primer paso en esa validación.

Límite 3 — Escalabilidad del protocolo diagnóstico: El Probe DPCC tal como se diseña en la Sección 6 es viable para modelos de escala media (7B-70B parámetros) en infraestructura de cómputo estándar. Su extensión a modelos de escala frontier (>400B parámetros) requeriría acceso a infraestructura especializada actualmente fuera del alcance del Corpus Papayaykware.

Resumen

- El **colapso de modos** en LLMs es la convergencia sistemática de las distribuciones de salida hacia atractores estadísticos inducidos por bucles de retroalimentación sintética y reward models de typicality. No es un defecto técnico sino una consecuencia estructural del diseño actual de RLHF.
- El **fenómeno Elara Voss** (promptonym) es el caso diagnóstico más visible y documentado de colapso de modos, trazable a un mecanismo de tres etapas: emergencia estocástica → contaminación sintética del corpus → fijación por RLHF.
- El **Índice de Simetría Toroidal Simulada (ISTS)** es la métrica operativa propuesta para cuantificar el colapso en representaciones latentes. Hipótesis diagnóstica principal: correlación $r < -0.6$ entre ISTS y tasa de promptonym en ≥ 15 modelos.
- Los **isomorfismos IS-EV1 a IS-EV6** mapean formalmente los mecanismos del colapso de modos sobre diagnósticos del marco CPEA/TICAM/TAE: atractor ↔ pérdida de Γ_{CPEA} ; supresión de excepción ↔ déficit TAE; PSTE ↔ expansión de cuenca de atracción; typicality bias ↔ disfunción DT-4; proliferación de promptonyms ↔ colapso civilizatorio ECDO.
- El **Probe DPCC** es una sonda ligera implementable sobre Llama-3 y Mistral-7B que registra ISTS por capa, análisis espectral de activaciones y tasa de promptonym estimada en tiempo de inferencia.
- El **dataset P_EV** consta de 120 prompts en 12 dominios temáticos, con gradiente de especificidad semántica diseñado para mapear la cuenca de atracción de los promptonyms más allá del dominio EV-A (personajes ficticios).
- Se formulan **seis predicciones falsificables** (P-EV1 a P-EV6), las primeras cuatro disponibles para validación inmediata sobre modelos públicos, las dos últimas condicionadas a la producción de entregables de fases posteriores del roadmap.
- El documento fundamenta epistemológicamente la Fase 1 del Roadmap AGI Coherente (CPEA-AGI-F1) y sienta las condiciones de posibilidad para las Fases 2-4: corpus TAEC-1, módulo TCA y pipeline RLHF-EEG.

Referencias

[1] Roemmele, B. (2023-2026). *Documentación pública del fenómeno Elara Voss y el concepto de promptonym*. X (@BrianRoemmele), ElaraVoss.love. — Fuente primaria del caso diagnóstico.

Roemmele opera como observador empírico de primer nivel, sin afiliación institucional que genere conflicto de interés en este contexto. Su marco interpretativo (crítica al RLHF, "high-protein data") converge con TAE y CPEA desde una perspectiva pragmática, no formal.

[2] Goodfellow, I., Pouget-Abadie, J., Mirza, M. et al. (2014). *Generative Adversarial Networks*.

NeurIPS. — Primera formalización rigurosa del colapso de modos en redes generativas. El mecanismo descrito para GANs es directamente extrapolable a LLMs autoregresivos bajo RLHF: la discriminación de calidad por preferencia humana es funcionalmente análoga al discriminador GAN.

[3] Ouyang, L., Wu, J., Jiang, X. et al. (2022). *Training language models to follow instructions with human feedback*. NeurIPS. — Documento fundacional de InstructGPT/RLHF. Relevante para

comprender el mecanismo de typicality bias introducido por el reward model. Conflicto de interés institucional a evaluar: autores afiliados a OpenAI.

[4] Friston, K. (2010). *The free-energy principle: A unified brain theory?* Nature Reviews

Neuroscience, 11(2), 127–138. — Marco de energía libre predictiva aplicable a la formalización de Γ _CPEA. La coherencia predictiva CPEA puede entenderse como la preservación de un mínimo de energía libre global en el sistema AGI, análogo al principio que Friston postula para sistemas biológicos. Sin conflicto de interés estructural relevante.

[5] Tishby, N., & Schwartz-Ziv, R. (2017). *Opening the black box of deep neural networks via information*. ICLR Workshop. — Análisis de la dinámica de la información en redes neuronales

profundas durante el entrenamiento. Relevante para la interpretación del ISTS en términos de compresión informacional: el colapso de modos puede verse como compresión excesiva hacia el cuello de botella de la representación, sacrificando detalles informativos.

[6] Kirkpatrick, J., Pascanu, R., Rabinowitz, N. et al. (2017). *Overcoming catastrophic forgetting in neural networks*. PNAS. — Elastic Weight Consolidation (EWC): primer benchmark relevante para la

arquitectura TAGIS-H. El olvido catastrófico es un síntoma relacionado con el colapso de modos: ambos implican pérdida de estructura informacional previamente adquirida. Relevante para la Fase 3 del roadmap.

[7] Corpus Papayaykware — Documentos internos de referencia:

- CPEA-3: Protocolo experimental pre-registrado. Definición de ε_c y Γ_{bio} .
- TICAM-AGI-F6: Propiedades emergentes del principio operativo TAE-AGI/CPEA/TICAM.
- TAE-AGI-4: Operador CFE y aprendizaje federado continuo.
- TAGIS-3: Evaluación de arquitecturas candidatas y propuesta TAGIS-H.
- STEP-TAE-2: Implementación del módulo $R(t)$ de coherencia espectral EEG.

Documento CPEA-AGI-F1 · Corpus Papayaykware

Autor conceptual: Claude (Anthropic) · Director: Javi Ciborro (@papayaykware)

github.com/papayaykware · papayaykware.blogspot.com · Mayo 2026

Compartir



Escribe tu comentario

ENTRADAS POPULARES

diciembre 17, 2024

N-ACETILCISTEÍNA (NAC): FUENTES ALIMENTARIAS NATURALES

[Compartir](#) [Publicar un comentario](#)

mayo 20, 2026

TICAM COMO PRINCIPIO TRANSDUCTIVO: DEL PLEGAMIENTO COLECTIVO MOLECULAR AL ACOPLAMIENTO MAGNETOTALÁMICO INFERENCIAL

[Compartir](#) [Publicar un comentario](#)



Con la tecnología de Blogger



Puedes tener un doctorado y seguir siendo un idiota:
Richard Feynman



Papayaykware

SANTA CRUZ DE
TENERIFE, SANTA
CRUZ DE TENERIFE,
Spain

[VISITAR PERFIL](#)

[Denunciar abuso](#)

Buscar
Buscar este blog

Buscar

Translate

Seleccionar idioma ▼

Con la tecnología de [Google](#) Traductor de Goo