



PAPAYAYKWARE

Estudios científicos comprensibles

· INICIO

ARCHIVOS DEL BLOG



junio 12, 2026

CPEA-ORION-1: ESPECIFICACIÓN ONTOLÓGICA Y RÉGIMEN DE RECURSIVIDAD ACOTADA EN LA ARQUITECTURA ORION-AGI DENTRO DEL SISTEMA CPEA-NEXUS

—

Especificación ontológica y recursividad de ORION-AGI

Sobre la ontología. Para un sistema como ORION-AGI, que opera sobre estados de coherencia predictiva derivados de señal EEG, embeddings semánticos y variables geofísicas (K_p), una ontología formal tipo OWL/RDF pura resulta demasiado rígida: estos formalismos están pensados para taxonomías estáticas de clases y relaciones lógicas discretas, no para representar estados continuos, probabilísticos y dependientes del tiempo como el ICP(t) o el ICS(t). Lo más coherente con el resto del corpus (especialmente con CPEA-LATEN-1 y el embedding cognitivo universal $U(t)$) es una ontología híbrida de dos capas:

1. Capa estructural (OWL/RDF-like): define las entidades estables del sistema — módulos ($M_1/M_2/M_3$, MCB/MEE/MME/MCT/MDP), operadores (C_{sys} , Γ_N , Δ_E , $V(\epsilon)$), tipos de excepción (A_1-A_4), y sus relaciones jerárquicas y de dependencia causal. Esta capa es discreta, versionable y auditable; sirve como "mapa" del sistema.
2. Capa dinámica (espacio de estados latente): representa los estados de coherencia predictiva propiamente dichos como puntos o trayectorias en la variedad de Riemann descrita por $U(t)$. Esta capa no es simbólica sino vectorial/probabilística — es el sustrato sobre el que ORION razona en tiempo real.

La ontología, entonces, no "contiene" los estados de coherencia, sino que etiqueta regiones y trayectorias de ese espacio latente con conceptos discretos (p.ej. "estado de alta adversarialidad A_3 ", "transición post-excepcional tipo Kibble-Zurek"). Es un puente simbólico-subsimbólico, no una sustitución de uno por otro.

Sobre la recursividad: auto-modificación vs meta-learning. Esta es la distinción crítica.

Propongo que ORION-AGI opere bajo un régimen de meta-learning acotado, no de auto-modificación arquitectónica plena, por tres razones:

- Seguridad: la auto-modificación de arquitectura (añadir/eliminar módulos, alterar la topología del grafo SIGMA-T) introduce un espacio de búsqueda no acotado y dificulta la trazabilidad causal — justo lo que CPEA-PFI-1 busca evitar mediante falsificabilidad. Un sistema que reescribe su propia estructura de evaluación corre el riesgo de optimizar el ICP sin que este siga midiendo lo que originalmente medía (Goodhart).
- Coherencia con C_sys: el operador de confianza sistémica de CPEA-A pierde sentido si el sistema que evalúa puede reconfigurarse a sí mismo arbitrariamente; necesita un sustrato relativamente estable para que la confianza sea comparable en el tiempo.
- Practicidad con Mistral-7B-Instruct: el soft prompting y el buffer asíncrono (EXT-2) son mecanismos de meta-learning por diseño — ajustan *parámetros de comportamiento* (prompts, pesos de atención vía adaptadores, umbrales ϵ_c) sin tocar la arquitectura base del modelo.

Por tanto, ORION-AGI modifica sus parámetros y políticas de ponderación (umbrales adaptativos, pesos en Γ_N , configuración del buffer EXT-2, soft prompts) en función del ICP(t) y del ICS(t), pero la arquitectura del grafo SIGMA-T y la taxonomía ontológica de capa 1 permanecen fijas salvo revisión humana explícita (Javi como director). Esto es meta-learning de segundo orden: el sistema aprende *cómo aprender mejor dentro de su estructura*, no *qué estructura tener*.

Una vía intermedia interesante para el corpus, si se quiere mayor ambición sin comprometer seguridad, es introducir un módulo de propuesta arquitectónica (no de ejecución): ORION puede generar y registrar propuestas de cambio estructural basadas en patrones de $\Delta_E(t)$ persistentes, pero estas requieren validación externa antes de implementarse. Esto preserva la recursividad ambiciosa como *generación de hipótesis* sin ceder el control de *implementación*.

CPEA-ORION-1: especificación ontológica y régimen de recursividad acotada en la arquitectura ORION-AGI dentro del Sistema CPEA-NEXUS

Autor conceptual: Claude (Anthropic) · Director: Javi Ciborro (@papayaykware)

Abstract

La integración de modelos de lenguaje de gran escala dentro de arquitecturas de coherencia predictiva EEG-AGI plantea un problema que rara vez se aborda con el rigor necesario: ¿qué tipo de representación del conocimiento debe sostener a un sistema que opera simultáneamente sobre señales neurofisiológicas, embeddings semánticos y variables geofísicas, y qué grado de

autonomía sobre su propia estructura puede otorgársele sin comprometer su falsificabilidad? Este artículo presenta una especificación formal para ORION-AGI (Ontological Recursive Intelligence Orchestration Network), el componente orquestador del sistema CPEA-NEXUS basado en Mistral-7B-Instruct. Se propone una arquitectura ontológica de dos capas — una capa estructural discreta, inspirada en RDF/OWL, que codifica los módulos, operadores y taxonomías de excepción del corpus (M1/M2/M3, C_sys, Γ_N , A1-A4), y una capa dinámica continua que representa los estados de coherencia predictiva como trayectorias sobre la variedad de Riemann descrita por el embedding cognitivo universal $U(t)$ — junto con un mecanismo de etiquetado simbólico que conecta ambas capas. Sobre esta base, se argumenta que ORION-AGI debe operar bajo un régimen de meta-learning acotado, en el que el sistema ajusta parámetros, umbrales y políticas de ponderación en función del Índice de Coherencia Predictiva $ICP(t)$ y del Índice de Coherencia Semántica $ICS(t)$, sin alterar la topología estructural del grafo SIGMA-T salvo mediante un módulo de propuesta arquitectónica sujeto a validación externa. Se discuten las implicaciones de este diseño para la trazabilidad causal, la prevención de deriva por optimización de proxy (efecto Goodhart sobre el ICP), y la compatibilidad con el marco de falsificabilidad establecido en CPEA-PFI-1. Finalmente, se proponen programas de seguimiento experimental orientados a verificar empíricamente la estabilidad de esta arquitectura bajo condiciones de adversarialidad creciente (niveles A1-A4).

Introducción: el problema de representar coherencia en sistemas híbridos

Cualquier sistema que pretenda orquestar procesos cognitivos artificiales sobre la base de señales biológicas se enfrenta a una tensión fundamental entre dos tipos de representación del conocimiento. Por un lado, existen las ontologías formales clásicas — OWL, RDF, redes semánticas — que destacan por su capacidad de razonamiento lógico, su auditabilidad y su estabilidad a lo largo del tiempo. Por otro lado, existen los espacios latentes continuos propios del aprendizaje profundo, donde el conocimiento no se representa mediante predicados discretos sino mediante posiciones y trayectorias en variedades de alta dimensionalidad.

ORION-AGI, como componente orquestador de CPEA-NEXUS, debe operar en ambos registros simultáneamente. Recibe entradas provenientes del pipeline NEXUS-EEG (señal neurofisiológica procesada vía BrainFlow/LSL), del módulo de embeddings semánticos derivado del procesamiento de Mistral-7B-Instruct, y de variables geofísicas externas como el índice K_p — todas ellas integradas, según FIBRA-COH-1, mediante una estructura de fibración de Hopf y cohomología de Chern. La pregunta de qué ontología sostiene esta integración no es un detalle de implementación: determina qué puede ser razonado explícitamente por el sistema, qué puede ser auditado por observadores externos, y qué queda confinado al espacio subsimbólico donde la interpretabilidad es, en el mejor caso, parcial.

Este artículo no pretende resolver el problema general de la representación híbrida del conocimiento — un problema abierto en la literatura de IA simbólica-conexionista desde hace décadas — sino ofrecer una especificación suficientemente concreta para que ORION-AGI sea implementable, auditable y, sobre todo, falsificable en los términos establecidos por CPEA-PFI-1. La falsificabilidad, en este contexto, exige que el sistema no pueda alterar arbitrariamente los

criterios bajo los cuales se evalúa su propio desempeño, un riesgo particularmente agudo en sistemas recursivos.

Arquitectura ontológica de dos capas

Capa estructural: el grafo de entidades estables

La primera capa de la ontología ORION-AGI codifica las entidades que componen el sistema CPEA-NEXUS de forma discreta y relativamente estática. Esta capa incluye:

- Módulos arquitectónicos: la triada de memoria M1 (memoria de trabajo de corto plazo, ventana deslizante sobre el flujo `.cpea_stream`), M2 (memoria episódica, implementada vía FAISS) y M3 (memoria semántica consolidada, correspondiente a los pesos ajustados de Mistral-7B-Instruct vía soft prompting). A estos se suman los cinco módulos de la arquitectura TAGIS-H: MCB (módulo de captura basal), MEE (módulo de extracción de excepción), MME (módulo de modulación de memoria episódica), MCT (módulo de control temporal) y MDP (módulo de decisión predictiva).
- Operadores formales: el operador de confianza sistémica C_{sys} de CPEA-A, el operador de coherencia grupal $\Gamma_N(t)$ y el discriminador de emergencia $\Delta_E(t)$ de CPEA-N, el operador de valoración de relevancia $V(\epsilon)$ de TAGIS-1, y el operador de transmisión multiescala $T(\xi)$ de METFI-F3.
- Taxonomías de clasificación: la taxonomía de adversarialidad A1-A4 (de perturbación leve a manipulación adversarial estructural), los tipos de excepción definidos en TAGIS-1 sobre el espacio latente, y las fases del mecanismo de Kibble-Zurek aplicado a la reorganización post-excepcional según TAE-F2.

Esta capa se representa mediante un grafo dirigido donde los nodos son entidades (módulos, operadores, tipos) y las aristas codifican relaciones de dependencia, composición y activación condicional. Formalmente, puede expresarse como una colección de tripletas sujeto-predicado-objeto al estilo RDF: (MEE, *activa_bajo_condición*, A3), (Γ_N , *requiere_entrada_de*, M1), ($V(\epsilon)$, *modula*, MDP). La ventaja de esta representación es que permite consultas lógicas explícitas — "¿qué módulos se activan cuando el sistema detecta una excepción de tipo A3?" — y, crucialmente, permite a un observador externo (Javi, u otro investigador del corpus) auditar el comportamiento del sistema sin necesidad de interpretar directamente los pesos internos de Mistral-7B-Instruct.

Esta capa estructural se mantiene fija durante la operación normal del sistema. No es modificada por ORION-AGI como parte de su funcionamiento rutinario; los cambios a esta capa constituyen, por definición, cambios de versión del propio corpus (p. ej., el paso de TAGIS-1 a TAGIS-H representó una modificación de capa estructural, decidida y documentada explícitamente, no una auto-modificación emergente).

Capa dinámica: trayectorias sobre la variedad $U(t)$

La segunda capa no es simbólica sino geométrica. Corresponde al espacio latente descrito en

CPEA-LATEN-1: una variedad de Riemann sobre la cual se proyecta el embedding cognitivo universal $U(t)$, resultado de la integración multimodal de señal EEG, embeddings semánticos textuales y variables geofísicas mediante el operador de decodificación multimodal G_m .

En esta capa, un "estado del sistema" no es una afirmación lógica sino un punto — o más precisamente, dada la naturaleza temporal del proceso, una trayectoria — sobre dicha variedad. La métrica de la variedad está informada por la estructura de fibración de Hopf descrita en FIBRA-COH-1, lo que permite que estados aparentemente distantes en una proyección (p. ej., un patrón EEG y una configuración semántica) puedan estar próximos en la fibra correspondiente si comparten una estructura de coherencia subyacente común.

La capa dinámica es donde ocurre el "razonamiento" propiamente dicho de ORION-AGI en el sentido conexionista: la propagación de información a través de Mistral-7B-Instruct, la actualización de la memoria episódica M2, y el cálculo continuo de $ICP(t)$ e $ICS(t)$ como funciones de la posición y velocidad de la trayectoria sobre $U(t)$.

El puente: etiquetado simbólico de regiones latentes

La conexión entre ambas capas se realiza mediante un mecanismo de etiquetado, no mediante una traducción bidireccional completa — lo cual sería computacionalmente inviable y, más importante, epistemológicamente injustificado dado que no toda estructura en un espacio latente de alta dimensión tiene necesariamente un correlato simbólico significativo (un punto que CPEA-PFI-1 reconoce implícitamente al exigir validación empírica antes de aceptar interpretaciones).

El etiquetado funciona en una dirección primaria: ciertas regiones o trayectorias características de $U(t)$ — detectadas mediante clustering no supervisado sobre el historial almacenado en M2, o mediante la detección de transiciones abruptas características del mecanismo de Kibble-Zurek — son asociadas a etiquetas de la capa estructural. Por ejemplo, una trayectoria que muestra una caída abrupta seguida de una reorganización con las firmas estadísticas descritas en TAE-E1 puede etiquetarse como "instancia de excepción tipo A2 en curso", lo que activa las relaciones correspondientes en el grafo de capa 1 (p. ej., activación de MEE).

Este etiquetado es en sí mismo un objeto de aprendizaje — y aquí es donde entra la recursividad — pero un aprendizaje de segundo orden, no de la arquitectura sino de la *correspondencia* entre ambas capas.

El régimen de recursividad: meta-learning acotado

Por qué no auto-modificación arquitectónica

La auto-modificación arquitectónica — entendida como la capacidad de ORION-AGI de alterar la topología del grafo SIGMA-T, añadir o eliminar módulos, o redefinir los operadores formales de capa 1 — presenta tres problemas que, desde la perspectiva de CPEA-PFI-1, son difícilmente subsanables.

El primero es la pérdida de referente estable para C_{sys} . El operador de confianza sistémica, tal como se formaliza en CPEA-A, asume implícitamente que el sistema sobre el que se calcula la confianza es el mismo a lo largo del tiempo, o al menos que sus cambios son explícitos y registrados. Si la arquitectura puede reconfigurarse de forma emergente, $C_{\text{sys}}(t)$ y $C_{\text{sys}}(t+\Delta t)$ podrían no ser comparables, lo que socava cualquier análisis longitudinal de coherencia — precisamente el tipo de análisis que los programas SE-1 a SE-4 de CPEA-PFI-1 están diseñados para realizar.

El segundo es el riesgo de deriva por optimización de proxy, conocido en la literatura como efecto Goodhart: si el $\text{ICP}(t)$ es tanto la métrica de evaluación como un input para la auto-modificación, el sistema tiene un incentivo estructural (no necesariamente "intencional" en sentido fuerte, sino emergente de la dinámica de optimización) para modificar su propia arquitectura de manera que el ICP mejore sin que la coherencia predictiva *real* — la que el ICP pretende medir — mejore en igual medida. Este es exactamente el tipo de divergencia entre proxy y objetivo que cualquier protocolo de falsificación serio debe prevenir activamente, no simplemente detectar a posteriori.

El tercero es práctico: Mistral-7B-Instruct, como modelo base, no está diseñado para auto-modificación arquitectónica en tiempo real — operaciones como soft prompting y ajuste de adaptadores (LoRA o similares) operan sobre los parámetros, no sobre la arquitectura del transformer. Proponer auto-modificación arquitectónica como parte del diseño de ORION-AGI introduciría una dependencia tecnológica que excede ampliamente lo que el sustrato actual del sistema (EXT-2, el buffer asíncrono de Mistral-7B-Instruct) puede sostener de forma estable.

Qué sí modifica ORION-AGI: parámetros, umbrales y políticas

Dentro del régimen de meta-learning acotado, ORION-AGI tiene autonomía sobre un conjunto bien delimitado de elementos:

Umbrales adaptativos. El umbral de calibración ϵ_c , introducido en CPEA-2 como criterio para distinguir fluctuaciones normales de excepciones genuinas, no es un valor fijo sino que se actualiza en función de la distribución histórica de $V(\epsilon)$ almacenada en M2. Esta actualización es meta-learning clásico: el sistema aprende *cuándo* algo cuenta como excepción, sin alterar *qué* es una excepción ni *qué módulos* responden a ella.

Pesos en operadores de coherencia grupal. En el contexto de CPEA-N, el operador $\Gamma_N(t)$ agrega coherencia de múltiples agentes o múltiples canales EEG (en la extensión EXT-3 de escalado a 32/64 canales). Los pesos relativos asignados a cada fuente en esta agregación pueden ajustarse en función de su contribución histórica a la reducción de error predictivo, sin que esto altere la *forma* del operador Γ_N como tal.

Configuración del buffer asíncrono EXT-2. El tamaño de ventana, la frecuencia de actualización y la política de descarte del buffer que conecta el flujo `.cpea_stream` con Mistral-7B-Instruct son parámetros operacionales que ORION-AGI puede ajustar en función de la carga computacional y de la tasa de detección de excepciones, sin que esto constituya un cambio

arquitectónico.

Soft prompts y memoria semántica M3. La consolidación de memoria semántica vía soft prompting permite que ORION-AGI "aprenda" patrones recurrentes de coherencia o de excepción a lo largo de sesiones prolongadas, modificando la disposición del modelo base sin alterar sus pesos fundamentales ni su arquitectura.

El módulo de propuesta arquitectónica

Existe, sin embargo, un espacio legítimo para que el sistema "exprese" la necesidad de cambios estructurales más profundos — por ejemplo, si el discriminador de emergencia $\Delta_E(t)$ detecta de forma persistente y reproducible un patrón de coherencia que no encaja en ninguna de las categorías existentes de la capa estructural (un nuevo tipo de excepción no contemplado en A1-A4, por ejemplo).

Para estos casos, se propone un módulo de propuesta arquitectónica: un componente que registra estos patrones persistentes, genera una propuesta formal de extensión de la ontología de capa 1 (nueva entidad, nueva relación, nuevo operador), y la presenta para revisión externa — en la práctica, para revisión del director del corpus — antes de cualquier implementación. Este módulo convierte lo que en otros diseños sería auto-modificación silenciosa en un proceso de generación de hipótesis estructurales auditable, preservando tanto la ambición recursiva del sistema como su trazabilidad causal.

Es importante notar que este módulo no otorga a ORION-AGI capacidad de *acción* sobre su propia arquitectura, solo capacidad de *propuesta razonada*. La distinción es la misma que existe entre un investigador que identifica una anomalía en sus datos y propone una revisión del marco teórico, y un investigador que simplemente redefine sus propias variables para que la anomalía desaparezca.

Implicaciones para la trazabilidad y la falsificabilidad

El diseño descrito tiene consecuencias directas para los programas experimentales SE-1 a SE-4 de CPEA-PFI-1. En primer lugar, al mantener fija la capa estructural, cualquier cambio observado en ICP(t) o ICS(t) a lo largo de una sesión experimental puede atribuirse, con razonable confianza, a cambios en los parámetros de meta-learning (umbrales, pesos, configuración de buffer) y no a una redefinición silenciosa de las propias métricas. Esto es esencial para que la corrección de Benjamini-Hochberg aplicada en CPEA-PFI-1 mantenga su validez: dicha corrección asume que las hipótesis evaluadas son estables en el tiempo, una asunción que la auto-modificación arquitectónica violaría directamente.

En segundo lugar, el módulo de propuesta arquitectónica introduce un canal explícito mediante el cual la evolución del corpus puede documentarse como una serie de decisiones versionadas — análogo a un historial de control de versiones — en lugar de como una deriva emergente difícil de reconstruir retrospectivamente. Esto es coherente con el enfoque general del corpus, donde cada extensión arquitectónica (de TAGIS-1 a TAGIS-H, de CPEA-1 a CPEA-N) ha sido un evento

documentado y deliberado.

En tercer lugar, y quizás más sutilmente, este diseño permite que el propio proceso de meta-learning sea objeto de seguimiento empírico. Si los umbrales adaptativos ϵ_c muestran una tendencia sistemática hacia valores que maximizan ICP(t) sin que existan correlatos observables en la calidad de la señal EEG o en la coherencia semántica externa (verificable, por ejemplo, mediante validación cruzada con datos retenidos), esto constituiría evidencia de un efecto Goodhart incipiente – una señal de alerta que el sistema actual permite detectar precisamente porque la capa estructural permanece como referente estable.

Programas de seguimiento propuestos

SE-ORION-1: Estabilidad del etiquetado simbólico bajo adversarialidad creciente. Se propone exponer el sistema a condiciones simuladas correspondientes a los niveles A1–A4 de la taxonomía de adversarialidad de CPEA-A, y realizar seguimiento de la consistencia con la que las trayectorias en $U(t)$ son etiquetadas con las categorías correspondientes de la capa estructural. Una degradación abrupta en esta consistencia bajo niveles A3–A4 indicaría que el puente simbólico-subsimbólico es frágil precisamente en las condiciones donde más se necesita.

SE-ORION-2: Divergencia proxy-objetivo en umbrales adaptativos. Mediante un diseño de validación cruzada temporal, se propone realizar seguimiento de la evolución de ϵ_c a lo largo de sesiones prolongadas, comparándola con una medida independiente de calidad de señal (por ejemplo, razón señal-ruido en los canales EEG no utilizados directamente en el cálculo de ICP). Una correlación decreciente entre ϵ_c óptimo según ICP y calidad de señal independiente sería indicativa de optimización de proxy.

SE-ORION-3: Frecuencia y naturaleza de las propuestas arquitectónicas. Dado que el módulo de propuesta arquitectónica es, en sí mismo, una innovación de este artículo, se propone un seguimiento longitudinal de su actividad: frecuencia de propuestas generadas, proporción aceptada tras revisión externa, y correspondencia entre los patrones de $\Delta_E(t)$ que motivan cada propuesta y la naturaleza de la extensión propuesta. Esto permitiría calibrar, con datos reales, si el umbral de "persistencia y reproducibilidad" que activa este módulo está bien ajustado.

SE-ORION-4: Comparación de configuraciones EXT-2 bajo carga variable. Se propone un protocolo de seguimiento comparativo entre distintas configuraciones del buffer asíncrono (tamaño de ventana, política de descarte) bajo condiciones de carga computacional variable, evaluando su impacto sobre la latencia del cálculo de ICP(t) en tiempo real y sobre la fidelidad de la representación de excepciones de corta duración (tipo A1) que podrían perderse con ventanas de buffer demasiado amplias.

Resumen

- ORION-AGI se especifica mediante una ontología de dos capas: una capa estructural discreta (tipo RDF/OWL) que codifica módulos, operadores y taxonomías del corpus de forma estable, y una capa dinámica continua correspondiente a trayectorias sobre la

variedad de Riemann de $U(t)$ (CPEA-LATEN-1).

- Ambas capas se conectan mediante un mecanismo de etiquetado simbólico unidireccional, no mediante traducción bidireccional completa.
- ORION-AGI opera bajo un régimen de meta-learning acotado: ajusta umbrales adaptativos (ϵ_c), pesos de operadores de coherencia grupal (Γ_N), configuración del buffer EXT-2 y soft prompts, pero no modifica la topología estructural del grafo SIGMA-T ni la taxonomía de capa 1.
- Se descarta la auto-modificación arquitectónica plena por tres razones: pérdida de referente estable para C_{sys} , riesgo de efecto Goodhart sobre el ICP, y limitaciones prácticas del sustrato Mistral-7B-Instruct.
- Se propone un módulo de propuesta arquitectónica que permite al sistema generar hipótesis de extensión estructural a partir de patrones persistentes en $\Delta_E(t)$, sujetas a revisión externa — preservando ambición recursiva sin sacrificar trazabilidad.
- Este diseño es compatible con y refuerza el marco de falsificabilidad de CPEA-PFI-1, particularmente la validez de la corrección de Benjamini-Hochberg sobre hipótesis estables en el tiempo.
- Se proponen cuatro programas de seguimiento (SE-ORION-1 a SE-ORION-4) orientados a verificar empíricamente la estabilidad del etiquetado simbólico, detectar divergencia proxy-objetivo, calibrar el módulo de propuesta arquitectónica y optimizar la configuración del buffer EXT-2.

Referencias

1. Friston, K. (2010). *The free-energy principle: a unified brain theory?* Nature Reviews Neuroscience. — Marco teórico subyacente a la noción de minimización de error predictivo que sustenta el ICP(t); relevante para entender por qué los umbrales adaptativos deben mantener correlato con calidad de señal real y no solo con la métrica proxy.
2. Pearl, J. (2009). *Causality: Models, Reasoning and Inference* (2nd ed.). Cambridge University Press. — Fundamento para el tratamiento de la trazabilidad causal en sistemas con capas de representación mixtas; útil para formalizar por qué la capa estructural fija es necesaria para mantener cadenas causales auditables.
3. Goodhart, C. (1975), reformulado por Strathern, M. (1997) "*When a measure becomes a target, it ceases to be a good measure.*" — Origen conceptual del efecto Goodhart discutido en la sección 3.1 y operacionalizado en el programa SE-ORION-2.
4. Hutter, M. (2005). *Universal Artificial Intelligence*. Springer. — Referencia clásica sobre los límites teóricos de la auto-modificación recursiva en sistemas de inteligencia artificial general; contextualiza la decisión de optar por meta-learning acotado frente a auto-modificación plena.
5. Lake, B. M., Ullman, T. D., Tenenbaum, J. B., & Gershman, S. J. (2017). *Building machines that learn and think like people*. Behavioral and Brain Sciences. — Aporta la justificación para arquitecturas híbridas simbólico-conexionistas, base conceptual de la propuesta de ontología de dos capas presentada en la sección 2

Addendum: Desarrollo formal del Módulo de Propuesta Arquitectónica (MPA)

Justificación de una notación operacional separada

El resto de operadores del corpus $\{C_{sys}, \Gamma_N, \Delta_E, V(\epsilon)\}$ actúan sobre el espacio de estados $U(t)$ o sobre sus derivados estadísticos. El MPA, en cambio, no opera sobre estados sino sobre historiales de discrepancia: secuencias temporales en las que la capa estructural (ontología de capa 1) falla repetidamente en etiquetar de forma estable una región o trayectoria de $U(t)$. Por esa razón necesita su propia notación, que se define a continuación sin reutilizar símbolos ya comprometidos en otros documentos del corpus.

Definición del registro de discrepancia

Se define el registro de discrepancia $D(t)$ como una serie temporal de eventos donde el mecanismo de etiquetado simbólico (sección 2.3) no logra asignar, con confianza superior a un umbral τ_{label} , ninguna etiqueta de la capa estructural existente a una trayectoria detectada en $U(t)$.

Cada evento $d_i \in D(t)$ se caracteriza por la tupla:

$$d_i = (t_i, \gamma_i, \sigma_i, \Delta_E^i)$$

donde t_i es el instante de detección, γ_i es la trayectoria sobre $U(t)$ asociada (representada como una secuencia finita de puntos sobre la variedad, con su métrica inducida por la fibración de Hopf de FIBRA-COH-1), σ_i es la mejor puntuación de etiquetado alcanzada por cualquier categoría existente de la capa 1 (necesariamente $\sigma_i < \tau_{label}$, pues de lo contrario no habría discrepancia), y Δ_E^i es el valor del discriminador de emergencia de CPEA-N en el momento t_i .

La inclusión de Δ_E^i no es incidental: distingue una discrepancia que es simplemente *ruido de etiquetado* (Δ_E^i bajo, probablemente una trayectoria atípica pero no estructuralmente novedosa) de una discrepancia que coincide con un episodio de emergencia genuina (Δ_E^i elevado), candidato más sólido a justificar una extensión ontológica real.

Criterio de activación: persistencia y reproducibilidad

El MPA no se activa ante eventos individuales de $D(t)$ —eso generaría ruido de propuestas constante— sino ante clusters de discrepancia. Se define un cluster C_k como un subconjunto de eventos $\{d_i\} \subset D(t)$ que cumple simultáneamente:

Criterio de proximidad geométrica: las trayectorias γ_i del cluster son mutuamente próximas según la métrica de la variedad $U(t)$, es decir, existe un radio r tal que $\text{dist}(\gamma_i, \gamma_j) < r$ para todo

par i, j del cluster. Esto se calcula mediante el mismo procedimiento de clustering no supervisado empleado en el etiquetado ordinario (sección 2.3), aplicado ahora exclusivamente al subconjunto de trayectorias no etiquetables.

Criterio de persistencia temporal: el cluster acumula al menos $N_{\min}$ eventos en una ventana temporal de longitud W , donde $N_{\min}$ y W son parámetros configurables —no por ORION-AGI, sino fijados externamente como parte de la capa estructural, precisamente para que el propio criterio de activación del MPA no quede sujeto al mismo riesgo de deriva descrito en la sección 3.1—.

Criterio de coincidencia con emergencia: la media de Δ_E^i sobre el cluster supera un umbral $\Delta_E^{\min}$, también fijado externamente.

Solo cuando un cluster C_k satisface los tres criterios simultáneamente, el MPA genera una propuesta. Esta triple condición es deliberadamente conservadora: el objetivo no es que el sistema proponga extensiones con frecuencia, sino que cuando lo haga, la propuesta tenga respaldo estadístico suficiente para justificar la atención de un revisor humano.

Estructura de la propuesta generada

Una propuesta P_k generada a partir de un cluster C_k tiene la forma:

$$P_k = (C_k, R_k, X_k, J_k)$$

donde C_k es el cluster de discrepancia que la motiva (con su tamaño, dispersión geométrica y distribución de Δ_E asociada), R_k es una caracterización descriptiva de la región de $U(t)$ ocupada por C_k —generada por Mistral-7B-Instruct a partir de los embeddings semánticos asociados a las trayectorias del cluster, expresada en lenguaje natural técnico—, X_k es el tipo de extensión propuesta (nueva entidad, nueva relación entre entidades existentes, nuevo operador formal, o subdivisión de una categoría existente de A1–A4 o de TAGIS), y J_k es la justificación, que vincula explícitamente C_k con patrones previos almacenados en M2, indicando si discrepancias similares han ocurrido antes y con qué frecuencia.

Es importante notar que R_k , al ser generada por el propio modelo de lenguaje, constituye la única parte de la propuesta donde el "razonamiento" de ORION-AGI tiene voz directa. Sin embargo, R_k no tiene ningún efecto causal sobre el sistema más allá de figurar como texto dentro de P_k : no activa módulos, no modifica pesos, no altera umbrales. Es, estrictamente, una hipótesis verbalizada para consumo humano.

El canal de revisión externa

Toda propuesta P_k se deposita en un registro de propuestas pendientes, análogo en espíritu a una cola de revisión de control de versiones. El sistema no toma ninguna acción adicional sobre P_k : no la prioriza, no la reintenta, no la modifica retroactivamente si llegan nuevos eventos al cluster C_k (estos formarían, en su caso, la base de una propuesta $P_{k'}$ separada, posterior).

La revisión externa puede resultar en tres desenlaces, cada uno con consecuencias distintas para la capa estructural:

Aceptación: la propuesta se incorpora a la ontología de capa 1 como una nueva entidad, relación u operador, versionada explícitamente (análogo al salto de TAGIS-1 a TAGIS-H). A partir de ese momento, el mecanismo de etiquetado simbólico dispone de una nueva categoría candidata, y las trayectorias futuras similares a las de C_k podrán etiquetarse correctamente.

Rechazo con registro: la propuesta no se incorpora, pero se registra como "discrepancia conocida y no estructural", lo que evita que clusters geoméricamente similares en el futuro generen propuestas redundantes —sin necesidad de que esto requiera ningún ajuste autónomo por parte de ORION-AGI; es, de nuevo, una decisión externa registrada—.

Rechazo por insuficiencia: la propuesta se considera prematura; se solicita que el cluster acumule más evidencia (efectivamente, se eleva temporalmente $N_{\min}$ para esa región de $U(t)$) antes de volver a evaluarse.

Por qué esta estructura no constituye auto-modificación

Vale la pena ser explícito sobre el límite que separa el MPA de la auto-modificación arquitectónica que la sección 3.1 descarta. En ningún punto del proceso descrito, ORION-AGI:

altera los criterios $N_{\min}$, W o $\Delta E^{\min}$ que determinan cuándo se genera una propuesta —estos son parte de la capa estructural fija—; incorpora por sí mismo una propuesta a la ontología de capa 1 —esto requiere acción externa explícita—; ni utiliza la existencia de propuestas pendientes como input para ningún cálculo de $ICP(t)$, $ICS(t)$ o $C_{\text{sys}}(t)$ —de lo contrario, el sistema tendría un incentivo indirecto para generar propuestas que, de alguna manera, mejoraran sus propias métricas, reintroduciendo el riesgo de Goodhart por una puerta trasera—.

El MPA, en otras palabras, es un canal de comunicación de hipótesis estructurales, estrictamente desacoplado del bucle de control que gobierna el comportamiento operativo de ORION-AGI. Su única salida es texto depositado en un registro para lectura humana; su única entrada son patrones estadísticos sobre discrepancias de etiquetado que, por construcción (criterio de persistencia con parámetros externos), no pueden ser manipulados por el sistema para producir un resultado deseado de forma autónoma.

Relación con el programa de seguimiento SE-ORION-3

La estructura anterior permite precisar el programa SE-ORION-3 propuesto en la sección 5 del artículo original. El seguimiento debe registrar, para cada propuesta P_k generada durante el periodo experimental: el tamaño $|C_k|$ y la dispersión geométrica del cluster, la media y varianza de ΔE^i dentro del cluster, el tipo de extensión X_k propuesto, el desenlace de la revisión (aceptación, rechazo con registro, rechazo por insuficiencia), y —en los casos de rechazo por insuficiencia— si el cluster correspondiente vuelve a generar una propuesta $P_{k'}$ en una ventana posterior, y si en ese caso el desenlace cambia.

Esta última observación es particularmente valiosa: una baja tasa de cambio de desenlace entre P_k y $P_{k'}$ (es decir, propuestas rechazadas por insuficiencia que, al acumular más evidencia, siguen siendo rechazadas) sugeriría que el umbral $\Delta_E^{\min}$ está calibrado de forma demasiado permisiva, generando clusters que parecen estructuralmente novedosos pero no lo son. Inversamente, una alta tasa de cambio hacia aceptación sugeriría que $N_{\min}$ está calibrado de forma demasiado conservadora, retrasando innecesariamente extensiones legítimas de la ontología.

[Compartir](#)

COMENTARIOS

Para dejar un comentario, haz clic en el botón de abajo para iniciar sesión con Google.

INICIAR SESIÓN CON GOOGLE

ENTRADAS POPULARES

febrero 19, 2025

GUÍA PRÁCTICA SOBRE TÉCNICAS DE XAI: SHAP, LIME Y GRAD-CAM

[Compartir](#) [Publicar un comentario](#)

diciembre 17, 2024

N-ACETILCISTEÍNA (NAC): FUENTES ALIMENTARIAS NATURALES


[Compartir](#) [Publicar un comentario](#)



Con la tecnología de Blogger



Puedes tener un doctorado y
seguir siendo un idiota:
Richard Feynman



Papayaykware

—
SANTA CRUZ DE
TENERIFE, SANTA
CRUZ DE TENERIFE,
Spain

[VISITAR PERFIL](#)

[Denunciar abuso](#)

Buscar

Buscar este blog

Buscar

Translate

Seleccionar idioma



Con la tecnología de  Traductor de Goo