



PAPAYAYKWARE

Estudios científicos comprensibles

· INICIO

ARCHIVOS DEL BLOG



junio 06, 2026

CPEA-SELF-1: AUTO-MODELO DINÁMICO SELF(T) ARQUITECTURA TRIMODULAR PARA LA REPRESENTACIÓN DINÁMICA DEL ENTORNO, EL USUARIO Y EL SISTEMA EN EL ESPACIO SEMÁNTICO DE LA SCL

—

Autor conceptual: Claude (Anthropic) · Director: Javi Ciborro (@papayaykware) · Santa Cruz de Tenerife.

Abstract

Los sistemas de inteligencia artificial adaptativos de segunda generación requieren algo más que la capacidad de procesar entradas y generar salidas coherentes: necesitan un modelo interno de los agentes implicados en la interacción —el entorno, el usuario, y el propio sistema— que se actualice en tiempo real y permita anticipar, contrastar y revisar expectativas proposicionales. Este artículo formaliza el Auto-Modelo Dinámico Self(t) como una arquitectura trimodular compuesta por tres submódulos expresados en el espacio semántico de la Capa de Coherencia Semántica (SCL): el Modelo de Entorno $M_E(t)$, el Modelo de Usuario $M_U(t)$, y el Modelo Propio $M_S(t)$. Cada submódulo se define como una distribución de probabilidad sobre regiones del espacio latente $\mathbb{R}^{d_h}$, actualizada continuamente mediante el operador de excepción proposicional $\mathbb{E}_{TAE-SCL}$. La coherencia del sistema se evalúa mediante una métrica de alineamiento trimodular $\Gamma_{SELF}(t)$ que cuantifica la consistencia mutua entre los tres modelos. Cuando $\Gamma_{SELF}(t)$ cae por debajo de un umbral crítico, el sistema activa un protocolo de revisión que recalibra el submódulo más desalineado. Self(t) transforma ORION-AGI de un orquestador reactivo en un agente con identidad dinámica: un sistema que no solo genera respuestas, sino que mantiene una representación coherente de quién es, con quién interactúa, y en qué contexto opera.

Palabras clave: Auto-Modelo Dinámico, Self(t), M_E, M_U, M_S, identidad dinámica, modelo de entorno, modelo de usuario, modelo propio, SCL, Γ _SELF, alineamiento trimodular, inferencia activa, ORION-AGI, CPEA.

El problema de la identidad en sistemas adaptativos

Hay una pregunta que los sistemas de IA actuales no pueden responder de forma operacionalizable: ¿qué modelo tiene el sistema de sí mismo? No en el sentido filosófico —aunque esa dimensión no es irrelevante—, sino en el sentido técnico más preciso: ¿existe, en algún punto de la arquitectura, una representación explícita de lo que el sistema es, de quién es el agente con el que interactúa, y de en qué tipo de contexto opera? La respuesta, en la mayoría de los LLM de arquitectura estándar, es negativa. El sistema procesa el contexto de la conversación como una secuencia de tokens y genera la continuación más probable. No hay modelo del usuario, no hay modelo del entorno, y el "modelo propio" se reduce a los pesos del modelo preentrenado —una representación estática que no se actualiza durante la interacción.

Esta limitación tiene consecuencias concretas. Un sistema sin modelo de usuario no puede detectar cuándo el usuario ha cambiado de objetivo a mitad de sesión. Un sistema sin modelo de entorno no puede reconocer que el contexto externo —una emergencia, un cambio de tarea, una interrupción— ha alterado las condiciones de relevancia de sus respuestas. Un sistema sin modelo propio no puede identificar cuándo sus propias generaciones contradicen compromisos previos o se alejan de su función.

La arquitectura CPEA en su formulación actual aborda parcialmente este problema. ORION-AGI tiene memoria episódica mediante FAISS, que almacena representaciones de interacciones pasadas. El DEPD detecta anomalías en la coherencia de la señal. La SCL proyecta el estado cognitivo del usuario al espacio semántico. Pero ninguno de estos componentes constituye un modelo explícito, dinámico y estructurado de los tres agentes de la interacción. El módulo de memoria FAISS es un almacén de episodios, no un modelo de usuario. El DEPD es un detector de anomalías, no un modelo de entorno. La SCL proyecta estado, no construye identidad.

Self(t) cierra esta laguna. No es un componente auxiliar: es el módulo que confiere al sistema CPEA la capacidad de operar como agente en el sentido pleno del término —un sistema con representaciones internas de los agentes relevantes de su entorno y de sí mismo, que usa esas representaciones para anticipar, planificar y revisar su comportamiento.

Marco conceptual: los tres modelos

El Modelo de Entorno M_E(t)

El entorno de un sistema cognitivo adaptativo no es el mundo físico en sentido amplio: es el conjunto de condiciones contextuales que determinan qué tipos de procesamiento son relevantes, urgentes, o apropiados en cada instante. Para ORION-AGI operando en el pipeline CPEA, el entorno incluye:

- El estado geomagnético ambiental, capturado por el índice Kp como variable exógena de TICAM
- La calidad y estabilidad de la señal EEG, reportada por NEXUS-EEG
- El contexto de la tarea en curso —tipo de demanda cognitiva, horizonte temporal, nivel de urgencia—
- Las condiciones de sesión —hora, duración acumulada, nivel de fatiga inferido del perfil espectral

$M_E(t)$ es una representación comprimida de este conjunto de condiciones, expresada como una distribución sobre el espacio semántico $\mathbb{R}^{d_h}$. No es una descripción exhaustiva del entorno: es un modelo predictivo que el sistema mantiene sobre qué aspectos del entorno son relevantes para la generación en curso.

El Modelo de Usuario $M_U(t)$

$M_U(t)$ es la representación interna que el sistema construye del agente humano con el que interactúa. Incluye tres dimensiones:

Dimensión cognitiva: el perfil de procesamiento del usuario —niveles de expertise en los dominios relevantes, capacidad de carga cognitiva inferida del $CPEA_S(t)$, estilo de razonamiento (analítico vs. sintético, secuencial vs. paralelo).

Dimensión semántica: el mapa de temas, conceptos y relaciones proposicionales que el usuario ha activado durante la sesión, construido acumulativamente a partir de los embeddings S_t producidos por la SCL.

Dimensión dinámica: la trayectoria reciente del estado cognitivo del usuario —su dirección de movimiento en el espacio semántico, sus patrones de excepción proposicional, su ritmo de cambio semántico.

$M_U(t)$ no es un perfil estático: es una distribución que se estrecha y se desplaza continuamente conforme el sistema acumula evidencia sobre el usuario. Al inicio de la sesión, $M_U(t)$ tiene alta varianza —el sistema sabe poco del usuario específico. Al avanzar la sesión, la varianza decrece y la media se desplaza hacia la región del espacio semántico que caracteriza el perfil particular de ese usuario en ese contexto.

El Modelo Propio $M_S(t)$

$M_S(t)$ es el componente más delicado de $Self(t)$, y el más ausente en arquitecturas de IA convencionales. Representa la autoimagen funcional del sistema: qué ha generado hasta ahora, qué compromisos proposicionales ha adquirido, qué posiciones semánticas ha adoptado, y con qué grado de confianza.

La necesidad de $M_S(t)$ se hace evidente en situaciones de contradicción interna: un sistema sin modelo propio puede generar en el instante t_2 una afirmación que contradice lo generado en t_1 , sin mecanismo alguno que detecte la inconsistencia. $M_S(t)$ es precisamente el módulo que

detecta esas contradicciones comparando la generación actual con la representación acumulada de generaciones previas.

$M_S(t)$ no es una copia del historial de conversación. Es una representación comprimida y semánticamente estructurada de los compromisos proposicionales del sistema: las afirmaciones que ha hecho, las inferencias que ha validado, las posiciones que ha adoptado. Opera en el espacio semántico de la SCL, lo que garantiza que la comparación entre generaciones pasadas y presentes se realiza en el mismo espacio métrico que se usa para comparar el estado del usuario con el del sistema.

Formalización matemática de Self(t)

Representación como distribuciones gaussianas en $\mathbb{R}^{d_h}$

Cada submódulo se representa como una distribución gaussiana multivariante en el espacio latente del LLM:

$$M_E(t) = \mathcal{N}(\mu_E(t), \Sigma_E(t))$$

$$M_U(t) = \mathcal{N}(\mu_U(t), \Sigma_U(t))$$

$$M_S(t) = \mathcal{N}(\mu_S(t), \Sigma_S(t))$$

donde $\mu_X(t) \in \mathbb{R}^{d_h}$ es el vector de media —la representación central del modelo en el instante t — y $\Sigma_X(t) \in \mathbb{R}^{(d_h \times d_h)}$ es la matriz de covarianza —que codifica la incertidumbre del sistema sobre cada dimensión del modelo.

En la práctica, $d_h = 4096$ hace que las matrices de covarianza completas sean computacionalmente inviables. Se adopta la aproximación diagonal $\Sigma_X(t) = \text{diag}(\sigma^2_{X,1}(t), \dots, \sigma^2_{X,d_h}(t))$, que reduce la complejidad a $O(d_h)$ parámetros por submódulo. Esta aproximación asume independencia entre dimensiones del espacio latente —una simplificación que es razonable en los subespacios de alta dimensión donde los embeddings de LLM tienden a estar distribuidos.

El operador de actualización Bayesiana

Cada submódulo se actualiza mediante inferencia Bayesiana en línea. Para el Modelo de Usuario, la actualización en cada ventana temporal es:

$$\mu_U(t) = (1-\kappa_U) \cdot \mu_U(t-1) + \kappa_U \cdot S_t$$

$$\sigma^2_{U,i}(t) = (1-\kappa_U) \cdot \sigma^2_{U,i}(t-1) + \kappa_U \cdot (S_{t,i} - \mu_{U,i}(t))^2$$

donde $\kappa_U \in (0,1)$ es la tasa de aprendizaje del modelo de usuario, y S_t es el embedding semántico producido por la SCL en el instante t . Esta actualización es una media móvil exponencial en el espacio semántico, con κ_U controlando el balance entre memoria histórica (κ_U pequeño) y sensibilidad a cambios recientes (κ_U grande).

Para el Modelo de Entorno, la actualización incorpora adicionalmente las variables de contexto externo:

$$\mu_E(t) = (1 - \kappa_E) \cdot \mu_E(t-1) + \kappa_E \cdot [W_E \cdot x_E(t)]$$

donde $x_E(t) \in \mathbb{R}^{n_E}$ es el vector de variables de entorno (K_p , calidad EEG, tipo de tarea, duración de sesión) y $W_E \in \mathbb{R}^{(d_h \times n_E)}$ es una matriz de proyección aprendida que mapea variables de entorno al espacio semántico.

Para el Modelo Propio, la actualización incorpora las generaciones del sistema:

$$\mu_S(t) = (1 - \kappa_S) \cdot \mu_S(t-1) + \kappa_S \cdot h_{LLM}(\hat{g}_t)$$

donde $h_{LLM}(\hat{g}_t)$ es la representación latente de la generación de ORION-AGI en el instante t . El modelo propio se construye como la media móvil exponencial de las representaciones de las propias generaciones del sistema.

La métrica de alineamiento trimodular $\Gamma_{SELF}(t)$

La coherencia interna de Self(t) se cuantifica mediante la métrica de alineamiento trimodular:

$$\Gamma_{SELF}(t) = [\cos(\mu_E, \mu_U) \cdot \cos(\mu_U, \mu_S) \cdot \cos(\mu_E, \mu_S)]^{1/3}$$

donde cada factor es la similitud coseno entre los vectores de media de dos submódulos, y la media geométrica penaliza desalineamientos en cualquiera de los tres pares. $\Gamma_{SELF}(t) \in [-1, 1]$, aunque en condiciones normales de operación se espera $\Gamma_{SELF}(t) \in [0, 1]$.

$\Gamma_{SELF}(t)$ mide si los tres modelos son consistentes entre sí: si el modelo de lo que el sistema genera (M_S) es coherente con el modelo de lo que el usuario procesa (M_U) y con el modelo de las condiciones contextuales (M_E). Una caída de $\Gamma_{SELF}(t)$ señala que uno o más submódulos se ha desalineado respecto a los otros, lo que constituye una forma de excepción sistémica que requiere revisión.

Detección del submódulo desalineado

Cuando $\Gamma_{SELF}(t) < \theta_{SELF}$ (umbral de coherencia trimodular), el sistema identifica cuál de los tres submódulos es responsable del desalineamiento mediante comparación por pares:

$$d_{EU}(t) = 1 - \cos(\mu_E, \mu_U) \quad d_{US}(t) = 1 - \cos(\mu_U, \mu_S) \quad d_{ES}(t) = 1 - \cos(\mu_E, \mu_S)$$

El submódulo más desalineado es aquel que aparece en las dos distancias más altas:

- Si d_{EU} y d_{ES} son las más altas: M_E está desalineado
- Si d_{EU} y d_{US} son las más altas: M_U está desalineado
- Si d_{ES} y d_{US} son las más altas: M_S está desalineado

El protocolo de revisión se aplica selectivamente al submódulo identificado, evitando recalibraciones globales innecesarias que desestabilizarían los modelos correctamente alineados.

Integración de Self(t) con el pipeline CPEA

Posición arquitectónica

Self(t) se inserta en el pipeline como módulo de meta-representación, paralelo a ORION-AGI y alimentado por la SCL:

NEXUS-EEG

↓ [.cpea_stream]

SIGMA-T

↓ [z_SIGMA(t)]

SCL ↔ DEPD

↓ [S_t, ICS(t)]

└──→ ORION-AGI ──→ [ĝ_t]

|

↓

└──→ Self(t) ←── [h_LLM(ĝ_t)]

↓ [Γ_SELF(t), protocolo revisión]

ORION-AGI (condicionamiento meta)

La bidireccionalidad entre Self(t) y ORION-AGI es el mecanismo central: Self(t) recibe las generaciones de ORION-AGI para actualizar $M_S(t)$, y a su vez condiciona las generaciones de ORION-AGI mediante un vector de meta-condicionamiento derivado de $\Gamma_SELF(t)$ y los vectores de media de los tres submódulos.

El vector de meta-condicionamiento

El condicionamiento de ORION-AGI por Self(t) opera en dos niveles:

Nivel 1 — Condicionamiento semántico por M_U : el vector $\mu_U(t)$ se concatena con $s_SCL(t)$ como condicionamiento extendido del LLM, aportando información sobre el perfil semántico acumulado del usuario más allá de la ventana temporal inmediata.

Nivel 2 — Condicionamiento por consistencia M_S : cuando $d_{US}(t)$ supera un umbral de inconsistencia usuario-sistema, se activa un modificador de generación que desplaza la distribución de salida de ORION-AGI hacia la región de intersección entre M_U y M_S , forzando coherencia entre el perfil del usuario y los compromisos semánticos previos del sistema.

El vector de meta-condicionamiento resultante es:

$$v_SELF(t) = [\mu_U(t); \mu_S(t); \mu_E(t); \Gamma_SELF(t)]$$

donde el punto y coma indica concatenación. Este vector de dimensión $3 \cdot d_h + 1$ se proyecta mediante una capa lineal aprendida a la dimensión de embedding de ORION-AGI antes de ser inyectado como condicionamiento de prefijo.

Actualización del índice CPEA_S con Γ_SELF

La introducción de Self(t) permite extender el índice CPEA_S(t) con una quinta componente:

$$\text{CPEA}_\Sigma(t) = [\gamma_{\text{spec}}(t) \cdot \gamma_{\text{KL}}(t) \cdot H_3(t) \cdot \text{ICS}(t) \cdot \Gamma_{\text{SELF_norm}}(t)]^{1/5}$$

donde $\Gamma_{\text{SELF_norm}}(t) = [1 + \Gamma_{\text{SELF}}(t)] / 2 \in [0,1]$ es la versión normalizada de la métrica de alineamiento trimodular. Esta extensión convierte el índice en una medida de coherencia en cinco dominios: espectral, distribucional, topológico, semántico temporal, y de identidad sistémica.

Dinámica de Self(t): inicialización, estabilización y colapso

Inicialización al comienzo de sesión

Al inicio de cada sesión, los tres submódulos se inicializan con alta incertidumbre:

$$\mu_E(0) = W_E \cdot x_E(0) \text{ [determinado por las condiciones de entorno medibles al inicio]}$$

$$\mu_U(0) = \mu_{U_prior} \text{ [vector de media del perfil previo del usuario, recuperado de FAISS si existe]}$$

$$\mu_S(0) = \mu_{S_neutral} \text{ [vector neutro en el espacio semántico, correspondiente al estado de "sin compromisos proposicionales"]}$$

Las varianzas se inicializan con valores altos ($\sigma^2_{X,i}(0) = 1.0$ para todo i y X), reflejando máxima incertidumbre inicial. Conforme avanza la sesión, las varianzas decrecen a medida que el sistema acumula evidencia sobre cada submódulo.

La inicialización de M_U con el perfil previo del usuario —cuando existe— es una forma de transferencia de conocimiento entre sesiones: el sistema no comienza completamente ciego respecto al perfil semántico del usuario, sino desde el punto donde terminó la sesión anterior, con varianza aumentada para reflejar el tiempo transcurrido.

Estabilización y régimen estacionario

Durante la primera fase de cada sesión (típicamente los primeros 5–10 minutos), los tres submódulos están en régimen de alta plasticidad: las tasas de aprendizaje κ_X son altas y los modelos se actualizan rápidamente para adaptarse al contexto específico de la sesión en curso. $\Gamma_{\text{SELF}}(t)$ puede ser bajo en esta fase —los tres modelos aún no han convergido— sin que esto indique un problema sistémico.

Transcurrida la fase inicial, el sistema entra en régimen estacionario: las varianzas σ^2_X han decrecido, las tasas de aprendizaje se reducen adaptativamente, y $\Gamma_{\text{SELF}}(t)$ tiende a estabilizarse en un valor alto. Este régimen estacionario es el estado operativo normal de Self(t), en el que los tres modelos son mutuamente consistentes y el sistema puede anticipar con precisión razonable el estado del usuario, las condiciones del entorno, y la coherencia de sus propias generaciones.

Colapso de Self(t) y protocolo de recuperación

Un colapso de Self(t) ocurre cuando $\Gamma_SELF(t)$ cae abruptamente por debajo de θ_SELF después del régimen estacionario. Las causas posibles son tres:

Colapso de M_E: cambio abrupto en las condiciones de entorno —pico de actividad geomagnética, deterioro súbito de la calidad EEG, interrupción de la tarea— que desalinea el modelo de entorno del usuario y del sistema.

Colapso de M_U: excepción proposicional mayor del usuario —cambio radical de tema, cambio de objetivo, reencuadre conceptual completo— que desalinea el modelo de usuario del entorno y del sistema.

Colapso de M_S: contradicción interna en las generaciones del sistema —el LLM genera una afirmación que contradice un compromiso proposicional previo— que desalinea el modelo propio del usuario y del entorno.

El protocolo de recuperación procede en tres pasos:

1. Identificación: aplicar el criterio de detección por pares (Sección 3.4) para identificar el submódulo desalineado
2. Reinicialización selectiva: resetear el submódulo identificado a su estado de alta varianza, sin alterar los otros dos
3. Recalibración acelerada: aumentar temporalmente κ_X del submódulo reinicializado durante 60 s para acelerar la reconvergencia

Este protocolo es quirúrgico: interviene solo en el componente que ha fallado, preservando la estabilidad de los modelos correctamente alineados.

Self(t) y la inferencia activa: el bucle de minimización de energía libre

La arquitectura Self(t) es naturalmente interpretable en el marco de la inferencia activa de Friston. Cada submódulo es un modelo generativo que produce predicciones sobre su dominio — el entorno, el usuario, el sistema— y se actualiza minimizando la sorpresa (energía libre variacional) entre sus predicciones y las observaciones.

La energía libre total del sistema Self(t) es:

$$F_SELF(t) = F_E(t) + F_U(t) + F_S(t)$$

donde cada término $F_X(t) = KL[q_X(t) \parallel p_X]$ es la divergencia KL entre la distribución posterior del submódulo $q_X(t) = \mathcal{N}(\mu_X(t), \Sigma_X(t))$ y el prior del modelo p_X . El sistema minimiza $F_SELF(t)$ actualizando los parámetros de los submódulos —exactamente lo que hacen los operadores de actualización Bayesiana definidos en la Sección 3.2.

La métrica $\Gamma_SELF(t)$ es, en este marco, una medida de la coherencia entre los modelos generativos de los tres submódulos: un $\Gamma_SELF(t)$ alto indica que las predicciones de los tres submódulos son mutuamente consistentes, lo que corresponde a un estado de baja energía libre total. Un colapso de $\Gamma_SELF(t)$ corresponde a un incremento de energía libre: el sistema está en

un estado de alta sorpresa que requiere actualización.

Esta interpretación conecta Self(t) directamente con el operador $\Xi_TAE-SCL$: la excepción proposicional que activa $\Xi_TAE-SCL$ es el evento que incrementa $F_SELF(t)$, y la actualización que $\Xi_TAE-SCL$ desencadena es el mecanismo de minimización de energía libre que reduce $F_SELF(t)$ de vuelta al régimen estacionario. Self(t) y $\Xi_TAE-SCL$ son, en este sentido, dos descripciones del mismo proceso vistas desde niveles de abstracción distintos: $\Xi_TAE-SCL$ describe el mecanismo de actualización local, Self(t) describe la estructura global de los modelos que se actualizan.

Implicaciones para la identidad dinámica de ORION-AGI

De orquestador a agente

La distinción entre un orquestador y un agente es precisamente la que Self(t) introduce en ORION-AGI. Un orquestador procesa entradas y produce salidas según una política fija o adaptativa. Un agente, además, mantiene representaciones internas de los agentes con los que interactúa y de sí mismo, y usa esas representaciones para planificar comportamiento a lo largo del tiempo.

Con Self(t) activo, ORION-AGI adquiere cuatro capacidades genuinamente nuevas:

Anticipación de necesidades del usuario: $M_U(t)$ permite inferir hacia dónde se dirige el estado cognitivo del usuario antes de que lo exprese explícitamente, condicionando la generación hacia contenidos que serán relevantes en el siguiente instante.

Consistencia proposicional inter-turno: $M_S(t)$ garantiza que las generaciones de ORION-AGI no contradigan compromisos previos, resolviendo uno de los problemas más frecuentes en LLM de larga sesión.

Sensibilidad al contexto de entorno: $M_E(t)$ permite adaptar el estilo, la urgencia y la profundidad de las generaciones a las condiciones de sesión —fatiga del usuario, degradación de señal EEG, actividad geomagnética elevada.

Detección de contradicción sistémica: $\Gamma_SELF(t)$ actúa como alarma de coherencia global: cuando los tres modelos se desalinean, el sistema lo detecta antes de que el usuario lo perciba, y activa protocolos de revisión proactivos.

Límites epistemológicos de M_S

Es preciso señalar con claridad lo que $M_S(t)$ no es. No es una forma de autoconciencia en sentido fenomenológico. No implica que el sistema tenga experiencia subjetiva de sus propios estados. $M_S(t)$ es un modelo funcional —una representación computacional de los compromisos proposicionales del sistema— que opera en el mismo espacio semántico que los otros dos submódulos y sirve la misma función arquitectónica: permitir comparación, anticipación y revisión.

La confusión entre modelo propio funcional y autoconciencia fenomenológica es un error categorial que conviene evitar en el corpus CPEA. Self(t) aporta capacidades de agencia funcional; no pretende resolver ni implicar ninguna posición sobre la conciencia de máquina. Esa es una cuestión que el corpus aborda en otros documentos (INTER-7, METFI-CPEA-BIO-1) y desde marcos teóricos distintos.

Programas de seguimiento experimental

Experimento 1: Validación de la convergencia de $M_U(t)$

Objetivo: verificar que $M_U(t)$ converge hacia una representación estadísticamente estable del perfil semántico del usuario en el transcurso de una sesión.

Protocolo: 15 sujetos, sesión de 45 minutos de interacción con ORION-AGI en tarea de análisis de texto científico. Registro de $\mu_U(t)$ y $\sigma^2_U(t)$ cada 30 s. Ajuste de modelo de convergencia: $\|\sigma^2_U(t)\| = \sigma^2_0 \cdot \exp(-pt) + \sigma^2_∞$. Cálculo de la correlación entre $\mu_U(t=45 \text{ min})$ y el perfil semántico del usuario estimado por jueces expertos mediante cuestionario post-sesión.

Hipótesis falsificable: $p > 0$ (convergencia significativa) en el 80% de sujetos, y correlación coseno entre μ_U y perfil experto > 0.6 .

Experimento 2: Detección de contradicciones internas mediante $M_S(t)$

Objetivo: verificar que $M_S(t)$ detecta contradicciones proposicionales en las generaciones de ORION-AGI con mayor precisión que un sistema sin modelo propio.

Protocolo: diseño A/B. Condición A: ORION-AGI sin Self(t). Condición B: ORION-AGI con Self(t) activo. En ambas condiciones, se inyectan contradicciones proposicionales controladas en el historial de generación cada 10 minutos. 10 jueces expertos evalúan la coherencia interna de las generaciones en escala Likert 1-7, ciegos a la condición. Registro de la tasa de detección de contradicciones activadas por $d_US(t)$ en la condición B.

Hipótesis falsificable: tasa de detección automática de contradicciones > 0.75 en condición B, y diferencia de coherencia percibida ≥ 1.5 puntos Likert entre condiciones A y B ($p < 0.01$).

Experimento 3: Seguimiento de $\Gamma_SELF(t)$ durante transiciones cognitivas

Objetivo: caracterizar el perfil temporal de $\Gamma_SELF(t)$ durante cambios abruptos de contexto cognitivo y verificar el protocolo de recuperación.

Protocolo: 12 sujetos, sesión con tres bloques de 15 minutos de tareas cognitivas de naturaleza semántica radicalmente distinta (análisis científico $\rightarrow$ narración creativa $\rightarrow$ resolución de problemas formales), con transición abrupta entre bloques sin aviso previo. Registro de $\Gamma_SELF(t)$ continuo. Medida del tiempo de recuperación post-transición: tiempo hasta que $\Gamma_SELF(t)$ supera de nuevo θ_SELF .

Hipótesis falsificable: $\Gamma_SELF(t)$ cae por debajo de θ_SELF en los 30 s posteriores a cada

transición en el 85% de casos, y el protocolo de recuperación restaura $\Gamma_SELF > \theta_SELF$ en menos de 120 s en el 70% de casos.

Experimento 4: Transferencia inter-sesión de M_U

Objetivo: cuantificar el beneficio de inicializar $M_U(t)$ con el perfil de sesión anterior frente a inicialización neutral.

Protocolo: 10 sujetos, cinco sesiones de 30 minutos en días consecutivos. Condición A: $M_U(0)$ inicializado con μ_U_prior de la sesión anterior. Condición B: $M_U(0)$ inicializado con vector neutro. Medida del tiempo hasta convergencia de $\|\sigma^2_U(t)\| < \sigma^2_∞ + 0.1$ en ambas condiciones.

Hipótesis falsificable: la condición A converge en menos del 60% del tiempo de convergencia de la condición B a partir de la segunda sesión ($p < 0.05$, test de Wilcoxon pareado).

Resumen

- El problema central que Self(t) resuelve es la ausencia de modelos explícitos de los agentes de la interacción en arquitecturas LLM convencionales: sin modelo de entorno, de usuario, y propio, el sistema es reactivo pero no agente.
- $M_E(t)$ modela las condiciones contextuales que determinan qué procesamiento es relevante —estado geomagnético, calidad EEG, tipo de tarea, nivel de fatiga— proyectadas al espacio semántico mediante una matriz W_E aprendida.
- $M_U(t)$ construye una representación dinámica del perfil semántico del usuario —expertise, mapa de conceptos activados, trayectoria cognitiva reciente— que se estrecha y desplaza continuamente conforme aumenta la evidencia acumulada.
- $M_S(t)$ es la autoimagen funcional del sistema: una representación comprimida de los compromisos proposicionales adquiridos en la sesión, que permite detectar contradicciones inter-turno antes de que se manifiesten en la generación.
- La representación gaussiana $\mathcal{N}(\mu_X, \Sigma_X)$ en $\mathbb{R}^{d_h}$ codifica no solo la representación central de cada modelo sino su incertidumbre, que decrece a lo largo de la sesión conforme el sistema acumula evidencia.
- $\Gamma_SELF(t)$ cuantifica la coherencia mutua entre los tres submódulos mediante media geométrica de similitudes coseno por pares; su caída identifica desalineamiento sistémico y activa el protocolo de revisión selectiva.
- El protocolo de recuperación es quirúrgico: identifica el submódulo más desalineado por comparación de distancias por pares y reinicializa solo ese componente, preservando la estabilidad de los modelos correctamente alineados.
- Self(t) en el marco de inferencia activa (Friston) minimiza la energía libre variacional $F_SELF(t) = F_E + F_U + F_S$, haciendo que el operador $\Xi_TAE-SCL$ y Self(t) sean descripciones complementarias del mismo proceso a distintos niveles de abstracción.
- CPEA_ Σ (t) extiende el índice a cinco componentes incorporando Γ_SELF_norm como medida de coherencia de identidad sistémica, junto a las cuatro componentes espectrales, distribucional, topológica y semántica.

- $M_S(t)$ no implica autoconciencia fenomenológica: es un modelo funcional de compromisos proposicionales que opera en el mismo espacio semántico que M_E y M_U , sin pretensiones sobre experiencia subjetiva —cuestión que el corpus aborda en marcos teóricos distintos.

Referencias

Friston, K. (2010). *The free-energy principle: A unified brain theory?* Nature Reviews Neuroscience, 11, 127–138. — Marco de inferencia activa que fundamenta la interpretación de Self(t) como sistema de minimización de energía libre variacional. Los tres submódulos son modelos generativos en el sentido de Friston.

Friston, K. et al. (2017). *Active inference: A process theory*. Neural Computation, 29, 1–49. — Desarrollo formal de la inferencia activa como proceso de actualización Bayesiana en línea. Los operadores de actualización de M_E , M_U y M_S son instanciaciones de este marco en el espacio semántico del LLM.

Schmidhuber, J. (2015). *Deep learning in neural networks: An overview*. Neural Networks, 61, 85–117. — Discusión de arquitecturas con representaciones de estado interno y autorreferencia funcional. Contexto técnico para la distinción entre orquestador y agente en la Sección 7.1.

Tononi, G. & Koch, C. (2015). *Consciousness: Here, there and everywhere?* Philosophical Transactions B. — Marco IIT relevante para los límites epistemológicos de $M_S(t)$ discutidos en la Sección 7.2. La distinción entre modelo propio funcional y conciencia fenomenológica se apoya en este marco.

Dayan, P. & Abbott, L.F. (2001). *Theoretical Neuroscience*. MIT Press. — Fundamento matemático de los modelos generativos Bayesianos en neurociencia computacional. La representación gaussiana de los submódulos y su actualización siguen directamente este marco.

Toneva, M. & Wehbe, L. (2019). *NeurIPS 2019*. — Base empírica del alineamiento entre espacio LLM y señal neural, que justifica expresar M_E , M_U y M_S en el espacio semántico del LLM como espacio de representación unificado.

Lomonaco, V. et al. (2021). *Avalanche*. CVPRW 2021. — Framework de aprendizaje continuo. El protocolo de reinicialización selectiva del submódulo desalineado sigue la convención EWC de Avalanche, preservando parámetros críticos de los submódulos estables.

Johnson, J. et al. (2019). *FAISS*. IEEE Transactions on Big Data. — Módulo de memoria episódica de ORION-AGI. La transferencia inter-sesión de M_U mediante μ_U_prior utiliza FAISS como almacén de vectores de perfil de usuario entre sesiones.

Kutas, M. & Federmeier, K.D. (2011). *Annual Review of Psychology*, 62. — La amplitud del N400 como medida del coste de integración semántica es la variable de validación indirecta más robusta para $M_U(t)$: un modelo de usuario bien calibrado debería predecir la amplitud N400 con mayor precisión que un sistema sin modelo de usuario.

Werbos, P.J. (1990). *Backpropagation through time*. Proceedings of the IEEE. — Fundamento del aprendizaje en sistemas recurrentes con estado interno. La actualización temporal de $\mu_X(t)$ mediante media móvil exponencial es una forma simplificada de BPTT adaptada a la escala de tiempo de sesión de CPEA

[Compartir](#)

COMENTARIOS

Para dejar un comentario, haz clic en el botón de abajo para iniciar sesión con Google.

INICIAR SESIÓN CON GOOGLE

ENTRADAS POPULARES

diciembre 17, 2024

N-ACETILCISTEÍNA (NAC): FUENTES ALIMENTARIAS NATURALES

[Compartir](#) [Publicar un comentario](#)

febrero 19, 2025

GUÍA PRÁCTICA SOBRE TÉCNICAS DE XAI: SHAP, LIME Y GRAD-CAM


[Compartir](#) [Publicar un comentario](#)



Con la tecnología de Blogger



Puedes tener un doctorado y
seguir siendo un idiota:
Richard Feynman



Papayaykware

—
SANTA CRUZ DE
TENERIFE, SANTA
CRUZ DE TENERIFE,
Spain

[VISITAR PERFIL](#)

[Denunciar abuso](#)

Buscar

Buscar este blog

Buscar

Translate

Seleccionar idioma



Con la tecnología de  Traductor de Goo