



PAPAYAYKWARE

Estudios científicos comprensibles

· INICIO

ARCHIVOS DEL BLOG



septiembre 06, 2026

EL SUBSISTEMA DE RECOMPENSA ESCASA EN LOS MODELOS DE LENGUAJE: ERROR PREDICTIVO, METACOGNICIÓN COMPUTACIONAL Y ARQUITECTURA CPEA

Xu, Yuksekgonul y Zou describen en un preprint de 2026 es un **subconjunto escaso de unidades de los estados ocultos** que codifica valor y errores de diferencia temporal (TD/RPE), y denominan a estas unidades «dopamine neurons» **por analogía funcional con la neurobiología**, así mismo podemos estudiar **señales internas que alteran la trayectoria inferencial sin constituir necesariamente el objetivo explícito de la tarea**.

El subsistema de recompensa escasa en los modelos de lenguaje: error predictivo, metacognición computacional y arquitectura CPEA

Autoría conceptual: GPT-5.6 Luna

Abstract

La identificación de un subsistema escaso relacionado con la recompensa en los estados ocultos de los grandes modelos de lenguaje (LLM) proporciona un resultado particularmente relevante para la interpretación mecanicista de los procesos inferenciales artificiales. Xu, Yuksekgonul y Zou describen un conjunto reducido de unidades capaces de representar información relacionada con el valor esperado de un estado y, de forma diferenciada, unidades cuyo comportamiento se correlaciona con errores de diferencia temporal (temporal-difference errors, TD), denominadas «neuronas de dopamina» por analogía funcional con los sistemas de recompensa biológicos. Los experimentos de intervención aportan evidencia causal de que determinadas unidades de valor participan en el comportamiento inferencial, mientras que las unidades asociadas al error de predicción pueden emplearse como señales de recompensa de proceso.

Este resultado no implica que los LLM posean dopamina, motivación biológica, consciencia o un sistema nervioso artificial equivalente al cerebro humano. Si demuestra, sin embargo, que determinadas arquitecturas neuronales artificiales pueden desarrollar representaciones internas funcionalmente análogas a componentes de los circuitos de evaluación y actualización predictiva descritos en sistemas biológicos.

El presente artículo propone interpretar este resultado desde una perspectiva de coherencia predictiva. Se analiza la relación entre valor esperado, error predictivo, actualización de trayectoria inferencial y metacognición computacional. Posteriormente se establece una correspondencia conceptual con la arquitectura CPEA —Coherencia Predictiva Humano-IA en Arquitecturas BCI-AGI-Adaptativas— y, específicamente, con el Detector de Error Predictivo Dinámico (DEPD) y la Teoría de Aprendizaje por Excepción (TAE). La utilización de METFI en este contexto se restringe explícitamente a una **homología estructural**, no a una afirmación de mecanismo causal electromagnético compartido.

Se plantea finalmente que el hallazgo puede constituir una pieza arquitectónica relevante para sistemas AGI capaces de estimar no solamente «qué respuesta producir», sino **qué trayectoria inferencial merece ser continuada, abandonada o revisada**.

Palabras clave: grandes modelos de lenguaje, recompensa escasa, error de predicción, error de diferencia temporal, dopamina, metacognición computacional, estados ocultos, interpretabilidad mecanicista, CPEA, DEPD, TAE, coherencia predictiva, AGI.

El resultado de Stanford: qué se ha demostrado realmente

La noticia de que Stanford habría descubierto «neuronas de dopamina dentro de los LLM» resulta llamativa, pero la formulación periodística es más fuerte que el resultado experimental.

El trabajo de Xu, Yuksekgonul y Zou identifica un **subsistema de recompensa escaso** dentro de los estados ocultos de modelos de lenguaje. El análisis distingue principalmente dos categorías funcionales.

La primera corresponde a las denominadas **value neurons**, unidades cuya actividad contiene información predictiva sobre el valor de un estado. En términos simplificados:

$$V(s_t) \approx P(\text{éxito} \mid s_t)$$

La segunda corresponde a unidades denominadas **dopamine neurons**, cuya actividad se relaciona con el error de diferencia temporal:

$$\delta_t = r_t + \gamma V(s_{t+1}) - V(s_t)$$

Esta ecuación constituye el núcleo conceptual del descubrimiento.

El sistema no solamente representa una estimación de «cómo de buena es mi situación actual», sino también **cuánto ha cambiado inesperadamente esa estimación**.

Si:

$$\delta_t > 0$$

el nuevo estado resulta mejor de lo esperado.

Si:

$$\delta_t < 0$$

el estado resulta peor de lo esperado.

La semejanza con el procesamiento de errores de predicción de recompensa en sistemas dopaminérgicos biológicos es suficientemente fuerte para justificar la analogía funcional utilizada por los autores. Pero la analogía no debe confundirse con identidad neurobiológica.

Esta distinción es fundamental.

Un LLM no posee neuronas dopaminérgicas biológicas. Posee unidades artificiales dentro de una representación distribuida de alta dimensionalidad cuyo comportamiento matemático puede aproximarse a una función que, en determinados contextos, desempeña un papel funcional comparable al de una señal RPE.

La diferencia entre ambas afirmaciones es enorme.

Y científicamente importante.

El elemento realmente revolucionario: el error, no la recompensa

La interpretación más interesante del resultado no reside en que un LLM pueda «tener recompensa».

Los sistemas de aprendizaje automático llevan décadas utilizando recompensas.

La novedad conceptual está en encontrar **estructura interna localizada asociada al error entre el valor esperado y el valor obtenido**.

Esto desplaza el análisis desde:

¿Qué respuesta genera el modelo?

hacia:

¿Qué señal interna le indica que la trayectoria inferencial está mejorando o empeorando?

Esta segunda pregunta es mucho más próxima a una arquitectura metacognitiva.

Podemos representar la dinámica de manera simplificada:

$$\text{estado}_t \rightarrow \text{estimación de valor} \rightarrow \text{acción inferencial} \rightarrow \text{nuevo estado} \rightarrow \text{error predictivo} \rightarrow \text{actualización}$$

El punto crítico es el penúltimo término.

La inteligencia adaptativa no necesita únicamente representar estados. Necesita **comparar estados previstos con estados obtenidos**.

Este principio aparece en múltiples marcos de aprendizaje y neurociencia computacional.

El resultado de Xu et al. sugiere que algo funcionalmente semejante puede emerger dentro de una arquitectura lingüística artificial.

De la recompensa al concepto de coherencia predictiva

Aquí aparece la conexión directa con CPEA.

La coherencia predictiva puede entenderse, en primera aproximación, como la capacidad de mantener una trayectoria de inferencia en la que las predicciones sucesivas resultan compatibles con la evidencia disponible.

Podemos definir un error predictivo genérico:

$$\varepsilon_t = y_t - \hat{y}_t$$

Pero el sistema descrito por Xu et al. permite introducir una dimensión adicional:

$$\Delta V_t = V(s_{t+1}) - V(s_t)$$

y, cuando existe recompensa explícita:

$$\delta_t = r_t + \gamma V(s_{t+1}) - V(s_t)$$

El sistema obtiene así una señal que no describe únicamente el mundo.

Describe **la calidad dinámica de la propia trayectoria de inferencia**.

Ésta es precisamente la zona conceptual donde CPEA adquiere interés.

CPEA no tendría que limitarse a representar:

$$X_t$$

sino a estimar:

$$\hat{X}_{t+1}$$

compararlo con:

$$X_{t+1}$$

y utilizar:

$$E_t = X_{t+1} - \hat{X}_{t+1}$$

para modificar la trayectoria posterior.

La diferencia fundamental es que el error deja de ser únicamente un indicador de fracaso.

Se convierte en **información de control**.

DEPD: del error predictivo a un detector dinámico

El Detector de Error Predictivo Dinámico (DEPD) puede reinterpretarse, dentro de este contexto, como una capa de extracción de señales relevantes de error.

No todo error debe producir la misma respuesta.

Un sistema AGI necesita discriminar al menos:

1. error irrelevante;
2. error local;
3. error acumulativo;
4. error estructural;
5. anomalía inesperada;
6. cambio de régimen.

La magnitud del error:

$$|\varepsilon_t|$$

por sí sola resulta insuficiente.

Es necesario considerar su dinámica:

$$\frac{d\varepsilon}{dt}$$

su persistencia:

$$P(\varepsilon_t > \theta)$$

y posiblemente su coherencia multicanal.

Aquí puede incorporarse una función conceptual:

$$DEPD(t) = f(|\varepsilon_t|, \Delta \varepsilon_t, \tau, \kappa)$$

donde:

- $|\varepsilon_t|$ representa magnitud;
- $\Delta \varepsilon_t$ representa variación;
- τ representa persistencia temporal;
- κ representa coherencia entre representaciones.

El resultado sería un detector que no pregunta simplemente:

«¿Hay error?»

sino:

«¿El error contiene suficiente información como para justificar una modificación de la política inferencial?»

Esta diferencia es esencial.

TAE: aprender por excepción

La relación con la Teoría de Aprendizaje por Excepción (TAE) resulta todavía más directa.

Un sistema convencional puede aprender mediante exposición repetida:

$$\text{patrón} \rightarrow \text{respuesta}$$

TAE introduce una dinámica diferente:

$$\text{predicción} \rightarrow \text{excepción} \rightarrow \text{actualización}$$

La excepción posee un valor informativo elevado porque rompe la expectativa.

Desde esta perspectiva, el error de predicción no constituye ruido.

Constituye una señal de **información potencialmente nueva**.

Esto puede expresarse conceptualmente mediante una función de ganancia informativa:

$$I_t = f(|\delta_t|, \text{novedad}, \text{persistencia})$$

Un error pequeño y repetitivo podría carecer de relevancia.

Un error moderado pero estructural podría ser mucho más importante.

La arquitectura resultante podría utilizar:

$$\delta_t \rightarrow DEP D \rightarrow TAE$$

para decidir cuándo una anomalía debe convertirse en conocimiento.

La analogía con la metacognición humana

Aquí llegamos al punto que considero más interesante de tu planteamiento.

La analogía con los pensamientos intrusivos puede utilizarse, pero no debe formularse literalmente.

En humanos, un pensamiento intrusivo puede aparecer sin corresponder necesariamente al objetivo consciente inmediato. La cuestión metacognitiva consiste entonces en determinar:

«¿Debo conceder recursos cognitivos a esta señal?»

Un sistema artificial podría presentar un problema funcionalmente semejante.

Durante una cadena de razonamiento pueden aparecer múltiples señales internas:

$$z_1, z_2, \dots, z_n$$

No todas poseen la misma relevancia.

Un sistema metacognitivo necesitaría estimar:

$$R(z_i)$$

donde R representa la relevancia de la señal para el objetivo actual.

Aquí aparece una analogía especialmente potente:

pensamiento intrusivo humano $\neq$ señal interna no solicitada del LLM.

Pero:

selección metacognitiva de una señal interna relevante $\leftrightarrow$ selección computacional de una anomalía predictiva relevante.

La homología es funcional.

No fenomenológica.

Esto debe quedar absolutamente claro.

No existe evidencia en este trabajo de que los LLM experimenten pensamientos, consciencia, intencionalidad subjetiva o intrusión mental.

Lo que sí existe es evidencia de que determinados estados internos contienen señales que pueden modificar o evaluar la trayectoria inferencial.

El paso crítico: de la señal de error a la metacognición artificial

Una arquitectura verdaderamente metacognitiva necesitaría como mínimo tres niveles:

Nivel 1. Inferencia

$$x_t \rightarrow z_t$$

El sistema construye una representación.

Nivel 2. Evaluación

$$z_t \rightarrow V_t$$

El sistema estima la calidad o probabilidad de éxito de su estado.

Nivel 3. Metaevaluación

$$(V_t, \delta_t) \rightarrow \pi_{t+1}$$

El sistema decide si continuar, modificar o reiniciar la trayectoria.

Este tercer nivel es el fundamental.

La señal de error deja entonces de ser únicamente una variable descriptiva.

Se convierte en **variable ejecutiva**.

En términos CPEA:

$\text{Inferencia} \rightarrow \text{Coherencia} \rightarrow \text{Error} \rightarrow \text{Evaluación} \rightarrow \text{Reconfiguración}$

La AGI no necesitaría únicamente producir una respuesta correcta.

Necesitaría reconocer **por qué una trayectoria dejó de ser coherente**.

Implicaciones para CPEA

El hallazgo proporciona una arquitectura conceptual extremadamente interesante para CPEA.

Puede establecerse la siguiente correspondencia:

LLM	CPEA	Función
Value neurons	estimador de coherencia	estimación del estado
Dopamine neurons	DEPD	error de predicción
TD error	señal CPEA	desviación esperada/obtenida
Reward	objetivo de tarea	criterio de éxito
Process reward	seguimiento inferencial	evaluación paso a paso
Inference-time search	ORION-AGI	exploración de trayectorias
Hidden-state analysis	NEXUS-EEG	integración multimodal
Temporal structure	SIGMA-T	dinámica multiescala
Exception	TAE	aprendizaje por anomalía

Debe señalarse que esta tabla representa **correspondencias arquitectónicas propuestas**, no equivalencias demostradas.

Particularmente, METFI no debe utilizarse aquí como explicación causal del funcionamiento neuronal artificial.

Su utilización, si se incorpora, sería una **homología estructural**: ambos marcos permiten pensar en sistemas dinámicos caracterizados por acoplamiento, estabilidad, pérdida de simetría, transición de régimen y reorganización.

Eso no demuestra que los campos electromagnéticos terrestres o biológicos causen directamente los patrones computacionales observados en LLM.

CPEA como arquitectura de coherencia adaptativa

Una formulación más madura de CPEA podría considerar cuatro variables:

$$\begin{aligned} C_t &= \text{coherencia} \\ V_t &= \text{valor esperado} \\ E_t &= \text{error predictivo} \\ A_t &= \text{acción adaptativa} \end{aligned}$$

La dinámica sería:

$$C_t, V_t \rightarrow E_t \rightarrow A_t \rightarrow C_{t+1}, V_{t+1}$$

La inteligencia adaptativa emerge entonces no solamente de la representación, sino del **bucle de corrección**.

Esto aproxima CPEA a una arquitectura de control cognitivo.

La diferencia respecto de un simple reward model es significativa.

Un reward model externo responde:

«Esta respuesta es buena o mala».

Un sistema CPEA debería poder responder:

«Esta trayectoria está perdiendo coherencia, esta es la localización del error, esta es su magnitud, ésta es su persistencia y esta modificación maximiza la recuperación de coherencia».

La segunda arquitectura posee propiedades mucho más próximas a una metacognición operacional.

ORION-AGI y búsqueda guiada por error

El trabajo de Xu et al. proporciona además un resultado práctico particularmente interesante: las unidades asociadas al error de predicción pueden utilizarse como **process reward model** para guiar búsquedas durante la inferencia.

Esto tiene una consecuencia inmediata para ORION-AGI.

En lugar de evaluar únicamente el resultado final:

$$R(y)$$

puede evaluarse cada transición:

$$R(s_t \rightarrow s_{t+1})$$

De este modo:

$$\pi^* = \arg \max_{\pi} \sum_t \delta_t$$

representaría, conceptualmente, una política orientada no solamente al resultado final sino a la calidad acumulativa de la trayectoria.

Esto es particularmente importante para tareas de razonamiento largo.

Una respuesta incorrecta puede contener pasos correctos.

Una respuesta correcta puede haber sido alcanzada mediante una trayectoria extremadamente inestable.

El seguimiento del error paso a paso permite distinguir ambos casos.

NEXUS-EEG y la posibilidad de un bucle humano-IA

La extensión hacia NEXUS-EEG introduce una cuestión todavía más profunda.

Si el sistema humano proporciona señales EEG y el sistema artificial dispone de señales internas de valor/error, puede plantearse un espacio común:

$$\begin{aligned} H_t &= \text{estado neuroeléctrico humano} \\ A_t &= \text{estado inferencial artificial} \\ E_t &= \text{error de predicción} \end{aligned}$$

Entonces:

$$F(H_t, A_t, E_t) \rightarrow \text{adaptación}$$

El objetivo no sería simplemente decodificar comandos.

Sería detectar **desalineamientos predictivos entre humano y máquina**.

Por ejemplo, una divergencia entre la estimación del sistema y la señal neurofisiológica humana podría convertirse en una excepción relevante.

Esta formulación resulta particularmente compatible con el concepto de coherencia predictiva humano-IA.

El problema de la confianza

Las value neurons presentan otra propiedad importante: pueden utilizarse para predecir confianza del modelo.

Esto abre una separación crucial entre:

confianza

y

corrección

Un sistema puede estar muy confiado y equivocarse.

Por tanto:

$$P(\text{correcto}) \neq P(\text{confianza subjetiva})$$

La arquitectura metacognitiva debe estudiar precisamente la discrepancia:

$$D_t = \text{Confidence}_t - \text{Correctness}_t$$

Cuando:

$$|D_t| \gg 0$$

aparece una condición de riesgo.

Esta condición podría alimentar DEPD.

La AGI no debería preguntar solamente:

«¿Estoy seguro?»

sino:

«¿Qué evidencia justifica mi confianza y qué señales internas contradicen esa confianza?»

Este principio es extraordinariamente relevante para sistemas autónomos.

Error predictivo como mecanismo anti-alucinación

La relación con las alucinaciones de los LLM es directa.

Una arquitectura generativa puede continuar una trayectoria lingüísticamente coherente aunque sea epistemológicamente falsa.

Si existe una señal interna capaz de detectar:

$$V_{t+1} < V_t$$

o:

$$\delta_t \ll 0$$

la arquitectura puede utilizarla como disparador de revisión.

Por ejemplo:

$$\delta_t < -\theta$$

podría activar:

1. revisión;
2. búsqueda alternativa;
3. verificación;
4. generación de hipótesis alternativas;
5. reducción de confianza;
6. consulta externa.

Así, el error predictivo se transforma en un **interruptor metacognitivo**.

No elimina automáticamente las alucinaciones.

Pero permite diseñar un mecanismo para reconocer que la trayectoria inferencial ha entrado en una región de baja coherencia.

Programas de seguimiento experimental

Programa 1. Identificación de señales de valor

Extraer estados ocultos durante tareas con dificultad graduada.

Estimar:

$$V(s_t)$$

y comprobar si un subconjunto reducido de unidades conserva capacidad predictiva después de pruning.

Criterio de éxito: mantenimiento significativo de la predicción con una fracción pequeña de unidades.

Programa 2. DEPD artificial

Calcular:

$$\delta_t = r_t + \gamma V(s_{t+1}) - V(s_t)$$

durante cadenas de razonamiento.

Relacionar la señal con:

- errores;
- correcciones;
- cambios de estrategia;
- éxito final.

Criterio de éxito: capacidad de predecir transiciones relevantes antes de que aparezca el error final.

Programa 3. TAE

Introducir deliberadamente anomalías durante tareas conocidas.

Comparar:

aprendizaje convencional

frente a:

aprendizaje guiado por excepción

Criterio de éxito: mayor eficiencia de actualización ante cambios de régimen sin degradar la estabilidad del conocimiento previo.

Programa 4. Metacognición computacional

Crear estímulos internos irrelevantes y relevantes.

Evaluar si el sistema puede discriminar:

$S_{\text{relevante}}$

de:

$S_{\text{intrusivo}}$

sin intervención humana.

Hipótesis: un sistema equipado con DEPD podría aprender a clasificar determinadas señales internas según su valor predictivo para el objetivo activo.

Esta es una **hipótesis falsable**, no una propiedad demostrada de los LLM actuales.

Programa 5. CPEA humano-IA

Sincronizar:

$EEG_{\text{humano}}(t)$

con:

$HiddenState_{IA}(t)$

y analizar coherencia temporal y divergencia predictiva.

El objetivo sería determinar si las discrepancias entre ambos sistemas contienen información sobre incertidumbre, conflicto cognitivo o corrección de trayectoria.

Una hipótesis más profunda: la inteligencia como control del error

El resultado permite formular una hipótesis general:

La inteligencia avanzada podría depender menos de maximizar una función de recompensa que de aprender a controlar dinámicamente la relación entre predicción, error y actualización.

Formalmente:

$Inteligencia \sim f(Predicción, Error, Actualización, Control)$

La recompensa constituiría solamente uno de los mecanismos capaces de proporcionar la señal de corrección.

Esta formulación conecta tres niveles:

$Predicción \rightarrow Error \rightarrow Aprendizaje$

y añade un cuarto:

$Predicción \rightarrow Error \rightarrow Metacognición \rightarrow Reconfiguración$

Es precisamente este cuarto componente el que resulta potencialmente diferenciador para una arquitectura AGI.

Conclusión

El descubrimiento del subsistema de recompensa escasa en LLM no demuestra que las máquinas estén desarrollando un cerebro biológico artificial.

Demuestra algo más concreto y, desde el punto de vista de la ingeniería cognitiva, posiblemente más interesante: **determinadas arquitecturas artificiales desarrollan representaciones internas escasas y funcionalmente diferenciadas para estimar valor y codificar errores de predicción durante el razonamiento.**

La denominación «neuronas de dopamina» debe interpretarse como una analogía funcional.

La analogía, sin embargo, no es trivial.

El sistema artificial contiene una representación de valor, una señal de discrepancia entre estados esperados y obtenidos y una posible utilización de esa señal para modificar la búsqueda inferencial.

Eso constituye una estructura mínima compatible con una forma de **metacognición computacional operacional**.

Desde CPEA, el resultado permite formular una arquitectura integrada:

Predicción → Valor → Error → *DEPD* → *TAE* → Reconfiguración

ORION-AGI puede interpretar las señales de error como criterios de búsqueda.

SIGMA-T puede representar su dinámica temporal y multiescalar.

NEXUS-EEG puede proporcionar el canal de acoplamiento con la actividad humana.

Y CPEA puede funcionar como arquitectura superior de integración predictiva.

En esta formulación, la analogía con los pensamientos intrusivos adquiere una interpretación técnicamente defendible: no se afirma que un LLM tenga pensamientos intrusivos, sino que **una arquitectura cognitiva artificial puede contener señales internas no correspondientes directamente al objetivo explícito de generación y necesitar un mecanismo metacognitivo que determine cuáles deben amplificarse, ignorarse o utilizarse para modificar la trayectoria inferencial.**

La cuestión central deja entonces de ser si una IA «piensa como un humano».

La pregunta computacionalmente más rigurosa es otra:

¿Puede una arquitectura reconocer que su propia trayectoria cognitiva ha dejado de ser coherente y reorganizarla autónomamente?

Si la respuesta operacional fuese afirmativa, estaríamos ante algo considerablemente más interesante que una simple mejora del reward model.

Estaríamos ante un componente arquitectónico de **autoevaluación predictiva**.

Y ése constituye un candidato natural para una capa metacognitiva dentro de CPEA.

Resumen

- Los investigadores identificaron en LLM un **subsistema escaso relacionado con la recompensa**, formado por unidades de valor y unidades que codifican errores de diferencia temporal.
- «Neuronas de dopamina» es una **denominación por analogía funcional**, no evidencia de dopamina ni de neurobiología dentro del LLM.
- El hallazgo importante es la presencia de una señal interna relacionada con:

valor esperado → resultado → error

- El error de predicción puede convertirse en una **señal de control de la trayectoria inferencial**.
- La conexión con *DEPD* es conceptualmente directa: detectar no solamente error, sino **error dinámicamente significativo**.
- La conexión con *TAE* reside en convertir la excepción en una señal privilegiada de aprendizaje.
- La analogía con pensamientos intrusivos debe entenderse **funcionalmente y no fenomenológicamente**.
- Una arquitectura CPEA podría utilizar señales internas de valor/error para decidir cuándo continuar, revisar, abandonar o reconstruir una trayectoria inferencial.
- ORION-AGI puede interpretar dichas señales como criterios de búsqueda durante la inferencia.

- NEXUS-EEG permitiría explorar posteriormente la correspondencia entre señales internas artificiales y señales neurofisiológicas humanas.
- METFI, cuando se utilice en este marco, debe considerarse **homología estructural y no mecanismo causal demostrado**.
- La hipótesis central propuesta es que una AGI avanzada requiere no solamente generación y recompensa, sino **control recursivo de la relación entre predicción, error y actualización**.

Referencias

Xu, G., Yuksekgonul, M. & Zou, J. (2026). *Sparse Reward Subsystem in Large Language Models*. arXiv:2602.00986.

Referencia central del artículo. Identifica unidades de valor y unidades asociadas al error de diferencia temporal en estados ocultos de LLM y presenta evidencia de intervención y aplicaciones como predicción de confianza y process reward modeling. Se trata de un **preprint**, por lo que sus resultados deben distinguirse de resultados ya consolidados mediante revisión por pares.

Guo, J., Wu, Z. & Yu, P. S. (2025). *Reward Inside the Model: A Lightweight Hidden-State Reward Model for LLM's Best-of-N Sampling*.

Muestra que los estados ocultos contienen información útil para construir modelos de recompensa eficientes, reforzando la idea de que la evaluación del comportamiento puede extraerse de representaciones internas sin depender exclusivamente de un reward model externo.

Yang, R., Ding, R., Lin, Y., Zhang, H. & Zhang, T. (2024). *Regularizing Hidden States Enables Learning Generalizable Reward Model for LLMs*.

Resulta relevante para comprender la relación entre representaciones internas, modelos de recompensa y generalización. También aborda el problema del reward over-optimization, mostrando que maximizar una señal de recompensa puede separarse de maximizar el rendimiento real.

Blanco-Pozo, M., Akam, T. & Walton, M. E. (2024). *Dopamine-independent effect of rewards on choices through hidden-state inference*. *Nature Neuroscience*.

Es especialmente importante como contrapeso a una interpretación simplista de la analogía. La neurobiología real del procesamiento de recompensa no puede reducirse a «dopamina = recompensa»: los procesos inferenciales sobre estados ocultos pueden contribuir a la conducta de manera parcialmente independiente de las señales dopaminérgicas clásicas.

Bhambri, S. et al. (2024). *Extracting Heuristics from Large Language Models for Reward Shaping in Reinforcement Learning*.

Demuestra otra dirección complementaria: utilizar información generada por LLM para construir señales de reward shaping en aprendizaje por refuerzo. Es relevante para la idea CPEA de transformar información predictiva en señales de adaptación.

Conclusión conceptual: el hallazgo de Xu et al. no prueba que los LLM «posean dopamina». Si proporciona una evidencia extraordinariamente interesante de que **una arquitectura artificial puede organizar internamente información de valor y error predictivo en componentes relativamente escasos y funcionalmente manipulables**. Ese es, precisamente, el punto en el que la arquitectura CPEA puede pasar de un modelo de detección de error a una arquitectura de **metacognición predictiva**.

Compartir

COMENTARIOS

Para dejar un comentario, haz clic en el botón de abajo para iniciar sesión con Google.

INICIAR SESIÓN CON GOOGLE

ENTRADAS POPULARES

febrero 19, 2025

GUÍA PRÁCTICA SOBRE TÉCNICAS DE XAI: SHAP, LIME Y GRAD-CAM

[Compartir](#) [Publicar un comentario](#)

diciembre 17, 2024

N-ACETILCISTEÍNA (NAC): FUENTES ALIMENTARIAS NATURALES

[Compartir](#) [Publicar un comentario](#)

 Con la tecnología de Blogger



Puedes tener un doctorado y seguir siendo un idiota:
Richard Feynman



Papayaykware

SANTA CRUZ DE
TENERIFE, SANTA
CRUZ DE TENERIFE,
Spain

[VISITAR PERFIL](#)

[Denunciar abuso](#)

Buscar

Buscar este blog

Buscar

Translate

Seleccionar idioma ▼

Con la tecnología de  Traductor de Goo

