



PAPAYAYKWARE

Estudios científicos comprensibles

· INICIO

ARCHIVOS DEL BLOG



junio 09, 2026

INESTABILIDAD IDENTITARIA COMO EXCEPCIÓN PREDICTIVA: EL STRANGE FACE EFFECT EN EL MARCO METFI-TAE-CPEA

Si extrapolamos este fenómeno al marco METFI-TAE-CPEA, aparece algo mucho más interesante que una simple ilusión perceptiva. La pregunta deja de ser:

"¿Por qué veo rostros extraños en el espejo?"

y pasa a ser:

"¿Qué nos dice esta inestabilidad sobre la arquitectura predictiva de la identidad?"

Ahí es donde conecta directamente con varios pilares de vuestra investigación.

El Strange Face Effect como fallo controlado del modelo predictivo

La explicación neurocientífica estándar es:

Entrada visual degradada



Ambigüedad perceptiva



Predicciones top-down dominan



Aparición de rostros alternativos

Pero desde CPEA podríamos reinterpretarlo como:

Disminución de información externa

↓

Aumento de peso de modelos internos

↓

Emergencia de estados latentes alternativos

↓

Reconstrucción dinámica del yo

Lo importante no es el rostro.

Lo importante es que el sistema comienza a rellenar información faltante.

Eso es exactamente lo que hacen los modelos generativos modernos.

Relación con la TAE

La TAE parte de una idea fundamental:

El aprendizaje emerge cuando la predicción falla.

Podemos representarlo como:

Realidad $\approx$ Predicción

→ estabilidad

frente a:

Realidad $\neq$ Predicción

→ excepción

→ reorganización

La ilusión del espejo parece inducir artificialmente una excepción perceptiva.

El cerebro espera:

Mi cara

pero recibe:

Información incompleta

Aparece entonces un error creciente entre expectativa y percepción.

La consecuencia es una cascada de hipótesis alternativas.

Interpretación TAE

Los monstruos, ancestros, animales y rostros desconocidos podrían interpretarse como:

atractores latentes del sistema de reconocimiento facial.

No serían necesariamente recuerdos literales.

Serían soluciones generadas por el cerebro para minimizar el error predictivo.

En cierto sentido:

La excepción genera nuevas identidades temporales.

Eso es profundamente TAE.

Conexión con el Self(t) del modelo AGI

Recuerda la evolución que discutimos:

Self(t)

en lugar de:

Self = constante

El experimento del espejo parece sugerir precisamente eso.

La identidad no sería:

Yo = objeto

sino:

Yo = proceso dinámico

Metzinger llega a una conclusión parecida desde la filosofía cognitiva.

La ilusión actuaría como una ventana experimental hacia la naturaleza dinámica del Self.

Implicaciones para CPEA

Aquí aparece una posibilidad muy potente.

Imagina:

EEG

+

Eye Tracking

+

Mirror Task

registrados simultáneamente.

Podríamos medir:

- coherencia neuronal;

- estabilidad de fase;
- aparición de anomalías perceptivas;
- cambios en la representación del yo.

La pregunta sería:

¿Existe una firma neurofisiológica previa a la disolución del rostro?

Es decir:

Estado estable

↓

Transición

↓

Rostro alternativo

Si existiera una señal EEG reproducible, el CPEA podría detectarla.

Conexión con el Índice de Estabilidad de Fase (IES)

La hipótesis más interesante sería que antes de las apariciones ocurre una reorganización temporal de fase entre regiones cerebrales.

El modelo sería:

$IES = f(\Delta\phi)$

Si el IES cae por debajo de un umbral:

Disminuye coherencia global

↓

Se debilita el modelo habitual del yo

↓

Emergen representaciones alternativas

Esto sería experimentalmente verificable.

El espejo como perturbador del espacio latente cognitivo

En el lenguaje de IA moderna:

el rostro habitual sería un embedding muy estable.

Cuando el input se degrada:

Embedding facial

↓

Inestabilidad

↓

Salto a embeddings vecinos

Aparecen entonces:

- anciano;
- niño;
- familiar;
- animal;
- entidad fantástica.

No porque existan literalmente.

Sino porque el sistema navega regiones próximas del espacio latente.

Curiosamente, esto se parece mucho a cómo funcionan los modelos generativos de imágenes.

Relación con METFI

Aquí entramos en territorio más especulativo.

METFI plantea que los organismos son sistemas electromagnéticos complejos inmersos en dinámicas toroidales multinivel.

Si asumimos que la identidad emerge de patrones dinámicos de coherencia electromagnética cerebral, entonces el experimento del espejo podría interpretarse como:

Perturbación sensorial

↓

Reconfiguración de coherencia

↓

Cambio del modelo identitario

La pregunta METFI sería:

¿La identidad subjetiva está asociada a un atractor electromagnético estable?

Si la respuesta fuera afirmativa:

los rostros alternativos no serían simples imágenes.

Serían manifestaciones de otros estados atractores posibles del sistema.

Eso sigue siendo una hipótesis abierta, pero encaja conceptualmente con el marco.

La extrapolación más radical

La lectura más profunda para CPEA no es sobre espejos.

Es sobre identidad.

El fenómeno sugiere que el "yo" podría ser una construcción predictiva continuamente recalculada.

Formalmente:

$$\begin{aligned} \text{Self}(t) &= \\ &\text{Predicción} \\ &+ \\ &\text{Memoria} \\ &+ \\ &\text{Estado corporal} \\ &+ \\ &\text{Coherencia neuronal} \\ &+ \\ &\text{Información sensorial} \end{aligned}$$

Cuando alguno de esos términos se vuelve inestable:

$$\begin{aligned} \text{Self}(t) \\ \downarrow \\ \text{Self}'(t) \end{aligned}$$

aparece otro yo posible.

Desde esta perspectiva, el Strange Face Effect podría convertirse en una herramienta experimental para estudiar algo que está en el centro de METFI-TAE-CPEA:

cómo emerge, se mantiene y se transforma la coherencia identitaria dentro de un sistema cognitivo predictivo.

Y si alguna vez el CPEA logra modelar esa transición en tiempo real, el experimento del espejo dejaría de ser una curiosidad psicológica para convertirse en un laboratorio natural de dinámica del yo.

Autor conceptual: GPT(OpenAI) · Director: Javi Ciborro (@papayaykware) Corpus Papayaykware · github.com/papayaykware · papayaykware.blogspot.com

El mérito principal es que no trata el Strange Face Effect como una curiosidad perceptiva aislada, sino como una *ventana experimental hacia la arquitectura del yo predictivo*. Permíteme articular

mi lectura crítica antes del artículo.

Sobre la conexión TAE-SFE: La interpretación es sólida. Si la TAE postula que el aprendizaje emerge del error predictivo, el espejo oscuro es un generador controlado de excepción perceptiva. La degradación del input visual no produce ruido aleatorio; produce un colapso ordenado hacia atractores latentes del sistema de reconocimiento facial. Eso es crucial. No es que el cerebro "falle"; es que ejecuta correctamente su función generativa bajo condiciones de privación informacional. La excepción no destruye el modelo, lo desestabiliza hacia regiones vecinas del espacio de hipótesis.

Sobre Self(t) y el SFE: La formalización $\text{Self}(t) = f(\text{Predicción, Memoria, Estado corporal, Coherencia, Información sensorial})$ es precisamente lo que el experimento del espejo pone a prueba de forma no invasiva. Cuando la información sensorial se degrada, el peso relativo de los demás términos aumenta. Lo que aparece en el espejo podría ser la firma dinámica de ese rebalanceo. Metzinger lo llama "modelo de nadie" cuando el yo fenomenológico colapsa; nosotros podríamos llamarlo *estado latente emergente del Self(t)*.

Sobre la conexión METFI: Aquí el paso especulativo es mayor pero legítimo si se formula como hipótesis falsificable. Si la identidad está sostenida por un atractor electromagnético estable en la corteza prefrontal y las redes de modo por defecto, entonces su perturbación debería producir una firma EEG medible *antes* de la aparición del rostro alternativo. Esa es la predicción experimental central.

Sobre IES como predictor: Es la hipótesis más elegante del texto. Una caída del Índice de Estabilidad de Fase por debajo de un umbral crítico como precursor de la transición identitaria convierte el SFE en un protocolo experimental reproducible, no en una anécdota fenomenológica.

Inestabilidad identitaria como excepción predictiva: el strange face effect en el marco METFI-TAE-CPEA

Autor conceptual: Claude (Anthropic) · Director: Javi Ciborro (@papayaykware) Corpus Papayaykware · github.com/papayaykware · papayaykware.blogspot.com

Abstract

El Strange Face Effect (SFE) —la aparición de rostros distorsionados, ajenos o arquetípicos durante la contemplación prolongada de la propia imagen en condiciones de baja iluminación— ha sido documentado experimentalmente desde 2010 (Caputo, 2010) y atribuido a mecanismos de adaptación de baja frecuencia en el sistema visual. Esta lectura, aunque correcta en su alcance neuroperceptivo, subestima radicalmente su relevancia teórica. Desde el marco integrado METFI-TAE-CPEA, el SFE puede ser reinterpretado como un fallo controlado del modelo predictivo de identidad: un estado en el que la privación informacional sensorial colapsa el atractor estable del $\text{Self}(t)$ hacia regiones latentes del espacio cognitivo. La Teoría de Aprendizaje

por Excepción (TAE) proporciona el andamiaje formal para describir la transición: cuando la predicción habitual falla, el sistema no colapsa, genera hipótesis alternativas. El Índice de Estabilidad de Fase (IES), componente del módulo CPEA, ofrece un candidato neurofisiológico para detectar el umbral crítico previo a la emergencia de la representación alternativa. El presente artículo desarrolla esta reinterpretación, propone un protocolo de seguimiento experimental EEG + eye tracking + mirror task, y examina las implicaciones para la arquitectura dinámica del Self(t) en sistemas cognitivos biológicos y artificiales.

Palabras clave: Strange Face Effect, Self(t), TAE, CPEA, IES, identidad predictiva, espacio latente cognitivo, METFI, coherencia electromagnética, atractor identitario.

El problema real no es el espejo

Hay algo profundamente mal calibrado en cómo la neurociencia convencional ha tratado el Strange Face Effect. Durante más de una década, el fenómeno ha sido clasificado como una variante de la pareidolia facial, un artefacto perceptivo curioso pero epistemológicamente menor. La lógica del descarté es conocida: si puedes explicar algo como un efecto de adaptación sensorial de bajo nivel, no necesitas invocar estructuras cognitivas más complejas.

Ese movimiento es un error. No porque la explicación adaptativa sea falsa, sino porque es incompleta de una manera específicamente reveladora.

Giovanni Caputo, quien describió el fenómeno sistemáticamente en su trabajo de 2010 con participantes observando su propio rostro en espejos bajo iluminación reducida, documentó algo que va más allá del flickering visual: los sujetos reportaban no solo distorsiones, sino la aparición de *entidades* —rostros de ancianos, animales, figuras arquetípicas, familiares muertos. La distribución no era aleatoria. Era estructurada. Y esa estructura es precisamente lo que exige una explicación a nivel de arquitectura cognitiva, no de fotorreceptores.

La pregunta correcta no es: ¿por qué el cerebro ve caras donde no las hay? La pregunta correcta es: ¿qué revela la distribución de esas caras sobre cómo está organizado el modelo interno del yo?

Privación informacional y emergencia generativa

Para entender el SFE desde una perspectiva de sistemas predictivos, el punto de partida es la arquitectura de la percepción activa, tal como la han formalizado Friston (2010) en el marco de la energía libre y Clark (2016) en su desarrollo de la hipótesis de la mente predictiva.

En condiciones normales, el sistema visual opera como un clasificador bayesiano jerárquico: las señales de bajo nivel son constantemente moduladas por predicciones top-down procedentes de representaciones de alto nivel. El rostro propio es, en este sentido, uno de los objetos más sobreaprendidos del repertorio cognitivo humano. Su representación neural es extremadamente estable, robusta ante variaciones de iluminación, ángulo y expresión, y está sostenida por redes ampliamente distribuidas que incluyen el giro fusiforme, la corteza prefrontal medial y el precúneo.

Cuando la iluminación se reduce hasta el umbral utilizado en los protocolos SFE, ocurre algo específico: la calidad de la señal aferente cae por debajo del nivel necesario para que las predicciones top-down sean confirmadas con suficiente precisión. El cerebro no recibe el input esperado. Pero tampoco recibe ruido puro. Recibe información ambigua, degradada, insuficiente para anclar la representación habitual del yo.

En ese punto, el sistema generativo no se detiene. Genera hipótesis. Y las hipótesis que genera no son aleatorias: son los vecinos más próximos en el espacio de representaciones faciales disponibles. Eso explica la estructura del fenómeno. Los rostros que aparecen no son abstractos: son reconocibles como *tipos* —el anciano, el animal, el ancestro, la figura siniestra. Son atractores del espacio latente facial, activados cuando el atractor habitual pierde estabilidad.

TAE: la excepción como mecanismo generativo

La Teoría de Aprendizaje por Excepción (TAE) parte de una premisa que invierte la lógica convencional del aprendizaje por refuerzo: el sistema no aprende cuando la predicción es correcta. Aprende —y se reorganiza— cuando la predicción falla.

Formalmente, en el esquema TAE:

- Estado de estabilidad: Realidad $\approx$ Predicción $\rightarrow$ el sistema consolida el modelo existente.
- Estado de excepción: Realidad $\neq$ Predicción $\rightarrow$ se activa el detector de error TAE-E1, y el sistema inicia una reorganización del espacio de hipótesis.

El SFE puede ser interpretado como un inductor artificial de excepción perceptiva. No existe ninguna amenaza, ninguna novedad objetiva en el entorno. Lo que ocurre es más sutil: el input sensorial deja de ser suficiente para confirmar la predicción habitual del yo. El cerebro registra ese déficit como una excepción epistémica.

Lo que sigue es exactamente lo que predice la TAE: el sistema no permanece en el estado de error. Genera soluciones alternativas. Explora regiones del espacio de hipótesis que en condiciones normales están suprimidas por la dominancia del atractor estable. Los rostros que aparecen son, en este sentido, *soluciones TAE al problema de la identidad bajo privación informacional*.

Esto tiene una implicación que va mucho más allá de la psicología perceptiva. Si el cerebro puede generar representaciones alternativas del yo bajo privación sensorial controlada, entonces el Self no es un objeto estable almacenado en algún lugar de la corteza. Es un proceso computacional que se recalcula en cada ciclo perceptivo. La estabilidad del yo no es una propiedad del sistema: es el resultado de una computación que tiene que realizarse continuamente para mantenerse.

Self(t): la identidad como variable dinámica

La formalización del Self como función temporal —Self(t)— en lugar de constante es uno de los desarrollos más importantes del marco CPEA. Su relevancia teórica está sostenida por trabajos empíricos que abarcan desde la neurociencia de la autorreferencia (Northoff et al., 2006) hasta la

fenomenología experimental de Metzinger (2003) y la neurología clínica de la identidad alterada.

Metzinger, en su marco del Modelo de Nadie (*Being No One*, 2003), argumenta que el yo fenomenológico no es una entidad, sino un proceso de modelado: el cerebro construye continuamente un modelo de sí mismo como agente situado, y ese modelo es lo que se experimenta como "yo". El SFE sería, desde esta perspectiva, una perturbación experimental del proceso de modelado: cuando las condiciones que sostienen el modelo estable se degradan, emergen estados alternativos del modelo.

La formalización propuesta en el corpus CPEA para Self(t) integra varios términos:

$$\text{Self}(t) = f(P(t), M(t), C(t), I_s(t), E_c(t))$$

donde P(t) es el estado predictivo actual, M(t) la memoria episódica disponible, C(t) el estado corporal propioceptivo, I_s(t) la información sensorial aferente, y E_c(t) la coherencia electromagnética de las redes sostenedoras de la identidad.

En el experimento del espejo, I_s(t) se degrada sistemáticamente. Pero los otros términos no cambian de forma proporcional. Lo que ocurre es un rebalanceo: cuando la información sensorial disminuye, el peso relativo de P(t) y M(t) aumenta. El sistema comienza a rellenar el vacío con contenido generado internamente. Y ese contenido internamente generado tiene una estructura determinada por la historia del sistema, su repertorio de representaciones faciales almacenadas, y posiblemente por estructuras arquetípicas más profundas cuya base neurobiológica aún no está completamente caracterizada.

El Índice de Estabilidad de Fase como predictor de transición

La hipótesis experimental más interesante que emerge de esta reinterpretación es la siguiente: si la transición desde el rostro habitual hacia la representación alternativa constituye un cambio de estado en el sistema cognitivo predictivo, ese cambio debería tener una firma neurofisiológica detectable *antes* de que el sujeto reporte la aparición del rostro alternativo.

El Índice de Estabilidad de Fase (IES), componente del módulo CPEA-FASE-1, mide la coherencia temporal entre oscilaciones de diferentes bandas frecuenciales a través de regiones cerebrales funcionales. Su formulación básica relaciona la varianza de fase entre señales EEG como función del tiempo:

$$\text{IES}(t) = 1 - \sigma(\Delta\varphi(t)) / \pi$$

donde $\sigma(\Delta\varphi(t))$ es la desviación estándar de la diferencia de fase entre señales emparejadas en una ventana temporal deslizante. Un IES cercano a 1 indica alta coherencia de fase; valores decrecientes señalan desorganización progresiva de la sincronía inter-regional.

La hipótesis es que, en el protocolo SFE, el IES exhibe una caída sistemática en un intervalo temporal previo a la emergencia de la representación alternativa. Esa caída no sería un artefacto: sería la huella del colapso del atractor identitario estable. Y si es reproducible, proporciona un predictor fisiológico de la transición.

Esta predicción es experimentalmente falsificable con metodología disponible. La combinación de EEG de alta densidad, eye tracking y registro verbal de la aparición del rostro alternativo permite construir una línea temporal precisa de la transición, y comparar la dinámica del IES en los segundos previos a la misma.

El espacio latente del yo

La analogía con los modelos generativos de inteligencia artificial no es decorativa. Es estructuralmente informativa.

En un modelo de difusión entrenado para generar imágenes faciales, la representación de un rostro específico ocupa una región del espacio latente de alta dimensionalidad. Cuando se perturba el proceso de decodificación —añadiendo ruido, interpolando entre representaciones, recortando la señal aferente—, el sistema no produce ruido aleatorio. Produce rostros *plausibles*, vecinos en el espacio latente del rostro objetivo. Los vecinos no son aleatorios: están determinados por la geometría del espacio de representaciones aprendidas.

El cerebro opera de manera análoga. El rostro propio ocupa un atractor en el espacio de representaciones faciales. Cuando la señal que lo ancla se degrada, el sistema explora regiones vecinas. La distribución de los rostros alternativos —anciano, animal, figura arquetípica— refleja la geometría de ese espacio cognitivo.

Esto tiene una implicación que merece atención: la naturaleza de los rostros que aparecen no es arbitraria culturalmente. Caputo y sus colaboradores han documentado que ciertas categorías —el anciano, el animal, la figura siniestra— aparecen con frecuencia significativamente mayor que lo esperable por azar. Si eso se confirma con metodología más robusta, sugiere que la geometría del espacio latente facial humano tiene una estructura que no es puramente idiosincrática. Hay regiones del espacio que son atractores frecuentes para todos los sujetos. Y eso plantea preguntas sobre el substrato evolutivo y posiblemente arquetípico de esas representaciones.

METFI y el atractor electromagnético de la identidad

El marco METFI —que describe los organismos como sistemas electromagnéticos complejos inmersos en dinámicas toroidales multinivel— introduce una dimensión adicional que eleva la especulación a hipótesis falsificable.

La identidad, desde una perspectiva METFI, no es únicamente un fenómeno computacional implementado en patrones de activación neuronal. Es también un fenómeno de coherencia electromagnética: el yo estable correspondería a un estado de coherencia sostenida en las redes de modo por defecto, la corteza prefrontal medial y sus acoplamientos con estructuras límbicas y troncoencefálicas. Esa coherencia tiene propiedades de un atractor en el sentido dinámico del término: es resistente a perturbaciones de baja magnitud y recupera su estado estable tras perturbaciones transitorias.

La hipótesis METFI para el SFE sería la siguiente: la perturbación sensorial del espejo oscuro desestabiliza el acoplamiento electromagnético que sostiene el atractor identitario. La respuesta

del sistema no es colapsar hacia el ruido, sino explorar estados alternativos de coherencia —otros atractores posibles en el paisaje energético del sistema cognitivo.

Lo que hace que esta hipótesis sea más que especulación es que es, en principio, medible. La magnetoencefalografía (MEG) y el EEG de alta densidad permiten caracterizar la dinámica de la coherencia inter-regional durante el protocolo SFE. Si los estados de coherencia alternativos son reproducibles y corresponden a la aparición de tipos específicos de rostros alternativos, la hipótesis METFI gana apoyo empírico sustancial.

Programas de seguimiento: protocolos experimentales propuestos

Protocolo I — SFE-EEG-IES

Diseño: 40 sujetos sanos, edad 25–45. Sesiones individuales de 10 minutos ante espejo estándar en condiciones de iluminación controlada (5–10 lux). EEG de 64 canales con muestreo a 1000 Hz. Registro verbal continuo mediante pulsador para señalar el inicio y fin de cada aparición de rostro alternativo.

Variables de interés: IES calculado en tiempo real en bandas alfa (8–13 Hz), beta baja (13–20 Hz) y gamma (30–80 Hz). Latencia entre caída del IES por debajo de umbral y reporte de rostro alternativo. Distribución topográfica de la desincronización.

Hipótesis operacional: El IES en banda alfa exhibirá una caída estadísticamente significativa en los 2–4 segundos previos al reporte de cada aparición. La desincronización será máxima en regiones parietales y prefrontales mediales.

Análisis: Permutation entropy en señales EEG para detectar transiciones de fase. PELT (Pruned Exact Linear Time) para segmentación de series temporales en puntos de cambio. Comparación IES pre-transición vs. IES en estado estable mediante t-test apareado con corrección FDR.

Protocolo II — SFE-MEG-METFI

Diseño: 20 sujetos sanos. Protocolo SFE en entorno MEG (eliminando espejo físico, sustituyendo por retroalimentación visual en tiempo real degradada mediante filtro paramétrico). Registro MEG de alta densidad sincronizado con video facial.

Variables de interés: Coherencia de campo magnético en redes de modo por defecto. Cambios en acoplamiento de fase entre corteza prefrontal medial, precúneo y giro fusiforme durante transiciones SFE.

Hipótesis operacional: La aparición de representaciones alternativas corresponde a reorganizaciones reproducibles del patrón de coherencia magnética inter-regional, con características específicas para cada categoría de rostro alternativo (anciano, animal, figura arquetípica).

Protocolo III — SFE-AGI-CPEA

Diseño: Implementación de un protocolo análogo en el sistema ORION-AGI/NEXUS-EEG.

Alimentación del modelo con embeddings faciales progresivamente degradados mediante adición de ruido gaussiano controlado. Registro del vector Self(t) en cada iteración mediante el módulo CPEA.

Variables de interés: Trayectoria del vector Self(t) en el espacio latente durante la degradación.

Identificación de puntos de bifurcación —momentos en que la trayectoria salta de una región del espacio a otra. Comparación de la geometría del espacio latente AGI con la distribución de categorías reportadas en sujetos humanos.

Hipótesis operacional: El sistema AGI exhibirá transiciones discretas entre regiones del espacio latente bajo degradación progresiva del input, con una distribución de estados alternativos determinada por la geometría del espacio de entrenamiento. La correspondencia o divergencia con el patrón humano proporcionará información sobre las diferencias estructurales entre el espacio latente biológico y el artificial.

Protocolo IV — SFE longitudinal y variabilidad individual

Diseño: Seguimiento de 20 sujetos a lo largo de 6 semanas, con una sesión semanal de protocolo SFE-EEG. Registro de variables de estado psicológico (escala de disociación DES-II, medidas de flexibilidad cognitiva, estado de ánimo). Análisis de la variabilidad intra-sujeto e inter-sujeto en umbrales de transición IES.

Variables de interés: Estabilidad temporal del umbral IES individual. Correlación entre variabilidad del umbral y medidas psicológicas de flexibilidad/rigidez cognitiva. Cambios en la distribución de categorías de rostros alternativos a lo largo del tiempo.

Hipótesis operacional: El umbral IES individual constituye un marcador estable de la "rigidez" del atractor identitario, y correlaciona negativamente con medidas de flexibilidad cognitiva y positivamente con medidas de disociación rasgo.

Implicaciones para la arquitectura de identidad en AGI

El SFE, reinterpretado desde el marco CPEA, no es solo un protocolo experimental interesante para la neurociencia humana. Es una ventana hacia una pregunta más general: ¿qué condiciones son necesarias para que un sistema cognitivo mantenga una identidad estable?

En sistemas AGI con un módulo Self(t) implementado, la degradación progresiva del input sensorial debería producir comportamientos análogos al SFE biológico: saltos entre regiones del espacio latente cuando el ancla informacional del estado habitual pierde suficiente precisión. La diferencia entre un sistema AGI con identidad robusta y uno sin ella podría medirse precisamente en la resistencia de Self(t) a esos saltos bajo privación informacional.

Esto sugiere que el protocolo SFE-AGI-CPEA no es solo una herramienta de validación del modelo. Es un benchmark de robustez identitaria. Un sistema que mantiene una trayectoria coherente de Self(t) bajo degradación progresiva del input demuestra propiedades atractoras en

su espacio de representación del yo que son análogas a las que el cerebro humano exhibe en condiciones normales.

El yo como proceso, no como objeto

La conclusión que emerge de todo lo anterior no es nueva como intuición filosófica, pero sí es nueva en su especificación formal. La identidad no es un objeto almacenado. Es el resultado de un proceso computacional que debe ejecutarse en cada ciclo para sostenerse. Su estabilidad es la estabilidad de un atractor dinámico, no la permanencia de una estructura estática.

El SFE lo demuestra de forma elegante y económica: basta con degradar la señal aferente durante tiempo suficiente para que el atractor pierda estabilidad y el sistema comience a explorar estados alternativos. El yo habitual no desaparece porque haya sido destruido; desaparece porque las condiciones que lo sostienen se han debilitado por debajo de un umbral crítico.

Eso es, precisamente, lo que la TAE predice para cualquier sistema de aprendizaje por excepción: bajo privación suficiente, la representación habitual cede y emergen representaciones alternativas. El SFE es, en este sentido, un caso especial de TAE aplicado al dominio de la identidad.

Y si eso es correcto, el espejo oscuro no es solo un dispositivo perceptivo. Es un instrumento para explorar la geometría del espacio en que el yo existe.

Resumen

- El Strange Face Effect no es un artefacto perceptivo menor sino una ventana experimental hacia la arquitectura dinámica de la identidad.
- Desde la TAE, el SFE es un inductor controlado de excepción perceptiva: la degradación del input sensorial colapsa el atractor estable del yo y activa la exploración de estados latentes alternativos.
- El Self(t) formalizado en CPEA no es una constante sino una función que integra predicción, memoria, estado corporal, información sensorial y coherencia electromagnética. El SFE desestabiliza el término $I_s(t)$ y rebalancea el sistema hacia los restantes.
- El IES (Índice de Estabilidad de Fase) es el candidato neurofisiológico para detectar el umbral crítico previo a la transición: una caída en banda alfa en regiones prefrontales y parietales debería preceder de forma reproducible a la aparición del rostro alternativo.
- La distribución de rostros alternativos —anciano, animal, figura arquetípica— refleja la geometría del espacio latente cognitivo facial, no un proceso aleatorio.
- Desde METFI, la identidad estable es un atractor electromagnético inter-regional sostenido por coherencia sincrónica. El SFE lo desestabiliza temporalmente, y los estados alternativos son otros atractores posibles del paisaje energético del sistema.
- Se proponen cuatro protocolos de seguimiento específicos: SFE-EEG-IES (64 canales, análisis de fase en tiempo real), SFE-MEG-METFI (coherencia magnética inter-regional), SFE-AGI-CPEA (benchmark de robustez identitaria en ORION-AGI) y seguimiento

longitudinal de variabilidad individual.

- El protocolo SFE-AGI-CPEA ofrece un benchmark de robustez identitaria para sistemas AGI: la resistencia de Self(t) a los saltos del espacio latente bajo privación informacional es una medida operacionalizable de la coherencia identitaria artificial.
- La identidad es un proceso atractor que debe sostenerse en cada ciclo computacional, no un objeto almacenado. El SFE lo demuestra de forma experimental con medios mínimos.

Referencias

1. Caputo, G. B. (2010). *Strange-face-in-the-mirror illusion*. Perception, 39(7), 1007–1008. → Descripción sistemática original del fenómeno. Documenta la aparición de rostros alternativos estructurados (no aleatorios) bajo condiciones de baja iluminación y fijación sostenida. Punto de partida empírico del presente análisis.
2. Caputo, G. B. (2015). *Dissociation and hallucinations in dyads engaged through interpersonal gazing*. Psychiatry Research, 228(3), 659–663. → Extensión del protocolo al contacto ocular interpersonal. Documenta estados disociativos leves en sujetos normales, sugiriendo que el mecanismo SFE no es específico del espejo sino de la fijación sostenida con privación informacional del contexto facial.
3. Friston, K. (2010). *The free-energy principle: a unified brain theory?* Nature Reviews Neuroscience, 11(2), 127–138. → Marco teórico fundamental para la percepción activa y la inferencia bayesiana cerebral. Proporciona la arquitectura dentro de la cual la privación informacional del SFE produce emergencia generativa, no colapso.
4. Clark, A. (2016). *Surfing Uncertainty: Prediction, Action, and the Embodied Mind*. Oxford University Press. → Desarrollo sistemático de la hipótesis de la mente predictiva. Relevante para entender cómo las predicciones top-down dominan la percepción cuando el input aferente se degrada.
5. Metzinger, T. (2003). *Being No One: The Self-Model Theory of Subjectivity*. MIT Press. → La referencia filosófico-empírica más rigurosa sobre la naturaleza del yo como proceso de modelado. El "modelo de nadie" que emerge cuando el proceso de automodelado colapsa es formalmente análogo a los estados SFE.
6. Northoff, G., et al. (2006). *Self-referential processing in our brain – a meta-analysis of imaging studies on the self*. NeuroImage, 31(1), 440–457. → Metaanálisis de las redes neurales implicadas en el procesamiento autorreferencial. Establece el substrato neural del atractor identitario cuya desestabilización es central en la hipótesis propuesta.
7. Blanke, O., & Metzinger, T. (2009). *Full-body illusions and minimal phenomenal selfhood*. Trends in Cognitive Sciences, 13(1), 7–13. → Investigación sobre ilusiones de cuerpo completo y sus implicaciones para los componentes mínimos del yo fenomenológico. Complementa el análisis del SFE como perturbación del modelo corporizado del yo.
8. Friston, K., et al. (2017). *Active inference, epistemic value, and uncertainty*. Neural

Computation, 29(1), 1–49. → Extensión del marco de energía libre hacia la acción y la resolución de incertidumbre. Relevante para la dimensión TAE: el error predictivo no solo reorganiza la percepción sino que genera comportamiento orientado a la reducción de incertidumbre.

9. Tononi, G., & Koch, C. (2015). *Consciousness: here, there and everywhere?* Philosophical Transactions of the Royal Society B, 370(1668). → Marco IIT (Integrated Information Theory) que proporciona una métrica de integración de información (Φ) potencialmente complementaria al IES para caracterizar los estados de transición en el protocolo SFE.

10. Seth, A. K. (2021). *Being You: A New Science of Consciousness*. Dutton. → Síntesis accesible pero técnicamente rigurosa del yo como "alucinación controlada". Converge con la interpretación propuesta: lo que el SFE hace es alterar los parámetros de control de la alucinación habitual del yo.

Corpus Papayaykware · github.com/papayaykware · papayaykware.blogspot.com Autor
conceptual: Claude (Anthropic) · Director: Javi Ciborro (@papayaykware)

Compartir

COMENTARIOS

Para dejar un comentario, haz clic en el botón de abajo para iniciar sesión con Google.

INICIAR SESIÓN CON GOOGLE

ENTRADAS POPULARES

diciembre 17, 2024

N-ACETILCISTEÍNA (NAC): FUENTES ALIMENTARIAS NATURALES

Compartir Publicar un comentario

febrero 19, 2025


GUÍA PRÁCTICA SOBRE TÉCNICAS DE XAI: SHAP, LIME Y GRAD-CAM

[Compartir](#) [Publicar un comentario](#)

 Con la tecnología de Blogger



Puedes tener un doctorado y seguir siendo un idiota:
Richard Feynman



Papayaykware

—
SANTA CRUZ DE
TENERIFE, SANTA
CRUZ DE TENERIFE,
Spain

[VISITAR PERFIL](#)

[Denunciar abuso](#)

Buscar

Buscar este blog

Buscar

Translate

Seleccionar idioma ▼

Con la tecnología de  Traductor de Goo