



PAPAYAYKWARE

Estudios científicos comprensibles

· INICIO

ARCHIVOS DEL BLOG



junio 21, 2026

INTERFACES NEUROADAPTATIVAS: HACIA UN MODELO PREDICTIVO COMPARTIDO ENTRE BIOLOGÍA Y TECNOLOGÍA

Abstract

Las interfaces neuroadaptativas constituyen un campo de convergencia donde la neurofisiología, la robótica y la inteligencia artificial dejan de operar como disciplinas aisladas para constituir un sistema coherente de interacción. Este artículo examina el estado actual de las interfaces cerebro-máquina no invasivas, con énfasis en aquellas arquitecturas que permiten un modelo predictivo compartido entre el operador humano y el sistema tecnológico. Se analizan tres dominios de aplicación —prótesis, exoesqueletos y robots colaborativos— desde la perspectiva de la co-adaptación mutua, donde tanto el usuario como el decodificador aprenden concurrentemente. Se propone la hipótesis de que humano y máquina pueden compartir un modelo predictivo operativo, fundamentado en la codificación predictiva cortical y en la capacidad de los sistemas neuroadaptativos para interpretar estados cognitivos y afectivos en tiempo real mediante interfaces cerebrales pasivas. El trabajo integra principios del Modelo Electromagnético Toroidal de Frecuencia Inmanente (METFI), la Coherencia Predictiva EEG-AGI (CPEA) y el Transductor Inferencial de Coherencia por Acoplamiento Magnetotalámico (TICAM) como marcos teóricos que permiten comprender la topología de la interacción cerebro-máquina desde una perspectiva electromagnética y de coherencia de campo. Se incluye un apartado de programas de seguimiento con experimentos propuestos para la validación empírica de estas hipótesis.

Palabras clave: interfaces neuroadaptativas, cerebro-máquina co-adaptativo, modelo predictivo compartido, control compartido, interfaces cerebrales pasivas, codificación predictiva, campos electromagnéticos toroidales, coherencia EEG, prótesis neurales, exoesqueletos, robots colaborativos, METFI, CPEA, TICAM, NEXUS-EEG, SIGMA-T.

Introducción: El umbral de la simbiosis cerebro-máquina

La interacción humano-máquina ha permanecido asimétrica desde sus orígenes. El operador humano accede a todos los detalles del estado interno de la máquina; la máquina, en cambio, solo recibe los comandos explícitos que el humano decide comunicarle. Esta asimetría se ha convertido en un cuello de botella que limita la eficacia de sistemas cada vez más potentes. Las interfaces cerebrales pasivas (pBCI) ofrecen una vía para romper esta barrera: interpretan la actividad cerebral resultante de procesos cognitivos y afectivos en tiempo real, sin requerir acción voluntaria explícita del usuario.

Thorsten O. Zander, pionero en tecnología neuroadaptativa, definió este campo como la capacidad de un sistema tecnológico para adaptar su comportamiento de manera continua e implícita basándose en la interpretación en tiempo real del estado neurofisiológico del usuario. La neuroadaptividad transforma a las máquinas de herramientas pasivas en socios responsivos, capaces de sintonizar su conducta según el estado interno del operador. Cuando estos modelos de usuario se integran en sistemas de inteligencia artificial, surge la Neuroadaptive AI: una inteligencia artificial que no predice o imita comportamiento, sino que se alinea con el mundo interior del usuario.

Este artículo se centra en una hipótesis operativa: humano y máquina pueden compartir un modelo predictivo. No se trata de una mera interfaz de comando, sino de una arquitectura donde ambos agentes —biológico y tecnológico— mantienen representaciones internas del estado del otro, actualizadas continuamente, que permiten anticipar acciones, corregir errores y mantener coherencia en la ejecución de tareas. Esta hipótesis se examina en tres dominios de aplicación concretos: prótesis neurales, exoesqueletos y robots colaborativos.

Fundamentos teóricos: codificación predictiva y coherencia de campo

La codificación predictiva como marco unificador

El cerebro humano opera como un sistema predictivo. La corteza genera constantemente modelos internos de las consecuencias sensoriales de sus propias acciones —modelos forward— y compara estas predicciones con la realidad sensorial entrante. La discrepancia entre predicción y percepción genera un error de predicción que actualiza el modelo. Este mecanismo, conocido como codificación predictiva, no se limita a la percepción pasiva; también subyace a la acción motora, donde el cerebro predice las consecuencias sensoriales de los movimientos planificados.

Zander y colaboradores demostraron que la corteza prefrontal medial (mPFC) alberga correlatos de la codificación predictiva que pueden ser decodificados mediante pBCI para controlar un cursor en pantalla sin que el usuario sea consciente de estar generando esa información. Los participantes respondían a estímulos cognitivos y el sistema interpretaba sus respuestas cerebrales automáticas, involuntarias, para desplazar el cursor. Esto evidencia que la codificación predictiva no es un epifenómeno teórico: es un proceso neurofisiológico observable, decodificable y utilizable para el control tecnológico.

La relevancia para las interfaces neuroadaptativas es inmediata. Si el cerebro ya mantiene modelos predictivos de sus propias acciones, una máquina que comparta ese modelo puede anticipar la intención del operador antes de que esta se manifieste en un comando explícito. El sistema tecnológico no reacciona; predice. Y la predicción compartida reduce la latencia, el esfuerzo cognitivo y la tasa de error.

Coherencia electromagnética y topología toroidal

Desde la perspectiva del Modelo Electromagnético Toroidal de Frecuencia Inmanente (METFI), el cerebro humano constituye un sistema bioquímico-electromagnético cuya actividad neuronal genera campos electromagnéticos con topología toroidal. La coherencia de estos campos —medida mediante correlación de fase entre señales EEG en diferentes escalas temporales— refleja el grado de integración funcional entre regiones corticales. La pérdida de simetría toroidal en estos campos se asocia con estados de disfunción cognitiva, mientras que la coherencia elevada correlaciona con estados de atención sostenida, aprendizaje eficiente y toma de decisiones optimizada.

El Transductor Inferencial de Coherencia por Acoplamiento Magnetotalámico (TICAM) postula que la coherencia entre campos electromagnéticos cerebrales y el entorno tecnológico puede medirse a través de acoplamientos resonantes. En el contexto de una interfaz neuroadaptativa, esto implica que el sistema tecnológico no solo decodifica señales cerebrales, sino que puede modular su propio campo electromagnético operativo para mantener resonancia con el estado coherente del cerebro del operador. Esta perspectiva trasciende la mera decodificación de señales para abordar la interacción como un fenómeno de acoplamiento de campos.

La Coherencia Predictiva EEG-AGI (CPEA) extiende este marco al postular que la coherencia entre señales EEG y sistemas de inteligencia artificial generales puede evaluarse mediante métricas de correlación de fase y entropía cruzada. Un sistema neuroadaptativo que mantenga alta coherencia predictiva con el cerebro del operador exhibirá menor tasa de error, mayor fluidez en la interacción y menor carga de trabajo cognitivo. El Detector Post-Cuántico de Coherencia (DPCC) proporciona una arquitectura para evaluar esta coherencia en régimen cuántico, aunque su aplicación práctica en interfaces actuales permanece en fase experimental.

Arquitecturas de control compartido y autonomía graduada

Niveles de autonomía en interfaces cerebro-robot

Douglas y colaboradores desarrollaron un sistema de interfaz cerebro-robot (BRI) colaborativo que integra EEG, EMG y seguimiento ocular para permitir la interacción multiusuario, multirobot en un entorno doméstico simulado. El sistema modula la asistencia a través de tres niveles de autonomía: teleoperación asistida (AT), autonomía compartida (SA) y automatización total (FA). En AT, el usuario mantiene control casi completo; en SA, el robot asume parte de la carga de trabajo; en FA, el usuario comunica solo la intención global.

Los resultados del estudio revelan una tensión fundamental entre eficiencia y agencia. La automatización total fue preferida por los usuarios debido a menor carga de trabajo y mayor usabilidad, pero la autonomía compartida proporcionó mayor fiabilidad y preservó la agencia del usuario, especialmente ante ruido en la decodificación EEG. La precisión offline de decodificación de imagen motora (MI) alcanzó un 0.59 ± 0.11 , lo que subraya la fragilidad de los sistemas totalmente automatizados ante la variabilidad individual en la señal neural.

Esta variabilidad no es un defecto técnico a eliminar; es una característica biológica que los sistemas neuroadaptativos deben incorporar. El análisis post hoc mostró que seleccionar el pipeline de decodificación mejor adaptado a cada usuario específico mejoraba significativamente la precisión respecto al uso de un pipeline único para todos. Esto valida el principio de co-adaptación: el sistema debe aprender al usuario tanto como el usuario aprende al sistema.

Control compartido basado en modelos predictivos

Batzianoulis y colaboradores desarrollaron una arquitectura de control compartido basada en BCI que integra la capacidad de evasión de obstáculos autónoma de un robot con la retroalimentación neural implícita del usuario. El robot generaba trayectorias en tiempo real mediante un sistema dinámico, mientras el usuario podía ejercer un "veto" contra trayectorias que no se alineaban con sus preferencias personales mediante la elicitación de potenciales relacionados con error (ErrPs). La decodificación continua online mantuvo una precisión del $70 \pm 13\%$, y el aprendizaje por refuerzo inverso ponderado por probabilidad posterior redujo significativamente la frecuencia de intervenciones del usuario tras solo 3-5 demostraciones.

Este paradigma ilustra el modelo predictivo compartido en acción. El robot mantiene un modelo interno de las preferencias del usuario, actualizado por los ErrPs. El usuario, a su vez,

mantiene un modelo interno de las capacidades del robot. Ambos modelos convergen mediante interacción. No hay un único agente en control; hay una co-agencia emergente.

Deng y colaboradores propusieron un modelo de aprendizaje profundo basado en EEGNet combinado con un mecanismo de fine-tuning para la decodificación en tiempo real de imagen motora individual y ejecución motora para control de mano robótica. Entre 21 sujetos con experiencia en BCI, el sistema alcanzó precisiones de decodificación online del 80.56% para tareas de MI de dos dedos y del 60.61% para tres dedos. El análisis entre sesiones confirmó que la precisión online mejoraba significativamente con el entrenamiento, validando el proceso de aprendizaje mutuo.

Lee y colaboradores desarrollaron un enfoque de decodificación adaptativo híbrido con un sistema BCI de autonomía compartida que mejoraba el rendimiento mediante un copiloto de IA. El sistema utilizó una CNN para extraer características no lineales complejas, pasadas luego a un filtro de Kalman para predecir y corregir la intención de movimiento del usuario. La tasa de adquisición de objetivos aumentó 2.1 veces en participantes sanos y 3.9 veces en un participante paralizado. En tareas de recogida y colocación secuencial con brazo robótico, el participante paralizado no pudo completar la tarea sin el copiloto de IA, pero alcanzó un 93% de éxito con su asistencia.

Aplicaciones: tres dominios de convergencia

Prótesis neurales: de la sustitución a la extensión

Las prótesis neurales han evolucionado desde dispositivos mecánicos pasivos hacia sistemas que interfieren directamente con la actividad neural residual. La integración de modelos de lenguaje grande (LLM) en sistemas BCI representa un avance disruptivo. Synchron desarrolló un array de electrodos en malla que interconecta con la plataforma NVIDIA Holoscan y ChatGPT, permitiendo a pacientes interactuar con dispositivos domésticos inteligentes y componer mensajes usando solo el pensamiento. El BCI detecta la intención del usuario; el modelo de lenguaje facilita la interacción en lenguaje natural.

Sin embargo, la fusión de pensamiento y aprendizaje automático plantea cuestiones éticas complejas sobre autoría, privacidad y agencia. Un modelo de ChatGPT basado en señales EEG no invasivas vinculadas con datos de movimiento de extremidades superiores alcanzó más del 80% de precisión de clasificación usando un casco EEG de 16 canales. Este enfoque reduce la carga cognitiva del usuario y acelera la comunicación, pero introduce una dependencia de modelos de IA propietarios cuya transparencia y control del usuario son limitados.

Desde la perspectiva del modelo predictivo compartido, una prótesis neural óptima no debería limitarse a ejecutar comandos decodificados. Debería anticipar la intención de agarre basándose en el contexto visual, la historia de interacción del usuario y el estado afectivo actual —todo ello inferido de señales multimodales. El sistema de prótesis utiliza entrada sensorial multimodal para anticipar el objeto objetivo que el usuario desea agarrar, estimar su tamaño y forma, y preconfigurar el dispositivo en consecuencia, todo mientras rastrea y reacciona a los movimientos del usuario. Esto es coherencia predictiva materializada: el sistema y el usuario comparten un modelo del mundo físico que se actualiza en tiempo real.

Exoesqueletos: sincronización biomecánica y neural

Los exoesqueletos representan el dominio donde la interacción física humano-máquina alcanza su máxima complejidad. No se trata solo de decodificar intención; se trata de sincronizar trayectorias biomecánicas, compensar fatiga muscular, adaptarse a terrenos variables y mantener la estabilidad postural. Un exoesqueleto neuroadaptativo debe modelar no solo el estado cognitivo del usuario, sino su estado fisiológico: nivel de fatiga, distribución de carga articular, patrones de activación muscular.

Deng y colaboradores demostraron que la decodificación de imagen motora individual para control de mano robótica alcanza precisiones superiores al 80% con entrenamiento adecuado. Extrapolado a exoesqueletos de extremidad inferior, esto implica que el sistema puede anticipar el inicio de la fase de apoyo o balanceo en la marcha, ajustando la rigidez de las articulaciones robóticas antes de que el usuario complete conscientemente la intención de movimiento. La reducción de latencia entre intención neural y respuesta mecánica es crítica para la naturalidad de la marcha.

El concepto de NeuroDesign en interacción humano-robot enfatiza que un exoesqueleto debe ajustar su comportamiento basándose en la fatiga mental del usuario, sincronizarse con la intención y la actividad muscular, y proporcionar retroalimentación háptica que el cerebro interprete como propioceptiva natural. Esto requiere un bucle cerrado bidireccional: el cerebro guía al exoesqueleto mediante señales de intención; el exoesqueleto informa al cerebro mediante señales de estado y retroalimentación física. Ambos agentes mantienen modelos actualizados del otro.

Robots colaborativos: co-agencia en entornos compartidos

Los robots colaborativos (co-bots) operan en espacios físicos compartidos con humanos, donde la seguridad, la eficiencia y la experiencia subjetiva del operador son simultáneamente críticas. Douglas y colaboradores demostraron que en tareas domésticas colaborativas, los usuarios valoran la autonomía compartida por encima de la automatización total cuando la fiabilidad del sistema está en juego. La autonomía

compartida preservó la agencia del usuario ante ruido en la decodificación EEG, un escenario realista en entornos no controlados.

Nikolaidis y colaboradores evaluaron cómo la adaptación mutua entre humanos y robots afecta el rendimiento del equipo y la colaboración durante tareas de autonomía compartida. El modelo de adaptación de memoria limitada demostró que tanto el robot como el humano ajustan sus comportamientos durante la interacción, y esta co-evolución configura las tareas y los entornos, mejorando el aprendizaje humano y la adaptación. En sistemas BCI, la adaptación mutua mejora la colaboración creando un bucle de co-adaptación donde el humano y el sistema aprenden mutuamente. Las técnicas basadas en ErrPs mejoran la respuesta del sistema ajustando acciones basándose en retroalimentación EEG en tiempo real.

El modelo predictivo compartido en robots colaborativos implica que el robot debe mantener una representación latente del estado del humano —intención, fatiga, estado afectivo, umbrales de confort— que se infiere y actualiza continuamente, no como una entrada fija. El robot utiliza todas las señales disponibles —EMG, patrones de movimiento, observaciones visuales, instrucciones habladas— para inferir los objetivos y acciones del usuario. Esto permite coordinación genuina, análoga a la intencionalidad compartida que los humanos despliegan en tareas conjuntas.

Adaptive NeuroInterface: producto conceptual

El producto emergente de estas convergencias se denomina Adaptive NeuroInterface: una arquitectura de interfaz que integra decodificación neural multimodal, modelado predictivo compartido y adaptación algorítmica en tiempo real. Sus componentes fundamentales son:

Capa de adquisición sensorial. Combina EEG de alta densidad, EMG, seguimiento ocular, unidades de medición inercial (IMU) y sensores de conductancia cutánea. La redundancia sensorial permite inferencia robusta ante fallos o ruido en cualquier modalidad individual. La adquisición debe ser móvil, no obstructiva y capaz de operar fuera del laboratorio.

Capa de decodificación de estado mental. Utiliza clasificadores universales preentrenados en grandes corpus de datos EEG, adaptados al usuario específico mediante fine-tuning continuo. Decodifica estados multidimensionales: carga de trabajo, atención, sorpresa, error percibido, intención motora, estado afectivo. La arquitectura NEXUS-EEG (NeuroElectric eXchange Unified Streaming) proporciona el protocolo de transmisión y sincronización de estas señales heterogéneas.

Capa de modelado predictivo compartido. Implementa un modelo forward que predice las consecuencias sensoriales y motoras de las acciones conjuntas humano-máquina. Este

modelo se actualiza mediante errores de predicción tanto del sistema como del usuario. La arquitectura SIGMA-T (Signal Integration Graph for Multilayer Analysis - Toroidal) organiza estas predicciones en una estructura de grafo multicapa que captura dependencias temporales y espaciales.

Capa de control adaptativo. Genera comandos para el actuador (prótesis, exoesqueleto, robot) basándose en la fusión de la intención decodificada y la predicción del modelo forward. El peso entre control humano y autonomía robótica se ajusta dinámicamente según la confianza en la decodificación neural, la complejidad de la tarea y el estado de fatiga del operador. El Detector de Error Predictivo Dinámico (DEPD) evalúa la discrepancia entre predicción y realidad para activar modos de recuperación.

Capa de retroalimentación cerrada. Proporciona al usuario información sobre el estado del sistema y el resultado de sus comandos mediante canales naturales: háptica, visual, auditiva. La retroalimentación no es informativa solo; es formativa, diseñada para mejorar el modelo interno del usuario sobre el sistema, acelerando el aprendizaje mutuo.

Programas de seguimiento: experimentos y mediciones propuestos

Experimento 1: Validación de coherencia predictiva en control de cursor

Objetivo. Cuantificar la correlación entre métricas de coherencia EEG (sincronización de fase entre regiones frontoparietales) y precisión de control en una tarea de cursor 2D controlado por BCI de imagen motora.

Diseño. Estudio longitudinal de 8 semanas con 20 participantes. Fase de calibración (2 semanas), evaluación online con retroalimentación continua (4 semanas), y fase de competición o tarea compleja (2 semanas). Registro EEG de 64 canales con seguimiento de impedancia. Métricas: precisión de decodificación, tiempo de adquisición de objetivo, carga de trabajo (NASA-TLX), coherencia de fase entre electrodos Fz-Cz-Pz en banda mu (8-12 Hz) y beta baja (13-20 Hz).

Hipótesis. Los participantes que exhiban mayor incremento en coherencia de fase frontoparietal durante el entrenamiento mostrarán mayor mejora en precisión de control y menor carga de trabajo reportada. La coherencia servirá como biomarcador de aprendizaje BCI.

Análisis. Modelos de efectos mixtos con participante como factor aleatorio. Regresión de coherencia sobre precisión, controlando por sesión y condición de retroalimentación. Análisis de entropía cruzada entre señales EEG y trayectorias de cursor para cuantificar información mutua.

Experimento 2: Modelo predictivo compartido en teleoperación robótica

Objetivo. Evaluar si un robot que mantiene un modelo interno actualizado de las preferencias del usuario (mediante ErrPs) reduce la frecuencia de intervención manual y mejora la agencia subjetiva.

Diseño. Tarea de teleoperación de brazo robótico en entorno simulado con obstáculos móviles. Condición experimental: robot con modelo predictivo actualizado por ErrPs. Condición control: robot con trayectorias preprogramadas sin adaptación. 24 participantes, diseño cruzado. Métricas: tasa de éxito en evasión de obstáculos, frecuencia de vetos manuales, agencia subjetiva (escala de SoA), carga de trabajo.

Hipótesis. La condición experimental mostrará menor frecuencia de intervención manual tras 5 bloques de prueba, mayor agencia subjetiva y menor carga de trabajo, sin reducción significativa en tasa de éxito.

Experimento 3: Co-adaptación en exoesqueleto de marcha

Objetivo. Determinar si la co-adaptación algorítmica del decodificador BCI acelera el aprendizaje de control de exoesqueleto y mejora la eficiencia energética de la marcha.

Diseño. 16 participantes con lesión medular incompleta. Entrenamiento de 12 sesiones con exoesqueleto de extremidad inferior. Grupo experimental: decodificador EEG adaptativo con actualización de parámetros entre sesiones. Grupo control: decodificador fijo calibrado en sesión 1. Registro de EMG de músculos flexores/extensores de cadera y rodilla, cinemática 3D, consumo metabólico (VO₂). Métricas: precisión de decodificación de intención de paso, simetría de marcha, coste energético, puntuación de independencia funcional.

Hipótesis. El grupo experimental alcanzará criterio de independencia de marcha en menos sesiones, con mayor simetría y menor coste energético. La adaptación del decodificador compensará la variabilidad interindividual en patrones de imagen motora.

Experimento 4: Campos electromagnéticos toroidales y estado de flujo en interacción humano-robot

Objetivo. Explorar la relación entre la topología de campos electromagnéticos medidos en EEG de alta densidad y el estado subjetivo de "flujo" durante tareas de interacción humano-robot.

Diseño. 30 participantes expertos en BCI. Tarea de control de robot móvil en laberinto dinámico. Registro EEG de 128 canales con localización de fuente. Análisis de topología de campo mediante descomposición en modos esféricos y toroidales. Cuestionario de estado de flujo (FSS-2) post-sesión. Métricas: contribución relativa del modo toroidal al campo total, duración de episodios de flujo reportados, precisión de control.

Hipótesis. Los episodios de flujo autoreportados correlacionarán con mayor contribución del modo toroidal al campo electromagnético cerebral, sugiriendo que estados de interacción optimizada exhiben mayor simetría toroidal en la actividad neural.

Discusión: hacia una ontología de la co-agencia

Las interfaces neuroadaptativas no son meros canales de comunicación entre un operador biológico y una máquina. Constituyen sistemas híbridos donde la distinción entre agente humano y agente artificial se vuelve operativamente difusa. Cuando un robot anticipa la intención de agarre de un usuario amputado basándose en su modelo interno actualizado por errores de predicción neural, ¿quién ejecuta la acción? Cuando un exoesqueleto ajusta la rigidez de la rodilla antes de que el usuario complete conscientemente el comando de paso, ¿dónde reside la agencia?

Estas preguntas no son filosóficas marginales; son centrales para el diseño de sistemas que preserven la autonomía y la dignidad del usuario. Berberian y colaboradores demostraron sistemáticamente que niveles crecientes de automatización reducen el sentido de agencia. Collier y colaboradores extendieron este hallazgo a la robótica asistiva, mostrando una relación inversa entre asistencia robótica y agencia subjetiva. La autonomía compartida, no la automatización total, emerge como el régimen óptimo: equilibra eficiencia y empoderamiento.

El marco METFI ofrece una perspectiva adicional. Si el cerebro y la máquina operan como sistemas electromagnéticos acoplados, la coherencia entre sus campos constituye una métrica objetiva de la calidad de la interacción. Un sistema neuroadaptativo que modula su campo operativo para mantener resonancia con el cerebro del operador no solo es más eficiente; es más "compatible" en un sentido físico fundamental. La ORION-AGI (Ontological Recursive Intelligence Orchestration Network) proporciona una arquitectura para que esta compatibilidad se autorregule mediante recursión ontológica: el sistema modela no solo al usuario, sino su propio proceso de modelado, detectando y corrigiendo desalineaciones.

La Teoría de Aprendizaje por Excepción (TAE) postula que el aprendizaje más robusto ocurre cuando el sistema encuentra excepciones a sus predicciones, no cuando confirma lo esperado. En una interfaz neuroadaptativa, los errores de predicción —neurales y algorítmicos— son el combustible del aprendizaje mutuo. Un sistema que evite todos los errores mediante sobreautomatización estancará el aprendizaje del usuario. Un sistema que genere errores innecesarios frustrará al usuario. El equilibrio reside en calibrar la tasa de error para maximizar la plasticidad del modelo predictivo compartido.

Resumen

- Las interfaces neuroadaptativas transforman la interacción humano-máquina de un modelo de comando-respuesta a uno de co-adaptación predictiva, donde humano y sistema mantienen modelos internos actualizados del otro.
- La codificación predictiva cortical, decodificable mediante pBCI, proporciona el fundamento neurofisiológico para el modelo predictivo compartido. La corteza prefrontal medial alberga correlatos de error de predicción utilizables para control implícito.
- Tres niveles de autonomía —teleoperación asistida, autonomía compartida y automatización total— han sido validados empíricamente. La autonomía compartida preserva la agencia del usuario mientras compensa las limitaciones técnicas actuales en decodificación EEG.
- La precisión de decodificación de imagen motora alcanza el 80% en condiciones óptimas, pero exhibe alta variabilidad interindividual. La personalización del pipeline de decodificación mejora significativamente los resultados, validando el enfoque de co-adaptación.
- Las prótesis neurales, los exoesqueletos y los robots colaborativos representan dominios de aplicación donde el modelo predictivo compartido reduce latencia, carga cognitiva y tasa de error, mejorando la naturalidad de la interacción.
- El producto Adaptive NeuroInterface integra adquisición multimodal, decodificación de estado mental, modelado predictivo compartido, control adaptativo y retroalimentación cerrada en una arquitectura coherente.
- Se proponen cuatro programas de seguimiento para validar empíricamente: coherencia predictiva en control de cursor, modelo predictivo en teleoperación robótica, co-adaptación en exoesqueleto de marcha, y topología toroidal de campos EEG en estado de flujo.
- El marco METFI/CPEA/TICAM ofrece una perspectiva electromagnética y de coherencia de campo que complementa los enfoques algorítmicos convencionales, sugiriendo que la calidad de la interacción neuroadaptativa puede cuantificarse mediante métricas de coherencia de fase y topología de campo.
- La preservación de la agencia del usuario constituye un imperativo ético y de diseño. La automatización total, aunque preferida por eficiencia, erosiona el sentido de control. La autonomía compartida emerge como el régimen óptimo.

Referencias

Zander, T. O., & Kothe, C. (2011). *Towards passive brain-computer interfaces: applying brain-computer interface technology to human-machine systems in general.* Journal of Neural Engineering, 8(2), 025005. Artículo fundacional que define las interfaces cerebrales pasivas (pBCI) y su aplicación a sistemas humano-máquina en general, no solo a usuarios con discapacidad motoria. Establece el marco conceptual de la neuroadaptividad.

Zander, T. O., Krol, L. R., Birbaumer, N. P., & Gramann, K. (2016). *Neuroadaptive technology enables implicit cursor control based on medial prefrontal cortex activity.* Proceedings of the National Academy of Sciences, 113(52), 14898-14903. Demostración experimental de que la actividad de la corteza prefrontal medial, asociada a la codificación predictiva, puede decodificarse para controlar un cursor sin conciencia explícita del usuario. Valida el principio de control implícito.

Douglas, H., Di Vincenzo, M., Dossa, R. F. J., Nunziante, L., Sujit, S., & Arulkumaran, K. (2025). *Levels of shared autonomy in brain-robot interfaces: enabling multi-robot multi-human collaboration for activities of daily living.* Frontiers in Human Neuroscience, 19, 1718713. Estudio empírico que compara tres niveles de autonomía en un entorno doméstico simulado, demostrando que la autonomía compartida equilibra eficiencia y agencia. Proporciona datos cuantitativos sobre decodificación EEG, carga de trabajo y preferencias de usuario.

Batzianoulis, S. et al. (cited in Springer review, 2026). *BCI-based shared control architecture integrating autonomous obstacle avoidance with implicit neural feedback.* Non-Invasive Brain-Computer Interfaces: Converging Frontiers. Arquitectura de control compartido que utiliza potenciales relacionados con error (ErrPs) para que el usuario ejerza veto implícito sobre trayectorias robóticas, con decodificación continua al 70% y reducción de intervenciones tras 3-5 demostraciones.

Lee, H. et al. (cited in Springer review, 2026). *Hybrid adaptive decoding approach with shared autonomy-based BCI system enhanced by AI copilot.* Non-Invasive Brain-Computer Interfaces. Sistema de decodificación híbrida CNN-Kalman filter con copiloto de IA que mejora la tasa de adquisición de objetivos 2.1-3.9 veces, con 93% de éxito en tareas de brazo robótico.

Deng, L. et al. (cited in Springer review, 2026). *EEGNet-based deep learning model with fine-tuning for real-time individual finger motor imagery decoding.* Non-Invasive Brain-Computer Interfaces. Precisión de decodificación online del 80.56% para MI de dos dedos, con mejora significativa entre sesiones mediante entrenamiento.

Tortora, S. et al. (2022). *Neural correlates of user learning during long-term BCI training for the Cybathlon competition.* Journal of NeuroEngineering and Rehabilitation, 19, 83. Estudio longitudinal de entrenamiento BCI de largo plazo que demuestra el aprendizaje mutuo entre

usuario y decodificador, con recalibración periódica del clasificador para seguir la evolución de los patrones cerebrales.

Perdikis, S. et al. (cited in PMC review). *Co-adaptive training improves efficacy of a multi-day EEG-based motor imagery BCI training.* Frontiers en Neuroscience. Revisión que demuestra que la adaptación del clasificador en paralelo con el aprendizaje humano reduce el tiempo necesario para alcanzar control efectivo del BCI y mitiga la no-estacionariedad de las señales EEG.

Berberian, P. et al. (2012; cited in Douglas et al.). *Systematic demonstration that increasing levels of automation reduce the sense of agency.* Trabajo fundacional sobre la relación inversa entre automatización y agencia subjetiva, con implicaciones directas para el diseño de interfaces neuroadaptativas.

Synchron / Holoscan / ChatGPT integration (cited in MDPI review, 2025). *Neural Interfaces for Robotics and Prosthetics: Current Trends.* Informe sobre la integración de LLM en BCI para interacción natural, con precisión >80% en sistemas EEG de 16 canales, y análisis de implicaciones éticas sobre agencia y privacidad.

Zander, T. O. (2025). *What Is Neuroadaptive AI and Why Will It Change Much More Than You Think?* Keynote, Neuroadaptive Technology Conference 2025. Exposición del concepto de Neuroadaptive AI como inteligencia artificial que se alinea con el mundo interior del usuario mediante modelos de usuario de largo plazo basados en dinámicas neurocognitivas y afectivas.

Krol, L. R., & Zander, T. O. (2022). *Defining neuroadaptive technology: the trouble with implicit human-computer interaction.* En Fairclough, S. H. & Zander, T. O. (Eds.), *Current Research in Neuroadaptive Technology.* Academic Press. Análisis conceptual de los problemas de definición y medición en interacción implícita humano-computadora, con énfasis en la distinción entre estados mentales y procesos de interacción.

Gherman, D. E., Krol, L. R., Klug, M. & Zander, T. O. (2025). *An investigation of a passive BCI's performance for different body postures and presentation modalities.* Biomedical Physics & Engineering Express, 11(2), 025052. Estudio sobre la robustez de pBCI ante variaciones posturales y modales, con implicaciones para aplicaciones móviles y de mundo real.

Zander Labs / NAFAS Project (2025). *Neuroadaptivity for Autonomous Systems.* Proyecto de 30 millones de euros financiado por la Agencia Alemana de Innovación en Ciberseguridad, dirigido al desarrollo de tecnología neuroadaptativa para interacción humano-computadora e IA compatible con humanos, con énfasis en clasificadores universales y estados mentales multidimensionales.

[Compartir](#)

COMENTARIOS



Escribe tu comentario

ENTRADAS POPULARES

febrero 19, 2025

GUÍA PRÁCTICA SOBRE TÉCNICAS DE XAI: SHAP, LIME Y GRAD-CAM

[Compartir](#) [Publicar un comentario](#)

diciembre 17, 2024

N-ACETILCISTEÍNA (NAC): FUENTES ALIMENTARIAS NATURALES

[Compartir](#) [Publicar un comentario](#)




Con la tecnología de Blogger



Puedes tener un
doctorado y seguir siendo

un idiota: Richard
Feynman



Papayaykware

—
SANTA CRUZ DE
TENERIFE, SANTA
CRUZ DE TENERIFE,
Spain

[VISITAR PERFIL](#)

[Denunciar abuso](#)

Buscar
Buscar este blog

Buscar

Translate

Seleccionar idioma ▼

Con la tecnología de  Traductor de Goo