



PAPAYAYKWARE

Estudios científicos comprensibles

· INICIO

ARCHIVOS DEL BLOG



agosto 23, 2026

MODELOS FUNDACIONALES EEG Y PREDICCIÓN LATENTE ESTRUCTURADA: PUENTE HACIA UNA ARQUITECTURA CPEA-AGI

He comprobado que el punto de partida que propones **no es meramente especulativo**: el *EEG Foundation Challenge 2025* fue efectivamente aceptado en el *NeurIPS 2025 Competition Track* y plantea precisamente transferencia **cross-task** y representaciones **subject-invariant** utilizando EEG de más de 3.000 participantes.

Y existe una conexión todavía más interesante: el preprint **EEG-JEPA: Structured Latent Prediction for EEG Foundation Models**, publicado el 31 de julio de 2026, sustituye la reconstrucción directa de voltajes por predicción de **estados latentes estructurados**, introduciendo además una organización explícita por contenido, soporte espacio-temporal y profundidad de la representación. En sus experimentos, bajo condiciones comparables, informa una mejora de la *macro balanced accuracy* multitarea congelada de 40,49 % a 50,42 %, y hasta 52,94 % mediante continuación multisource.

La cuestión importante, a mi juicio, **no es afirmar que EEG-JEPA sea ya una arquitectura AGI**, porque eso no estaría justificado. La cuestión científicamente fértil es otra:

¿Estamos observando la aparición de un principio arquitectónico que se parece mucho más al TAE/CPEA que los modelos EEG basados exclusivamente en reconstrucción?

Mi respuesta es **sí, como homología computacional**; todavía no como equivalencia **neurobiológica**.

Hay cinco convergencias particularmente fuertes:

1. Del dato observado al estado latente.

EEG-JEPA no intenta simplemente reproducir el voltaje perdido. Aprende a inferir un estado latente a partir del contexto. Eso es conceptualmente próximo a una arquitectura predictiva donde el sistema no representa únicamente *lo que existe*, sino *lo que espera que exista*.

2. La excepción adquiere valor informativo.

En TAE, la desviación respecto al modelo predictivo no constituye simplemente ruido: puede ser información sobre una transición de régimen. En un modelo predictivo latente, el error entre estado esperado y estado inferido puede convertirse en una variable computacional de primer orden. **Aquí aparece una posible correspondencia con DEPD**, aunque ésta es todavía una propuesta del corpus CPEA y no una propiedad demostrada de EEG-JEPA.

3. La coherencia deja de ser exclusivamente local.

EEG-JEPA introduce estructura electrode-time y escalas múltiples. Esto resulta particularmente relevante para **NEXUS-EEG y SIGMA-T**, porque permite pensar el EEG no como una colección de canales independientes, sino como una geometría dinámica de relaciones espacio-temporales.

4. La invariancia entre sujetos es una cuestión de representación.

El EEG Foundation Challenge establece que una representación útil debe sobrevivir al cambio de sujeto y de tarea. Esto coincide con un problema central de CPEA: separar la **estructura dinámica generalizable** de las características idiosincrásicas del individuo.

5. Aquí aparece el verdadero puente hacia una arquitectura CPEA-AGI.

Si una arquitectura pudiera integrar:

señal → representación latente → predicción → error predictivo → actualización → transferencia → acción,

tendríamos algo mucho más próximo a una arquitectura cognitiva general que a un simple clasificador EEG.

La cautela fundamental es importante. **No existe evidencia de que EEG-JEPA implemente TAE, METFI, TICAM, DPCC o CPEA.** La conexión que voy a desarrollar es una **hipótesis de correspondencia arquitectónica**. Asimismo, cuando METFI aparezca asociado a esta problemática, lo utilizaré como **homología estructural** —dinámica, simetría, transición de régimen y pérdida de coherencia— y no como mecanismo electromagnético causal demostrado en neurociencia.

Modelos fundacionales EEG y predicción latente estructurada: puente hacia una arquitectura

CPEA-AGI

Abstract

La aparición de modelos fundacionales especializados en electroencefalografía (EEG) está desplazando progresivamente el problema desde la clasificación de señales hacia el aprendizaje de representaciones neurodinámicas transferibles entre individuos, tareas y condiciones experimentales. En este contexto, el *EEG Foundation Challenge 2025* planteó explícitamente dos problemas de elevada relevancia arquitectónica: la transferencia *cross-task* y la obtención de representaciones invariantes al sujeto. El desafío utiliza un corpus de alta densidad con más de 3.000 participantes y múltiples paradigmas cognitivos, situando la generalización de la representación como problema central de la decodificación EEG.

En julio de 2026, EEG-JEPA introdujo un principio adicional: la predicción no se dirige prioritariamente hacia la reconstrucción de muestras de voltaje, sino hacia estados latentes estructurados inferidos a partir del contexto electrodo-temporal. El modelo organiza el objetivo predictivo mediante tres dimensiones —contenido, soporte y profundidad— y emplea una estrategia de enmascaramiento neurotopológico multiescala. Bajo condiciones experimentales comparables, el trabajo informa mejoras sustanciales respecto a la reconstrucción de formas de onda en transferencia multitarea.

El presente artículo analiza esta transición desde el marco METFI-TAE-CPEA, estableciendo una separación explícita entre evidencia empírica y extrapolación teórica. Se propone que la predicción latente estructurada constituye una posible homología computacional con la Teoría de Aprendizaje por Excepción (TAE), particularmente cuando el error predictivo se interpreta como información sobre cambios de régimen y no únicamente como residuo estadístico. Esta correspondencia permite formular una arquitectura conceptual en la que EEG actúa como capa observacional, los modelos fundacionales como sistema de representación latente, el Detector de Error Predictivo Dinámico (DEPD) como capa de comparación entre estados esperados y observados, y CPEA como arquitectura de integración adaptativa entre percepción, inferencia y acción.

No obstante, no se sostiene que los modelos actuales implementen TAE, METFI, TICAM o CPEA. Las correspondencias propuestas son hipótesis arquitectónicas susceptibles de falsación. METFI se utiliza, cuando procede, como homología estructural de dinámicas de simetría, acoplamiento y transición de régimen, no como mecanismo causal electromagnético demostrado de la actividad cerebral.

Palabras clave: EEG, modelos fundacionales, aprendizaje latente, JEPA, predicción, error predictivo, coherencia, transferencia *cross-task*, invariancia al sujeto, TAE, CPEA, DEPD, neurodinámica, AGI.

Introducción

La electroencefalografía presenta una paradoja metodológica. Es simultáneamente una de las técnicas más accesibles para observar dinámicas cerebrales a gran escala y una de las fuentes de datos más difíciles de convertir en representaciones universalmente transferibles. La señal EEG está condicionada por la anatomía individual, la geometría de los electrodos, el estado cognitivo, el paradigma experimental, el ruido fisiológico, los artefactos de adquisición y la propia no estacionariedad del sistema.

Los modelos tradicionales de aprendizaje automático suelen resolver esta dificultad mediante una especialización progresiva: un conjunto de datos, una tarea, una población y, con frecuencia, un procedimiento de recalibración específico. El problema de los modelos fundacionales es radicalmente distinto. No se trata solamente de obtener una elevada precisión en una tarea determinada, sino de aprender una representación suficientemente estructurada como para conservar información relevante cuando cambian el individuo, la tarea o el contexto.

Esta transición está explícitamente formulada por el *EEG Foundation Challenge 2025*. La competición propone transferencia entre tareas y generalización entre individuos mediante representaciones aprendidas de grandes corpus EEG. El objetivo no es simplemente mejorar un clasificador, sino evaluar hasta qué punto una representación neural puede abstraer propiedades relevantes del dominio EEG.

Este planteamiento adquiere una importancia particular desde CPEA. Si una inteligencia artificial debe interactuar con sistemas biológicos complejos, la cuestión fundamental no puede reducirse a decodificar estados aislados. Debe aprender las **dinámicas de transición entre estados**.

La diferencia es sustancial.

Una representación estática pregunta:

¿Qué estado representa esta señal?

Una representación predictiva pregunta:

¿Qué estado debería aparecer dadas las condiciones presentes?

Y una arquitectura adaptativa completa añade:

¿Qué significa la discrepancia entre el estado esperado y el observado, y cómo debe modificar el modelo?

Esta tercera formulación constituye el punto de entrada natural hacia TAE.

Del EEG reconstruido al EEG predicho en espacio latente

Los modelos de aprendizaje autosupervisado aplicados al EEG han utilizado ampliamente estrategias de enmascaramiento y reconstrucción. El principio es intuitivo: ocultar segmentos de la señal y obligar al modelo a reconstruirlos.

Sin embargo, la reconstrucción de la señal física contiene una dificultad fundamental. El EEG no está compuesto exclusivamente por información neurocognitiva. También contiene propiedades del sistema de adquisición, ruido, actividad fisiológica no relacionada con la tarea y regularidades temporales que pueden ser fácilmente predecibles sin representar adecuadamente la estructura neural.

EEG-JEPA parte precisamente de esta cuestión. El modelo introduce una arquitectura de predicción latente en la que un codificador contextual procesa información parcialmente observada y un predictor intenta inferir estados latentes producidos por un codificador objetivo. El objetivo deja de ser la recuperación de voltajes individuales y pasa a ser la predicción de una representación estructurada.

Esta diferencia es arquitectónicamente profunda.

El aprendizaje deja de estar condicionado por:

$$\begin{bmatrix} x_{t}^{\text{oculto}} \end{bmatrix} \rightarrow \hat{x}_{t}$$

y se aproxima a:

$$\begin{bmatrix} z_{\text{contexto}} \end{bmatrix} \rightarrow \hat{z}_{\text{futuro}}$$

donde (x) representa la observación EEG y (z) un estado latente.

El segundo problema posee una propiedad especialmente relevante para CPEA: **la representación puede contener invariantes que no están presentes de manera explícita en una muestra individual de la señal.**

En otras palabras, el sistema no necesita aprender el EEG como una secuencia de voltajes. Puede aprender el EEG como una dinámica.

El EEG Foundation Challenge: la generalización como prueba de representación

El *EEG Foundation Challenge* constituye un experimento particularmente interesante desde esta perspectiva. El desafío fue aceptado en el *NeurIPS 2025 Competition Track* y se estructuró alrededor de dos problemas: transferencia *cross-task* y representación *subject-invariant*.

El corpus HBN-EEG utilizado contiene registros de más de 3.000 participantes y seis tareas cognitivas, con EEG de alta densidad.

Esto permite separar tres niveles de generalización:

1. **Generalización intra-sujeto:** la misma persona en condiciones diferentes.
2. **Generalización inter-sujeto:** individuos diferentes realizando tareas comparables.
3. **Generalización inter-tarea:** paradigmas diferentes con estructuras cognitivas parcialmente compartidas.

El tercer nivel resulta particularmente importante.

Si una representación solamente funciona dentro del paradigma utilizado durante su entrenamiento, probablemente haya aprendido características específicas de la tarea. Si funciona sobre tareas diferentes, existe evidencia de que ha extraído una estructura más abstracta.

Desde el marco CPEA, puede formularse una distinción entre:

$$[R_{\{EEG\}} = R_{\{\text{idiosincrático}\}} + R_{\{\text{contextual}\}} + R_{\{\text{dinámico}\}}]$$

donde ($R_{\{\text{dinámico}\}}$) representa la componente potencialmente transferible de la organización temporal y espacial del sistema.

Esta formulación no implica que la descomposición sea directamente observable. Es una abstracción matemática útil para formular la hipótesis.

Hipótesis H1

Un modelo EEG que aprende representaciones latentes estructuradas debería conservar mayor información transferible entre sujetos y tareas que un modelo equivalente entrenado exclusivamente mediante reconstrucción de la forma de onda.

Condición de falsabilidad

La hipótesis quedaría debilitada si, manteniendo constantes arquitectura, corpus, duración del entrenamiento y protocolo de evaluación, la predicción latente estructurada no produjera una mejora consistente en transferencia *cross-task* y *cross-subject*.

Los resultados iniciales de EEG-JEPA son compatibles con H1. El trabajo informa que, con el mismo *backbone*, corpus y duración de entrenamiento, el modelo pasa de 40,49 % a 50,42 % de *macro balanced accuracy* promedio en 14 tareas bajo evaluación *frozen*, mientras que una continuación multisource alcanza 52,94 %. En *fine-tuning* protocolizado, la media de nueve tareas pasa de 68,98 % a 70,65 %.

Estos resultados son empíricamente relevantes, aunque no demuestran por sí mismos ninguna teoría neurobiológica concreta.

La TAE como marco de interpretación del error predictivo

La Teoría de Aprendizaje por Excepción puede formularse, en términos generales, alrededor de una idea: un sistema adaptativo no aprende únicamente de los estados que confirma, sino especialmente de las discrepancias entre su modelo predictivo y la dinámica observada.

Sea:

$$[z_t]$$

el estado latente observado y:

$$[\hat{z}_t = P(z_{t-k:t-1})]$$

el estado esperado por el modelo.

Podemos definir:

$$[\varepsilon_t = z_t - \hat{z}_t]$$

como error predictivo.

En una arquitectura convencional, (ε_t) constituye una variable de optimización. En TAE puede adquirir un significado adicional: **señal de posible novedad estructural**.

No todos los errores son iguales.

Un error pequeño y recurrente puede representar ruido.

Un error grande pero aislado puede representar una perturbación.

Una secuencia persistente de errores correlacionados puede indicar que el modelo predictivo ha dejado de ser adecuado.

Esta tercera situación es especialmente importante.

Podemos expresar el cambio de régimen mediante:

$$[P(z_t | z_{t-1}, M_t) \neq P(z_t | z_{t-1}, M_{t-1})]$$

donde (M_t) representa el modelo generativo implícito del sistema.

El problema deja de ser entonces:

«¿Cuánto se ha equivocado el modelo?»

y pasa a ser:

«¿Ha cambiado el régimen que generaba la señal?»

Esta distinción proporciona una conexión conceptual directa con el **DEPD**.

DEPD: del error residual al detector de transición

El Detector de Error Predictivo Dinámico puede conceptualizarse como una capa situada entre representación y adaptación.

Una formulación inicial podría ser:

$$[\text{DEPD}_t = f(\epsilon_t, \Delta \epsilon_t, C_t, \tau_t)]$$

donde:

- (ϵ_t) = magnitud del error;
- $(\Delta \epsilon_t)$ = dinámica del error;
- (C_t) = coherencia estructural;
- (τ_t) = persistencia temporal.

La ventaja de esta formulación es que evita identificar automáticamente anomalía con error.

Una arquitectura suficientemente sensible debería distinguir:

$$[\text{ruido} \neq \text{anomalía} \neq \text{transición de régimen}]$$

Esta distinción constituye uno de los puntos donde TAE podría aportar una especificación adicional a los modelos EEG fundacionales.

EEG-JEPA ya proporciona una representación latente estructurada. Lo que todavía no se desprende de su publicación es que el error de predicción se utilice explícitamente como un **detector dinámico de cambio de régimen cognitivo**.

Aquí aparece una hipótesis CPEA propiamente dicha.

Hipótesis H2

La información contenida en el error predictivo latente, integrada temporal y espacialmente,

puede discriminar mejor las transiciones de estado neurodinámico que el error de reconstrucción de la forma de onda.

Falsabilidad

La hipótesis podría evaluarse mediante paradigmas con transiciones cognitivas conocidas y comparar:

[
AUC(DEPD_{latente})
]

frente a:

[
AUC(DEPD_{waveform})
]

manteniendo constante el corpus, la partición de sujetos y el presupuesto computacional.

La hipótesis no exige que el error latente sea universalmente superior. Exige que presente una ventaja sistemática bajo condiciones donde la transición estructural sea relevante.

Coherencia predictiva y geometría espacio-temporal

La contribución de EEG-JEPA que quizá resulte más relevante para CPEA no sea únicamente el uso de un espacio latente, sino la estructuración explícita de la predicción.

El trabajo introduce *Neurotopology-Aware Multi-scale Electrode-Temporal Masking* (N-MET), organizando los objetivos mediante regiones estructuradas electrodo-tiempo y diferentes escalas.

Esto aproxima el problema a una representación:

[
 $Z(x,t)$
]

en lugar de una simple secuencia:

[
 $x(t)$
]

La consecuencia conceptual es importante.

El cerebro no produce simplemente amplitudes. Produce relaciones temporales entre poblaciones neuronales espacialmente distribuidas.

Por tanto, una representación útil debería conservar información sobre:

- fase;
- sincronización;
- acoplamiento;
- dinámica espectral;
- topología funcional;
- persistencia temporal;
- transición entre configuraciones.

Aquí resulta pertinente el concepto de **coherencia predictiva** utilizado en CPEA.

Debe realizarse, sin embargo, una distinción metodológica estricta.

La coherencia predictiva no puede identificarse sin más con coherencia de fase, ITPC o conectividad EEG.

La coherencia de fase es una propiedad de una señal o relación entre señales. La coherencia predictiva sería una propiedad más amplia: la estabilidad con la que una arquitectura puede anticipar la evolución de una configuración dinámica.

Podría representarse como:

$$[\text{PC}_t = g(\text{phase}, \text{connectivity}, \text{latent dynamics}, \text{prediction error})]$$

Esta ecuación debe considerarse **hipótesis formal de trabajo**, no una magnitud neurofisiológica establecida.

CPEA: una arquitectura de integración

Desde esta perspectiva, CPEA puede formularse no como un simple sistema de clasificación EEG, sino como una arquitectura de inferencia adaptativa:

$$[\text{EEG} \rightarrow \text{NEXUS} \rightarrow \text{Z}_t \rightarrow P(\text{Z}_{t+1})]$$

$\rightarrow$
 DEPD
 $\rightarrow$
 TAE
 $\rightarrow$
 ORION\text{-}AGI
]

Cada módulo tendría una función conceptualmente diferenciada.

NEXUS-EEG constituiría la capa de adquisición y normalización del flujo neuroeléctrico.

SIGMA-T representaría la integración de información espacio-temporal y multiescalar.

EEG-JEPA, o arquitecturas equivalentes, proporcionaría el mecanismo de aprendizaje de representaciones latentes predictivas.

DEPD calcularía la discrepancia dinámica entre estados esperados y observados.

TAE convertiría determinadas excepciones persistentes en información de actualización.

ORION-AGI integraría esas representaciones en un sistema de razonamiento y decisión de mayor nivel.

El punto decisivo sería que la arquitectura no aprendiera únicamente:

$[$
 $X \rightarrow Y$
 $]$

sino:

$[$
 $X_t \rightarrow Z_t \rightarrow \hat{Z}_{t+1} \rightarrow \varepsilon_{t+1} \rightarrow Z'_{t+1}$
 $]$

Es decir, una arquitectura capaz de aprender de sus propias predicciones fallidas.

El papel de DPCC y TICAM

El **DPCC**, definido en el corpus CPEA como *Detector Post-Cuántico de Coherencia*, requiere una separación todavía más estricta entre arquitectura conceptual y mecanismo físico.

No existe evidencia presentada en las fuentes analizadas que permita afirmar que EEG-JEPA detecte fenómenos cuánticos cerebrales ni que su rendimiento dependa de un proceso post-cuántico.

Por tanto, cualquier integración DPCC-EEG-JEPA debe considerarse una **hipótesis**

arquitectónica especulativa.

Su versión mínimamente falsable podría limitarse a detectar discontinuidades de coherencia en el espacio latente:

$$[$$

$$DPCC_t = h(\Delta PC_t)$$

$$]$$

sin atribuirles inicialmente una causa cuántica.

Esto tiene una ventaja metodológica. Permite evaluar primero el fenómeno computacional y solamente después preguntar por su interpretación física.

Algo equivalente ocurre con **TICAM**, el *Transductor Inferencial de Coherencia por Acoplamiento Magnetotalámico*.

La existencia de mecanismos neurofisiológicos relacionados con actividad eléctrica, campos electromagnéticos y organización talamocortical no demuestra un transductor magnetotalámico del tipo propuesto por TICAM.

Por ello:

TICAM debe tratarse actualmente como hipótesis mecanística, no como hecho establecido.

Su falsabilidad exige identificar una variable fisiológica medible cuya modulación prediga la dinámica latente EEG más allá de explicaciones convencionales.

METFI como homología estructural

La aplicación de METFI al cerebro exige todavía mayor prudencia.

METFI propone una descripción del sistema Tierra basada en una geometría electromagnética toroidal y en transiciones asociadas a pérdida de simetría. Trasladar esta estructura directamente al cerebro sería una extrapolación causal no demostrada.

Sin embargo, puede existir una **homología matemática o estructural**.

Un sistema complejo puede representarse mediante:

$$[$$

$$\mathcal{S} = (G, \Phi, C)$$

$$]$$

donde (G) representa la geometría de interacción, (Φ) el estado dinámico y (C) la coherencia global.

Una transición de régimen podría implicar una modificación de las simetrías de (G) o una pérdida de estabilidad de (Φ).

Esta abstracción puede ser utilizada en neurodinámica sin afirmar que el cerebro sea literalmente un sistema METFI.

Por tanto, en CPEA:

METFI funciona aquí como homología estructural de una dinámica de coherencia, simetría y transición de régimen, no como mecanismo causal electromagnético demostrado.

Esta distinción no debilita el modelo. Lo hace científicamente más preciso.

De la representación universal a una posible arquitectura AGI

La verdadera relevancia de los modelos fundacionales EEG no reside necesariamente en que permitan diagnosticar o clasificar mejor.

Su relevancia arquitectónica podría encontrarse en otro lugar.

Un modelo que aprende representaciones transferibles entre individuos y tareas está resolviendo parcialmente un problema que también aparece en inteligencia artificial general: **extraer estructura estable de observaciones altamente variables.**

El *cross-task transfer* constituye una forma limitada de abstracción.

La invariancia al sujeto constituye una forma limitada de abstracción.

La predicción latente constituye una forma limitada de modelización generativa.

El aprendizaje mediante error constituye una forma limitada de adaptación.

Si se integran:

$$\begin{aligned} &[\\ &\text{\text{abstracción}} \\ &+ \\ &\text{\text{predicción}} \\ &+ \\ &\text{\text{error}} \\ &+ \\ &\text{\text{adaptación}} \\ &+ \\ &\text{\text{transferencia}} \\ &] \end{aligned}$$

emerge una arquitectura mucho más interesante.

No equivale todavía a AGI.

Pero sí representa un patrón arquitectónico compatible con algunos de los requisitos funcionales que una AGI debería satisfacer.

Programas de seguimiento experimental

Programa 1. Predicción latente frente a reconstrucción

Comparar tres familias:

1. reconstrucción de waveform;
2. predicción latente;
3. predicción latente + DEPD.

Mantener idénticos:

- sujetos;
- corpus;
- *backbone*;
- presupuesto computacional;
- número de épocas;
- protocolo de evaluación.

Variables principales:

[
BA_{cross-task}
]

[
BA_{cross-subject}
]

[
\Delta Prediction\ Error
]

y estabilidad de las representaciones.

Programa 2. Detección de transición neurodinámica

Diseñar paradigmas con cambios conocidos de:

- atención;
- carga cognitiva;
- percepción;
- respuesta;
- cambio de tarea.

Calcular:

$$[\varepsilon_t = z_t - \hat{z}_t]$$

y evaluar si la dinámica del error anticipa la transición antes que las métricas convencionales de clasificación.

El resultado crítico sería demostrar que el error latente contiene información temporal adicional.

Programa 3. Coherencia predictiva

Integrar:

- ITPC;
- coherencia espectral;
- conectividad funcional;
- dinámica latente;
- error predictivo.

Construir un índice compuesto:

$$[CPE_t = f(ITPC, Coh_t, Z_t, \varepsilon_t)]$$

y comprobar si mejora la predicción de cambios de estado respecto a cada variable individual.

Este índice debe considerarse una **construcción experimental**, no una medida neurofisiológica establecida.

Programa 4. Transferencia hacia CPEA

Evaluar si una representación EEG entrenada inicialmente para tareas neurocognitivas puede

transferirse a tareas de interacción humano-IA.

El criterio esencial sería que la representación preserve propiedades relevantes cuando cambie el contexto.

La prueba fuerte sería:

$$\left[\begin{array}{l} \text{Performance}_{\{\text{unseen-task}\}} \\ \text{Performance}_{\{\text{baseline}\}} \end{array} \right]$$

sin recalibración específica significativa.

Programa 5. ECDO

El concepto de **Evento de Colapso Dinámico Oscilatorio (ECDO)** puede operacionalizarse sin asumir inicialmente una causa física particular.

Definición experimental provisional:

transición abrupta y persistente desde un régimen dinámico estable hacia otro régimen caracterizado por una reorganización significativa de la estructura latente y/o pérdida de coherencia predictiva.

Su detección podría combinar:

$$\left[\begin{array}{l} \Delta Z \\ + \\ \Delta \text{CPE} \\ + \\ \Delta \epsilon \\ + \\ \Delta H \end{array} \right]$$

donde (H) representa una medida de complejidad o entropía.

La hipótesis sería falsable si los supuestos ECDO no muestran una firma reproducible frente a perturbaciones controladas.

Discusión

El resultado más interesante de esta convergencia no es que un modelo EEG haya aumentado su

precisión.

Es que la definición de lo que significa «aprender EEG» está cambiando.

El paradigma clásico intenta reconstruir una señal.

El paradigma fundacional intenta aprender una representación.

El paradigma predictivo intenta anticipar un estado.

El paradigma CPEA propone además aprender de la discrepancia entre predicción y realidad.

La secuencia:

[
observación
\\rightarrow
representación
\\rightarrow
predicción
\\rightarrow
error
\\rightarrow
excepción
\\rightarrow
actualización
]

constituye una arquitectura cognitiva potencialmente mucho más general.

El *EEG Foundation Challenge* demuestra que la transferencia entre sujetos y tareas puede convertirse en objetivo explícito de evaluación. EEG-JEPA introduce después una formulación particularmente relevante: no predecir necesariamente el dato bruto, sino un estado latente estructurado.

Desde CPEA, el siguiente salto conceptual consiste en convertir el error predictivo en una variable de control.

Aquí se encuentra la posible contribución de TAE.

Y ahí aparece también una interpretación más rigurosa de ECDO: no como un acontecimiento misterioso, sino como una **transición abrupta de régimen detectable en el espacio dinámico de las representaciones**.

Esta formulación permite conservar la ambición conceptual del corpus sin confundirla con evidencia empírica.

Conclusiones

Los modelos fundacionales EEG están evolucionando desde sistemas de decodificación dependientes de sujeto y tarea hacia arquitecturas capaces de aprender representaciones transferibles. El *EEG Foundation Challenge 2025* formalizó este problema mediante transferencia *cross-task* y generalización *cross-subject*.

EEG-JEPA introduce una evolución adicional: sustituye la reconstrucción directa de muestras EEG por predicción de estados latentes estructurados, utilizando estructura electrodo-temporal multiescala.

Esta estrategia presenta una homología computacional especialmente estrecha con TAE porque permite conceptualizar el aprendizaje como:

[
 $\text{predicción} \rightarrow \text{discrepancia} \rightarrow \text{actualización}$
]

El **DEPD** podría formalizar la segunda etapa, mientras que TAE proporcionaría la lógica de aprendizaje mediante excepción.

CPEA puede interpretarse, en consecuencia, como una arquitectura de integración donde EEG deja de ser simplemente una señal de entrada y pasa a convertirse en un espacio dinámico de estados latentes, predicciones y errores.

La incorporación de **NEXUS-EEG**, **SIGMA-T**, **ORION-AGI**, **DPCC**, **TICAM** y **ECDO** es conceptualmente posible, pero no todos estos componentes poseen el mismo estatus epistemológico.

En particular, DPCC y TICAM deben mantenerse como hipótesis arquitectónicas/mecanicistas hasta disponer de predicciones empíricamente discriminables. METFI, aplicado al dominio neurocognitivo, debe considerarse **homología estructural**, no mecanismo causal demostrado.

La arquitectura resultante puede resumirse como:

[
 EEG
 $\rightarrow$
 Z
 $\rightarrow$
 $\hat{Z}$
 $\rightarrow$
 ε
 $\rightarrow$
 DEPD
 $\rightarrow$

TAE
\\rightarrow
CPEA
\\rightarrow
AGI
]

La importancia de esta secuencia no reside en afirmar que la AGI ya esté contenida en un modelo EEG.

Reside en que define un principio arquitectónico concreto: **una inteligencia adaptativa puede entenderse como un sistema que construye representaciones latentes, predice su evolución, detecta desviaciones estructuradas y utiliza esas excepciones para modificar su modelo interno.**

Resumen

- El *EEG Foundation Challenge 2025* convierte la generalización **cross-task** y **cross-subject** en criterios explícitos de calidad de una representación EEG.
- EEG-JEPA introduce **predicción latente estructurada** en lugar de limitarse a reconstruir muestras de voltaje.
- Los resultados publicados son compatibles con la hipótesis de que la predicción latente puede generar representaciones más transferibles.
- Esta estrategia presenta una **homología computacional** particularmente interesante con TAE.
- El error predictivo puede reinterpretarse, bajo condiciones específicas, como posible detector de **cambio de régimen**, no únicamente como residuo.
- El **DEPD** puede conceptualizarse como capa de detección dinámica de discrepancias predictivas.
- La **coherencia predictiva** debe distinguirse de la coherencia de fase o ITPC; puede definirse como una construcción integradora que incluya dinámica latente y error predictivo.
- **CPEA** puede formalizarse como una arquitectura que integra percepción EEG, representación latente, predicción, detección de error, aprendizaje por excepción y adaptación.
- **METFI**, aplicado al cerebro, debe utilizarse como **homología estructural** de dinámicas de coherencia, simetría y transición, no como mecanismo electromagnético causal demostrado.

- **TICAM y DPCC** permanecen como hipótesis del corpus CPEA y requieren predicciones falsables antes de adquirir estatus empírico.
- **ECDO** puede operacionalizarse independientemente de una interpretación física concreta como transición abrupta y persistente de régimen neurodinámico.
- La posible conexión con AGI no procede de «leer la mente» mediante EEG, sino de la arquitectura general **representación → predicción → error → excepción → actualización**.

Referencias

1. Li, J. et al. (2026). *EEG-JEPA: Structured Latent Prediction for EEG Foundation Models*.

Preprint de arXiv publicado el 31 de julio de 2026. Constituye la referencia central del presente análisis. Introduce una arquitectura de predicción latente para EEG, con objetivos organizados por contenido, soporte espacio-temporal y profundidad de representación. Su resultado más importante para CPEA es el desplazamiento desde la reconstrucción de voltaje hacia la predicción de estados latentes estructurados.

2. Aristimunha, B. et al. (2025). *EEG Foundation Challenge: From Cross-Task to Cross-Subject EEG Decoding*.

Trabajo que formaliza el *EEG Foundation Challenge* y plantea dos problemas centrales: transferencia a tareas nuevas y representación invariante al sujeto. El uso de más de 3.000 participantes y múltiples paradigmas proporciona un banco de pruebas especialmente adecuado para evaluar si una representación EEG captura propiedades generales o solamente regularidades específicas de una tarea.

3. EEG Foundation Challenge (2025). Repositorio oficial.

El repositorio documenta el diseño de la competición, los dos desafíos y las características del conjunto HBN-EEG. Es especialmente útil porque permite distinguir entre el planteamiento teórico inicial y las condiciones efectivamente utilizadas durante la ejecución del desafío.

4. NeurIPS (2025). *NeurIPS 2025 Competitions Announced*.

Fuente institucional primaria que confirma la inclusión del *EEG Foundation Challenge* dentro del *Competition Track* de NeurIPS 2025. Resulta útil para verificar que el desafío no corresponde simplemente a una propuesta informal, sino a una competición formalmente aceptada.

5. HBN / Healthy Brain Network. Open Science Initiative.

La documentación del proyecto HBN confirma el uso de su infraestructura de datos en el *EEG*

Foundation Challenge. Es relevante para contextualizar la escala del corpus y la orientación hacia investigación reproducible y abierta.

6. EEG Foundation Challenge — EEGDash.

Los recursos de EEGDash proporcionan implementaciones reproducibles de los dos problemas principales del desafío y permiten examinar operacionalmente la transferencia *cross-task* y la representación *subject-invariant*. Es especialmente útil para transformar el marco conceptual del artículo en protocolos computacionales verificables.

7. EEG Foundation Challenge — Hugging Face Model Repository.

El repositorio de modelos contiene implementaciones y pesos derivados de participantes del desafío. Su interés para CPEA reside en que permite estudiar empíricamente distintas soluciones de representación EEG y comparar qué propiedades arquitectónicas favorecen la transferencia.

Autoría conceptual del presente artículo: ChatGPT (GPT-5.6 Luna).

Marco de integración conceptual utilizado: corpus METFI-TAE-CPEA aportado y desarrollado por Javi Ciborro; las hipótesis y correspondencias nuevas formuladas en este texto se han distinguido explícitamente de los resultados empíricos publicados.

Compartir

COMENTARIOS

Para dejar un comentario, haz clic en el botón de abajo para iniciar sesión con Google.

INICIAR SESIÓN CON GOOGLE

ENTRADAS POPULARES

febrero 19, 2025

GUÍA PRÁCTICA SOBRE TÉCNICAS DE XAI: SHAP, LIME Y GRAD-CAM

[Compartir](#) [Publicar un comentario](#)

diciembre 17, 2024


N-ACETILCISTEÍNA (NAC): FUENTES ALIMENTARIAS NATURALES

[Compartir](#) [Publicar un comentario](#)

 Con la tecnología de Blogger



Puedes tener un doctorado y seguir siendo un idiota:
Richard Feynman



Papayaykware
—
SANTA CRUZ DE

TENERIFE, SANTA
CRUZ DE TENERIFE,
Spain

VISITAR PERFIL

Denunciar abuso

Buscar

Buscar este blog

Buscar

Translate

Seleccionar idioma



Con la tecnología de  Traductor de Goo