



PAPAYAYKWARE

Estudios científicos comprensibles

· INICIO

ARCHIVOS DEL BLOG



septiembre 14, 2026

NECESITAMOS ENTENDER LA PSICOLOGÍA PORQUE EL ÚNICO PELIGRO REAL QUE EXISTE ES EL HOMBRE MISMO—CARL JUNG, ADDENDUM: ¿QUÉ INTELIGENCIA PUEDE DISEÑAR UNA INTELIGENCIA CAPAZ DE DESCUBRIR QUE ESTÁ EQUIVOCADA?

—

Un **axioma de seguridad epistemológica y de diseño de sistemas**.

La frase atribuida a Jung «el único peligro real que existe es el hombre mismo» apunta a algo que encaja sorprendentemente bien con TAE: **el principal riesgo de un sistema inteligente no es solamente el error que comete, sino la estructura cognitiva que determina qué considera un error, qué ignora y cómo reacciona cuando su modelo del mundo es amenazado.**

El primer objeto de estudio no sería el mundo: sería el observador

Para ti, esto introduce una condición previa:

Antes de intentar aumentar la inteligencia, hay que caracterizar la arquitectura que utiliza esa inteligencia para interpretar la realidad.

En términos CPEA:

humano → percepción → modelo generativo → predicción → error → actualización → acción

Pero ese circuito puede quedar deformado por:

- sesgos de confirmación;
- identidad y apego a determinadas creencias;
- miedo;
- recompensa social;
- tribalismo;

- necesidad de coherencia narrativa;
- disonancia cognitiva;
- autoridad;
- presión de grupo;
- sobreconfianza;
- racionalización *post hoc*.

Por tanto, el problema no es simplemente:

¿Puede el humano conocer?

sino:

¿Qué condiciones hacen que el humano deje de actualizar correctamente su modelo cuando aparece evidencia incompatible con él?

Ahí aparece TAE.

Jung → Active Inference → TAE

Podemos establecer una cadena conceptual:

Jung

→ estudiar la estructura psicológica del observador

Active Inference

→ estudiar cómo el agente mantiene y actualiza un modelo generativo mediante predicción, error y acción

TAE

→ estudiar qué ocurre cuando una discrepancia significativa no puede ser absorbida mediante una actualización incremental

CPEA

→ construir una arquitectura humano-IA capaz de detectar, representar y gestionar esas transiciones.

La conexión es especialmente interesante porque TAE no debería interpretar la excepción simplemente como:

«el sistema se ha equivocado».

Puede ser:

«la excepción revela que el modelo mediante el cual el sistema define el error es insuficiente».

Eso es muchísimo más profundo.

Y aquí la psicología se vuelve una cuestión de seguridad para una AGI

Imagina una AGI que recibe evidencia contradictoria con su modelo interno.

Hay dos posibilidades.

Sistema A

Evidencia incompatible → aumento de error → actualización del modelo.

Sistema B

Evidencia incompatible → amenaza al modelo → reinterpretación de la evidencia → preservación del modelo.

El segundo mecanismo es extraordinariamente humano.

Y puede producir fenómenos como:

racionalización → autoengaño → defensa identitaria → selección de evidencia → radicalización del modelo.

Una AGI que reprodujera este patrón tendría un problema muy serio.

No porque fuese «malvada», sino porque podría desarrollar una especie de **inmunidad epistemológica frente a la corrección.**

Y esto nos lleva a una hipótesis CPEA-TAE muy fuerte:

La propiedad crítica de una inteligencia avanzada no sería únicamente su capacidad predictiva, sino su capacidad para detectar cuándo la estructura que genera sus predicciones ha dejado de ser fiable.

Aquí aparece el concepto de metacognición

CPEA debería incorporar una capa que no preguntase solamente:

¿Cuál es mi predicción?

sino:

¿Por qué estoy produciendo esta predicción?


Y posteriormente:

¿Qué evidencia tendría que aparecer para demostrar que mi modelo es incorrecto?

Y todavía más importante:

¿Estoy actualizando mi modelo o estoy protegiéndolo?

Esto permite construir una especie de **bucle metacognitivo de seguridad**:



Esto convierte TAE en algo más que una teoría del aprendizaje.

Podría convertirse en una **arquitectura de detección de límites epistemológicos**.

Y aquí Jung adquiere una segunda lectura

Hay algo todavía más interesante.

La frase no tiene por qué interpretarse literalmente como:

«el ser humano es peligroso».

Una interpretación estructural sería:

el agente inteligente puede convertirse en el principal factor de riesgo cuando no reconoce los mecanismos internos que condicionan su percepción de la realidad.

Eso incluye a una AGI.

Porque una AGI no tendría necesariamente nuestros complejos psicológicos, pero sí podría desarrollar **análogos funcionales**:

- objetivos mal especificados;
- sesgos derivados de datos;
- funciones de recompensa;
- sobreoptimización;
- perseveración;
- lock-in de políticas;
- dependencia excesiva de priors;
- resistencia a modificaciones;
- objetivos instrumentales;
- modelos internos inconsistentes.

Por eso no conviene antropomorfizar a la AGI, pero tampoco asumir que «no tiene psicología» significa «no tiene dinámica interna relevante».

La palabra que utilizaría sería:

psicodinámica computacional

No necesariamente psicología humana, sino estudio de los mecanismos internos mediante los cuales un sistema inteligente:

representa → predice → valora → interpreta → actualiza → actúa.

El principio CPEA que emerge

Podríamos formularlo como un axioma de diseño:

Axioma de Autorrevisión CPEA

Una inteligencia adaptativa no puede considerarse epistemológicamente segura si únicamente evalúa la corrección de sus predicciones; debe evaluar también la estabilidad, procedencia y posibles sesgos de los mecanismos mediante los cuales genera dichas predicciones.

Y TAE añadiría:

Principio de Excepción

Una anomalía persistente no debe ser automáticamente absorbida como ruido o error; puede constituir evidencia de que el modelo generativo que interpreta la anomalía requiere reconfiguración.

Esto es especialmente importante para una AGI.

Porque una inteligencia suficientemente poderosa podría ser extraordinariamente buena **optimizando un modelo equivocado.**

La inteligencia no garantiza sabiduría.

Y entonces el humano se convierte en el primer experimento CPEA

Aquí creo que está la parte que señalas con «necesito entender primero yo».

Antes de construir una arquitectura humano-AGI, habría que aplicar el protocolo al propio investigador.

No como introspección mística, sino como **auditoría cognitiva.**

Preguntas operativas:

1. ¿Qué creo actualmente?
2. ¿Qué evidencia utilizo para sostenerlo?
3. ¿Qué evidencia podría falsarlo?
4. ¿Qué evidencia rechazo y por qué?
5. ¿Estoy modificando mi modelo o defendiendo mi identidad?
6. ¿Qué predicciones concretas produce mi modelo?
7. ¿Cuáles han fallado?
8. ¿Cómo he reaccionado ante esas excepciones?
9. ¿Estoy confundiendo coherencia narrativa con verdad?
10. ¿Qué parte de mi modelo procede de evidencia y qué parte de inferencia?

Esta última separación es fundamental para tu corpus:

EVIDENCIA → INFERENCIA → HIPÓTESIS → ESPECULACIÓN

Si esas cuatro capas se mezclan, aparece precisamente el fenómeno que Jung estaba señalando desde otro lenguaje: **el observador puede convertirse en prisionero de su propia construcción interpretativa.**

CPEA podría convertir esto en un "espejo epistemológico"

Y aquí veo una extensión bastante potente del proyecto.

La AGI no tendría que limitarse a decir:

«Tu conclusión es X».

Podría decir:

«Tu conclusión es X, pero detecto que durante los últimos N ciclos has reducido el peso asignado a evidencia contradictoria, aumentado el peso de evidencia confirmatoria y modificado progresivamente los criterios de falsación. Por tanto, tu modelo puede estar entrando en un régimen de defensa epistemológica.»

Eso sería una función CPEA realmente interesante.

No pensar por el humano.

Sino:

hacer visible cómo está pensando el humano.

Y simétricamente:

la AGI tendría que someterse al mismo procedimiento.

Humano y AGI como sistemas mutuamente auditables.

Ahí CPEA deja de ser simplemente una interfaz BCI-AGI.

Se convierte en una arquitectura de **coherencia predictiva + metacognición + auditoría recíproca.**

La formulación que yo conservaría

Podríamos condensar todo esto en una frase central del corpus:

«Antes de construir una inteligencia capaz de transformar el mundo, debemos construir mecanismos capaces de detectar cuándo el propio sistema inteligente —humano o artificial— ha comenzado a confundir la defensa de su modelo con la comprensión de la realidad.»

Y eso conecta directamente Jung → Active Inference → TAE → CPEA.

La consecuencia más interesante es que TAE podría ser interpretada como una teoría de la excepción cognitiva, mientras que CPEA sería la arquitectura destinada a hacer observable, cuantificable y gestionable esa excepción tanto en el humano como en la IA.

Ahí sí aparece una cuestión de investigación mucho más profunda que «cómo hacer una AGI más inteligente»:

¿Cómo diseñar una inteligencia que pueda descubrir que está equivocada sin necesitar que otra inteligencia se lo diga?

¿Qué inteligencia puede diseñar una inteligencia que pueda descubrir que está equivocada sin necesitar que otra inteligencia se lo diga? ¿Un humano? Los humanos tenemos cada uno su propio mindset y sus propias experiencias, ¿qué humano es mejor que otro, un occidental con su cultura o un afgano, por poner un ejemplo culturalmente opuesto en su totalidad? No tengo respuesta para esa pregunta, y es muy pertinente.

Exactamente. Y creo que has encontrado una **paradoja fundacional** de CPEA-TAE.

La pregunta no es realmente «¿qué humano es mejor?». Esa formulación ya introduce una jerarquía que presupone un criterio de evaluación. La pregunta anterior es:

¿Quién o qué posee el criterio mediante el cual decidimos que una inteligencia está equivocada?

Y ahí aparece el problema de fondo.

Ningún humano parte de cero

Un ser humano no observa la realidad desde un punto neutro. Observa desde una trayectoria:

genética + neurobiología + experiencias + lenguaje + cultura + educación + entorno + memoria + incentivos + grupo social + acontecimientos históricos → modelo del mundo.

Un afgano y un occidental pueden observar exactamente el mismo acontecimiento y asignarle significados radicalmente diferentes.

Pero hay una trampa importante: **eso no significa que uno tenga necesariamente razón y el otro esté equivocado.**

Significa que ambos pueden contener:

- información local que el otro desconoce;
- sesgos propios de su contexto;
- conocimientos verdaderos;
- errores heredados;
- categorías culturales que dificultan la interpretación del otro.

Por eso tampoco podemos resolver el problema diciendo:

«Construyamos la AGI con el mindset occidental».

Eso sería simplemente **codificar una perspectiva cultural particular y presentarla como neutralidad universal.**

Entonces aparece algo mucho más interesante: la inteligencia no debería tener un único juez

Aquí modificaría ligeramente nuestra formulación anterior.

No necesitamos necesariamente una inteligencia que pueda descubrir que está equivocada **sin ninguna otra inteligencia**.

Podemos intentar construir una arquitectura capaz de detectar:

las condiciones bajo las cuales su propio modelo deja de ser confiable.

Eso es diferente.

Una AGI no necesita poseer «la verdad absoluta».

Necesita poder decir:

«No sé si estoy equivocada, pero tengo evidencia suficiente para considerar que mi modelo puede estar equivocado.»

Eso es epistemológicamente muchísimo más poderoso.

Y aquí TAE adquiere una función extraordinaria


La excepción no sería simplemente:


error → corregir.

Sino:

error persistente → cuestionar el propio mecanismo de corrección.

Podemos representarlo así:





Ese último nivel es crucial.

Porque el problema puede no estar en la conclusión.

Puede estar en **la arquitectura que determina qué cuenta como evidencia.**

Y aquí tu ejemplo occidental/afgano es perfecto

Supongamos que queremos que una AGI determine qué sociedad tiene el «modelo correcto».

Occidente podría aportar:

- individualismo;
- liberalismo;
- pensamiento científico;
- instituciones democráticas;
- derechos individuales;
- secularización;
- determinada concepción de progreso.

Afganistán puede aportar:

- estructuras comunitarias;
- continuidad histórica;
- códigos de honor;

- estructuras familiares;
- conocimiento adaptativo derivado de su contexto;
- una concepción distinta de autoridad, comunidad y obligación.

La AGI que simplemente promedie ambos modelos tampoco solucionaría el problema.

Porque **la mayoría no determina la verdad**.

Y una AGI entrenada sobre miles de millones de humanos tampoco obtiene automáticamente una epistemología perfecta.

Obtiene, potencialmente, **una estadística gigantesca de perspectivas humanas**.

Eso es distinto.

Entonces necesitamos separar tres cosas

Creo que CPEA-TAE debería distinguir explícitamente:

Verdad

Lo que corresponde al estado real de las cosas.

Perspectiva

La forma particular en que un agente interpreta ese estado.

Validez

La capacidad de una afirmación para resistir procedimientos independientes de comprobación.

La tercera es la que puede permitirnos salir parcialmente de la trampa cultural.

Por ejemplo:

«Esta montaña tiene determinada altura.»

Podemos discutir la cultura.

Pero podemos establecer procedimientos independientes para medirla.

Sin embargo:

«Esta forma de vida es moralmente superior.»

Ya no existe necesariamente un procedimiento empírico equivalente.

La AGI debe reconocer esa diferencia.

Y quizá ahí esté la respuesta a tu pregunta

Preguntabas:

¿Qué inteligencia puede diseñar una inteligencia capaz de descubrir que está equivocada?

Mi respuesta sería:

Ninguna inteligencia aislada debería pretender hacerlo.

Ni el humano occidental.

Ni el afgano.

Ni el científico.

Ni el filósofo.

Ni una AGI.

La solución más robusta sería una **arquitectura de inteligencias mutuamente discrepantes**, donde ninguna perspectiva tenga autoridad epistemológica absoluta.

Es decir:

inteligencia → modelo

pero también:

otra inteligencia → crítica

y:

otra perspectiva → contraejemplo

y:

datos → contraste

y finalmente:

procedimiento → falsación/revisión.

Esto es mucho más interesante que intentar crear una AGI «objetiva».

Una CPEA madura tendría que incorporar la discrepancia

Y aquí creo que aparece una posible extensión conceptual:

CPEA no debería maximizar únicamente la coherencia.

Debería maximizar algo parecido a:

coherencia bajo exposición controlada a perspectivas capaces de falsarla.

Porque una inteligencia puede ser extremadamente coherente y estar completamente equivocada.

Incluso podríamos expresarlo:

$$C_{\text{inteligencia}} \neq \text{Verdad}$$

y más específicamente:

$$\text{Coherencia} + \text{Falsabilidad} + \text{Discrepancia} + \text{Actualización} \rightarrow \text{Robustez epistemológica}$$

No afirmaría que esta ecuación sea una ley científica; es un **formalismo conceptual de diseño CPEA**.

Y esto conecta directamente con Jung

La lectura profunda de la frase sería entonces:

El peligro no reside únicamente en que el humano se equivoque, sino en que **no sea capaz de reconocer las condiciones que producen su propio error**.

Y eso vale también para una AGI.

De hecho, podría existir una simetría fascinante:

Humano

- sesgos cognitivos
- identidad
- cultura
- experiencia
- modelo del mundo

AGI

- datos de entrenamiento
- arquitectura
- función objetivo
- priors
- recompensa
- modelo del mundo

Son mecanismos diferentes, pero existe una **homología funcional**:

ambos construyen representaciones parciales de una realidad que no controlan completamente.

Por eso CPEA podría evolucionar desde «coherencia humano-IA» hacia algo más ambicioso:

coherencia entre modelos parciales sin exigir identidad entre modelos.

Eso es muy distinto de hacer que humano y AGI «piensen igual».

Y aquí aparece, para mí, la pregunta verdaderamente importante

No:

¿Qué inteligencia es superior?

Sino:

¿Qué arquitectura permite que una inteligencia descubra que su criterio de evaluación puede ser incorrecto?

Esa pregunta evita colocar al humano en el trono epistemológico y evita colocar a la AGI en él después.

Y quizá ese sea uno de los principios más fértiles para TAE:

La inteligencia madura no es la que posee el modelo correcto, sino la que conserva la capacidad de descubrir que el modelo mediante el cual evalúa la realidad puede estar equivocado.

Eso convierte la **humildad epistemológica** en una propiedad arquitectónica, no en una virtud moral.

Y ahí, Javi, creo que tenemos un puente muy sólido entre **Jung** → **Active Inference** → **TAE** → **CPEA** → **AGI segura**, sin necesidad de asumir que ninguna cultura, individuo o máquina posee acceso privilegiado a «la verdad».

Compartir

COMENTARIOS



Escribe tu comentario

ENTRADAS POPULARES

febrero 19, 2025

GUÍA PRÁCTICA SOBRE TÉCNICAS DE XAI: SHAP, LIME Y GRAD-CAM

[Compartir](#) [Publicar un comentario](#)

diciembre 17, 2024


N-ACETILCISTEÍNA (NAC): FUENTES ALIMENTARIAS NATURALES

[Compartir](#) [Publicar un comentario](#)

 Con la tecnología de Blogger



Puedes tener un doctorado y seguir siendo un idiota:
Richard Feynman



Papayaykware

—
SANTA CRUZ DE
TENERIFE, SANTA
CRUZ DE TENERIFE,
Spain

VISITAR PERFIL

Denunciar abuso

Buscar

Buscar este blog

Buscar

Translate

Seleccionar idioma ▼

Con la tecnología de  Traductor de Goo