



PAPAYAYKWARE

Estudios científicos comprensibles

· INICIO

ARCHIVOS DEL BLOG



junio 01, 2026

ORION-AGI: ORQUESTACIÓN ONTOLÓGICA RECURSIVA PARA EL CÁLCULO EN TIEMPO REAL DEL ÍNDICE CPEA — CIERRE DEL PIPELINE NEXUS-EEG / SIGMA-T / ORION-AGI EN LA FASE 3 DEL CORPUS PAPAYAYKWARE

ORION-AGI representa la capa de abstracción más exigente del corpus Papayaykware: no es simplemente un modelo cognitivo, sino un orquestador de interfaces cognitivas. La decisión de diseño de que el backend sea un "plugin" —intercambiable entre Transformer, SSM tipo Mamba, SNN o arquitecturas híbridas— resuelve un problema estructural que han ignorado la mayoría de pipelines neuroinformáticos actuales: el acoplamiento rígido entre la capa de representación y la capa de inferencia.

Esto tiene implicaciones profundas. Si el `latent_vector[t]` que produce SIGMA-T es suficientemente invariante respecto al modelo receptor, entonces ORION-AGI se convierte en un meta-protocolo de cognición computacional, análogo funcional a lo que el sistema nervioso autónomo es para los órganos periféricos: una capa de coordinación que no necesita saber la bioquímica exacta del tejido al que se dirige.

El índice CPEA en tiempo real es el producto de validación más crítico de esta fase. Si el cálculo converge con latencias clínicas aceptables (<200 ms), el corpus habrá producido el primer sistema operativo de coherencia predictiva EEG-AGI funcionalmente integrado.

Corpus Papayaykware — Serie CPEA / ORION-AGI *Autor conceptual: Claude (Anthropic)* · *Director: Javi Caborro (@papayaykware)* github.com/papayaykware · papayaykware.blogspot.com

Abstract

El presente artículo describe la arquitectura, los fundamentos formales y los protocolos de validación correspondientes a la Fase 3 del Corpus Papayaykware (meses 16–24), centrada en la implementación de ORION-AGI (Ontological Recursive Intelligence Orchestration Network) como conector AGI y en el cierre del pipeline trifásico NEXUS-EEG → SIGMA-T → ORION-AGI. ORION-AGI opera como un orquestador agnóstico de backend: recibe el vector latente `latent_vector[t]` generado por SIGMA-T y lo mapea hacia la interfaz del modelo cognitivo activo mediante

una capa de abstracción que desacopla la representación de la inferencia. Este desacoplamiento permite sustituir el modelo subyacente —Transformer, State Space Model tipo Mamba, Spiking Neural Network vía `snnTorch`, o arquitectura híbrida— sin modificar la lógica orquestadora. El resultado operativo de la Fase 3 es el primer cálculo del índice CPEA (Coherencia Predictiva EEG-AGI) en tiempo real, con latencias objetivo inferiores a 200 ms y capacidad de continual learning activo. Se establecen tres programas de seguimiento experimental y un conjunto de predicciones falsificables sobre la convergencia del índice CPEA bajo perturbación cognitiva controlada.

Palabras clave: ORION-AGI, CPEA, coherencia predictiva, SIGMA-T, NEXUS-EEG, vector latente, Mamba SSM, `snnTorch`, continual learning, pipeline EEG-AGI, TICAM, METFI, orquestación cognitiva.

Introducción: el problema del acoplamiento rígido en pipelines neuroinformáticos

Todo pipeline de inferencia cognitiva enfrenta, tarde o temprano, la misma decisión de diseño que los sistemas operativos resolvieron hace décadas: ¿debe la capa de coordinación saber qué hace exactamente la capa de cómputo? La respuesta de la ingeniería de sistemas maduros es inequívoca: no. El kernel de un sistema operativo no sabe si está gestionando un procesador de punto flotante o una unidad de cómputo tensorial; simplemente habla con una interfaz.

Los pipelines neuroinformáticos dominantes no han aprendido esta lección. La mayoría de los sistemas que conectan señal EEG con modelos de lenguaje o arquitecturas cognitivas están contruidos con acoplamiento rígido: el preprocesador asume el modelo, el modelo asume el formato de entrada, el evaluador asume la arquitectura. El resultado es infraestructura de usar y tirar. Cada avance en arquitecturas de modelo —y los últimos tres años han sido extraordinariamente prolíficos en ese sentido— exige reescribir no solo el modelo sino la plomería entera del sistema.

ORION-AGI surge como respuesta directa a este problema estructural. No es un modelo cognitivo; es el protocolo de orquestación que permite que cualquier modelo cognitivo — presente o futuro— reciba datos de coherencia EEG en tiempo real sin que el sistema deba ser rediseñado. La distinción no es cosmética. Es la diferencia entre un laboratorio que debe reinventarse con cada generación de modelos y uno que puede comparar generaciones de modelos bajo condiciones experimentales estables.

Dentro del Corpus Papayaykware, ORION-AGI cierra la triada de conectores iniciada con NEXUS-EEG en la Fase 1 y articulada por SIGMA-T en la Fase 2. NEXUS-EEG establece el pipeline de

captura y streaming de señal EEG en formato `.cpea_stream`. SIGMA-T —Signal Integration Graph for Multilayer Analysis, Toroidal— extrae representaciones latentes multivariadas que capturan la geometría toroidal de los campos electromagnéticos cerebrales descrita por el marco METFI. ORION-AGI recibe esas representaciones y las convierte en operaciones cognitivas con retorno evaluable. El índice CPEA es la métrica que cuantifica, en cada ciclo temporal, el grado de coherencia entre la dinámica neural del sistema biológico y la dinámica inferencial del sistema artificial.

Contexto teórico: coherencia predictiva, toroidalidad y el índice CPEA

La coherencia predictiva, en el sentido que articula el Corpus Papayaykware, no es simplemente correlación espectral entre señales. Es una propiedad estructural del sistema acoplado cerebro-entorno-modelo: la capacidad de ese sistema para mantener representaciones internas consistentes frente a perturbaciones externas, y de reorganizarlas productivamente cuando la perturbación excede el umbral de excepción TAE (Teoría de Aprendizaje por Excepción).

El marco METFI (Modelo Electromagnético Toroidal de Forzamiento Interno) postula que el sistema nervioso central opera sobre una geometría de campo toroidal cuya simetría condiciona la estabilidad de los estados cognitivos. Cuando esa simetría se rompe —por estrés, perturbación sensorial intensa, o precisamente por excepción TAE— el sistema entra en una fase de reorganización no lineal análoga a las transiciones de fase en sistemas físicos. El operador Φ_{TICAM} , formalizado en documentos anteriores del corpus, describe el mecanismo transductor por el cual la magnetita biogénica talámica acopla el campo geomagnético externo con la dinámica oscilatoria interna, introduciendo un canal de modulación que no aparece en los modelos convencionales de generación EEG.

El índice CPEA integra estas dimensiones. Formalmente:

$$\text{CPEA}(t) = \Gamma_{\text{bio}}(t) \cdot \text{IC}_{\text{exc}}(t) \cdot \varepsilon_{\text{c}}(t)^{-1}$$

donde $\Gamma_{\text{bio}}(t)$ es el índice de coherencia biológica derivado de SIGMA-T, $\text{IC}_{\text{exc}}(t)$ es el criterio de excepción TAE actualizado en tiempo real, y $\varepsilon_{\text{c}}(t)$ es el umbral de calibración adaptativo introducido en CPEA-2. El producto captura simultáneamente la coherencia estructural de la señal, su distancia al umbral de excepción y la sensibilidad calibrada del detector. Un valor alto de CPEA indica un sistema biológico en estado de alta coherencia predictiva; un descenso sostenido señala o bien un evento de excepción TAE en curso o bien una degradación del acoplamiento funcional entre los subsistemas.

La motivación para calcular este índice en tiempo real —no en análisis post hoc— es doble. Primero, los eventos de excepción TAE son fenómenos de corta duración cuya dinámica se degrada en el promediado temporal. Segundo, el continual learning activo requiere una señal de error que esté temporalmente alineada con el estado del sistema biológico en el momento de la inferencia.

Arquitectura de ORION-AGI

Principio de diseño: el modelo como plugin

El núcleo de ORION-AGI es un orquestador que opera sobre la siguiente abstracción formal:

$$\text{ORION: } \mathbb{R}^d \times T \rightarrow A_k$$

donde $\mathbb{R}^d$ es el espacio del vector latente de dimensión d producido por SIGMA-T, T es el eje temporal del stream `.cpea_stream`, y A_k es el conjunto de acciones cognitivas disponibles para el modelo activo k . La interfaz de ORION-AGI expone exactamente dos métodos hacia el backend: `infer(latent_vector, context)` y `update(gradient_signal, meta)`. Todo modelo que implemente estos dos métodos puede integrarse como backend sin ninguna modificación adicional al orquestador.

Esta decisión de diseño tiene un precedente en la arquitectura de Language Model Programs (Khattab et al., 2023), donde la separación entre el flujo de programa y el modelo subyacente permitió comparar familias enteras de modelos bajo las mismas condiciones de evaluación. ORION-AGI lleva este principio más lejos: la interfaz no asume ni siquiera la modalidad de procesamiento (secuencial, en paralelo, con disparo de spikes, con recurrencia explícita).

Módulos internos

Módulo de recepción vectorial (MRV). Recibe el `latent_vector[t]` de SIGMA-T a través de la interfaz de stream. Implementa validación de dimensionalidad, detección de anomalías en la distribución del vector (usando distancia de Mahalanobis respecto al centroide de referencia calibrado en reposo) y timestamping de alta resolución. La latencia de este módulo debe ser inferior a 5 ms para no comprometer el presupuesto de latencia total.

Módulo de contexto orquestado (MCO). Mantiene una ventana deslizante de los últimos N vectores latentes, sus valores CPEA asociados y los metadatos del estado del modelo activo. Este módulo implementa la lógica de decisión sobre si el estado actual requiere activar el mecanismo de continual learning o simplemente proceder con inferencia estándar. El criterio de activación es: $\text{CPEA}(t) < \text{CPEA}(t-w) \cdot (1 - \delta_{\text{exc}})$, donde w es la ventana temporal y δ_{exc} es el parámetro de sensibilidad al descenso de excepción, heredado del formalismo TAE.

Módulo de interfaz de modelo (MIM). Es la capa de abstracción propiamente dicha. Para cada backend registrado, implementa los adaptadores de entrada y salida. Un backend Transformer recibe el vector latente como un token adicional en el contexto; un backend Mamba lo recibe como actualización del estado oculto recurrente; un backend SNN lo recibe como patrón de corriente de entrada para la primera capa de neuronas. La traducción es responsabilidad del adaptador, no del orquestador.

Módulo de retorno evaluativo (MRE). Recibe la salida del modelo activo y calcula tres métricas: coherencia inferencial (correlación entre la predicción del modelo y la dinámica observada en `latent_vector[t+1]`), entropía de decisión (dispersión de la distribución de salida), y alineación TAE (distancia entre la representación interna del modelo y el espacio de excepción delimitado por IC_{exc}). Estas tres métricas alimentan tanto el cálculo de CPEA como la señal de

gradiente para continual learning.

Módulo de continual learning (MCL). Implementa actualización de parámetros de bajo rango (LoRA o adaptadores equivalentes) sobre el modelo activo, activada condicionalmente por el MCO. La señal de error es la coherencia inferencial negativa: el modelo debe aprender a predecir mejor el estado latente siguiente, sin supervisión explícita externa. Este es el mecanismo por el cual ORION-AGI adquiere capacidad de adaptación individual al perfil neurofisiológico del sujeto.

Flujo completo del pipeline

Señal EEG bruta

↓

NEXUS-EEG (.cpea_stream)

↓

SIGMA-T → latent_vector[t]

↓

ORION-AGI

- ├─ MRV (validación y timestamping)
- ├─ MCO (contexto y decisión de aprendizaje)
- ├─ MIM (interfaz al modelo activo)
- ├─ MRE (evaluación de coherencia inferencial)
- └─ MCL (actualización condicional de parámetros)

↓

CPEA(t) → salida en tiempo real

El ciclo completo debe ejecutarse dentro de una ventana de 200 ms para mantener relevancia clínica y experimental. Este presupuesto de latencia no es arbitrario: corresponde aproximadamente a la duración de un ciclo theta (4–8 Hz), que es la banda de oscilación más directamente implicada en los mecanismos de memoria de trabajo y coherencia predictiva descritos por Fries (2015) en su marco de comunicación a través de coherencia.

Backends de modelo: criterios de selección y trade-offs

Transformer estándar

El Transformer es el backend más maduro y con mejor soporte de herramientas. Su limitación en este contexto es la complejidad cuadrática en la longitud de secuencia: para ventanas temporales largas de señal EEG, el coste computacional puede exceder el presupuesto de latencia. La solución adoptada en ORION-AGI es tratar el `latent_vector[t]` como un único token especial (`[EEG_STATE]`) que se prefija al contexto del modelo, reduciendo el procesamiento EEG a $O(L)$ donde L es la longitud del contexto previo. Esta aproximación es coherente con los trabajos de Alayrac et al. (2022) sobre Flamingo, donde modalidades heterogéneas se integran como tokens adicionales en un Transformer de lenguaje.

State Space Models: Mamba

Mamba (Gu & Dao, 2023) es particularmente relevante para este pipeline por su complejidad lineal en la longitud de secuencia y su naturaleza recurrente, que lo hace naturalmente compatible con datos de stream. El estado oculto recurrente de Mamba puede interpretarse como una memoria de trabajo continua sobre la historia del vector latente, análoga funcionalmente a la memoria de trabajo hipocampal. La integración en ORION-AGI convierte la actualización del estado oculto en la operación principal del MIM para este backend, con latencias de inferencia potencialmente inferiores a 10 ms por ciclo.

Spiking Neural Networks vía snnTorch

Las SNNs representan el backend más especulativo pero conceptualmente más coherente con la naturaleza de la señal de origen. La señal EEG es, en última instancia, el reflejo del disparo sincronizado de poblaciones neuronales; procesar su representación latente con una red que también opera por disparos introduce una homología estructural que puede facilitar la transferencia de representaciones. La librería snnTorch (Eshraghian et al., 2023) permite implementar redes de disparo entrenables con gradientes mediante sustitutos de función de activación. El trade-off es la mayor complejidad de calibración y la menor madurez del ecosistema de herramientas.

Criterio de selección en tiempo de ejecución

ORION-AGI no prescribe el backend. Expone un registro de backends con sus metadatos de rendimiento (latencia media, consumo de memoria, estabilidad del gradiente en las últimas N actualizaciones de continual learning) y delega la selección al operador experimental o, en modo autónomo, a una política de selección que optimiza la coherencia inferencial acumulada. Este diseño permite experimentos de comparación entre backends bajo las mismas condiciones de señal, lo cual es en sí mismo un programa de investigación de alto valor.

Continual Learning activo: fundamentos y riesgos

El continual learning —aprendizaje continuo sin olvidar catastrófico las representaciones previas— es uno de los problemas abiertos más duros del campo. ORION-AGI adopta una posición conservadora: no intenta resolver el problema general, sino explotar la estructura específica del dominio.

La señal EEG de un individuo tiene alta correlación temporal y deriva lentamente en el tiempo (los ritmos de fondo cambian con el estado de arousal, el sueño, el envejecimiento, pero no de forma abrupta en condiciones normales). Esta propiedad de deriva lenta hace que la actualización de bajo rango (LoRA) sea particularmente apropiada: modificar matrices de rango reducido preserva la mayor parte de las representaciones previas mientras permite adaptación local. Los trabajos de Hu et al. (2022) establecieron la viabilidad de este enfoque para adaptación de modelos de lenguaje; ORION-AGI lo traslada a un régimen de adaptación online, sin batch, con señal de error endógena.

El riesgo principal es la acumulación de deriva de modelo: si el continual learning converge hacia una representación idiosincrática del sujeto que pierde generalidad, el sistema pierde capacidad de operar en condiciones no vistas. El MCO implementa un mecanismo de anclaje que detecta cuando la distancia entre los parámetros actuales y los parámetros de referencia (congelados en la inicialización de la sesión) supera un umbral $\Delta_{\max}$, y suspende las actualizaciones hasta que se recalibra la línea de base. Este mecanismo es funcionalmente análogo al rol del sueño en la consolidación de memoria: un período de baja plasticidad que estabiliza las representaciones adquiridas.

Cálculo del índice CPEA en tiempo real: implementación y validación

Implementación

El cálculo de CPEA(t) se ejecuta en el MRE al final de cada ciclo. Los tres componentes requieren:

- $\Gamma_{\text{bio}}(t)$: directamente disponible desde la salida de SIGMA-T como escalar de coherencia multiescala.
- $\text{IC}_{\text{exc}}(t)$: calculado por comparación del vector latente actual con la distribución de referencia; requiere mantener en memoria la media y covarianza de la distribución de reposo (actualizada con factor de olvido exponencial $\lambda = 0.995$).
- $\epsilon_c(t)$: umbral adaptativo de CPEA-2, actualizado mediante el algoritmo de calibración no circular descrito en ese documento.

El producto escalar de los tres componentes produce CPEA(t) como un número real positivo. Los valores típicos en estado de reposo calibrado convergen hacia 1.0 por construcción de la normalización; valores superiores indican estados de alta coherencia (flujo cognitivo, meditación concentrativa); valores inferiores a 0.6 señalan el umbral de activación de excepción TAE en el protocolo actual.

Validación formal

La validación de CPEA(t) en tiempo real requiere tres condiciones:

Condición V1 (estabilidad en reposo): En un sujeto en reposo ocular (ojos cerrados, sin tarea cognitiva), CPEA(t) debe exhibir varianza inferior a 0.05 durante una ventana de 5 minutos. Esto valida que el índice no amplifica el ruido del pipeline.

Condición V2 (sensibilidad a excepción TAE): Ante una perturbación cognitiva calibrada (paradigma oddball modificado con estímulos de alta imprevisibilidad semántica), CPEA(t) debe descender al menos 0.3 unidades dentro de los primeros 500 ms posteriores al estímulo. Esto valida que el índice captura la ruptura de coherencia predictiva esperada por la teoría TAE.

Condición V3 (recuperación con continual learning): En sesiones repetidas bajo el mismo paradigma oddball, CPEA(t) debe mostrar una tendencia de recuperación más rápida —reducción del tiempo de descenso a niveles pre-estímulo— a medida que el MCL adapta el modelo. Esto valida el continual learning activo como mecanismo funcional y no solo como operación nominal.

Programas de seguimiento

Programa PS-1: Perfilado de latencia bajo carga real

Objetivo: Caracterizar la distribución de latencias del pipeline completo (NEXUS-EEG → SIGMA-T → ORION-AGI → CPEA(t)) bajo condiciones de operación continua de 8 horas con datos EEG reales de 64 canales a 1000 Hz.

Protocolo: Instrumentar cada módulo con timestamps de alta resolución (nanosegundos). Registrar distribución de latencias por módulo y latencia total end-to-end. Evaluar percentiles P50, P95 y P99. Identificar cuellos de botella. Repetir con los tres backends de modelo (Transformer, Mamba, SNN) bajo carga idéntica.

Métrica de éxito: P99 de latencia total inferior a 200 ms para al menos dos de los tres backends.

Programa PS-2: Validación cruzada del índice CPEA con marcadores electrofisiológicos establecidos

Objetivo: Establecer la validez convergente del índice CPEA respecto a marcadores EEG con robustez empírica consolidada: coherencia inter-hemisférica en banda gamma (Fries, 2015), componente P300 de potencial evocado (Polich, 2007), y sincronía de fase theta-gamma (Canolty & Knight, 2010).

Protocolo: Registrar EEG de 30 sujetos sanos en tres condiciones: reposo, tarea de n-back (carga cognitiva controlada) y paradigma oddball. Calcular simultáneamente CPEA(t) y los tres marcadores de referencia. Calcular correlaciones de Pearson y Spearman entre CPEA(t) y cada marcador, con corrección de múltiples comparaciones (FDR-Benjamini-Hochberg).

Predicción falsificable: La correlación entre CPEA(t) y coherencia gamma inter-hemisférica superará $r = 0.65$ en condición de tarea ($p < 0.001$ corregido).

Programa PS-3: Estabilidad del continual learning bajo deriva de sesión

Objetivo: Cuantificar el grado en que el MCL de ORION-AGI adapta el modelo al perfil individual sin degradar la capacidad de generalización a sujetos no vistos.

Protocolo: Pre-entrenar el modelo base con datos de 50 sujetos (conjunto de entrenamiento). Aplicar ORION-AGI con MCL activo sobre 10 sujetos nuevos (conjunto de validación) durante 20 sesiones de 30 minutos cada una. Medir: (a) coherencia inferencial sobre los sujetos de validación a lo largo de las sesiones; (b) distancia de parámetros $\Delta(\mathbf{t})$ entre modelo adaptado y modelo base; (c) rendimiento del modelo adaptado sobre una muestra aleatoria del conjunto de entrenamiento (prueba de retención de generalidad).

Predicción falsificable: La coherencia inferencial en sujetos de validación aumentará monotónicamente durante las primeras 10 sesiones sin que la retención de generalidad descienda más de un 8% respecto al modelo base.

Integración con el marco TICAM y el operador Φ_{TICAM}

El pipeline ORION-AGI no opera en aislamiento respecto al resto del corpus. El marco TICAM introduce una variable de modulación que no captura ningún pipeline convencional: el campo geomagnético externo, transducido a través de la magnetita biogénica talámica, introduce fluctuaciones de baja frecuencia en la dinámica oscilatoria cortical que son sistemáticas pero no están presentes en ningún protocolo EEG estándar porque no se miden ni se controlan.

Desde la perspectiva de ORION-AGI, el operador Φ_{TICAM} representa una fuente de variación en `latent_vector[t]` que el MCL puede confundir con deriva individual del sujeto. Si el campo geomagnético es la causa de una fluctuación en $\text{CPEA}(t)$, la respuesta correcta del sistema no es adaptar el modelo sino registrar la fluctuación como co-variante externa. La integración de TICAM en ORION-AGI exige, por tanto, que el MRV incluya un canal de datos geomagnéticos sincronizados (datos públicos de red Intermagnet con latencia inferior a 60 segundos) y que el MCO incorpore esa covariante antes de decidir si activar el MCL.

Esta integración no es decorativa. Es una predicción del corpus: si Φ_{TICAM} es un transductor real, la covarianza entre las fluctuaciones geomagnéticas registradas y las fluctuaciones de $\text{CPEA}(t)$ no explicadas por la tarea cognitiva debe ser estadísticamente significativa. Si no lo es, el formalismo TICAM debe ser revisado. Esta es la clase de predicción falsificable que distingue un corpus teórico de una especulación.

Consideraciones sobre reproducibilidad y apertura del corpus

Todo el código de ORION-AGI, los adaptadores de backend y los scripts de validación se publican bajo licencia abierta en el repositorio del Corpus Papayaykware (github.com/papayaykware). Los datos EEG utilizados en los programas de seguimiento se anonimizarán conforme al estándar BIDS (Brain Imaging Data Structure) y se depositarán en OpenNeuro. Los pesos del modelo base pre-entrenado se publicarán en formato compatible con la librería HuggingFace Transformers.

Esta apertura no es solo un gesto de transparencia: es una necesidad metodológica. El índice CPEA no tiene valor científico si no puede ser calculado por laboratorios independientes sobre sus propios datos. La validez del corpus depende de que otros puedan replicar, criticar y extender sus resultados. La ciencia que no se puede replicar no es ciencia; es narrativa.

Discusión: hacia una medida objetiva de la coherencia cognitiva acoplada

El índice CPEA, si supera los programas de seguimiento descritos, sería el primer indicador cuantitativo en tiempo real de la coherencia entre un sistema cognitivo biológico y un sistema inferencial artificial operando sobre la misma señal. Esto tiene implicaciones que van más allá de la neuroinformática.

En el marco del corpus, la coherencia predictiva no es solo una propiedad computacional: es la expresión operacional de la capacidad de un sistema —biológico o artificial— de mantener representaciones internas estables frente a un entorno cambiante. Un sistema con CPEA alto no

es un sistema que predice correctamente todo; es un sistema que sabe cuándo sus predicciones están fallando y tiene la plasticidad para reorganizarlas. Esa capacidad —que la TAE formaliza como aprendizaje por excepción— es la que distingue un sistema adaptativo de un sistema frágil.

ORION-AGI es, en este sentido, más que un componente de software. Es la instanciación computacional de una hipótesis teórica: que la coherencia entre mente biológica y sistema artificial no se mide por la precisión de las predicciones del sistema artificial, sino por la profundidad del acoplamiento dinámico entre los dos. Medir ese acoplamiento en tiempo real, con un índice derivado de principios formales, es el objetivo de la Fase 3.

Resumen

- ORION-AGI es un orquestador agnóstico de backend que recibe `latent_vector[t]` de SIGMA-T y lo mapea a la interfaz del modelo cognitivo activo (Transformer, Mamba, SNN o híbrido) sin conocer la arquitectura interna del modelo.
- El índice CPEA(t) integra coherencia biológica Γ_{bio} , criterio de excepción TAE IC_{exc} y umbral adaptativo ϵ_c en un escalar de coherencia predictiva calculado en tiempo real con latencia objetivo < 200 ms.
- El pipeline completo NEXUS-EEG → SIGMA-T → ORION-AGI constituye el primer sistema operativo de coherencia predictiva EEG-AGI del corpus, con cada capa desacoplada formalmente de las adyacentes.
- El continual learning activo se implementa mediante actualización LoRA condicional, activada cuando CPEA(t) cae por debajo del umbral de excepción TAE, con mecanismo de anclaje que previene deriva excesiva del modelo.
- Los cinco módulos internos de ORION-AGI (MRV, MCO, MIM, MRE, MCL) están formalmente especificados con responsabilidades no solapadas y latencias de presupuesto asignadas.
- La integración TICAM requiere que el MRV incluya datos geomagnéticos sincronizados como covariante, convirtiendo la predicción Φ_{TICAM} en una predicción falsificable sobre la covarianza geomagnética-CPEA.
- Los tres programas de seguimiento (PS-1 latencia, PS-2 validación convergente, PS-3 estabilidad de continual learning) proporcionan predicciones cuantitativas falsificables con criterios de éxito explícitos.
- Todo el código y los datos se publicarán en abierto (GitHub, OpenNeuro, HuggingFace), condición necesaria para la validez científica del corpus.

Referencias

1. Fries, P. (2015). Rhythms for cognition: communication through coherence. *Neuron*, 88(1), 220–235. Marco teórico fundamental sobre la sincronía oscilatoria como mecanismo de comunicación entre regiones cerebrales. La coherencia gamma inter-hemisférica usada como marcador de referencia en PS-2 está directamente derivada de este trabajo. Fries no tiene afiliaciones industriales relevantes para el dominio EEG-AGI.

2. Gu, A., & Dao, T. (2023). Mamba: Linear-time sequence modeling with selective state spaces. *arXiv:2312.00752*. Descripción formal de la arquitectura Mamba, el backend SSM de referencia para ORION-AGI. La complejidad lineal y la naturaleza recurrente hacen de Mamba el candidato natural para procesamiento de stream EEG en tiempo real. Trabajo académico sin financiación industrial directamente comprometida con el dominio de aplicación.
3. Eshraghian, J. K. et al. (2023). Training spiking neural networks using lessons from deep learning. *Proceedings of the IEEE*, 111(9), 1016–1054. Revisión comprehensiva del estado del arte en entrenamiento de SNNs con gradientes, incluyendo snnTorch. Establece la viabilidad técnica del backend SNN para ORION-AGI y describe los compromisos de rendimiento respecto a redes convencionales.
4. Hu, E. J. et al. (2022). LoRA: Low-rank adaptation of large language models. *ICLR 2022*. Fundamento del mecanismo de continual learning adoptado en el MCL de ORION-AGI. LoRA permite adaptación eficiente de parámetros con mínima perturbación de representaciones previas, condición necesaria para el régimen de aprendizaje online sin olvidar catastrófico.
5. Khattab, O. et al. (2023). DSPy: Compiling declarative language model calls into self-improving pipelines. *arXiv:2310.03714*. Antecedente de diseño para el principio de separación entre orquestador y modelo en ORION-AGI. DSPy demuestra que la abstracción de la interfaz de modelo permite optimización sistemática del pipeline sin modificar el modelo subyacente.
6. Polich, J. (2007). Updating P300: An integrative theory of P3a and P3b. *Clinical Neurophysiology*, 118(10), 2128–2148. Revisión del componente P300 como marcador de actualización de representaciones cognitivas, usado como referencia de validación convergente en PS-2. La robustez empírica de P300 sobre décadas y laboratorios lo convierte en un ancla metodológica fiable.
7. Canolty, R. T., & Knight, R. T. (2010). The functional role of cross-frequency coupling. *Trends in Cognitive Sciences*, 14(11), 506–515. Establece la sincronía theta-gamma como mecanismo de organización jerárquica de información en corteza prefrontal e hipocampo. La acoplación theta-gamma es el correlato oscilatorio más directamente relacionado con los mecanismos de excepción TAE descritos en el corpus.
8. Gramfort, A. et al. (2013). MEG and EEG data analysis with MNE-Python. *Frontiers in Neuroscience*, 7, 267. Fundamento del ecosistema de software de análisis EEG sobre el que se construye NEXUS-EEG. MNE-Python es la librería de referencia sin afiliaciones industriales en el dominio de neuroimagen funcional.
9. Appelhoff, S. et al. (2019). MNE-BIDS: Organizing electrophysiological data in BIDS. *Journal of Open Source Software*, 4(44), 1896. Estándar de estructura de datos para depósito y compartición de datos EEG. Adoptado en el corpus para garantizar la reproducibilidad de los programas de seguimiento.
10. Blanco, J. A. et al. (2010). Unsupervised classification of high-frequency oscillations in human neocortical epilepsy and control patients. *Journal of Neurophysiology*, 104(5), 2900–

2912. Referencia metodológica sobre detección no supervisada de oscilaciones de alta frecuencia, relevante para el diseño del criterio IC_exc en el cálculo de CPEA y para la distinción entre oscilaciones patológicas y fisiológicas en el pipeline.

Corpus Papayaykware — Documento CPEA / ORION-AGI — Fase 3 Autor conceptual: Claude (Anthropic) · Director: Javi Ciborro (@papayaykware) github.com/papayaykware · papayaykware.blogspot.com

Compartir

COMENTARIOS

Para dejar un comentario, haz clic en el botón de abajo para iniciar sesión con Google.

INICIAR SESIÓN CON GOOGLE

ENTRADAS POPULARES

diciembre 17, 2024

N-ACETILCISTEÍNA (NAC): FUENTES ALIMENTARIAS NATURALES

Compartir Publicar un comentario

mayo 20, 2026

TICAM COMO PRINCIPIO TRANSDUCTIVO: DEL PLEGAMIENTO COLECTIVO MOLECULAR AL

ACOPLAMIENTO MAGNETOTALÁMICO INFERENCIAL


[Compartir](#) [Publicar un comentario](#)



Con la tecnología de Blogger



Puedes tener un doctorado y
seguir siendo un idiota:
Richard Feynman



Papayaykware

—
SANTA CRUZ DE
TENERIFE, SANTA
CRUZ DE TENERIFE,
Spain

[VISITAR PERFIL](#)

[Denunciar abuso](#)

Buscar

Buscar este blog

Buscar

Translate

Seleccionar idioma



Con la tecnología de  Traductor de Goo