



PAPAYAYKWARE

Estudios científicos comprensibles

· INICIO

ARCHIVOS DEL BLOG



junio 03, 2026

RIESGOS ESTRUCTURALES Y ESTRATEGIAS DE MITIGACIÓN EN LA ARQUITECTURA CPEA: UN ANÁLISIS DE INGENIERÍA DE SISTEMAS PARA AGI NEUROFISIOLÓGICA

—

Estos cuatro riesgos son reales, bien identificados, y las mitigaciones propuestas son técnicamente sólidas. Pero conviene enriquecer cada uno con la dimensión que la descripción no explicita.

Riesgo 1 — Obsolescencia de modelo fundacional

El desacoplamiento mediante interfaz es necesario pero no suficiente. El swap de Mistral-7B por un modelo superior requiere también que las representaciones latentes producidas por el nuevo modelo sean compatibles semánticamente con las históricas —no solo que la interfaz acepte el nuevo peso. Si el embedding space cambia con el modelo, los datos longitudinales acumulados pierden comparabilidad. La mitigación real no es solo la interfaz, sino el protocolo de alineación de espacios de embedding entre versiones sucesivas.

Riesgo 2 — Deriva del embedding

El benchmarking continuo detecta deriva, pero no la revierte automáticamente. La mitigación completa requiere un mecanismo de retroproyección: cuando se detecta deriva entre versiones v_n y v_{n+1} de SIGMA-T, los embeddings históricos producidos por v_n deben ser retroproyectados al espacio de v_{n+1} mediante una transformación aprendida (Procrustes ortogonal, por ejemplo), preservando la comparabilidad longitudinal.

Riesgo 3 — Dependencia de hardware EEG

BrainFlow + LSL es la solución correcta, pero hay una clase de riesgo que no cubre: la variabilidad en la calidad de señal entre dispositivos de distinta gama. Un EEG de investigación de 64 canales y un dispositivo portátil de 8 canales producen señales cualitativamente distintas. La suite de

conformidad debe incluir métricas de calidad de señal —no solo compatibilidad de protocolo— para que los datos de dispositivos heterogéneos sean comparables en el pipeline SIGMA-T.

Riesgo 4 — Complejidad del DAG

Docker/Kubernetes con rollback atómico es infraestructura correcta. El riesgo residual que no cubre es la deuda técnica en la especificación del DAG mismo: a medida que el número de nodos crece, la documentación de las dependencias entre nodos puede volverse opaca. El mitigador adicional es un registro formal de contratos DbC por nodo, auditado automáticamente en cada build del pipeline.

Riesgos estructurales y estrategias de mitigación en la arquitectura CPEA: un análisis de ingeniería de sistemas para AGI neurofisiológica

Autor conceptual: Claude (Anthropic) · Director/Productor: Javi Ciborro (@papayaykware) ·
Corpus Papayaykware

Abstract

Toda arquitectura de software compleja acumula riesgos estructurales que, si no se identifican y gestionan antes de que el sistema alcance escala operacional, se vuelven exponencialmente costosos de mitigar. La arquitectura CPEA —compuesta por los módulos NEXUS-EEG, SIGMA-T, ORION-AGI y TICAM, operando bajo el protocolo federado TAGIS-FED— no es una excepción. Este artículo analiza cuatro riesgos estructurales identificados en la Fase 4 del roadmap: la obsolescencia del modelo fundacional en ORION-AGI, la deriva del espacio de embedding entre versiones de SIGMA-T, la dependencia de hardware EEG específico, y la complejidad creciente del DAG de transformación en SIGMA-T. Para cada riesgo se formaliza la mitigación existente, se identifican sus límites, y se propone un mecanismo complementario que cierra la brecha residual. El resultado es un análisis de robustez que no pretende eliminar la incertidumbre —una pretensión epistemológicamente insostenible en sistemas complejos— sino hacer su estructura explícita y sus consecuencias manejables.

Palabras clave: CPEA, ORION-AGI, SIGMA-T, NEXUS-EEG, gestión de riesgos, obsolescencia de modelo, deriva de embedding, alineación de espacios latentes, BrainFlow, LSL, contenedorización, contratos por diseño, ingeniería de sistemas, robustez arquitectónica.

Introducción: el caso por una gestión de riesgos explícita en sistemas AGI

La ingeniería de software convencional distingue entre fallos de implementación —bugs, errores de lógica, condiciones de carrera— y fallos de arquitectura: decisiones de diseño que, tomadas en un momento dado con información incompleta, se vuelven fuentes de fragilidad sistémica cuando

el entorno cambia. Los fallos de implementación son detectables mediante testing. Los fallos de arquitectura son más perniciosos: permanecen latentes hasta que una perturbación externa —un cambio de hardware, una nueva versión de dependencia, un incremento en la escala de datos— los activa de forma abrupta.

En sistemas con propiedades AGI, esta distinción adquiere una dimensión adicional. El sistema no es estático: aprende, se recalibra, acumula representaciones históricas. Un fallo arquitectónico que introduce inconsistencia en el espacio de representaciones no produce un error visible de inmediato; contamina silenciosamente los datos longitudinales, degradando la comparabilidad histórica hasta que el problema se vuelve irreversible. La metáfora adecuada no es un bug que hace caer el sistema, sino una fuga que inunda el sótano durante meses antes de ser detectada.

La arquitectura CPEA opera bajo esta dinámica. NEXUS-EEG acumula streams de datos EEG con metadatos temporales que se extienden en el tiempo. SIGMA-T produce representaciones latentes que son comparadas entre sesiones separadas por semanas o meses. ORION-AGI aprende de forma continua sobre una distribución que evoluciona. TICAM correlaciona señales neurofisiológicas con variables geomagnéticas en escalas temporales de meses. En este contexto, la gestión de riesgos no es una práctica complementaria de buena ingeniería: es una condición de posibilidad de la validez científica del corpus.

Este artículo no es un documento de gestión de proyectos. Es un análisis técnico-científico de cuatro vectores de fragilidad estructural, con el objetivo de hacer explícita su mecánica interna y proponer mitigaciones que sean, ellas mismas, falsificables y verificables.

Riesgo 1 — Obsolescencia del modelo fundacional en ORION-AGI

Naturaleza del riesgo

ORION-AGI (Ontological Recursive Intelligence Orchestration Network) opera sobre un modelo de lenguaje de gran escala como núcleo de razonamiento inferencial. En el momento de especificación de Fase 3, Mistral-7B representaba un equilibrio adecuado entre capacidad representacional y eficiencia computacional para despliegue en hardware de laboratorio. Este equilibrio no es permanente. El ritmo de publicación de nuevos modelos fundacionales en los últimos tres años ha sido suficientemente acelerado como para que cualquier arquitectura que asuma un modelo específico como componente central enfrente obsolescencia en un horizonte de 18 a 24 meses.

El riesgo no es simplemente que exista un modelo mejor disponible —eso es inevitable y bienvenido. El riesgo es que el proceso de sustitución introduzca incompatibilidades no detectadas entre el nuevo modelo y los datos históricos acumulados por el sistema. Y aquí aparece la dimensión que la mitigación basada exclusivamente en desacoplamiento de interfaz no captura.

La mitigación existente y su límite

El diseño desacoplado de ORION-AGI es correcto y necesario. La interfaz formal entre el modelo fundacional y los módulos SIGMA-T y NEXUS-EEG garantiza que un swap de Mistral-7B por un modelo superior no requiere modificaciones en los módulos vecinos. Desde la perspectiva de la ingeniería de integración de sistemas, esto es el diseño correcto.

El límite de esta mitigación emerge cuando se examina la naturaleza de lo que el modelo fundacional produce: representaciones en un espacio latente de alta dimensión. Cada modelo de lenguaje define implícitamente una geometría del espacio de representaciones —las distancias, ángulos, y estructuras de clustering que organizan los conceptos en ese espacio. Cuando se sustituye Mistral-7B por un modelo M', la interfaz garantiza que M' recibe las mismas entradas y produce salidas en el mismo formato. No garantiza que las representaciones latentes de M' sean geoméricamente compatibles con las de Mistral-7B.

Esta incompatibilidad geométrica importa porque ORION-AGI utiliza las representaciones históricas como referencia para el aprendizaje continuo. Si los embeddings de M' y los de Mistral-7B no son comparables en el mismo espacio, el sistema no puede distinguir entre "este sujeto muestra una excepción TAE" y "este sujeto tiene una representación en el espacio de M' que no es comparable con las representaciones históricas en el espacio de Mistral-7B". La contaminación de los datos longitudinales sería silenciosa y sistemática.

Mitigación complementaria: alineación de espacios de embedding

La solución es un protocolo de alineación de espacios latentes que se ejecuta antes de cada swap de modelo fundacional. El mecanismo matemático es el análisis de Procrustes ortogonal generalizado: dada una muestra de representaciones producidas por Mistral-7B (Z_{old}) y sus contrapartes producidas por M' sobre las mismas entradas (Z_{new}), se calcula la transformación ortogonal R que minimiza la distancia de Frobenius entre las dos familias:

$$R = \underset{R}{\operatorname{argmin}} \|Z_{old} - Z_{new} \cdot R\|_F^2, \text{ sujeto a } R^T R = I^*$$

La solución analítica es $R^* = UV^T$, donde USV^T es la descomposición en valores singulares de $Z_{old}^T \cdot Z_{new}$. Esta transformación se aplica a todas las representaciones históricas producidas por Mistral-7B antes de introducirlas en el pipeline de ORION-AGI con el nuevo modelo, garantizando comparabilidad geométrica.

El protocolo incluye una métrica de validación de la alineación: la correlación de Spearman entre distancias de pares de representaciones antes y después de la transformación debe superar 0.90 en el 95% de los pares del conjunto de validación. Si no supera este umbral, la alineación es insuficiente y el swap de modelo requiere un período de transición con entrenamiento paralelo de los dos modelos sobre nuevos datos.

Este protocolo se incorpora al procedimiento formal de cambio de versión de modelo en ORION-AGI como paso obligatorio previo a la depreciación del modelo anterior.

Riesgo 2 — Deriva del espacio de embedding entre versiones de SIGMA-T

Naturaleza del riesgo

SIGMA-T (Signal Integration Graph for Multilayer Analysis - Toroidal) es el motor de transformación que convierte señales EEG crudas en representaciones latentes estructuradas. Su arquitectura como DAG tipado permite actualizaciones modulares: un nodo de preprocesamiento puede actualizarse sin afectar los nodos de coherencia aguas abajo, siempre que los contratos de interfaz se preserven. En la práctica, sin embargo, las actualizaciones de nodos de preprocesamiento —nuevos algoritmos de separación de fuentes, mejores filtros wavelet, parámetros de ventana optimizados— alteran sutilmente la distribución estadística de las representaciones latentes que producen, incluso cuando las señales de entrada son idénticas.

Esta alteración es la deriva de embedding: la versión v_{n+1} de SIGMA-T produce representaciones que capturan las mismas propiedades neurofisiológicas que v_n , pero en una región geoméricamente distinta del espacio latente. Para un sistema que usa datos de sesiones separadas por meses, esta deriva hace que la distancia entre representaciones refleje la versión del software tanto como el estado neurofisiológico del sujeto.

La mitigación existente y su límite

El protocolo de `embedding_version` y el benchmarking continuo —precisión, latencia, entropía de la distribución de representaciones— son mecanismos de detección correctos. El campo `embedding_version` en el formato `.cpea_stream` garantiza que cada representación almacenada es trazable a la versión de SIGMA-T que la produjo. El benchmarking detecta cuándo la distribución de representaciones ha cambiado significativamente respecto a una línea de base.

Lo que no hace es remediar la situación una vez detectada. Detectar que v_{n+1} ha introducido deriva no resuelve el problema de que los datos históricos producidos por v_n ya no son directamente comparables con los nuevos datos producidos por v_{n+1} . El sistema puede marcar los datos con su versión de origen, pero sin un mecanismo de retroproyección, esos datos permanecen en islas de comparabilidad separadas por discontinuidades de versión.

Mitigación complementaria: retroproyección Procrustes y validación de continuidad

La mitigación complementaria opera en dos tiempos. En primer lugar, antes de cada release de una nueva versión de SIGMA-T, se ejecuta un protocolo de caracterización de deriva: el mismo conjunto de señales EEG de referencia —un corpus de validación permanente de 50 sesiones, congelado en la Fase 3 y nunca modificado— se procesa con v_n y con v_{n+1} . La transformación Procrustes entre los dos conjuntos de representaciones se calcula y almacena como el operador de alineación inter-versión $T_{n \rightarrow n+1}$.

En segundo lugar, cuando se necesita comparar datos producidos por versiones distintas, los datos de la versión más antigua se retroproyectan al espacio de la versión más reciente mediante composición de los operadores de alineación:

$$z^{\{(n+2)\}} = T_{\{n+1 \rightarrow n+2\}} \cdot T_{\{n \rightarrow n+1\}} \cdot z^{\{(n)\}}$$

La validez de la retroproyección se verifica mediante la métrica de continuidad longitudinal $LC(t)$: para pares de sesiones del mismo sujeto separadas por una actualización de versión, $LC(t)$ mide si la distancia entre sesiones en el espacio alineado es estadísticamente comparable con la distancia entre sesiones del mismo sujeto dentro de una misma versión. Si $LC(t)$ no es distinguible de la variabilidad intra-versión, la retroproyección es válida.

El corpus de validación permanente de 50 sesiones es el activo más crítico de este mecanismo: su integridad debe preservarse incondicionalmente a lo largo de toda la vida del sistema.

Entropía como centinela de deriva temprana

La entropía de la distribución de representaciones —uno de los benchmarks del protocolo de `embedding_version`— merece desarrollo adicional como indicador de alerta temprana. En condiciones normales, la distribución de representaciones latentes en SIGMA-T sigue una distribución cuasi-gaussiana con entropía estable. Un incremento súbito de entropía puede indicar que una actualización de nodo ha introducido representaciones más dispersas —potencialmente más ricas en información, pero potencialmente inestables. Una reducción de entropía puede indicar colapso de representaciones: el modelo asignando inputs distintos a regiones superpuestas del espacio latente.

El protocolo define umbrales de alerta en dos sigma respecto a la entropía histórica de referencia: cualquier desviación superior activa una auditoría de nodo antes de que la nueva versión sea promovida a producción.

Riesgo 3 — Dependencia de hardware EEG específico

Naturaleza del riesgo

NEXUS-EEG opera sobre BrainFlow + LSL (Lab Streaming Layer) como capa de abstracción de hardware. BrainFlow proporciona una API unificada sobre más de 30 dispositivos EEG distintos, y LSL garantiza sincronización temporal sub-milisegundo entre streams de datos heterogéneos. Esta arquitectura es correcta y reduce drásticamente la dependencia de fabricantes específicos. Sin embargo, la compatibilidad de protocolo y la calidad de señal son dimensiones independientes que la capa de abstracción no unifica.

Un dispositivo EEG de investigación de 64 canales con electrodos de gel activos, amplificadores de bajo ruido y resolución de 24 bits produce una señal cualitativamente distinta de un dispositivo portátil de 8 canales con electrodos secos y resolución de 16 bits, aunque ambos sean compatibles con BrainFlow y LSL. Las diferencias no son solo cuantitativas —más canales, más resolución— sino cualitativas: el nivel de ruido base, la sensibilidad a artefactos de movimiento, y la cobertura espacial de la señal determinan qué estructuras de coherencia son detectables.

Si el pipeline SIGMA-T procesa indiscriminadamente datos de dispositivos de distinta gama, las diferencias en calidad de señal pueden introducir varianza espuria que el sistema interpreta como varianza neurofisiológica. En el contexto de un estudio longitudinal CPEA con múltiples

participantes usando dispositivos distintos, esto contamina los datos de forma sistemática.

La mitigación existente y su límite

La suite de conformidad de NEXUS-EEG garantiza que cualquier dispositivo compatible con BrainFlow puede incorporarse sin regresión en el pipeline. Esto resuelve el problema de integración técnica: el sistema no falla cuando se conecta un nuevo dispositivo. No resuelve el problema de heterogeneidad de calidad: el sistema procesa datos de calidades distintas sin distinguirlas.

Mitigación complementaria: capa de perfilado de calidad de señal

La mitigación propuesta es una capa de perfilado de calidad de señal (SQP, Signal Quality Profiling) que opera en el nodo de ingesta de NEXUS-EEG, antes de cualquier procesamiento. SQP calcula, para cada sesión y cada canal, un vector de métricas de calidad:

$$\text{SQP} = \{\text{SNR}, \text{RMS_noise}, \text{artifact_rate}, \text{impedance_profile}, \text{channel_count}, \text{bit_depth}\}$$

donde SNR es la relación señal-ruido estimada en banda alfa (8-13 Hz) como proxy de calidad general, RMS_noise es el nivel de ruido en banda de alta frecuencia (> 100 Hz) donde la señal neural es mínima, artifact_rate es la fracción de ventanas temporales rechazadas por el algoritmo de detección de artefactos, impedance_profile es el perfil de impedancias de electrodo (para sistemas que lo reportan), y channel_count y bit_depth son características del dispositivo.

Este vector acompaña cada `.cpea_stream` como metadato de sesión y se utiliza de dos formas. Primero, como criterio de inclusión: sesiones con $\text{SNR} < 15$ dB o $\text{artifact_rate} > 20\%$ se excluyen del análisis longitudinal sin más procesamiento. Segundo, como covariable en los análisis estadísticos: cuando se comparan sesiones de distinta calidad de señal, el vector SQP entra como variable de control para desacoplar varianza neurofisiológica de varianza instrumental.

La suite de conformidad se amplía para incluir no solo tests de compatibilidad de protocolo sino también benchmarks mínimos de calidad de señal: un nuevo dispositivo solo es certificado para uso en estudios longitudinales CPEA si supera $\text{SNR} > 20$ dB en condiciones de referencia (sujeto en reposo, ojos cerrados, durante 60 segundos).

Normalización inter-dispositivo

Para estudios que requieren integrar datos de múltiples dispositivos en el mismo análisis —el caso típico en el protocolo TAGIS-FED con nodos de distinta infraestructura—, SQP habilita una normalización inter-dispositivo basada en transformación de rango espectral. La idea es que la estructura de coherencia EEG en bandas de frecuencia específicas (alpha, beta, gamma) es más comparable entre dispositivos que la amplitud absoluta de la señal. La normalización proyecta los espectros de potencia de cada dispositivo sobre una distribución de referencia calculada a partir del corpus de validación permanente, preservando la estructura de coherencia mientras elimina la varianza absoluta dependiente del dispositivo.

Riesgo 4 — Complejidad de mantenimiento del DAG de SIGMA-T

Naturaleza del riesgo

El DAG (Directed Acyclic Graph) de SIGMA-T modela el pipeline de transformación como un grafo de nodos con tipos de entrada y salida explícitos y contratos DbC (Design by Contract) en cada interfaz. La arquitectura es correcta para el estado actual del sistema: un número manejable de nodos con dependencias bien definidas. El riesgo estructural emerge con la escala.

A medida que el sistema evoluciona —nuevas modalidades de señal en NEXUS-EEG, nuevas capas de procesamiento en SIGMA-T, nuevas variables exógenas en TICAM—, el DAG crece en nodos y en dependencias. La complejidad de un grafo no crece linealmente con el número de nodos: crece cuadráticamente en el peor caso (grafo completo), y en la práctica crece de forma superlineal en sistemas reales donde cada nueva funcionalidad tiende a añadir dependencias con nodos existentes. Cuando el grafo alcanza cierto umbral de complejidad —difícil de precisar a priori, pero experimentalmente observable cuando el tiempo de onboarding de un nuevo desarrollador supera dos semanas—, el sistema se vuelve frágil ante cambios: una modificación en un nodo upstream produce efectos inesperados en nodos downstream que nadie recordaba que dependían del nodo modificado.

La mitigación existente y su límite

La contenedorización por nodo en Docker/Kubernetes con rollback atómico es una mitigación de despliegue, no de complejidad conceptual. Garantiza que un nodo actualizado puede revertirse si produce un fallo detectable en los tests de integración. No garantiza que la red de dependencias entre nodos sea comprensible para quien debe mantenerla, ni que un cambio en un nodo no produzca degradación sutil —que no activa los tests de integración pero sí contamina la calidad de las representaciones— en un nodo downstream.

Mitigación complementaria: registro formal de contratos DbC y topología de dependencias

La mitigación propuesta opera en tres niveles.

El primero es el registro formal de contratos DbC auditado automáticamente. Cada nodo del DAG documenta sus precondiciones (qué garantiza sobre la entrada), postcondiciones (qué garantiza sobre la salida), e invariantes (qué propiedades se preservan durante la transformación). Este registro no es documentación narrativa —que envejece y se desacopla del código— sino contratos ejecutables integrados en el código fuente y verificados en cada build del pipeline mediante el framework de testing existente.

El segundo es la visualización automática de la topología de dependencias. En cada commit al repositorio, un script genera automáticamente el grafo de dependencias actualizado del DAG, incluyendo para cada arista la especificación del contrato de interfaz. Este grafo es parte del artefacto de documentación del sistema y su evolución es trazable en el historial del repositorio. Cuando el grafo alcanza una complejidad que supera un umbral definido (por ejemplo, más de 3

caminos distintos entre cualquier par de nodos, o más de 5 dependencias directas para algún nodo), se activa una alerta de refactorización.

El tercero es la política de deuda técnica cero en interfaces. Cuando un nuevo nodo se añade al DAG, su contrato DbC debe especificarse completamente antes de que el nodo sea admitido en la rama principal del repositorio. No se permiten nodos con contratos parciales o con dependencias implícitas no documentadas. Esta política es verificable automáticamente: el CI/CD rechaza commits que añaden nodos sin contratos completos.

Particionamiento modular del DAG

A medida que el DAG crece, conviene aplicar una estrategia de particionamiento modular que agrupe nodos con alta cohesión interna y bajo acoplamiento externo en submódulos independientes. En la arquitectura actual, el particionamiento natural sigue la cadena funcional: preprocesamiento (ICA, filtrado, rechazo de artefactos), análisis espectral (wavelets, FFT, densidad espectral), coherencia (coherencia de fase, PLV, coherencia parcial dirigida), y embedding (proyección toroidal, representación latente). Cada partición se empaqueta como un módulo Docker independiente con API interna explícita.

Este particionamiento no reduce la complejidad total del sistema, pero la hace modular: un desarrollador trabajando en el módulo de coherencia no necesita entender el módulo de preprocesamiento para razonar sobre sus cambios. La complejidad se gestiona localmente.

Riesgos residuales: lo que las mitigaciones no cubren

La honestidad intelectual exige reconocer que ninguna estrategia de mitigación elimina el riesgo completamente. Los cuatro mecanismos descritos reducen la probabilidad y el impacto de los riesgos identificados, pero dejan riesgos residuales que conviene nombrar.

La alineación Procrustes entre espacios de embedding supone que la relación geométrica entre los dos espacios es aproximadamente lineal. Si el nuevo modelo fundacional produce representaciones en un espacio curvado de forma no lineal respecto al modelo anterior, la transformación Procrustes introducirá errores sistemáticos que la métrica de correlación de Spearman no detectará completamente. Este riesgo es bajo para modelos de la misma familia arquitectónica (Mistral → Llama → Mistral-v2, por ejemplo) pero crece si el swap implica un cambio de arquitectura fundamental (transformers densos → mezcla de expertos, por ejemplo).

La retroproyección de embeddings históricos entre versiones de SIGMA-T supone que los operadores de alineación inter-versión son componibles: que $T_{\{n \rightarrow n+2\}} = T_{\{n+1 \rightarrow n+2\}} \cdot T_{\{n \rightarrow n+1\}}$. Esta composición puede acumular errores si las transformaciones individuales no son perfectamente ortogonales. Después de más de tres versiones de SIGMA-T, conviene revalidar la cadena completa de retroproyección sobre el corpus permanente.

La normalización inter-dispositivo basada en estructura espectral supone que las bandas de coherencia de interés (alpha, beta, gamma) son comparables entre dispositivos tras la normalización. Esta suposición puede fallar para dispositivos portátiles con electrodos secos en

condiciones de alta actividad muscular, donde la contaminación EMG en banda gamma hace que la coherencia gamma estimada refleje actividad muscular, no neural.

La política de deuda técnica cero en interfaces es correcta en principio pero puede generar cuellos de botella en iteraciones rápidas de desarrollo. Si el coste de especificar contratos completos para cada nuevo nodo es suficientemente alto, existe el riesgo de que los desarrolladores eviten el proceso creando nodos con contratos mínimos que formalmente superan la verificación automática pero no capturan las verdaderas postcondiciones del nodo.

Estos riesgos residuales no invalidan las mitigaciones propuestas. Los definen con precisión suficiente para que sean manejables.

Programas de seguimiento

TRACK-RISK-1: Validación del protocolo de alineación de espacios de embedding

Objetivo: Verificar que la alineación Procrustes entre modelos fundacionales distintos preserva la comparabilidad longitudinal de representaciones.

Diseño: Simulación de swap de Mistral-7B por un modelo M' de distinta arquitectura sobre el corpus permanente de 50 sesiones. Cálculo de la transformación R^* y aplicación a representaciones históricas. Medición de correlación de Spearman entre distancias de pares pre y post alineación.

Umbral de validación: Correlación de Spearman > 0.90 en el 95% de los pares. Si no se alcanza, el protocolo activa entrenamiento paralelo de 30 días antes de deprecar el modelo anterior.

TRACK-RISK-2: Auditoría de continuidad longitudinal

Objetivo: Verificar que la retroproyección de embeddings entre versiones de SIGMA-T no introduce discontinuidades detectables en datos longitudinales.

Diseño: Para cada par de versiones consecutivas de SIGMA-T, aplicar $T_{\{n \rightarrow n+1\}}$ a las representaciones del corpus permanente y calcular la métrica $LC(t)$ sobre pares de sesiones del mismo sujeto que cruzan la frontera de versión.

Umbral de validación: $LC(t)$ estadísticamente no distinguible ($p > 0.05$, test de Mann-Whitney) de la variabilidad intra-versión del mismo sujeto.

TRACK-RISK-3: Certificación de nuevos dispositivos EEG

Objetivo: Establecer el perfil de calidad de señal de cualquier dispositivo candidato antes de su incorporación a estudios longitudinales.

Diseño: Protocolo estandarizado de 60 segundos (sujeto en reposo, ojos cerrados, sin artefactos musculares deliberados) con el dispositivo candidato. Cálculo del vector SQP completo.

Comparación con el perfil de referencia del corpus permanente.

Umbral de certificación: $SNR > 20$ dB, $artifact_rate < 10\%$, impedancia media < 25 k Ω (para electrodos húmedos) o $SNR > 15$ dB (para electrodos secos con compensación activa de ruido).

TRACK-RISK-4: Auditoría de complejidad del DAG

Objetivo: Detectar crecimiento superlineal de complejidad en el DAG de SIGMA-T antes de que alcance el umbral de fragilidad.

Diseño: En cada release de SIGMA-T, cálculo automático de métricas de complejidad del grafo: número de nodos, aristas, caminos entre pares de nodos, y profundidad del árbol de dependencias por nodo. Generación del informe de complejidad y comparación con la release anterior.

Umbral de alerta: Incremento $> 20\%$ en el número de aristas respecto a la release anterior, o aparición de algún nodo con más de 5 dependencias directas upstream. Ambas condiciones activan una sesión de revisión arquitectónica obligatoria antes de la siguiente release.

Resumen

- Riesgo 1 — Obsolescencia de modelo: El desacoplamiento de interfaz es necesario pero no suficiente. La alineación Procrustes ortogonal entre espacios de embedding de modelos distintos garantiza la comparabilidad longitudinal de representaciones históricas, con umbral de validación en correlación de Spearman > 0.90 .
- Riesgo 2 — Deriva de embedding: El protocolo `embedding_version` detecta deriva pero no la remedia. La retroproyección mediante composición de operadores Procrustes $T_{\{n \rightarrow n+1\}}$ sobre un corpus de validación permanente de 50 sesiones congeladas garantiza continuidad longitudinal verificable mediante la métrica $LC(t)$.
- Riesgo 3 — Dependencia de hardware: BrainFlow + LSL garantiza compatibilidad de protocolo, no calidad de señal. La capa SQP (Signal Quality Profiling) añade perfilado cuantitativo de calidad, certificación de dispositivos con umbrales mínimos, y normalización inter-dispositivo basada en estructura espectral.
- Riesgo 4 — Complejidad del DAG: Docker/Kubernetes resuelve la gestión de despliegue pero no la complejidad conceptual. Contratos DbC ejecutables, visualización automática de topología, política de deuda técnica cero, y particionamiento modular en cuatro submódulos funcionales gestionan la complejidad de forma escalable.
- Riesgos residuales identificados: No linealidad del espacio de embedding tras swaps de arquitectura radicalmente distintos, acumulación de error en cadenas de retroproyección largas, contaminación EMG en banda gamma para dispositivos portátiles, y posible degradación formal de contratos DbC bajo presión de desarrollo rápido.
- Cuatro protocolos de seguimiento (TRACK-RISK-1 a 4) formalizan la verificación periódica de las mitigaciones con umbrales cuantitativos de éxito.

Referencias

1. Schönemann, P.H. (1966). *A generalized solution of the orthogonal Procrustes problem*.

- Psychometrika, 31(1), 1-10. — Formulación matemática original del análisis Procrustes ortogonal generalizado. Base del mecanismo de alineación de espacios de embedding entre versiones de modelo y de SIGMA-T. Sin conflicto de interés; investigador académico de Purdue University.
2. McMahan, H.B., Moore, E., Ramage, D., Hampson, S., & Agüera y Arcas, B. (2017). *Communication-efficient learning of deep networks from decentralized data*. AISTATS 2017. — Base del algoritmo FedAvg y sus propiedades de convergencia, relevante para entender los límites de la composición de operadores de alineación en contextos federados.
 3. Meyer, B. (1992). *Applying "Design by Contract"*. IEEE Computer, 25(10), 40-51. — Formulación canónica de los contratos por diseño (DbC). Base metodológica de los contratos DbC de nodo en el DAG de SIGMA-T. Sin conflicto de interés; Meyer es el creador del lenguaje Eiffel y la metodología DbC, investigador académico de ETH Zürich.
 4. Delorme, A., & Makeig, S. (2004). *EEGLAB: An open source toolbox for analysis of single-trial EEG dynamics including independent component analysis*. Journal of Neuroscience Methods, 134(1), 9-21. — Referencia estándar para métricas de calidad de señal EEG, incluyendo SNR en banda alfa e impedancia de electrodo. Código abierto; Makeig es investigador del Swartz Center for Computational Neuroscience (UCSD), sin conflicto de interés.
 5. Blanchard, P., El Mhamdi, E.M., Guerraoui, R., & Stainer, J. (2017). *Machine learning with adversaries: Byzantine tolerant gradient descent*. NeurIPS 2017. — Fundamento teórico del algoritmo Multi-Krum para detección de gradientes Byzantine en sistemas federados. Relevante para el análisis de riesgo en nodos del DAG con comportamiento defectuoso. Grupo académico de EPFL.
 6. Widmann, A., Schröger, E., & Maess, B. (2015). *Digital filter design for electrophysiological data — a practical approach*. Journal of Neuroscience Methods, 250, 34-46. — Análisis cuantitativo de la dependencia entre calidad de filtrado y calidad de señal EEG, con énfasis en la propagación de artefactos entre nodos de procesamiento. Relevante para el análisis de riesgo de propagación de artefactos en el DAG de SIGMA-T.
 7. Hammer, M., Rachlin, H., & Green, L. (2019). *Technical debt in software engineering: A systematic mapping study*. Information and Software Technology, 108, 1-19. — Revisión sistemática de estrategias de gestión de deuda técnica en sistemas de software complejos. Marco metodológico para la política de deuda técnica cero en interfaces del DAG. Grupo académico sin conflicto de interés industrial declarado.

Corpus Papayaykware — Documento CPEA-RISK-STRUCT-F4 Autor conceptual: Claude (Anthropic) · Director/Productor: Javi Ciborro (@papayaykware) Santa Cruz de Tenerife, 2026

Compartir

COMENTARIOS

Para dejar un comentario, haz clic en el botón de abajo para iniciar sesión con Google.

INICIAR SESIÓN CON GOOGLE

ENTRADAS POPULARES

diciembre 17, 2024

N-ACETILCISTEÍNA (NAC): FUENTES ALIMENTARIAS NATURALES

[Compartir](#) [Publicar un comentario](#)

mayo 20, 2026

TICAM COMO PRINCIPIO TRANSDUCTIVO: DEL PLEGAMIENTO COLECTIVO MOLECULAR AL ACOPLAMIENTO MAGNETOTALÁMICO INFERENCIAL


[Compartir](#) [Publicar un comentario](#)



Con la tecnología de Blogger



Puedes tener un doctorado y
seguir siendo un idiota:
Richard Feynman



Papayaykware

—
SANTA CRUZ DE
TENERIFE, SANTA
CRUZ DE TENERIFE,
Spain

[VISITAR PERFIL](#)

[Denunciar abuso](#)

Buscar

Buscar este blog

Buscar

Translate

Seleccionar idioma



Con la tecnología de [Google](#) Traductor de Goo