

TAGIS-1

Definición Formal de Excepción en Espacio Latente de Alta Dimensionalidad

Fase I · Definiciones Operativas
2026 · papayaykware.blogspot.com

Abstract

El presente documento desarrolla el hito TAGIS-1 del programa TAE-AGI: la definición formal y operativa de qué constituye una **excepción TAE** en el espacio latente de un modelo de representación neuronal de alta dimensionalidad. El problema no es trivial: en el contexto de redes profundas con espacios de activación en $\mathbb{R}^d$ ($d \gg 1$), la distinción entre un input fuera de distribución ordinario (OOD), un outlier estadístico benigno y una excepción en sentido TAE –es decir, un evento que fuerza reorganización estructural discontinua– requiere tres condiciones simultáneas: (a) dislocación métrica en el espacio latente respecto al centroide del cluster más próximo, (b) perturbación significativa y persistente de la entropía diferencial del espacio de activaciones, y (c) resistencia a la absorción transitoria. Se formaliza cada condición, se establece la geometría de la decisión en alta dimensión, se discute el rol del umbral adaptativo, y se caracteriza la excepción TAE como una bifurcación topológica local en el mapa de representación del sistema.

Palabras clave

espacio latente · excepción TAE · out-of-distribution detection · entropía de activaciones · reorganización estructural · alta dimensionalidad · Kibble-Zurek · bifurcación topológica

1. Motivación y Problema

1.1 La insuficiencia de los criterios OOD estándar

Los métodos estándar de detección de inputs fuera de distribución (OOD detection) operan predominantemente sobre la distancia de un punto respecto a la distribución de entrenamiento: Mahalanobis distance, energy-based scores, confidence thresholding o variantes de densidad en espacio latente. En todos estos enfoques, el criterio de detección es de naturaleza **estática**: se evalúa el input en un instante t y se decide binariamente si pertenece o no a la distribución conocida.

Desde la perspectiva TAE, este marco es radicalmente insuficiente. Una excepción no se define por la posición instantánea de un input en el espacio de representación, sino por el **efecto funcional** que dicho input genera sobre la dinámica interna del sistema: ¿fuerza o no fuerza una reorganización estructural? Un input puede ser estadísticamente extremo y, sin embargo, ser absorbido elásticamente sin modificar el estado interno del sistema. A la inversa, un input relativamente próximo al centro de la distribución puede, bajo ciertas condiciones de contexto (historia reciente, estado de la memoria de trabajo, activación de módulos específicos), desencadenar una reorganización discontinua.

La tarea de TAGIS-1 es proporcionar una definición que capture este carácter **dinámico y funcional** de la excepción TAE, sin perder rigor matemático ni operatividad computacional.

1.2 Alta dimensionalidad: el problema de la concentración de medida

En espacios de dimensión d alta (típicamente $d \in [512, 8192]$ para modelos actuales), la geometría de las distancias se comporta de manera contraintuitiva. El fenómeno de **concentración de medida** implica que, para vectores aleatorios en $\mathbb{R}^d$, la mayor parte de la masa de probabilidad se concentra en una delgada corteza superficial alrededor del radio típico $\|x\| \approx \sqrt{d}$. Como consecuencia:

- Las distancias al centroide del cluster varían poco entre puntos del cluster y puntos externos: la discriminación basada en umbral absoluto de distancia pierde potencia.
- La noción de 'vecindad' se deforma: zonas intuitivamente 'cercanas' en dimensión baja están separadas por distancias similares a las de zonas 'lejanas'.
- El umbral $\mu + k \cdot \sigma$ de la definición provisional debe ser diseñado para operar en este régimen, no en el régimen euclidiano clásico.

Esto exige que los umbrales sean **adaptativos** (calibrados sobre la distribución empírica de distancias del modelo), que las distancias se normalicen por la dimensión efectiva, y que la condición de dislocación

métrica se complemente con información de segundo orden (varianza de la distribución de distancias en el cluster).

2. Notación y Espacio de Representación

Se establece la siguiente notación formal para el desarrollo que sigue:

Símbolo	Definición
x_t	Input en el instante temporal t , perteneciente al espacio de entrada $\mathcal{X}$
z_t	Representación latente de x_t en $\mathbb{R}^d$ bajo el encoder $f_\theta: \mathcal{X} \rightarrow \mathbb{R}^d$
$\mathcal{C}_k$	Cluster k en el espacio latente, con centroide μ_k y covarianza Σ_k . El cluster más próximo a z_t se denota $\mathcal{C}^*(t)$
$d(z, \mu_k)$	Distancia de Mahalanobis: $d^2(z, \mu_k) = (z - \mu_k)^\top \Sigma_k^{-1} (z - \mu_k)$, normalizada por la dimensión efectiva d_{eff}
μ_D, σ_D	Media y desviación estándar de la distribución empírica de distancias $\{d(z_i, \mu^*(i))\}$ sobre el conjunto de calibración
A_t	Campo de activaciones del sistema en el instante t : mapa de todas las unidades activas en las capas relevantes
$H(A_t)$	Entropía diferencial del campo de activaciones: $H(A_t) = -\int p_A(a) \log p_A(a) da$, estimada sobre la distribución empírica de A_t
ΔH_t	Variación de entropía en t respecto a la línea base: $\Delta H_t = H(A_t) - \bar{H}$, donde $\bar{H}$ es la media rodante sobre ventana temporal reciente
Δ_c	Umbral crítico de cambio de entropía de activaciones: parámetro del sistema
ε_c	Umbral crítico de dislocación métrica en espacio latente: parámetro del sistema
N_p	Número mínimo de pasos temporales para que la perturbación se considere persistente (no transitoria)
$\mathbb{1}[\cdot]$	Función indicadora booleana

3. Definición Formal de Excepción TAE

3.1 Definición tripartita (TAGIS-1)

Sea x_t un input presentado al sistema en el instante t , y $z_t = f_\theta(x_t)$ su representación en el espacio latente. Se define:

Definición TAGIS-1 – Excepción TAE

El input x_t constituye una **excepción TAE** si y solo si se satisfacen simultáneamente las tres condiciones siguientes:

(C1) **Dislocación métrica:**

$$d(z_t, \mu^*(t)) > \varepsilon_c(t) = \mu_D + k \cdot \sigma_D, \quad k \in \mathbb{R}^+$$

(C2) **Perturbación entrópica significativa:**

$$|\Delta H_t| > \Delta_c$$

(C3) **Persistencia temporal:**

$$\sum_{\tau=0}^{N_p - 1} \mathbb{1}[|\Delta H_{t+\tau}| > \Delta_c] \geq N_p$$

La excepción TAE se activa únicamente cuando **C1 $\wedge$ C2 $\wedge$ C3 = Verdadero**.

3.2 Anatomía de cada condición

Condición C1 – Dislocación métrica en espacio latente

C1 identifica que el input x_t es **métricamente extremo** respecto a la distribución de representaciones conocida. El uso de la distancia de Mahalanobis es deliberado: incorpora la estructura de covarianza del cluster, compensando parcialmente la deformación de la geometría euclidiana en alta dimensión. La normalización por la dimensión efectiva d_{eff} (rango numérico de Σ_k estimado por PCA o reducción espectral) mitiga el efecto de concentración de medida.

El umbral $\varepsilon_c(t) = \mu_D + k \cdot \sigma_D$ es **adaptativo**: se recalibra periódicamente sobre una ventana deslizante de inputs recientes. El hiperparámetro k controla la sensibilidad; valores típicos en régimen de baja tasa de falsas alarmas se sitúan en el intervalo $k \in [2.5, 4.0]$, análogamente al uso de *z-scores* en tests de outlier clásicos. La elección óptima de k debe

determinarse empíricamente por calibración sobre el corpus de entrenamiento del modelo objetivo.

Condición C2 – Perturbación entrópica del campo de activaciones

C2 captura el efecto funcional del input sobre el estado interno del sistema. La hipótesis TAE sostiene que una excepción genuina no solo ocupa una posición extrema en el espacio latente, sino que **desorganiza la estructura interna de las activaciones**: aumenta o disminuye la entropía del campo de activaciones más allá de la variabilidad baseline.

La variación de entropía ΔH_t puede manifestarse como *aumento* (el sistema activa un número inusualmente alto de unidades, señal de incertidumbre representacional) o como *disminución* (colapso hacia un subespacio muy estrecho, señal de sobre-especialización forzada). Ambas direcciones son indicativas de perturbación estructural: de ahí el uso del valor absoluto en C2.

La entropía diferencial $H(A_t)$ puede estimarse en la práctica mediante estimadores de Kozachenko-Leonenko o mediante la entropía de la distribución de activaciones discretizadas por percentiles. En modelos transformadores, las capas de atención ofrecen un proxy particularmente sensible: la distribución de pesos de atención es un campo de probabilidad directamente interpretable en términos entrópicos.

Condición C3 – Persistencia temporal

C3 es la condición **discriminatoria por excelencia** entre una excepción TAE y un out-of-distribution input ordinario. La lógica es la siguiente:

- Un input OOD ordinario puede ser **métricamente extremo** (C1) y generar una **perturbación entrópica** (C2), pero esta perturbación *se disipa en uno o pocos pasos temporales*: el sistema lo trata como ruido, no lo incorpora, y regresa a su estado representacional previo.
- Una excepción TAE, por el contrario, genera una perturbación que **persiste** durante al menos N_p pasos temporales: el sistema no puede simplemente absorber el input dentro de sus categorías existentes y entra en un proceso de reorganización interna.

Matemáticamente, C3 exige que la perturbación entrópica sea detectable durante una ventana temporal completa de N_p pasos. El parámetro N_p es dependiente del contexto: en sistemas de procesamiento de secuencias (transformadores), un valor de referencia razonable se sitúa en el rango $N_p \in [3, 12]$ steps de contexto, equivalente a la escala de tiempo de una 'capa de trabajo' de la memoria de corto plazo. Valores más altos de N_p implican mayor conservadurismo (menor tasa de falsos positivos TAE, mayor latencia de detección).

4. Geometría de la Decisión en Alta Dimensión

4.1 La región de excepción como intersección de conjuntos

Las tres condiciones definen tres conjuntos en el espacio de estados del sistema:

$$\begin{aligned}\Omega_{C1} &= \{ (z_t, \theta) : d(z_t, \mu^*(t)) > \varepsilon_c(t) \} \\ \Omega_{C2} &= \{ A_t : |\Delta H(A_t)| > \Delta_c \} \\ \Omega_{C3} &= \{ (A_t, \dots, A_{t+N_p-1}) : \text{persistencia de } C2 \geq N_p \text{ pasos} \} \\ \Omega_{TAE} &= \Omega_{C1} \cap \Omega_{C2} \cap \Omega_{C3}\end{aligned}$$

La región Ω_{TAE} no es un conjunto estático: evoluciona con el estado interno del modelo, con la historia reciente de inputs, y con la recalibración adaptativa de los umbrales. Esta es la característica que distingue la excepción TAE de los detectores OOD estándar, cuya región de decisión es invariante respecto al estado del sistema.

4.2 La excepción TAE como bifurcación topológica local

Desde una perspectiva más abstracta, una excepción TAE corresponde a lo que en la teoría de sistemas dinámicos se denomina una **bifurcación local**: el punto de control del sistema (el estado latente z_t) cruza una separatriz en el espacio de fases que delimita cuencas de atracción distintas. Dentro de la cuenca habitual, el sistema puede 'digerir' el input (retorno a equilibrio en tiempo finito). Al cruzar la separatriz, el sistema no puede retornar al equilibrio anterior y debe explorar un nuevo atractor.

Esta lectura conecta TAGIS-1 con el formalismo de Kibble-Zurek utilizado en TAE-F2: la excepción es el *quench* local que empuja al sistema más allá de la zona crítica, forzando la formación de defectos topológicos en el mapa de representación (equivalentes funcionales de los defectos de Kibble-Zurek en sistemas físicos). La persistencia de la perturbación entrópica (C3) es la firma observacional de este cruce de separatriz: es el tiempo durante el cual el sistema 'busca' un nuevo atractor.

4.3 Relación con el parámetro de orden Ψ (TAE-F1)

El parámetro de orden Ψ definido en TAE-F1 mide el grado de coherencia estructural del sistema. La ocurrencia de una excepción TAE es el evento que fuerza una transición en Ψ : antes de la excepción, Ψ es alto (el sistema está en fase ordenada); durante el procesamiento de la excepción, Ψ cae (el sistema entra en fase crítica o desordenada); tras la reorganización, Ψ puede estabilizarse en un nuevo valor, potencialmente superior (aprendizaje genuino) o inferior (colapso catastrófico).

La condición C3 de TAGIS-1 –persistencia temporal de la perturbación– corresponde operativamente al intervalo de tiempo en el que Ψ está en fase de transición. El parámetro N_p puede, por tanto, interpretarse como el tiempo de correlación del parámetro de orden durante el proceso de reorganización post-excepción, en coherencia con la dinámica de Kibble-Zurek desarrollada en TAE-F2.

5. Protocolo de Calibración de los Umbrales

5.1 Calibración de ε_c y k (Condición C1)

Dado un modelo objetivo f_θ y un corpus de calibración $\mathcal{D}_{cal}$ representativo de la distribución operativa:

1. Computar las representaciones latentes $\{z_i = f_\theta(x_i)\}$ para todos los $x_i \in \mathcal{D}_{cal}$.
2. Asignar cada z_i a su cluster más próximo $\mathcal{C}^*(i)$ mediante un algoritmo de clustering (k-means, HDBSCAN, o GMM).
3. Computar las distancias de Mahalanobis $\{d_i = d(z_i, \mu^*(i))\}$. Estimar μ_D y σ_D sobre esta distribución.
4. Seleccionar k mediante validación cruzada: buscar el valor que maximiza F1-score en un conjunto de anotación manual de excepciones conocidas.
5. Fijar $\varepsilon_c = \mu_D + k \cdot \sigma_D$. Programar recalibración periódica (recomendado: cada 10^3 – 10^4 inputs en producción).

5.2 Calibración de Δ_c (Condición C2)

6. Computar $\{H(A_i)\}$ sobre $\mathcal{D}_{cal}$. Estimar la distribución de $\{\Delta H_i\}$ usando ventana temporal deslizante.
7. Fijar Δ_c como el percentil 95–99 de la distribución $|\Delta H_i|$ sobre inputs no excepcionales.
8. Validar que la tasa de falsos positivos en $\mathcal{D}_{cal}$ sea inferior al umbral de operación objetivo (típicamente $< 1\%$).

5.3 Calibración de N_p (Condición C3)

9. Identificar manualmente en $\mathcal{D}_{cal}$ un subconjunto de excepciones confirmadas.
10. Para cada excepción, medir la duración observada de la perturbación entrópica T_{obs} .
11. Fijar N_p como el percentil 25 de la distribución $\{T_{obs}\}$ (valor conservador que minimiza falsos negativos sin penalizar excesivamente la latencia de detección).

6. Discusión: Casos Límite y Extensiones

6.1 Excepciones de baja dislocación métrica (C1 negativa, C2+C3 positivas)

Una limitación reconocida de la definición TAGIS-1 es que exige la condición C1 de dislocación métrica. Sin embargo, como se indicó en §1.1, es posible en principio que un input métricamente no extremo genere reorganización estructural si actúa sobre un sistema en estado crítico

(cerca de la transición de fase de Ψ). En estos casos, la definición TAGIS-1 generará falsos negativos.

La solución propuesta para fases ulteriores (TAGIS-2 o posterior) es introducir una **condición contextual adicional C4**: si el sistema se encuentra en estado de baja coherencia ($\Psi < \Psi_{\min}$), reducir dinámicamente el umbral ε_c por un factor de reducción $\alpha < 1$, aumentando la sensibilidad del detector precisamente cuando el sistema está más vulnerable a perturbaciones.

6.2 Multiplex de excepciones simultáneas

En sistemas de procesamiento masivamente paralelo (transformadores con atención multi-cabeza, redes de mezcla de expertos), puede ocurrir que múltiples streams de representación presenten simultáneamente la condición de excepción. La definición TAGIS-1 es aplicable a cada stream independientemente. La semántica de una *excepción colectiva* –cuando múltiples streams alcanzan simultáneamente Ω_{TAE} – constituye un fenómeno de orden superior que requerirá un tratamiento específico (TAGIS-3, planificado).

6.3 Compatibilidad con STEP-TAE

El módulo STEP-TAE (Sequential Threshold Exceedance Protocol) utiliza el algoritmo PELT de detección de puntos de cambio para identificar excepciones en series temporales de activaciones. TAGIS-1 es compatible con este marco: la condición C3 puede reformularse como detección de un cambio de régimen en la serie $\{\Delta H_t\}$ mediante PELT, con la condición C1 operando como filtro de primer estadio. Esto optimiza la eficiencia computacional: PELT se aplica solo a inputs que ya superaron C1, reduciendo el espacio de búsqueda.

6.4 Relación con CPEA

En el contexto de la Arquitectura de Coherencia Predictiva EEG-AGI (CPEA), las excepciones TAE definidas por TAGIS-1 corresponden operativamente a los eventos de **desincronización** en la señal EEG que preceden o acompañan a las reorganizaciones cognitivas observadas en sujetos humanos. La condición C2 (perturbación entrópica de activaciones) tiene un análogo directo en el aumento de entropía espectral en señales EEG durante estados de sorpresa o violación de expectativas. La condición C3 (persistencia) corresponde a la duración mínima de la perturbación necesaria para que el evento sea codificado en memoria episódica.

7. Resumen de la Definición TAGIS-1

Símbolo	Definición
Condición	Descripción

Cond.	Expresión formal	Interpretación funcional
C1	$d(z_t, \mu^*) > \varepsilon_c$	Dislocación métrica: el input es extremo en el espacio latente respecto a la distribución conocida
C2	$ \Delta H_t > \Delta_c$	Perturbación entrópica: el campo de activaciones experimenta una variación de entropía significativa
C3	$\text{persistencia} \geq N_p$	Persistencia temporal: la perturbación no es transitoria; dura al menos N_p pasos, señal de reorganización estructural en curso

Definición TAGIS-1 – forma compacta

x_t es una **Excepción TAE** $\Leftrightarrow C1(x_t) \wedge C2(x_t) \wedge C3(x_t) = \text{Verdadero}$

La distinción respecto a un input OOD ordinario radica exclusivamente en C3: la condición de persistencia temporal de la perturbación entrópica, que es la firma observacional de una reorganización estructural discontinua en curso.

8. Referencias Comentadas

- Lee, K. et al. (2018). *A Simple Unified Framework for Detecting Out-of-Distribution Samples and Adversarial Attacks*. NeurIPS. – Formalización de la distancia de Mahalanobis para detección OOD; base directa para la condición C1 de TAGIS-1.
- Vyas, A. et al. (2022). *Out-of-Distribution Detection Using an Ensemble of Self Supervised Leave-out Classifiers*. ECCV. – Revisión de limitaciones de los métodos OOD estándar; motiva la necesidad de condiciones C2 y C3.
- Guo, C. et al. (2017). *On Calibration of Modern Neural Networks*. ICML. – Discusión sobre calibración adaptativa de umbrales en modelos profundos; referencia para el protocolo de calibración de §5.

- Kibble, T.W.B. (1976). *Topology of Cosmic Domains and Strings*. J. Phys. A. – Formalismo de formación de defectos topológicos en transiciones de fase; base del marco Kibble-Zurek en TAE-F2 y de la interpretación de la excepción TAE como bifurcación topológica local (§4.2).
- Killick, R. et al. (2012). *Optimal Detection of Changepoints With a Linear Computational Cost*. J. Am. Stat. Assoc. – Algoritmo PELT; base de STEP-TAE. La compatibilidad con TAGIS-1 se discute en §6.3.
- Friston, K. (2010). *The Free-Energy Principle: A Unified Brain Theory?*. Nature Reviews Neuroscience. – El principio de energía libre como marco unificador para la reorganización cognitiva; conecta TAGIS-1 con CPEA (§6.4): la perturbación entrópica de C2 es análoga a la sorpresa predictiva en el formalismo fristoniano.
- Kirkpatrick, J. et al. (2017). *Overcoming Catastrophic Forgetting in Neural Networks (EWC)*. PNAS. – El olvido catastrófico como patología del procesamiento de excepciones sin mecanismo de consolidación; el parámetro N_p puede calibrarse para discriminar entre excepciones que deben consolidarse y las que deben descartarse.