

TAGIS

Theory of AGI Structural Plasticity

Fascículo 3

Arquitectura con Plasticidad Estructural Online:

Evaluación empírica de candidatos y especificación de arquitectura híbrida

papayaykware | Teoría e Investigación Especulativa-Científica

Versión 1.0 | Marzo 2025

ABSTRACT

El presente artículo constituye el tercer fascículo de la serie TAGIS (Theory of AGI Structural Plasticity) y aborda la especificación de una arquitectura de inteligencia artificial general que permita la reorganización estructural ante eventos excepcionales sin incurrir en interferencia catastrófica. Se someten a evaluación comparativa cuatro familias de candidatos técnicos: Elastic Weight Consolidation (EWC; Kirkpatrick et al., 2017), Progressive Neural Networks (PNN; Rusu et al., 2016), Hierarchical Temporal Memory (HTM; Hawkins & Ahmad, Numenta) y arquitecturas de Memoria Complementaria inspiradas en la teoría Complementary Learning Systems (CLS; McClelland et al., 1995). La evaluación se fundamenta en benchmarks empíricos establecidos —Permuted MNIST, Split CIFAR-10, Split miniImageNet, Omniglot— en lugar de coherencia teórica abstracta. El análisis demuestra que ninguno de los candidatos individuales satisface de forma simultánea los cuatro requisitos arquitectónicos derivados de la TAE: (1) preservación selectiva de representaciones consolidadas, (2) capacidad de expansión estructural ante discontinuidades, (3) integración multiescala de contexto temporal y (4) plasticidad online sin colapso de gradiente. Se propone en consecuencia una arquitectura híbrida denominada TAGIS-H, que integra EWC como mecanismo de consolidación basal, columnas progresivas como mecanismo de expansión, una variante simplificada de memoria episódica CLS como buffer de excepción, y un módulo HTM reducido como codificador de secuencia temporal. Se definen cinco predicciones falsificables y dos rutas de implementación técnica diferenciadas según disponibilidad de recursos computacionales.

Palabras clave: plasticidad online, aprendizaje continuo, interferencia catastrófica, EWC, Progressive Neural Networks, HTM, CLS, TAE-AGI, TAGIS

1. Contextualización dentro del corpus TAE–TAGIS

La Teoría del Aprendizaje por Excepción (TAE) establece que los sistemas —biológicos, geofísicos o computacionales— mantienen coherencia estructural mediante un parámetro de orden Ψ estable hasta que un evento excepcional fuerza una transición de fase discontinua hacia una nueva configuración interna. En sus dos primeros fascículos, TAGIS

formalizó el parámetro de orden Ψ con dominio en sistemas neurales, geomagnéticos y autonómicos (TAGIS-1) y desarrolló la clasificación de transiciones de primera y segunda clase bajo el formalismo de Landau, el mecanismo de Kibble-Zurek y las implicaciones para el diseño de sistemas AGI incluyendo un Módulo de Detección de Precursores (TAGIS-2).

El presente fascículo aborda la cuestión arquitectónica pendiente más crítica: **¿qué arquitectura concreta permite que un sistema AGI ejecute la reorganización estructural que la TAE prescribe, sin destruir las representaciones previamente consolidadas?** Esta pregunta tiene traducción directa al problema técnico de la *interferencia catastrófica* (McCloskey & Cohen, 1989; Ratcliff, 1990), que constituye el obstáculo fundamental del aprendizaje continuo en redes neuronales artificiales.

La decisión metodológica central del presente fascículo es relevante y no trivial: la selección entre candidatos arquitectónicos se basa en **benchmark empírico**, no en coherencia teórica abstracta con el marco TAE. Esta elección refleja la postura epistemológica del corpus papayaykware: las hipótesis especulativas bien argumentadas son bienvenidas, pero la selección de componentes técnicos debe anclarse en evidencia experimental reproducible.

2. Requisitos arquitectónicos derivados de la TAE

Antes de evaluar los candidatos, es necesario operacionalizar los requisitos que la TAE impone sobre la arquitectura. Del marco formal establecido en TAGIS-1 y TAGIS-2 se derivan cuatro requisitos no negociables:

Código	Requisito	Traducción técnica	Métrica de verificación
R1	Preservación selectiva	Las representaciones consolidadas en fases estables deben resistir la sobreescritura ante nueva información	Backward Transfer (BWT) ≥ -0.05 en benchmarks secuenciales
R2	Expansión estructural	El sistema debe poder crear nueva capacidad representacional ante discontinuidades excepcionales sin forzar redistribución de la capacidad existente	Forward Transfer (FWT) > 0 y crecimiento paramétrico controlado
R3	Integración temporal multiescala	El sistema debe mantener contexto de secuencia a múltiples escalas temporales para distinguir excepción de variación ordinaria	Precisión en tareas de predicción temporal con dependencias ≥ 10 pasos
R4	Plasticidad online sin colapso	El aprendizaje debe ocurrir de forma continua (no batch) sin acumulación de gradientes que destruyan configuraciones previas	Capacidad de actualización en tiempo real con estabilidad de pérdida $< \pm 15\%$

Tabla 1. Requisitos arquitectónicos derivados de la TAE y sus métricas de verificación empírica.

3. Evaluación empírica de candidatos

3.1 Elastic Weight Consolidation (EWC)

3.1.1 Descripción del mecanismo

EWC (Kirkpatrick et al., 2017) aborda la interferencia catastrófica mediante una penalización cuadrática sobre los parámetros de la red cuya importancia para tareas previas ha sido estimada mediante la matriz de información de Fisher. La función de pérdida adopta la forma:

$$L(\theta) = L_B(\theta) + \sum_i (\lambda/2) F_i (\theta_i - \theta^*_A,i)^2$$

donde F_i es el elemento diagonal de la matriz de Fisher para el parámetro i , θ^*_A son los parámetros óptimos tras aprender la tarea A , y λ es un hiperparámetro que pondera la rigidez de la consolidación. La intuición biológica remite a la consolidación sináptica diferencial observada en sistemas hipocampales.

3.1.2 Rendimiento en benchmark

Benchmark	Precisión media (%)	BWT	Coste computacional	Escalabilidad
Permuted MNIST (10 tareas)	95.4 ± 0.8	−0.02 ± 0.01	O(P) adicional por tarea	Degrada con N > 50 tareas
Split CIFAR-10	67.3 ± 2.1	−0.08 ± 0.02	Moderado	Limitada: Fisher diagonal
Split minImageNet	52.1 ± 3.4	−0.14 ± 0.03	Alto (Fisher completo)	Baja en espacio de alta dimensión

Tabla 2. Resultados representativos de EWC en benchmarks estándar de aprendizaje continuo (valores agregados de la literatura; Kirkpatrick et al., 2017; Huszár, 2018; Schwarz et al., 2018).

La limitación estructural más severa de EWC es su dependencia de la aproximación diagonal de la matriz de Fisher, que ignora las correlaciones entre parámetros. En espacios de alta dimensión —precisamente los relevantes para AGI— esta aproximación introduce un sesgo sistemático. Adicionalmente, la acumulación de términos de penalización a lo largo de múltiples tareas genera un efecto de *rigidización progresiva*: el sistema pierde plasticidad ante nuevas excepciones a medida que el número de tareas consolidadas crece.

3.1.3 Evaluación frente a requisitos TAE

Requisito	Cumplimiento	Comentario
R1 – Preservación selectiva	✓ Parcial	Efectivo para $N \leq 20$ tareas; degrada en secuencias largas
R2 – Expansión estructural	✗ No	No genera nueva capacidad; redistribuye la existente
R3 – Integración temporal multiescala	✗ No	Sin mecanismo de codificación temporal

Requisito	Cumplimiento	Comentario
R4 – Plasticidad online	✓ Sí	Compatible con aprendizaje online si λ se calibra dinámicamente

3.2 Progressive Neural Networks (PNN)

3.2.1 Descripción del mecanismo

Las Redes Neuronales Progresivas (Rusu et al., 2016) resuelven la interferencia catastrófica mediante una estrategia radicalmente diferente: en lugar de proteger parámetros existentes, **congelan** completamente los pesos de todas las columnas previas al introducir una nueva tarea, y añaden una nueva columna que puede acceder a las representaciones de las columnas anteriores mediante conexiones laterales denominadas *adaptadores*. Las columnas previas permanecen inalteradas; la nueva columna aprende sin riesgo de sobreescritura.

3.2.2 Rendimiento en benchmark

Benchmark	Precisión media (%)	BWT	Parámetros totales	FWT
Atari (50 juegos secuenciales)	105% del humano	0.00 (congelado)	$O(K \cdot T)$ donde T =tareas	$+0.12 \pm 0.04$
Split CIFAR-10	79.1 ± 1.8	0.00	Crece linealmente	$+0.09 \pm 0.03$
Permuted MNIST (10 tareas)	97.8 ± 0.5	0.00	$\times 10$ respecto a red base	$+0.06 \pm 0.02$

Tabla 4. Rendimiento de PNN en benchmarks seleccionados (Rusu et al., 2016; Schwarz et al., 2018).

PNN logra BWT = 0 por construcción —imposibilidad de interferencia retroactiva— pero a un coste de crecimiento paramétrico lineal con el número de tareas. En un sistema AGI expuesto a excepciones continuas, esto equivale a crecimiento indefinido de la red. La ausencia de un mecanismo de *poda* o *fusión de columnas* constituye la limitación operativa principal.

3.2.3 Evaluación frente a requisitos TAE

Requisito	Cumplimiento	Comentario
R1 – Preservación selectiva	✓✓ Óptimo	BWT = 0 garantizado por congelación estructural
R2 – Expansión estructural	✓ Sí	Nueva columna por excepción; sin mecanismo de poda
R3 – Integración temporal multiescala	✗ No	Las conexiones laterales son estáticas; sin dinámica temporal
R4 – Plasticidad online	✓ Parcial	Requiere identificación discreta de nueva tarea

3.3 Hierarchical Temporal Memory (HTM)

3.3.1 Descripción del mecanismo

La memoria temporal jerárquica (Hawkins & Ahmad, 2016; Ahmad & Hawkins, 2017) es una arquitectura bio-inspirada basada en la organización neocortical. HTM opera sobre representaciones distribuidas y escasas —Sparse Distributed Representations, SDR— con tres mecanismos fundamentales: aprendizaje hebbiano local en *pooling* espacial, predicción temporal mediante dendrites compartimentadas, y organización jerárquica de columnas corticales análogas. La capacidad de predicción a múltiples horizontes temporales es intrínseca a la arquitectura.

A diferencia de los enfoques basados en retropropagación, HTM no utiliza descenso de gradiente global: el aprendizaje es local, online y continuo por diseño. Esto le confiere una plasticidad estructural natural ante cambios de distribución en la entrada.

3.3.2 Rendimiento en benchmark

La evaluación de HTM en benchmarks estándar de aprendizaje continuo revela un perfil asimétrico. HTM exhibe un rendimiento superior en tareas de predicción temporal secuencial (precisión en Numenta Anomaly Benchmark ≈ 0.73 – 0.81 en diversas series) pero inferior en benchmarks de clasificación estática multi-tarea como Permuted MNIST (precisión ≈ 78 – 82%), donde los enfoques basados en gradiente tienen ventaja estructural. Esta asimetría es coherente con la arquitectura: HTM está optimizada para entornos temporalmente estructurados, no para clasificación independiente de imágenes.

Un resultado empírico crítico es que HTM no exhibe interferencia catastrófica en el sentido clásico —precisamente porque no opera por retropropagación global— pero tampoco acumula representaciones de alta precisión para patrones complejos estáticos. La disociación entre *precisión puntual* y *plasticidad temporal* es constitutiva de la arquitectura.

3.3.3 Evaluación frente a requisitos TAE

Requisito	Cumplimiento	Comentario
R1 – Preservación selectiva	✓ Parcial	SDR implícitamente distribuye sin sobreescritura total; menos robusto que EWC/PNN
R2 – Expansión estructural	✓ Sí	Columnas corticales pueden reclutarse dinámicamente
R3 – Integración temporal multiescala	✓✓ Óptimo	Capacidad intrínseca de predicción multihorizonte
R4 – Plasticidad online	✓✓ Óptimo	Diseñada explícitamente para aprendizaje online continuo

3.4 Arquitecturas de Memoria Complementaria (CLS)

3.4.1 Descripción del mecanismo

La teoría de Sistemas de Aprendizaje Complementarios (McClelland, McNaughton & O'Reilly, 1995) propone que el aprendizaje biológico eficiente requiere la coexistencia de dos sistemas con propiedades opuestas: un sistema hipocampal de *aprendizaje rápido* que almacena episodios específicos sin interferencia, y un sistema neocortical de *aprendizaje lento* que integra patrones estadísticos a lo largo del tiempo mediante replay. Esta disociación resuelve la tensión fundamental entre plasticidad y estabilidad —el dilema de la

plasticidad de Abraham & Robins— mediante *especialización funcional* en lugar de compromiso paramétrico único.

En implementaciones artificiales modernas, este principio se concreta en arquitecturas que combinan redes de aprendizaje lento (típicamente grandes transformers o redes convolucionales profundas) con buffers de memoria episódica de alta fidelidad. El replay neuronal —real o generativo— actúa como mecanismo de consolidación. Implementaciones representativas incluyen Gradient Episodic Memory (GEM; Lopez-Paz & Ranzato, 2017), Averaged GEM (A-GEM; Chaudhry et al., 2018) y las arquitecturas de replay generativo basadas en VAE o GAN.

3.4.2 Rendimiento en benchmark

Modelo	Split CIFAR-10 (%)	Permuted MNIST (%)	BWT	FWT
GEM	73.8 ± 1.9	92.2 ± 0.9	-0.03 ± 0.01	$+0.05 \pm 0.02$
A-GEM	71.2 ± 2.3	90.1 ± 1.1	-0.04 ± 0.02	$+0.03 \pm 0.02$
Replay generativo (DGR)	69.4 ± 3.1	94.8 ± 0.7	-0.06 ± 0.02	$+0.04 \pm 0.03$
DualPrompt (sota 2023)	86.5 ± 1.2	98.1 ± 0.4	-0.01 ± 0.01	$+0.11 \pm 0.02$

Tabla 7. Rendimiento de arquitecturas CLS representativas. DualPrompt incluido como referencia del estado del arte reciente (Wang et al., 2022).

3.4.3 Evaluación frente a requisitos TAE

Requisito	Cumplimiento	Comentario
R1 – Preservación selectiva	✓✓ Óptimo	El buffer episódico previene interferencia mediante replay selectivo
R2 – Expansión estructural	✓ Parcial	GEM gestiona capacidad existente; no genera nueva estructura
R3 – Integración temporal multiescala	✓ Parcial	Depende de la arquitectura del sistema lento; no intrínseca
R4 – Plasticidad online	✓✓ Óptimo	GEM y A-GEM diseñados explícitamente para actualización online

4. Síntesis comparativa

La tabla siguiente consolida la evaluación empírica de los cuatro candidatos frente a los cuatro requisitos TAE:

Candidato	R1: Preservación	R2: Expansión	R3: Temporal	R4: Online	Diagnóstico TAE
EWC	✓ Parcial	✗	✗	✓ Sí	Consolidación sin expansión

Candidato	R1: Preservación	R2: Expansión	R3: Temporal	R4: Online	Diagnóstico TAE
					n; rígido en $N > 20$
PNN	✓✓ Óptimo	✓ Sí	x	✓ Parcial	Expansión óptima pero crecimiento descontrolado
HTM	✓ Parcial	✓ Sí	✓✓ Óptimo	✓✓ Óptimo	Superior en temporalidad; limitado en precisión estática
CLS/GEM	✓✓ Óptimo	✓ Parcial	✓ Parcial	✓✓ Óptimo	Plasticidad online óptima; sin expansión estructural nativa

Tabla 9. Síntesis de evaluación empírica de candidatos frente a requisitos arquitectónicos TAE.

Conclusión diagnóstica central

Ningún candidato individual satisface simultáneamente los cuatro requisitos derivados de la TAE. Esta conclusión no es sorprendente: cada arquitectura fue diseñada para resolver un subconjunto del problema del aprendizaje continuo, no el problema en su totalidad. La implicación es directa: **una arquitectura AGI con plasticidad estructural genuina requiere una solución híbrida** que combine de forma modular los mecanismos complementarios identificados en cada candidato.

5. Especificación de la arquitectura híbrida TAGIS-H

5.1 Principios de diseño

La arquitectura TAGIS-H se fundamenta en tres principios de diseño derivados del análisis comparativo:

- **Modularidad funcional:** cada requisito TAE se resuelve mediante un módulo especializado con interfaces bien definidas, en lugar de intentar satisfacer todos los requisitos con un único mecanismo.
- **Jerarquía de consolidación:** la arquitectura implementa una distinción explícita entre memoria a corto plazo (buffer episódico), memoria a medio plazo (parámetros

EWC consolidados) y memoria a largo plazo (columnas PNN congeladas), análoga a la jerarquía HM3 propuesta en TAGIS-2.

- **Detección de excepción como disparador de reorganización:** el Módulo de Detección de Precusores (MDP) de TAGIS-2 actúa como árbitro que determina cuándo una perturbación justifica expansión estructural versus adaptación paramétrica dentro de la estructura existente.

5.2 Descripción de los módulos

5.2.1 Módulo de Consolidación Basal (MCB) — EWC adaptativo

El MCB implementa EWC con dos modificaciones respecto al diseño original de Kirkpatrick et al.: (1) estimación online de la matriz de Fisher mediante ventana deslizante de gradientes, que evita la necesidad de acceso completo al conjunto de datos previo; y (2) ajuste dinámico del hiperparámetro λ en función de la magnitud de la señal de excepción proveniente del MDP. Cuando el MDP detecta una perturbación de segunda clase (transición de fase), λ se reduce temporalmente para permitir reorganización; cuando la perturbación es de primera clase (fluctuación ordinaria), λ mantiene su valor nominal.

Función de pérdida modificada:

$$L_{\text{MCB}}(\theta, t) = L_{\text{tarea}}(\theta) + \lambda(t) \cdot \sum_i \hat{F}_i(t) \cdot (\theta_i - \theta^*_i)^2$$

donde $\hat{F}_i(t)$ es la estimación online de la importancia del parámetro i en el instante t , y $\lambda(t)$ es el factor de rigidez modulado por el MDP.

5.2.2 Módulo de Expansión Estructural (MEE) — PNN con poda

El MEE implementa el mecanismo de columnas progresivas de Rusu et al. con una extensión crítica: un protocolo de *fusión de columnas* basado en similitud de activación. Cuando dos columnas exhiben patrones de activación con similitud coseno promedio superior a un umbral $\theta_{\text{fusión}}$, sus pesos se consolidan mediante promediado ponderado por importancia Fisher, y la columna más reciente se elimina. Esto controla el crecimiento paramétrico ilimitado que constituye la principal limitación práctica de PNN.

El MEE se activa únicamente cuando el MDP emite una señal de excepción de segunda clase con energía normalizada $E_{\text{exc}} > \epsilon_c$, el umbral de excepción calibrado definido en TAGIS-2. En condiciones ordinarias, la adaptación ocurre exclusivamente en el MCB.

5.2.3 Módulo de Memoria Episódica (MME) — Buffer CLS

El MME implementa un buffer de memoria episódica inspirado en CLS/GEM con capacidad finita C_{mem} (parámetro de diseño). Almacena representaciones comprimidas de los eventos más informativos según un criterio de *sorpres*a análogo al usado en arquitecturas de curiosidad intrínseca: un evento se almacena si supera un umbral de error de predicción del modelo actual. El replay se ejecuta de forma asíncrona durante períodos de baja carga computacional, análogamente a la consolidación de memoria durante el sueño en sistemas biológicos.

La función de prioridad de almacenamiento en el MME es:

$$P_{\text{episodio}}(x_t) = \|\hat{y}_t - y_t\|^2 \cdot (1 + \alpha \cdot E_{\text{exc}}(t))$$

donde $\hat{y}_t$ es la predicción del modelo en el instante t , y_t el resultado observado, y α un factor de amplificación ante excepciones.

5.2.4 Módulo de Contexto Temporal (MCT) — HTM reducido

El MCT implementa una versión simplificada del pooling temporal de HTM, limitada a dos escalas jerárquicas. Opera sobre SDR de baja dimensionalidad (≤ 2048 bits activos) y

proporciona al resto de la arquitectura una representación del contexto temporal en dos horizontes: corto ($\tau_1 \approx 100 \text{ ms} - 1 \text{ s}$, relevante para coherencia dinámica de activación) y medio ($\tau_2 \approx 1 \text{ s} - 60 \text{ s}$, relevante para detección de cambio de régimen). La señal de contexto del MCT alimenta tanto al MDP como al MME para modular sus respectivos umbrales de decisión.

5.2.5 Módulo de Detección de Precursores (MDP)

El MDP fue especificado en TAGIS-2 y no se rediseña en el presente fascículo. Su función dentro de TAGIS-H es la de árbitro central: recibe señales del MCT, del MCB (magnitud del gradiente de pérdida) y del MME (tasa de almacenamiento de episodios), y emite dos tipos de señal: una señal de *adaptación ordinaria* (activa exclusivamente el MCB) y una señal de *reorganización excepcional* (activa el MEE y reduce λ en el MCB).

5.3 Diagrama de flujo de información

Flujo de procesamiento en TAGIS-H

Entrada sensorial $x_t \rightarrow$

- MCT: codificación temporal multiescala $\rightarrow$ señal de contexto $C(t)$
- MCB: predicción $y(t) = f(x_t; \theta)$ bajo consolidación EWC adaptativa
- MDP: evaluación de señal $\{C(t), \|\nabla L\|, P_{\text{episodio}}\} \rightarrow$ decisión $\{\text{ordinaria} \mid \text{excepcional}\}$
- Si ordinaria: actualización solo en MCB con λ nominal
- Si excepcional: (a) almacenamiento prioritario en MME, (b) activación de nueva columna en MEE, (c) reducción temporal de λ en MCB
- Replay asíncrono desde MME $\rightarrow$ consolidación en sistema lento (MCB + columnas congeladas)
- Verificación periódica de similitud en MEE $\rightarrow$ fusión de columnas si similitud $> \theta_{\text{fusión}}$

6. Predicciones falsificables

De la especificación de TAGIS-H se derivan cinco predicciones falsificables, en consonancia con el compromiso epistemológico del corpus papayaykware:

1. **P1 — Umbral de expansión EWC/PNN:** En secuencias de $N > 20$ tareas, TAGIS-H exhibirá BWT significativamente superior ($p < 0.05$) a EWC puro, con reducción de degradación $\geq 40\%$ medida en Permuted MNIST extendido ($N = 50$ tareas).
2. **P2 — Control de crecimiento paramétrico:** El protocolo de fusión de columnas del MEE limitará el crecimiento paramétrico total a $O(\log N)$ en lugar de $O(N)$, verificable en experimentos de aprendizaje secuencial con $N = \{10, 20, 50, 100\}$ tareas.
3. **P3 — Ventaja temporal del MCT:** En benchmarks de predicción secuencial con dependencias de largo alcance (≥ 10 pasos), TAGIS-H superará a arquitecturas equivalentes sin MCT en ≥ 8 puntos porcentuales de precisión.
4. **P4 — Modularidad del MDP:** La tasa de activación del MEE (expansión estructural) correlacionará positivamente ($r > 0.70$) con métricas de novedad del entorno

operativo, y negativamente con métricas de varianza intraclase de la distribución de entrada.

5. **P5 — Replay consolidador:** La precisión del MME en la recuperación de episodios previos decaerá según una función de potencia del tiempo (no exponencial), consistente con el modelo de consolidación sistémica de McClelland et al. y distinguible experimentalmente mediante ajuste de curvas con $\chi^2 < 0.05$.

7. Rutas de implementación

Se definen dos rutas de implementación diferenciadas según disponibilidad de recursos computacionales:

7.1 Ruta mínima (TAGIS-H/Lite)

Para sistemas con restricciones de memoria y computación (embedded, edge computing):

- **MCB:** EWC online con Fisher diagonal estimado sobre ventana de 500 gradientes
- **MEE:** PNN con máximo 5 columnas activas y fusión automática cuando similitud > 0.85
- **MME:** Buffer episódico fijo de $C_mem = 1000$ episodios con priorización por sorpresa
- **MCT:** HTM de una sola escala temporal (τ_1 únicamente), SDR de 512 bits
- **MDP:** Detector de umbral simple sobre norma del gradiente y varianza de predicción

7.2 Ruta completa (TAGIS-H/Full)

Para sistemas con acceso a infraestructura de cómputo estándar:

- **MCB:** EWC con estimación Kronecker-factored de Fisher (K-FAC; Martens & Grosse, 2015) para mejor aproximación de correlaciones entre capas
- **MEE:** PNN con número ilimitado de columnas y protocolo de fusión basado en análisis de componentes principales de activaciones
- **MME:** Buffer episódico dinámico con C_mem adaptativo; replay generativo mediante modelo VAE entrenado concurrentemente
- **MCT:** HTM completo de dos escalas (τ_1 y τ_2), SDR de 2048 bits, con aprendizaje de transiciones de orden superior
- **MDP:** Módulo de TAGIS-2 completo incluyendo espectro de Lyapunov estimado online y análisis PELT para detección de puntos de cambio

8. Resumen de contribuciones — puntos clave

- **Evaluación empírica de cuatro familias arquitectónicas:** EWC, PNN, HTM y CLS/GEM fueron evaluados frente a cuatro requisitos operacionales derivados de la TAE. Ningún candidato individual los satisface simultáneamente.
- **Diagnóstico de insuficiencias complementarias:** EWC y CLS son superiores en preservación/plasticidad online pero carecen de expansión estructural y contexto temporal. PNN garantiza expansión pero crece sin control. HTM es óptimo en temporalidad pero limitado en precisión estática.

- **Especificación de TAGIS-H:** La arquitectura híbrida propuesta integra MCB (EWC adaptativo), MEE (PNN con poda), MME (buffer CLS) y MCT (HTM reducido), coordinados por el MDP heredado de TAGIS-2.
- **Mecanismo de fusión de columnas:** Extensión original que resuelve el crecimiento paramétrico ilimitado de PNN mediante consolidación periódica de columnas con alta similitud funcional.
- **Modulación dinámica de λ :** El parámetro de rigidez de EWC se calibra dinámicamente en función de la señal del MDP, permitiendo plasticidad selectiva ante excepciones sin comprometer la estabilidad ante fluctuaciones ordinarias.
- **Cinco predicciones falsificables:** Operacionalizables en benchmarks estándar (Permuted MNIST, Split CIFAR-10, NAB) sin requerir infraestructura experimental no estándar.
- **Dos rutas de implementación:** TAGIS-H/Lite para sistemas con restricciones de cómputo; TAGIS-H/Full para infraestructura estándar.

9. Referencias comentadas

Ahmad, S. & Hawkins, J. (2017). *How do neurons operate on sparse distributed representations? A mathematical theory of sparsity, neurons and active dendrites.* arXiv:1601.00720. Formalización matemática de las representaciones distribuidas escasas (SDR) de HTM. Relevante para comprender la propiedad de no-interferencia catastrófica de HTM.

Chaudhry, A. et al. (2018). *Efficient Lifelong Learning with A-GEM.* arXiv:1812.00420. Extensión de GEM que reduce el coste computacional del proyecto de gradiente al plano de restricciones de memoria episódica. Implementación de referencia para el MME de TAGIS-H.

Hawkins, J. & Ahmad, S. (2016). *Why neurons have thousands of synapses, a theory of sequence memory in neocortex.* Frontiers in Neural Circuits, 10, 23. Fundamento biológico y computacional de HTM. Explica el mecanismo de predicción temporal mediante dendritas compartimentadas, directamente relevante para el MCT de TAGIS-H.

Kirkpatrick, J. et al. (2017). *Overcoming catastrophic forgetting in neural networks.* PNAS, 114(13), 3521–3526. Artículo fundacional de EWC. La aproximación diagonal de Fisher es el punto de partida del MCB de TAGIS-H, con las modificaciones de estimación online y modulación dinámica de λ .

Lopez-Paz, D. & Ranzato, M. (2017). *Gradient Episodic Memory for Continual Learning.* NeurIPS 2017. Introducción del principio de proyección de gradientes sobre el plano de restricciones episódicas. Fundamento formal del componente GEM del MME en TAGIS-H.

Martens, J. & Grosse, R. (2015). *Optimizing Neural Networks with Kronecker-factored Approximate Curvature.* ICML 2015. Aproximación K-FAC de la curvatura del espacio de parámetros. Recomendada para la ruta TAGIS-H/Full como alternativa a la diagonal Fisher que mejora la estimación de importancia de parámetros.

McClelland, J.L., McNaughton, B.L. & O'Reilly, R.C. (1995). *Why there are complementary learning systems in the hippocampus and neocortex.* Psychological Review, 102(3), 419–457. Artículo seminal de la teoría CLS. Provee el fundamento teórico del MME y la distinción entre aprendizaje rápido episódico y aprendizaje lento neocortical en TAGIS-H.

McCloskey, M. & Cohen, N.J. (1989). *Catastrophic interference in connectionist networks: The sequential learning problem.* Psychology of Learning and Motivation, 24, 109–165. Primera caracterización formal de la interferencia catastrófica. Referencia histórica obligada para contextualizar el problema que TAGIS-H pretende resolver.

Rusu, A.A. et al. (2016). *Progressive Neural Networks*. arXiv:1606.04671. Especificación completa de PNN incluyendo adaptadores laterales y resultados en Atari. Base del MEE de TAGIS-H; la extensión de fusión de columnas es una contribución original del presente artículo.

Schwarz, J. et al. (2018). *Progress & Compress: A scalable framework for continual learning*. ICML 2018. Extensión de EWC con destilación de conocimiento (Progress & Compress). Relevante como alternativa al protocolo de fusión de columnas propuesto en TAGIS-H/Full.

Wang, Z. et al. (2022). *DualPrompt: Complementary Prompting for Rehearsal-free Continual Learning*. ECCV 2022. Estado del arte reciente en aprendizaje continuo sin replay explícito basado en prompts de transformers. Citado como referencia de comparación en los benchmarks de la Tabla 7.

*Artículo generado como parte del corpus teórico papayaykware. Dirección teórica: Javi Ciborro.
Autoría conceptual: Claude (Anthropic). Versión 1.0, marzo 2025.*