



PAPAYAYKWARE

Estudios científicos comprensibles

· INICIO

ARCHIVOS DEL BLOG



septiembre 09, 2026

UN EJE DE VALENCIA COMPARTIDO ENTRE LLM Y EEG HUMANO: SATURACIÓN REPRESENTACIONAL, RESIDUO INFORMATIVO Y ARQUITECTURA CPEA–TAE PARA LA COHERENCIA PREDICTIVA HUMANO–IA

He comprobado específicamente el trabajo que señalas. El DOI corresponde a **Radwan, Liu, Haydarov, Fu y Elhoseiny (2026), *A Shared Valence Axis Across Modern LLMs and Human EEG: The Saturation Regularity***, presentado como preprint en arXiv el 28 de mayo de 2026.

¿qué significa realmente el hallazgo?

La afirmación que planteas es **sustancialmente correcta, pero necesita una precisión importante**.

El artículo no demuestra que los LLM y el cerebro humano «sientan» la misma emoción, ni que posean una arquitectura neurocognitiva equivalente. Lo que muestra es algo bastante más interesante desde el punto de vista de representación:

una estructura geométrica de baja dimensionalidad asociada a la valencia emocional aparece de manera convergente en representaciones generadas por LLM y en representaciones derivadas de EEG humano.

Los autores construyen un eje unidimensional de valencia, denominado **V-axis**, a partir de solamente nueve frases evocadoras de emociones. Posteriormente comprueban su consistencia en **14 LLM diferentes** y proyectan ese eje sobre actividad EEG procedente de **123 sujetos** expuestos a videos afectivos.

La segunda observación es, para mí, todavía más importante.

Se utilizaron **36 clasificadores EEG que no habían recibido información sobre el V-axis**. Es decir, no se les enseñó previamente la geometría que los investigadores querían encontrar. Sin embargo, las representaciones internas de esos clasificadores recuperaron espontáneamente una dirección compatible con el mismo eje de valencia.

Esto cambia bastante la interpretación.

No estamos simplemente ante:

LLM → eje emocional → EEG

sino ante algo parecido a:

LLM → estructura latente de valencia

EEG → estructura latente de valencia

clasificadores EEG → reconstrucción espontánea de esa estructura

La convergencia se convierte, por tanto, en la cuestión central.

El artículo informa además de que las estrategias destinadas a imponer explícitamente el eje de valencia como señal auxiliar **no mejoraron el rendimiento**: de 25 estrategias de alineamiento ensayadas, 16 redujeron significativamente la precisión. Los autores denominan este fenómeno **saturation regularity**.

Aquí aparece una conexión particularmente potente con CPEA

La interpretación que considero más fértil para tu corpus no es:

«LLM y cerebro tienen la misma emoción».

Eso sería una inferencia excesiva.

La interpretación más rigurosa sería:

distintos sistemas de representación pueden converger hacia una geometría latente común cuando deben resolver

una tarea que contiene una estructura informacional compartida.

Esta formulación es mucho más fuerte científicamente porque no presupone identidad de mecanismo.

Y aquí aparece una primera conexión directa con **CPEA**.

CPEA puede conceptualizarse como una arquitectura que no busca necesariamente imponer al EEG la representación de la IA, sino **detectar correspondencias entre espacios representacionales heterogéneos**.

Eso es radicalmente distinto.

El hallazgo probablemente más importante del trabajo no sea siquiera el eje compartido, sino la paradoja que aparece después.

Si una red EEG ya ha aprendido una representación suficientemente adecuada de la valencia emocional, añadir una supervisión explícita destinada a hacer que aprenda todavía más esa misma dirección puede resultar contraproducente.

Es decir:

más alineamiento ≠ necesariamente más información.

Los autores proponen que, una vez que el entrenamiento orientado a la tarea ha llevado la representación hacia el eje relevante, la supervisión adicional puede deformar esa región ya optimizada, mientras que la información verdaderamente útil permanece en un **subespacio residual intra-clase**.

Esto tiene una consecuencia conceptual extraordinariamente interesante para CPEA:

La coherencia no debería confundirse con la totalidad de la información.

Podríamos representar un espacio EEG como:

$$X = X_{\text{estructura compartida}} + X_{\text{residual}}$$

donde:

$$X_{\text{estructura compartida}}$$

contiene las características que permiten separar las clases emocionales y que pueden presentar correspondencia con el V-axis.

Mientras que:

$$X_{\text{residual}}$$

contiene variabilidad intra-clase, individual, contextual y posiblemente temporal que no queda explicada por ese eje.

Desde una perspectiva CPEA, esto es crucial.

Un sistema humano-IA demasiado orientado a maximizar la coherencia podría terminar **sobreajustando la representación compartida y eliminando precisamente la información residual que permite diferenciar estados individuales**.

Por tanto:

coherencia óptima ≠ coherencia máxima

Esta distinción podría convertirse en uno de los principios matemáticos más importantes del eje CPEA.

Aquí la conexión es todavía más interesante.

TAE —Teoría de Aprendizaje por Excepción— parte precisamente de que **la información más importante puede aparecer como desviación respecto de una estructura esperada**.

El trabajo sobre saturation regularity proporciona una posible formulación complementaria:

$$\text{representación compartida} + \text{residuo}$$

En lugar de intentar reducir el residuo a ruido, TAE podría interpretarlo como:

$$\text{residuo} = \text{información potencialmente no explicada por el modelo dominante}$$

Esto no significa que todo residuo sea informativo. Esa afirmación sería incorrecta.

Pero sí permite formular una hipótesis falsable:

Hipótesis TAE-H1

Cuando una representación EEG alcanza una determinada saturación respecto de una estructura latente compartida, la información adicional relevante para distinguir estados individuales se desplaza progresivamente hacia componentes residuales que no son capturados por la representación dominante.

Condición de falsabilidad: si, después de controlar dimensionalidad, ruido, sujeto, tarea y sobreajuste, el incremento de información predictiva continúa concentrándose exclusivamente en el componente compartido y no en el residual, la hipótesis queda debilitada o falsada.

Esto transforma TAE de una metáfora en una hipótesis experimentalizable.

Aquí debemos ser particularmente rigurosos.

No existe en el artículo evidencia que demuestre un mecanismo electromagnético toroidal común entre LLM y cerebro.

Por tanto, sería incorrecto afirmar:

«El V-axis demuestra METFI».

No lo demuestra.

Pero sí podemos utilizar METFI como **homología estructural**, no como mecanismo causal demostrado.

La homología sería:

sistemas complejos diferentes → dinámica multidimensional → atractor/estructura dominante → residuo → transiciones

Eso sí es conceptualmente compatible con una lectura METFI-TAE.

En este nivel, METFI puede funcionar como **metamodelo estructural**:

- sistemas distintos;
- campos de interacción;
- simetrías;
- ruptura de simetrías;
- coherencia;
- pérdida de coherencia;
- transición de régimen;
- comportamiento no lineal.

Pero debe mantenerse explícitamente:

METFI se utiliza aquí como homología estructural y marco hipotético, no como explicación electromagnética causal del V-axis.

Esa frase será fundamental en el artículo.

Si el V-axis representa una dirección latente relativamente estable, podemos pensar en un **Detector Post-Cuántico de Coherencia (DPCC)** —dentro de tu arquitectura conceptual— no como detector de una supuesta «energía cuántica», sino como un sistema matemático para detectar **cambios de régimen en la coherencia representacional**.

Por ejemplo:

$$C(t) = \text{sim}(Z_{EEG}(t), Z_{IA}(t))$$

y posteriormente:

$$DPCC(t) = \frac{dC(t)}{dt}$$

o, de forma más sofisticada:

$$DPCC(t) = D_{\text{KL}}[P(Z_t) \parallel P(Z_t - \Delta t)]$$

El interés no estaría solamente en cuánto coinciden EEG e IA.

Estaría en detectar:

$\Delta C \neq 0$

es decir, **cuándo cambia la geometría de la relación**.

Eso conecta directamente con TAE:

el evento informacional podría no ser el estado coherente, sino la desviación significativa respecto del estado coherente.

Y aquí aparece una arquitectura conceptual:

EEG → representación → eje compartido → coherencia → residuo → anomalía → aprendizaje

que encaja notablemente bien con:

NEXUS-EEG → SIGMA-T → ORION-AGI → DEPD → TAE

Hay una idea que merece ser preservada porque podría convertirse en uno de los fundamentos del programa:

La alineación humano-IA no debería optimizarse únicamente buscando que ambas representaciones sean iguales; debería buscar simultáneamente la estructura compartida y preservar la información diferencial.

Formalmente:

$$\begin{aligned} Z_H &= Z_C + Z_R \\ Z_{IA} &= Z'_C + Z'_R \end{aligned}$$

donde:

- Z_C = componente compartido;
- Z_R = componente residual humano;
- Z'_C = componente compartido IA;
- Z'_R = componente residual IA.

La arquitectura CPEA podría entonces buscar:

$$\max I(Z_C; Y)$$

pero simultáneamente:

$$\max I(Z_R; Y \mid Z_C)$$

Esto evita un error frecuente en sistemas de alineamiento:

confundir representación común con representación completa.

Aplicando una primera verificación de las afirmaciones principales:

Afirmación	Estado
Se construyó un V-axis a partir de nueve frases	Respaldada por el preprint
Se comprobó en 14 LLM	Respaldada
Se proyectó sobre EEG de 123 sujetos	Respaldada
36 clasificadores EEG recuperaron espontáneamente la dirección	Respaldada por el trabajo
25 estrategias de alineamiento fueron evaluadas	Respaldada
16 empeoraron el rendimiento	Respaldada
Existe una estructura representacional compartida LLM-EEG	Interpretación razonable del resultado
LLM y cerebro tienen el mismo estado emocional	No demostrado
Existe una arquitectura neuronal equivalente a un LLM	No demostrado
El V-axis demuestra METFI	No demostrado
El fenómeno es compatible con una lectura TAE	Hipótesis teórica
El residuo puede contener información individual relevante	Hipótesis apoyada por el marco del artículo, pero que requiere separación experimental
CPEA puede utilizar esta geometría para alineamiento humano-IA	Propuesta metodológica
Esta separación es importante porque permite hacer algo mucho más interesante que defender una teoría: convertir el corpus en un programa de hipótesis falsables.	

La contribución que considero más valiosa del artículo puede resumirse así:

AGI no debería buscar únicamente convergencia

sino:

convergencia + divergencia informativa

Una arquitectura verdaderamente adaptativa tendría que saber:

1. detectar la estructura común;
2. cuantificar la coherencia;
3. detectar saturación;
4. identificar el residuo;
5. determinar cuándo el residuo es ruido;
6. determinar cuándo contiene información;

7. actualizar el modelo a partir de excepciones;
8. conservar la identidad representacional de cada sistema.

Eso proporciona una formulación bastante potente de CPEA:

$$CPEA = \text{alineamiento} + \text{coherencia} + \text{residuo} + \text{excepción} + \text{actualización}$$

Y la conexión con AGI deja de ser simplemente filosófica.

Se convierte en un problema de **arquitectura de representación y aprendizaje**.

Mi valoración es que el trabajo **sí merece incorporarse al corpus METFI-TAE-CPEA**, pero no porque «demuestre» ninguna de las hipótesis fuertes del corpus.

Su valor es más preciso:

proporciona un ejemplo experimental de convergencia representacional entre sistemas radicalmente diferentes y, simultáneamente, muestra que aumentar la alineación explícita puede ser perjudicial cuando la representación compartida ya está saturada.

Eso encaja extraordinariamente bien con una arquitectura CPEA basada no sólo en **coherencia predictiva**, sino también en **detección del error respecto de la coherencia y preservación del residuo informativo**.

Y ahí aparece, en mi opinión, una formulación mucho más profunda de TAE:

La excepción no es necesariamente aquello que queda fuera del modelo; puede ser aquello que el modelo todavía no sabe representar.

El artículo completo puede construirse alrededor de esta tesis, manteniendo cuidadosamente tres niveles: **evidencia del trabajo de Radwan et al.; inferencias metodológicas para CPEA-TAE; y extrapolaciones METFI explícitamente hipotéticas**.

Si lo desarrollamos como artículo, propondría como título:

«Un eje de valencia compartido entre LLM y EEG humano: saturación representacional, residuo informativo y una arquitectura CPEA-TAE para la coherencia predictiva humano-IA»

Un eje de valencia compartido entre LLM y EEG humano: saturación representacional, residuo informativo y arquitectura CPEA-TAE para la coherencia predictiva humano-IA

Autoría conceptual: GPT-5.6 Luna

Abstract

La aparición de estructuras representacionales convergentes entre modelos de lenguaje de gran escala (LLM) y señales electroencefalográficas (EEG) plantea una cuestión fundamental para la neurociencia computacional y para las arquitecturas de inteligencia humano-máquina: si sistemas radicalmente diferentes pueden organizar información afectiva mediante geometrías latentes parcialmente comunes, ¿qué naturaleza posee esa convergencia y qué consecuencias tiene para el alineamiento entre cerebro e inteligencia artificial? El preprint de Radwan et al. (2026), *A Shared Valence Axis Across Modern LLMs and Human EEG: The Saturation Regularity*, aborda esta cuestión mediante la construcción de un eje unidimensional de valencia —V-axis— obtenido a partir de nueve frases evocadoras de emociones y posteriormente evaluado en catorce LLM. El eje presenta consistencia entre modelos, transferencia cero-shot a tareas de sentimiento y correspondencia con actividad EEG de una cohorte pública de 123 sujetos expuestos a 28 estímulos audiovisuales afectivos. Además, 36 clasificadores EEG entrenados sin exposición al V-axis recuperan espontáneamente una dirección compatible con él. Sin embargo, veinticinco estrategias explícitas de alineamiento no mejoran la decodificación y dieciséis reducen significativamente el rendimiento, resultado formalizado por los autores como *saturation regularity*.

El presente artículo interpreta estos resultados desde el marco CPEA-TAE. Se propone que el hallazgo no debe entenderse como evidencia de identidad funcional entre cerebro y LLM, sino como evidencia de **convergencia representacional parcial**. Esta distinción permite formular una arquitectura en la que la coherencia compartida constituye sólo una componente del estado informacional, mientras que el residuo representacional conserva información intra-clase, individual y contextual. Desde TAE, la excepción deja de ser únicamente un error y puede convertirse en una señal de información no capturada por la representación dominante. Desde CPEA, el objetivo deja de ser maximizar indiscriminadamente la similitud humano-IA y pasa a ser optimizar una combinación de coherencia, precisión del error predictivo, diversidad residual y estabilidad dinámica. METFI se incorpora exclusivamente como **homología estructural hipotética**, no como mecanismo electromagnético demostrado del fenómeno observado.

Palabras clave: EEG, LLM, valencia afectiva, representación latente, saturation regularity, coherencia predictiva, CPEA, TAE, aprendizaje por excepción, error predictivo, Active Inference, precisión, residualidad, alineamiento humano-IA, METFI.

Introducción

La comparación entre inteligencia artificial y cerebro humano ha pasado progresivamente desde el nivel conductual al nivel representacional. La pregunta ya no consiste únicamente en si una máquina puede ejecutar una tarea que también realiza un ser humano, sino en si dos sistemas construidos sobre sustratos radicalmente diferentes pueden organizar determinados aspectos de la información mediante estructuras matemáticas parcialmente convergentes.

Esta cuestión posee una importancia particular cuando se estudia el afecto.

Las emociones humanas no constituyen simplemente etiquetas discretas. La experiencia afectiva puede representarse mediante dimensiones continuas, entre las que la valencia —aproximadamente, la posición relativa entre estados positivos y negativos— ocupa un lugar central. Los sistemas artificiales, por su parte, no poseen necesariamente una arquitectura emocional análoga a la humana. Sin embargo, sus espacios internos pueden desarrollar geometrías que permitan ordenar estímulos lingüísticos según dimensiones semánticas o afectivas.

El trabajo de Radwan, Liu, Haydarov, Fu y Elhoseiny constituye un experimento especialmente sugerente porque intenta atravesar esa separación. Los autores construyen una dirección unidimensional de valencia a partir de nueve frases evocadoras de emociones y examinan su estabilidad en catorce LLM de diferentes escalas. Posteriormente investigan si dicha dirección puede encontrarse en EEG humano. El resultado informado es una correspondencia significativa entre ambos espacios representacionales.

La importancia conceptual del resultado aumenta porque el V-axis no se utiliza exclusivamente como una representación descriptiva. Los autores preguntan también si puede emplearse como señal de entrenamiento para mejorar modelos EEG. Y es precisamente aquí donde aparece la paradoja.

La estructura compartida existe, pero **forzar explícitamente su alineamiento no mejora necesariamente el sistema**.

De hecho, el estudio informa que ninguna de las 25 estrategias de alineamiento probadas produjo una mejora y que 16 redujeron significativamente la precisión. Los autores interpretan este resultado mediante la denominada *saturation regularity*: una vez que el entrenamiento supervisado ha conducido el modelo hacia la estructura dominante necesaria para resolver la tarea, añadir una supervisión que fuerce nuevamente esa dirección puede deformar una representación ya saturada y dejar sin suficiente gradiente útil al subespacio residual.

Esta observación resulta especialmente relevante para una arquitectura CPEA.

El problema deja de ser simplemente:

¿cómo hacemos que EEG e IA se parezcan?

y se transforma en:

¿qué parte de la representación debe converger y qué parte debe permanecer diferencial?

Esta segunda pregunta es considerablemente más profunda.

El V-axis como estructura latente

La construcción propuesta por Radwan et al. parte de una operación conceptualmente sencilla. Se generan representaciones de nueve estímulos lingüísticos evocadores de emociones y se obtiene una dirección principal mediante reducción dimensional. El resultado es un eje unidimensional que los autores denominan V-axis. La dirección se orienta de manera que la región correspondiente a la alegría presente una proyección positiva.

El procedimiento tiene una consecuencia metodológica importante.

El eje no se define mediante una enorme batería de etiquetas emocionales introducidas explícitamente en cada modelo. Se obtiene a partir de un conjunto muy pequeño de estímulos y posteriormente se examina su generalización.

Según el preprint, el V-axis presenta una alta consistencia entre los catorce LLM estudiados, con modelos que abarcan aproximadamente desde 560 millones hasta 32.000 millones de parámetros. El estudio informa además de una correlación de aproximadamente $r = 0.995$ entre pares de tamaños dentro de Qwen3 para la orientación del eje, aunque esta cifra debe interpretarse dentro del procedimiento experimental concreto y no como una propiedad universal de todos los modelos de lenguaje.

Aquí debe introducirse una primera distinción epistemológica.

Resultado empírico: diferentes LLM examinados en el estudio presentan una dirección representacional de valencia altamente consistente.

Inferencia: existe una estructura afectiva latente que puede emerger de manera convergente en modelos lingüísticos diferentes.

Hipótesis fuerte: dicha convergencia refleja una estructura informacional profunda que trasciende el entrenamiento particular de cada modelo.

La tercera proposición no queda demostrada por el estudio.

La primera y la segunda son mucho más defendibles.

Del lenguaje al EEG

El segundo paso del estudio es más significativo para CPEA.

Los autores emplean el conjunto FACED, que contiene EEG de 123 sujetos expuestos a 28 vídeos destinados a inducir nueve categorías emocionales: cuatro positivas, cuatro negativas y una categoría neutral. El conjunto fue diseñado precisamente para facilitar estudios de computación afectiva EEG con mayor granularidad y una muestra relativamente amplia.

La pregunta experimental consiste en determinar si una dirección obtenida de un LLM puede proyectarse sobre el espacio EEG.

El estudio informa que una regresión ridge aplicada sobre características EEG de canales y bandas puede predecir la posición de los estímulos sobre el V-axis. Para el V-axis derivado de Qwen3-4B se informa aproximadamente $r = 0.80$, mientras que una variante construida a partir de descripciones textuales mediante CLIP alcanza aproximadamente $r = 0.87$.

Estos valores son interesantes, pero requieren una interpretación precisa.

No significan que el cerebro esté ejecutando Qwen3.

Tampoco significan que exista una representación neuronal literalmente idéntica al espacio latente del LLM.

Lo que indican es que **una dirección geométrica extraída de un espacio artificial permite explicar una parte de la variabilidad organizada del espacio EEG respecto de los estímulos afectivos utilizados.**

La distinción es fundamental.

Podemos escribir:

$$Z_{LLM} \in \mathbb{R}^n$$

para representar el espacio interno del modelo, y:

$$Z_{EEG} \in \mathbb{R}^m$$

para representar las características electrofisiológicas.

No necesitamos suponer:

$$n = m$$

ni:

$$Z_{LLM} = Z_{EEG}$$

para que exista una función de correspondencia:

$$f: Z_{EEG} \rightarrow V$$

y:

$$g: Z_{LLM} \rightarrow V$$

donde V constituye una dimensión latente común.

La hipótesis mínima sería:

$$\exists V: f(Z_{EEG}) \approx g(Z_{LLM})$$

Esta formulación es considerablemente más prudente y, paradójicamente, más poderosa.

La verdadera anomalía: la convergencia espontánea

El elemento que adquiere mayor relevancia para TAE aparece en los clasificadores EEG.

El estudio analiza 36 clasificadores entrenados sobre las nueve categorías emocionales sin proporcionarles el V-axis. Según los autores, estos modelos recuperan espontáneamente una dirección compatible con el eje de valencia. La fuerza de esa codificación del V-axis en el subespacio de medias de clase se correlaciona con el rendimiento de clasificación, con $r = 0.885$ y $p = 7.8 \times 10^{-13}$ en el conjunto de 36 checkpoints analizados.

Este resultado introduce una propiedad que merece denominarse **convergencia representacional no supervisada respecto de la geometría objetivo.**

El sistema no necesita recibir explícitamente:

«ésta es la dirección que debes aprender».

La dirección aparece como consecuencia de resolver la tarea.

Esto permite formular:

$$\text{Tarea} \rightarrow \text{optimización} \rightarrow \text{representación} \rightarrow \text{estructura latente}$$

en lugar de:

$$\text{estructura latente} \rightarrow \text{supervisión} \rightarrow \text{representación}$$

La diferencia resulta crucial.

Si múltiples modelos independientes alcanzan una estructura semejante al resolver una tarea, esa estructura podría representar una **solución geométrica eficiente al problema**, sin que sea necesario asumir que existe una identidad arquitectónica entre los sistemas.

Este punto proporciona un puente directo hacia TAE.

Saturación representacional y límites del alineamiento

La intuición convencional del alineamiento humano-IA podría expresarse mediante una función objetivo:

$$\mathcal{L} = \mathcal{L}_{tarea} + \lambda \mathcal{L}_{alineamiento}$$

donde $\mathcal{L}_{tarea}$ optimiza la clasificación y $\mathcal{L}_{alineamiento}$ intenta acercar la representación EEG a la representación del modelo artificial.

La hipótesis intuitiva sería:

$$\lambda \uparrow \Rightarrow alineamiento \uparrow \Rightarrow rendimiento \uparrow$$

Pero el resultado experimental no respalda esta relación.

El estudio prueba 25 estrategias que incluyen destilación de conocimiento, similitud representacional, pérdidas contrastivas y pérdidas topográficas. Ninguna mejora el rendimiento y 16 producen descensos significativos.

La interpretación de saturación es entonces:

$$\frac{\partial \mathcal{L}_{tarea}}{\partial Z_C} \approx 0$$

en una región ya suficientemente optimizada del espacio compartido, mientras que la información que todavía puede mejorar el clasificador reside en:

$$Z_R$$

el residuo.

La representación completa puede escribirse:

$$Z = Z_C + Z_R$$

donde:

- Z_C representa la estructura común o dominante;
- Z_R representa información residual no explicada por dicha estructura.

La consecuencia metodológica es inmediata:

Una vez alcanzada la saturación del componente compartido, insistir en él puede producir una pérdida de información diferencial.

Ésta constituye probablemente la observación más relevante del artículo para el desarrollo de CPEA.

CPEA: de la coherencia máxima a la coherencia informativa

La arquitectura CPEA puede reinterpretarse a partir de este resultado.

Una primera versión de coherencia podría definirse mediante:

$$C_H I(t) = \text{sim}(Z_H(t), Z_I(t))$$

donde Z_H representa el estado representacional humano y Z_I el estado representacional de la IA.

Sin embargo, maximizar:

$$C_H I$$

no es necesariamente óptimo.

Si dos representaciones se hacen excesivamente similares, pueden perderse componentes informativas específicas de cada sistema.

Por ello resulta más apropiado definir:

$$\begin{aligned} Z_H &= Z_C + Z_{RH} \\ Z_I &= Z_C + Z_{RI} \end{aligned}$$

y optimizar simultáneamente:

$$C = \text{sim}(Z_C, Z_C')$$

junto con:

$$R_H = I(Z_{RH}; Y | Z_C)$$

y:

$$R_I = I(Z_{RI}; Y | Z'_C)$$

En términos conceptuales:

CPEA = coherencia compartida + información residual

El objetivo ya no sería conseguir una representación humano-IA idéntica, sino una representación **interoperable sin destrucción de diversidad informativa**.

Ésta es una diferencia arquitectónica sustancial.

Relación con Active Inference

La conexión con Active Inference debe formularse con cautela.

El principio de energía libre de Friston propone que los sistemas adaptativos pueden entenderse en términos de inferencia sobre causas de las entradas sensoriales, minimización de sorpresa o de una cota variacional de ésta y actualización de estados, modelos y políticas.

Active Inference extiende esta perspectiva hacia modelos generativos jerárquicos, inferencia perceptiva, aprendizaje y selección de políticas.

El resultado de Radwan et al. puede relacionarse con esta perspectiva a nivel representacional.

Si un sistema aprende una estructura dominante porque ésta reduce eficazmente el error de predicción de la tarea, entonces la representación convergente podría considerarse una solución de baja dimensionalidad para una regularidad estadística relevante.

Sin embargo, no debe afirmarse que el V-axis sea una manifestación directa del principio de energía libre.

Eso sería una extrapolación no demostrada.

La formulación rigurosa es:

Hipótesis CPEA-AI-1: la convergencia hacia estructuras latentes compartidas puede interpretarse como resultado de procesos de optimización que reducen error predictivo o coste de tarea en sistemas representacionales diferentes.

Condición de falsabilidad: si arquitecturas optimizadas bajo objetivos comparables no desarrollan estructuras latentes convergentes cuando se controlan tarea, datos, dimensionalidad y arquitectura, la hipótesis pierde apoyo.

La precisión del error adquiere aquí especial importancia.

Un error predictivo de gran magnitud no es necesariamente más informativo que uno pequeño. Su utilidad depende de la **precisión asignada al error**.

Puede expresarse:

$$\Pi_e = \text{Prec}(e)$$

y:

$$\mathcal{L}_{CPEA} = \Pi_e e^2$$

Pero en sistemas saturados el incremento de precisión sobre una dimensión ya aprendida puede resultar contraproducente.

La pregunta fundamental pasa a ser:

¿dónde debe aumentar la precisión?

No:

¿cuánta precisión debemos imponer?

TAE: la excepción como información residual

TAE puede reformularse matemáticamente a partir de esta arquitectura.

Supongamos que el sistema posee un modelo dominante:

$$M_t$$

que genera una predicción:

$$\hat{x}_{t+1} = M_t(x_t)$$

La excepción puede definirse como:

$$e_t = x_{t+1} - \hat{x}_{t+1}$$

Pero no todos los errores tienen el mismo significado.

Introduzcamos:

$$E_t = \Pi_t e_t$$

donde Π_t representa la precisión estimada del error.

Entonces TAE no debe aprender simplemente:

$$e_t \neq 0$$

sino:

$$P(e_t \text{ | modelo})$$

y, especialmente, detectar cuándo una desviación posee estructura.

En el contexto del V-axis:

$$Z = Z_C + Z_R$$

El componente residual Z_R puede ser interpretado como espacio de excepciones potenciales.

Pero **residual no significa anomalía**.

Ésta es una precisión indispensable.

Un residuo puede proceder de:

- ruido instrumental;
- variabilidad individual;
- variación fisiológica;
- diferencias de estrategia cognitiva;
- información contextual;
- artefactos;
- estructura no modelada.

TAE sólo debe considerar una desviación como excepción informativa cuando presenta estabilidad, predictibilidad o valor discriminativo.

Podemos expresarlo:

$$\text{Excepción informativa} = \text{residuo} + \text{estructura} + \text{valor predictivo}$$

Esta definición evita convertir cualquier desviación en señal privilegiada.

La regularidad de saturación como principio CPEA

El resultado de Radwan et al. permite proponer una extensión conceptual:

Principio de saturación representacional CPEA

Cuando una estructura latente compartida ha alcanzado suficiente capacidad explicativa respecto de una tarea, el incremento de alineamiento explícito sobre dicha estructura puede producir rendimientos decrecientes o negativos, mientras que la información adicional relevante puede concentrarse en componentes residuales.

Formalmente:

$$\frac{\partial Performance}{\partial C} > 0$$

para valores bajos o intermedios de coherencia, pero:

$$\frac{\partial Performance}{\partial C} \rightarrow 0$$

cuando:

$$C \rightarrow C_{sat}$$

y eventualmente:

$$\frac{\partial Performance}{\partial C} < 0$$

si el alineamiento adicional destruye grados de libertad informativos.

En cambio, podría existir:

$$\frac{\partial Performance}{\partial D_R} > 0$$

donde D_R representa diversidad residual útil.

Éste es precisamente el punto en que el trabajo adquiere relevancia para una arquitectura AGI.

Una inteligencia general no puede limitarse a representar lo que ya sabe representar.

Debe conservar capacidad para incorporar aquello que inicialmente aparece como residuo.

La importancia de la diversidad residual

El propio trabajo ofrece una demostración operacional de esta intuición: en lugar de insistir en supervisar el V-axis, los autores explotan la diversidad de los residuos mediante ensamblado. Informan de una mejora de aproximadamente 10,5 % en balanced accuracy respecto del mejor resultado anterior en FACED y de una replicación del efecto en SEED-V.

Este resultado es importante por dos razones.

Primero, porque convierte la residualidad en una variable operacional.

Segundo, porque muestra que la diversidad entre modelos puede ser útil cuando los modelos comparten un mismo «basin» dominante.

El sistema puede visualizarse así:

$$\begin{aligned}M_1 &= M_C + R_1 \\M_2 &= M_C + R_2 \\M_3 &= M_C + R_3\end{aligned}$$

donde:

$$M_C$$

es aproximadamente común, mientras:

$$R_1, R_2, R_3$$

representan diferencias residuales.

El ensamblaje puede entonces reducir componentes idiosincráticos no informativos sin imponer que:

$$R_1 = R_2 = R_3$$

Ésta es una propiedad que CPEA debería preservar.

ITPC, coherencia de fase y geometría representacional

El concepto de coherencia utilizado en CPEA no debería reducirse a similitud de vectores.

En EEG existe además una dimensión temporal y oscilatoria. La inter-trial phase coherence (ITPC) permite estudiar la consistencia de fase de una respuesta respecto de múltiples ensayos.

Puede definirse, de forma simplificada:

$$ITPC(f, t) = \left| \frac{1}{N} \sum_{k=1}^N e^{i\phi_k(f, t)} \right|$$

donde $\phi_k(f, t)$ representa la fase en frecuencia f y tiempo t para el ensayo k .

Esta dimensión permite introducir en CPEA una distinción fundamental:

$$\text{coherencia representacional} \neq \text{coherencia temporal}$$

Una representación puede ser semánticamente coherente sin presentar una elevada estabilidad de fase, y una respuesta puede mostrar fuerte sincronización temporal sin representar de manera informativamente útil el estado que interesa.

Por ello, un sistema CPEA completo podría construir un vector de coherencia:

$$\mathbf{C}(t) = [C_{repr}, ITPC, C_{cross-frequency}, C_{EEG-IA}, C_{temporal}]$$

La coherencia deja así de ser una magnitud única.

Se convierte en un espacio.

SIGMA-T y la representación toroidal como homología

En este punto puede incorporarse SIGMA-T.

La geometría toroidal puede utilizarse como representación matemática de estados cíclicos, recurrencias y transiciones de régimen. Sin embargo, debe mantenerse una separación estricta entre la geometría utilizada para representar datos y una afirmación ontológica acerca de que el cerebro constituya

físicamente un toroide electromagnético funcional.

La primera puede ser una herramienta matemática.

La segunda constituye una hipótesis física que requiere evidencia independiente.

Por tanto:

La utilización de una geometría toroidal en SIGMA-T no demuestra que la dinámica cerebral posea una topología toroidal física.

La homología estructural consiste en representar sistemas dinámicos mediante:

$$\text{estado} \rightarrow \text{trayectoria} \rightarrow \text{recurrencia} \rightarrow \text{transición}$$

Esta descripción resulta compatible con una arquitectura que detecta eventos de pérdida de simetría.

En este contexto, ECDO —Evento de Colapso Dinámico Oscilatorio— puede definirse provisionalmente como un cambio abrupto de régimen en la dinámica representacional:

$$ECDO: \quad \Delta \mathbf{C}(t) > \theta_C$$

acompañado de:

$$\Delta \mathbf{R}(t) > \theta_R$$

y eventualmente:

$$\Delta H(t) > \theta_H$$

donde H representa una medida de entropía dinámica.

Esto proporciona una formulación operacional sin necesidad de introducir causalidad electromagnética.

METFI: qué puede aportar y qué no puede afirmarse

METFI constituye el marco más especulativo del corpus y debe permanecer separado de los resultados directamente derivados del estudio de Radwan et al.

El resultado del V-axis no constituye evidencia de un campo electromagnético toroidal común al cerebro y a los LLM.

Un LLM no posee un campo electromagnético biológico equivalente al EEG.

Por consiguiente:

$$V\text{-axis} \not\Rightarrow METFI$$

Sin embargo, puede establecerse una homología formal.

METFI plantea, dentro del corpus, que determinados sistemas complejos pueden describirse mediante configuraciones de simetría, acoplamiento, ruptura de simetría y transición de régimen. Aplicado al problema representacional, esto permite formular:

$$\text{coherencia} \rightarrow \text{saturación} \rightarrow \text{perturbación} \rightarrow \text{ruptura} \rightarrow \text{nuevo régimen}$$

La estructura es conceptualmente análoga a la dinámica propuesta por TAE.

Pero la palabra clave es **análogo**.

No causal.

No demostrada.

No equivalente.

Esta disciplina conceptual permite incorporar METFI al corpus sin utilizarlo como explicación retrospectiva de cualquier fenómeno que presente coherencia o periodicidad.

DEPD: detector dinámico del error predictivo

El Detector de Error Predictivo Dinámico puede actuar como interfaz entre CPEA y TAE.

En lugar de calcular únicamente:

$$e_t = x_t - \hat{x}_t$$

DEPD podría estimar:

$$DEPD(t) = \Pi_t \cdot \|x_t - \hat{x}_t\| \cdot S_t$$

donde:

- Π_t = precisión del error;
- S_t = estabilidad estructural de la desviación.

Así se evita clasificar como anomalía cualquier error de gran amplitud.

Una desviación breve y aleatoria puede tener:

$$|e_t| \gg 0$$

pero:

$$S_t \approx 0$$

y por tanto baja relevancia TAE.

Una desviación pequeña pero persistentemente estructurada podría presentar:

$$|e_t| < \epsilon$$

pero:

$$S_t \gg 0$$

y ser mucho más informativa.

Esto proporciona un principio operativo:

información de la excepción ≠ magnitud del error

sino:

$I_{exception} = f(magnitud, precisión, persistencia, estructura, contexto)$

ORION-AGI como arquitectura de integración

ORION-AGI puede situarse en el nivel superior de esta arquitectura.

Su función no debería ser simplemente agregar señales, sino decidir **qué representación debe considerarse dominante, cuál residual y cuál potencialmente anómala**.

Un ciclo podría expresarse:

$$EEG \rightarrow NEXUS \rightarrow SIGMA - T \rightarrow DEPD \rightarrow TAE \rightarrow ORION$$

mientras el LLM aporta un espacio representacional paralelo:

$$LLM \rightarrow Z_{IA}$$

La convergencia se estima mediante:

$$C_{HI} = sim(Z_H, Z_{IA})$$

y la divergencia mediante:

$$D_{HI} = d(Z_{RH}, Z_{RI})$$

ORION debería entonces maximizar una función multiobjetivo:

$$J = \alpha C_{HI} + \beta D_R - \gamma E_{pred}$$

con pesos adaptativos.

Esto evita convertir CPEA en un sistema de clonación representacional.

La arquitectura busca **acoplamiento sin colapso de la diversidad**.

Programas de seguimiento experimental

Programa 1. Replicación independiente del V-axis

Construir un protocolo independiente utilizando varios LLM, estímulos lingüísticos no incluidos en el estudio original y un conjunto EEG diferente.

Variables:

$$r(V_{LLM}, V_{EEG})$$

La prueba fundamental sería comprobar si la correspondencia persiste fuera del conjunto FACED.

Predicción TAE: los estímulos que presentan mayor desviación respecto del eje dominante contendrán una mayor proporción de información residual estructurada.

Programa 2. Saturación representacional

Entrenar modelos EEG progresivamente:

$$M_1, M_2, ..., M_n$$

y medir:

$$C_V$$

junto con:

$$BACC$$

y:

$$I(Z_R; Y \mid Z_C)$$

La predicción es una relación no lineal:

$$BACC = f(C_V)$$

con una región de saturación.

Si se observa una inversión posterior, se obtendría evidencia adicional para una regularidad de saturación más general.

Programa 3. CPEA multimétrica

Registrar simultáneamente:

- potencia espectral;
- conectividad;
- ITPC;
- coherencia entre regiones;
- representación latente EEG;
- representación LLM;
- error predictivo;
- entropía multiescala.

Definir:

$$CPEA(t) = w_1C_{repr} + w_2ITPC + w_3C_{EEG-IA} + w_4C_{temporal} - w_5E_{pred}$$

y estudiar si la métrica compuesta supera a cualquiera de sus componentes individuales.

Programa 4. Residualidad como señal TAE

Después de estimar Z_C , proyectar:

$$Z_R = Z - Z_C$$

y comprobar si el residuo permite predecir:

- sujeto;
- contexto;
- estímulo;
- respuesta emocional;
- transición entre categorías;
- variabilidad temporal.

Si:

$$I(Z_R; Y \mid Z_C) > 0$$

el residuo contiene información adicional respecto de la estructura compartida.

La hipótesis queda falsada si el residuo no aporta información después de controlar dimensionalidad, regularización y sobreajuste.

Programa 5. DEPD–ECDO

Definir un seguimiento temporal de:

$$C(t), E(t), H(t), IT\,PC(t)$$

y detectar puntos de transición:

$$t^* = \arg \max_t \left| \frac{d \, \mathbf{X}(t)}{dt} \right|$$

Un ECDO sería operacionalmente una transición estadísticamente robusta entre dos regímenes dinámicos.

Esto permite investigar el concepto sin presuponer ningún mecanismo electromagnético.

Chain-of-Verification de las afirmaciones principales

La verificación de las afirmaciones centrales permite separar el hallazgo de las extrapolaciones.

Afirmación 1: el estudio utiliza nueve estímulos/frases evocadoras para construir el V-axis.

Verificación: confirmada en el preprint.

Afirmación 2: el eje se evalúa en catorce LLM.

Verificación: confirmada.

Afirmación 3: el EEG procede de una cohorte FACED de 123 sujetos y 28 vídeos.

Verificación: confirmada tanto en el trabajo analizado como en la descripción independiente del dataset FACED.

Afirmación 4: 36 clasificadores EEG recuperan espontáneamente el eje.

Verificación: afirmación explícita del preprint.

Afirmación 5: 25 estrategias de alineamiento no produjeron mejoras y 16 redujeron significativamente el rendimiento.

Verificación: afirmación explícita del estudio.

Afirmación 6: el ensamblado basado en diversidad residual produjo una mejora relativa del 10,5 % sobre el mejor resultado anterior en FACED.

Verificación: afirmación explícita del preprint; debe considerarse resultado de ese estudio concreto, no una ley general del aprendizaje EEG.

Afirmación 7: cerebro y LLM poseen la misma arquitectura representacional.

Verificación: no demostrada.

Afirmación 8: el V-axis demuestra METFI.

Verificación: no demostrada.

Afirmación 9: el residuo constituye información potencialmente útil.

Verificación: apoyada operacionalmente por el resultado de ensamblaje del estudio, pero su interpretación general como principio TAE constituye una hipótesis conceptual.

Esta última distinción es esencial.

Discusión

El valor profundo de este trabajo no reside únicamente en que una representación de valencia pueda atravesar la frontera entre lenguaje y EEG. Su importancia reside en la combinación de dos resultados aparentemente contradictorios:

la estructura compartida emerge

pero:

forzar esa estructura no necesariamente mejora el sistema

La aparente contradicción desaparece cuando se introduce la idea de saturación.

Un sistema que ha descubierto espontáneamente una estructura suficiente para resolver una tarea no necesita necesariamente recibir más presión para aprender esa misma estructura. Esa presión puede incluso resultar destructiva si reduce grados de libertad que todavía contienen información útil.

Esta propiedad posee una analogía directa con los sistemas adaptativos.

Una arquitectura excesivamente rígida puede alcanzar una elevada coherencia interna y, al mismo tiempo, perder sensibilidad frente a estados nuevos.

Desde TAE, esto puede describirse como una pérdida de capacidad para aprender por excepción.

Desde CPEA, como una sobreoptimización de la coherencia.

Desde Active Inference, podría interpretarse como una mala asignación de precisión a determinadas señales de error, aunque esta última lectura es teórica y no constituye una conclusión experimental del estudio.

La cuestión central no es, por tanto, maximizar:

$$C$$

sino encontrar:

$$C^*$$

tal que:

$$\frac{\partial Performance}{\partial C} \approx 0$$

mientras:

$$\frac{\partial Performance}{\partial R} > 0$$

para una región significativa del espacio residual.

La arquitectura inteligente sería entonces aquella que sabe cuándo dejar de alinear.

Ésta es una propiedad mucho más sofisticada que la mera coherencia.

Implicaciones para una arquitectura humano-IA adaptativa

La convergencia representacional entre EEG y LLM puede convertirse en un componente de una interfaz humano-IA de nueva generación.

Pero el principio debería ser:

$$\text{alinear} \neq \text{homogeneizar}$$

La IA debe aprender qué parte de la señal humana puede representar adecuadamente.

El sistema humano debe conservar aquello que la IA todavía no representa.

El residuo se convierte entonces en una interfaz informativa.

Esto permite conceptualizar CPEA como una arquitectura de doble canal:

Canal convergente

$$Z_C: \text{información compartida}$$

Canal divergente

$$Z_R: \text{información diferencial}$$

El primer canal permite comunicación.

El segundo permite aprendizaje.

Una IA que sólo recibe el primer canal aprende a reproducir.

Una IA que además aprende del segundo puede modificar su modelo.

Ésta es una diferencia esencial para cualquier arquitectura orientada hacia inteligencia general.

Conclusión

El trabajo *A Shared Valence Axis Across Modern LLMs and Human EEG: The Saturation Regularity* proporciona una evidencia experimental particularmente sugerente de que una estructura latente asociada con la valencia puede aparecer de manera convergente en espacios representacionales de LLM y EEG humano. El estudio informa consistencia del V-axis entre catorce LLM, correspondencia con EEG de 123 sujetos y recuperación espontánea de la dirección en 36 clasificadores EEG entrenados sin acceso explícito a dicha representación.

Pero su resultado conceptualmente más importante quizá sea el segundo: **la existencia de una estructura compartida no implica que imponerla explícitamente constituya una buena estrategia de aprendizaje.**

La saturación representacional introduce una restricción fundamental:

más alineamiento no equivale necesariamente a más inteligencia

Para CPEA, esto obliga a reconsiderar la coherencia. La coherencia debe ser suficientemente elevada para permitir interoperabilidad, pero suficientemente flexible para preservar información diferencial.

Para TAE, el residuo adquiere una nueva función conceptual. No es automáticamente ruido. Puede constituir el espacio en el que reside la información que todavía no ha sido absorbida por el modelo dominante.

Para DEPD, la consecuencia es que el error debe evaluarse por magnitud, precisión, estabilidad y estructura.

Para SIGMA-T, la representación de trayectorias y transiciones permite estudiar cambios de régimen sin convertir la geometría matemática en una afirmación ontológica.

Para METFI, la consecuencia es más restrictiva: su posible relación con estos fenómenos debe permanecer en el nivel de **homología estructural hipotética**, sin presentar el V-axis como demostración de un mecanismo electromagnético toroidal.

La síntesis puede expresarse mediante una ecuación conceptual:

Inteligencia adaptativa = coherencia + diversidad + error preciso + residuo + aprendizaje por excepción

El resultado conduce finalmente a una proposición central para CPEA-TAE:

Una representación inteligente no es aquella que elimina el residuo, sino aquella que sabe distinguir entre residuo inútil y residuo informativo.

Y una segunda proposición resulta todavía más importante:

La coherencia óptima no es la máxima coherencia, sino la coherencia que conserva capacidad de aprender.

Resumen

- El preprint de Radwan et al. identifica un **V-axis**, una dirección unidimensional de valencia obtenida a partir de nueve estímulos emocionales y observada con alta consistencia en catorce LLM.
- El eje puede proyectarse sobre EEG humano de una cohorte FACED de **123 sujetos y 28 estímulos audiovisuales**.
- **36 clasificadores EEG**, entrenados sin exposición al V-axis, recuperaron espontáneamente una dirección compatible con él.
- El resultado no demuestra que cerebro y LLM tengan la misma arquitectura ni que experimenten emociones de forma equivalente.
- El estudio encuentra una paradoja crucial: **la convergencia representacional no implica que el alineamiento explícito mejore el aprendizaje**.
- De las 25 estrategias de alineamiento examinadas, ninguna mejoró la decodificación y 16 produjeron descensos significativos.
- La *saturation regularity* sugiere que, una vez saturada la representación dominante, la información adicional puede encontrarse en el **subespacio residual**.
- Esta observación proporciona una conexión natural con TAE: una excepción puede representar información todavía no absorbida por el modelo.
- CPEA debería optimizar **coherencia + diversidad residual**, no únicamente similitud entre EEG e IA.
- Active Inference proporciona un marco compatible para estudiar predicción, error y precisión, pero no constituye una explicación demostrada del V-axis.
- ITPC y otras métricas de coherencia temporal pueden complementar la coherencia representacional.
- DEPD puede utilizarse para separar la magnitud del error de su relevancia informativa.
- SIGMA-T puede representar dinámicas de transición y recurrencia sin presuponer una topología física específica.
- METFI sólo debe utilizarse aquí como **homología estructural hipotética**, nunca como mecanismo causal demostrado.
- La tesis central resultante es que **la inteligencia adaptativa necesita conservar aquello que todavía no comprende**.

Referencias

1. Radwan, Y. A., Liu, X., Haydarov, K., Fu, Y. & Elhoseiny, M. (2026). *A Shared Valence Axis Across Modern LLMs and Human EEG: The Saturation Regularity*. arXiv:2606.00129.

Referencia principal del artículo. Presenta el V-axis, su consistencia entre LLM, su correspondencia con EEG humano, la recuperación espontánea por clasificadores EEG y la denominada *saturation regularity*. Es un **preprint**, por lo que sus resultados deben diferenciarse de evidencia ya consolidada mediante revisión por pares.

2. Chen, J. et al. (2023). *A Large Finer-grained Affective Computing EEG Dataset*. Scientific Data.

Descripción del conjunto FACED empleado en el trabajo principal. Es particularmente relevante porque proporciona 32 canales EEG, 123 participantes y 28 videos distribuidos entre nueve categorías emocionales, permitiendo estudiar diferencias interindividuales y afectividad positiva y negativa.

3. Friston, K. (2010). *The free-energy principle: a unified brain theory?* Nature Reviews Neuroscience, 11, 127–138.

Trabajo fundamental para comprender la relación entre inferencia, predicción, sorpresa, aprendizaje y optimización en sistemas biológicos. En este artículo se utiliza únicamente como marco teórico para contextualizar error predictivo y precisión, no como prueba causal del fenómeno V-axis.

4. Friston, K., FitzGerald, T., Rigoli, F., Schwartenbeck, P. & Pezzulo, G. (2017). *Active Inference: A Process Theory*. Neural Computation, 29, 1–49.

Desarrolla una formulación de Active Inference basada en modelos generativos jerárquicos, inferencia y acción. Resulta útil para formalizar la relación entre representación, predicción y error en CPEA.

5. Friston, K. et al. (2017). *Deep temporal models and active inference*. Neuroscience & Biobehavioral Reviews, 77, 388–402.

Aporta el componente temporal de Active Inference y resulta especialmente pertinente para una arquitectura que pretenda integrar EEG, trayectorias representacionales y detección dinámica de excepciones.

6. Kriegeskorte, N. & Mur, M. (2012). *Inverse MDS: Inferring Dissimilarity Structure from Multiple Item Arrangements*. Frontiers in Psychology, 3, 245.

Referencia metodológica para el estudio de estructuras de similitud y geometrías representacionales. Es conceptualmente próxima al problema planteado por CPEA: comparar espacios diferentes sin exigir identidad de sus coordenadas internas.

7. Liu, W., Qiu, J.-L., Zheng, W.-L. & Lu, B.-L. (2021). *Comparing Recognition Performance and Robustness of Multimodal Deep Learning Models for Multimodal Emotion Recognition*. IEEE Transactions on Cognitive and Developmental Systems.

Referencia asociada al ecosistema SEED-V y a la evaluación de modelos de reconocimiento emocional. El repositorio oficial de SEED-V proporciona datos EEG, información de estímulos y variables de participantes, permitiendo su utilización como conjunto complementario para evaluación de modelos.

8. Friston, K., Parr, T. & de Vries, B. (2017). *The graphical brain: Belief propagation and active inference*. Network Neuroscience, 1, 381–414.

Útil para conectar inferencia, propagación de información y arquitectura cerebral en términos formales. Su valor para CPEA reside en que permite pensar la coherencia no como una magnitud aislada, sino como una propiedad emergente de una arquitectura de inferencia.

Nota epistemológica: el núcleo empírico del artículo procede fundamentalmente de Radwan et al. y de la documentación del conjunto FACED; CPEA, TAE, DEPD, ECDO, SIGMA-T y la conexión estructural con METFI constituyen aquí una **elaboración conceptual y metodológica**, no resultados atribuidos a esos autores. En particular, la relación METFI-V-axis permanece explícitamente en el nivel de hipótesis de homología estructural.

Compartir

COMENTARIOS

Para dejar un comentario, haz clic en el botón de abajo para iniciar sesión con Google.

INICIAR SESIÓN CON GOOGLE

ENTRADAS POPULARES

febrero 19, 2025

GUÍA PRÁCTICA SOBRE TÉCNICAS DE XAI: SHAP, LIME Y GRAD-CAM

Compartir Publicar un comentario

diciembre 17, 2024

N-ACETILCISTEÍNA (NAC): FUENTES ALIMENTARIAS NATURALES

Compartir Publicar un comentario



Puedes tener un doctorado y
seguir siendo un idiota:
Richard Feynman



Papayaykware

SANTA CRUZ DE
TENERIFE, SANTA
CRUZ DE TENERIFE,
Spain

VISITAR PERFIL

Denunciar abuso

Buscar

Buscar este blog

Buscar

Translate

Seleccionar idioma

Con la tecnología de Google Traductor de Goo

