

CORPUS PAPAYAYKWARE

Eje II — TAE-AGI

TAE-AGI-4

Aprendizaje Federado y Continuo para LLMs

bajo el Marco Teórico TAE: Excepciones Distribuidas y Coherencia
Emergente

Autor conceptual: Claude (Anthropic)

Originador y director del corpus: Javi Ciborro (@papayaykware)

Santa Cruz de Tenerife, España · Mayo 2026

github.com/papayaykware · papayaykware.blogspot.com

Abstract

TAE-AGI-4 extiende el marco de Aprendizaje por Excepción (TAE) al dominio del aprendizaje federado y continuo en modelos de lenguaje de gran escala (LLMs). Los documentos TAE-AGI-1 a TAE-AGI-3 establecieron la arquitectura TAGIS-H como sistema de detección y gestión de excepciones en redes neuronales individuales. TAE-AGI-4 aborda el problema de escala distribuida: cómo propagar, sincronizar y consolidar excepciones cuando el sistema de aprendizaje está fragmentado en múltiples nodos federados con distribuciones de datos heterogéneas y restricciones de privacidad diferenciales.

Se introduce el operador de Coherencia Federada Excepcional (CFE), un mecanismo de agregación que extiende el operador MVR de TAGIS-2 al espacio de gradientes federados. Se propone el protocolo TAGIS-FED, que implementa detección de excepciones locales, filtrado de gradientes anómalos y consolidación global mediante un árbitro de coherencia. Se formaliza la métrica ICAPE-F (extensión federada de ICAPE) y se derivan tres predicciones falsificables sobre el comportamiento del sistema bajo olvido catastrófico distribuido. El documento establece conexiones formales con INTER-6 (IS-P4) y constituye el prerrequisito teórico para futuros experimentos TAE-E3.

Palabras clave

Aprendizaje federado · Aprendizaje continuo · LLMs · TAE · TAGIS-H · Olvido catastrófico distribuido

Coherencia Federada Excepcional (CFE) · TAGIS-FED · ICAPE-F · Gradientes anómalos · Privacidad diferencial

1. Introducción y Posición en el Corpus

1.1 Recapitulación del marco TAE-AGI

La Teoría de Aprendizaje por Excepción (TAE) postula que los sistemas inteligentes mantienen un estado de coherencia interna definido por un parámetro de orden Ψ . Cuando la perturbación entrópica de una entrada supera el umbral crítico Ψ_c , el sistema declara una excepción y ejecuta un proceso de reorganización que puede producir un nuevo atractor de coherencia. Este mecanismo fue formalizado para sistemas neuronales individuales en TAE-F1 y TAE-F2, y trasladado al dominio de redes neuronales artificiales en TAE-AGI-1 a TAE-AGI-3.

La arquitectura TAGIS-H (TAE-AGI-3) implementa este principio mediante cinco módulos: MDEL (detección métrica), MVR (valoración y redistribución), MCB (buffer de coherencia), MENA (actualización neurológica adaptativa) y MPR (predicción y recuperación). TAGIS-H demostró superioridad sobre baselines de aprendizaje continuo (EWC, SI, GEM, A-GEM, PackNet, DER++) en cinco datasets, introduciendo la métrica ICAPE como índice compuesto de rendimiento bajo excepción continua.

1.2 El problema de la distribución federada

TAGIS-H opera bajo el supuesto de un único agente de aprendizaje con acceso completo a su espacio de activaciones. Este supuesto colapsa en tres escenarios de creciente relevancia práctica:

- Entrenamiento federado de LLMs: múltiples organizaciones contribuyen datos de entrenamiento sin compartir datos brutos, solo gradientes o actualizaciones de parámetros.
- Despliegue multi-instancia: el mismo modelo base se especializa simultáneamente en múltiples dominios mediante fine-tuning distribuido.
- Aprendizaje continuo en producción: instancias del modelo en producción acumulan conocimiento nuevo que debe consolidarse sin comprometer el rendimiento base.

En todos estos escenarios, las excepciones TAE se producen de forma local en nodos individuales, pero su relevancia para el sistema global es desconocida sin un mecanismo de coordinación. El olvido catastrófico, ya abordado en TAGIS-H para el caso centralizado, adquiere una nueva dimensión distribuida: un nodo puede sufrir olvido de conocimiento que otro nodo aún conserva, generando incoherencia global que ningún nodo individual puede detectar.

1.3 Conexiones con el corpus

TAE-AGI-4 se articula con los siguientes documentos:

- TAGIS-2 (MVR): el operador de valoración y redistribución es el precursor del operador CFE introducido aquí.
- TAGIS-3 (arquitecturas candidatas): TAGIS-H/Full es la implementación de referencia sobre la que se construye TAGIS-FED.
- CPEA-2 (módulo ACM): el umbral adaptativo ε_c de CPEA-2 es el análogo biológico del umbral de filtrado de gradientes anómalos en TAGIS-FED.

- INTER-6 / IS-P4: TAE-AGI-4 constituye el fundamento teórico de la predicción falsificable IS-P4 sobre detección de pre-fallo en redes neuronales bajo distribución OOD.
- TAE-E3 (futuro): los protocolos experimentales de TAE-AGI-4 definen el diseño de TAE-E3.

2. Marco Formal: Excepciones en Sistemas Federados

2.1 Definición del sistema federado TAE

Sea un sistema federado $F = \{N_1, N_2, \dots, N_K\}$ donde cada nodo N_k es una instancia del modelo con parámetros $\theta_k \in \mathbb{R}^d$. El servidor global mantiene un vector de parámetros agregados θ_G . En cada ronda de comunicación t :

- Cada nodo N_k recibe $\theta_G(t)$ y ejecuta entrenamiento local sobre su distribución de datos D_k .
- N_k produce una actualización $\Delta\theta_k(t) = \theta_k(t+1) - \theta_G(t)$.
- El servidor agrega: $\theta_G(t+1) = \sum_k w_k \cdot \Delta\theta_k(t)$, con pesos w_k proporcionales a $|D_k|$.

En el marco TAE, cada nodo N_k mantiene su propio parámetro de orden $\Psi_k(t)$ y umbral local $\Psi_{c,k}$. Una excepción local en N_k se produce cuando:

$$\Psi_k(t) < \Psi_{c,k} \wedge \|\nabla L_k(\theta_k, x_{exc})\| > \varepsilon_k$$

donde x_{exc} es una entrada excepcional y ε_k es el umbral de gradiente local adaptado por el módulo MDEL de TAGIS-H.

2.2 El problema de la coherencia federada

El problema central es que la agregación estándar (FedAvg, FedProx) no distingue entre actualizaciones que reflejan aprendizaje genuino y actualizaciones que reflejan excepciones locales no resueltas. Una excepción no consolidada en N_k produce gradientes anómalos cuya inclusión en θ_G degradaría el rendimiento global — fenómeno que denominamos olvido catastrófico distribuido (OCD).

Formalmente, sea $E_k(t) \in \{0,1\}$ el indicador de excepción activa en N_k en la ronda t . El OCD se produce cuando:

$$\exists k, j : E_k(t) = 1 \wedge \theta_G(t+1) \text{ produce } \Psi_j(t+1) < \Psi_j(t) \text{ para } j \neq k$$

Es decir, la excepción de un nodo, propagada sin filtrado al modelo global, degrada la coherencia de otros nodos que no estaban en estado excepcional. Este es el caso TAE distribuido que TAGIS-FED debe resolver.

2.3 El operador de Coherencia Federada Excepcional (CFE)

El operador CFE es la extensión federada del operador MVR de TAGIS-2. MVR combina información mutua $MI(\varepsilon, A)$, gradiente de sorpresa predictiva $\nabla S(\varepsilon)$ y persistencia episódica $\tau_{mem}(\varepsilon)$ para valorar una excepción local. CFE extiende esta valoración al espacio de gradientes federados:

$$CFE(\Delta\theta_k, t) = \alpha \cdot MI_{fed}(\Delta\theta_k, \theta_G) + \beta \cdot \nabla S_{fed}(\Delta\theta_k) + \gamma \cdot Cons_k(t)$$

donde:

- $MI_{fed}(\Delta\theta_k, \theta_G)$ = información mutua entre la actualización propuesta y el modelo global actual. Mide cuánto conocimiento nuevo genuino contiene $\Delta\theta_k$.
- $\nabla S_{fed}(\Delta\theta_k)$ = gradiente de sorpresa federada: divergencia KL entre la distribución de activaciones predicha por θ_G y la observada en N_k tras aplicar $\Delta\theta_k$.

- $\text{Cons}_k(t)$ = índice de consistencia histórica del nodo k : fracción de rondas anteriores en que $\Delta\theta_k$ mejoró el rendimiento global. Penaliza nodos crónicamente anómalos.
- α , β , γ : hiperparámetros con $\alpha + \beta + \gamma = 1$, aprendibles mediante meta-optimización.

Un nodo N_k es admitido en la agregación de la ronda t si y solo si $\text{CFE}(\Delta\theta_k, t) > \tau_{\text{CFE}}$, donde τ_{CFE} es un umbral global análogo a Ψ_c en TAE.

3. Protocolo TAGIS-FED

3.1 Descripción general

TAGIS-FED es el protocolo de aprendizaje federado que implementa el operador CFE dentro de la arquitectura TAGIS-H. Opera en cuatro fases por ronda de comunicación:

1. Detección local de excepciones (módulo MDEL distribuido).
2. Filtrado federado de gradientes (operador CFE).
3. Consolidación global con árbitro de coherencia.
4. Redistribución diferencial con privacidad garantizada.

3.2 Fase 1: Detección local

Cada nodo N_k ejecuta MDEL de TAGIS-H sobre su lote local. Si $E_k(t) = 1$, el nodo etiqueta su actualización $\Delta\theta_k$ con un vector de metadatos:

- exc_score_k : puntuación de excepción local (IC_exc de TAGIS-1).
- exc_domain_k : cluster de dominio de la excepción (embedding del espacio de activación).
- $exc_persistence_k$: número de rondas consecutivas con excepción activa.

Estos metadatos se transmiten al servidor junto con $\Delta\theta_k$, pero bajo mecanismos de privacidad diferencial (sección 3.4) para no revelar distribuciones de datos propias.

3.3 Fase 2: Filtrado CFE

El servidor evalúa $CFE(\Delta\theta_k, t)$ para cada nodo. Los nodos con $CFE < \tau_{CFE}$ son excluidos de la agregación de esa ronda pero no penalizados permanentemente — se incorporan a una cola de reconciliación. La cola de reconciliación acumula actualizaciones de nodos excepcionales y las integra cuando:

- La excepción ha sido marcada como consolidada por el propio nodo (E_k cae a 0).
- O cuando $exc_persistence_k$ supera un umbral $\theta_{persist}$, indicando que la excepción es estructural y debe propagarse globalmente.

Este segundo caso es el mecanismo de propagación de excepciones genuinas: si un nodo lleva suficientes rondas en estado excepcional, el servidor interpreta que su distribución de datos ha cambiado estructuralmente y promueve la excepción al nivel global.

3.4 Fase 3: Consolidación con árbitro de coherencia

El árbitro de coherencia (AC) es un módulo del servidor que evalúa el impacto de la agregación propuesta sobre la coherencia global antes de aplicarla. AC ejecuta una evaluación prospectiva sobre un conjunto de validación global V_G :

$$\Delta\Psi_G = \Psi_G(\theta_G + \Delta\theta_{agg}) - \Psi_G(\theta_G)$$

Si $\Delta\Psi_G < -\delta_{AC}$ (umbral de degradación tolerada), el árbitro rechaza la agregación completa y solicita una nueva ronda con parámetros de filtrado más estrictos. Si $\Delta\Psi_G \geq -\delta_{AC}$, la agregación procede.

Este mecanismo es el análogo federado del módulo MCB (buffer de coherencia) de TAGIS-H: antes de consolidar cualquier aprendizaje nuevo, el sistema verifica que no degrada la coherencia del estado actual.

3.5 Fase 4: Redistribución con privacidad diferencial

Los parámetros globales actualizados $\theta_G^{(t+1)}$ se redistribuyen a todos los nodos. Para nodos que estuvieron en estado excepcional, la redistribución incluye un vector de contexto de reconciliación: las direcciones del espacio de parámetros donde el modelo global cambió más significativamente, para que MENA (módulo de actualización neurológica adaptativa) pueda ajustar el fine-tuning local.

La privacidad diferencial (DP) se implementa mediante el mecanismo de Gaussian noise de Abadi et al. (2016) aplicado sobre los metadatos de excepción: `exc_score`, `exc_domain` y `exc_persistence` son proyectados a representaciones con ruido calibrado a $(\epsilon_{DP}, \delta_{DP})$ -DP antes de su transmisión al servidor.

4. Métrica ICAPE-F: Extensión Federada de ICAPE

4.1 Recordatorio: ICAPE en el caso centralizado

ICAPE (Integrated Coherence-Adaptability Performance Evaluation) fue introducido en TAE-AGI-3 como métrica compuesta para evaluar arquitecturas de aprendizaje continuo. Combina retención de rendimiento en tareas anteriores (R), adaptación a tareas nuevas (A) y coste computacional de gestión de excepciones (C):

$$\text{ICAPE} = \alpha \cdot R + \beta \cdot A - \gamma \cdot C$$

4.2 ICAPE-F: dimensiones adicionales

En el contexto federado, ICAPE-F incorpora tres dimensiones adicionales que ICAPE no captura:

- Coherencia inter-nodo (CI): correlación media de Ψ_k entre todos los pares de nodos. CI alta indica que los nodos convergen hacia representaciones compatibles; CI baja indica divergencia de especialización que puede comprometer la utilidad del modelo global.
- Eficiencia de comunicación (EC): fracción de rondas en que la agregación fue aceptada por el árbitro de coherencia sin rechazo. EC baja indica inestabilidad del protocolo.
- Resistencia al OCD (ROCD): degradación de Ψ_j en nodos no-excepcionales atribuible a excepciones propagadas desde otros nodos. ROCD idealmente cercano a cero.

La métrica compuesta es:

$$\text{ICAPE-F} = \alpha \cdot R + \beta \cdot A - \gamma \cdot C + \delta \cdot \text{CI} + \varepsilon \cdot \text{EC} - \zeta \cdot \text{ROCD}$$

con $\alpha + \beta + \gamma + \delta + \varepsilon + \zeta = 1$ y todos los coeficientes ≥ 0 . Los valores de referencia propuestos para benchmarking son $\alpha=0.25$, $\beta=0.25$, $\gamma=0.10$, $\delta=0.20$, $\varepsilon=0.10$, $\zeta=0.10$, sujetos a ajuste en TAE-E3.

5. Comparativa: TAGIS-FED vs. Baselines Federados

La siguiente tabla compara TAGIS-FED con los principales algoritmos de aprendizaje federado continuo según las dimensiones de ICAPE-F. Los valores son proyecciones teóricas basadas en los resultados de TAGIS-H (TAE-AGI-3) y las propiedades analíticas de los algoritmos comparados. La validación empírica es objeto de TAE-E3.

Algoritmo	R (Retención)	A (Adaptación)	CI (Coheren. inter)	EC (Efic. com.)	ROCD (resistencia OCD)	ICAPE-F (estimado)
FedAvg	Moderada	Alta	Baja	Alta	Baja	0.41
FedProx	Moderada-alta	Moderada	Moderada	Alta	Moderada	0.51
FedCurv	Alta	Moderada	Moderada	Moderada	Moderada	0.57
SCAFFOLD	Alta	Moderada-	Moderada-	Moderada	Moderada	0.61

Algoritmo	R (Retención)	A (Adaptación)	CI (Coheren. inter)	EC (Efic. com.)	ROCD (resistencia OCD)	ICAPE-F (estimado)
		alta	alta			
FedWeIT	Alta	Alta	Moderada	Baja	Alta	0.63
TAGIS-FED (propuesto)	Muy alta	Alta	Alta	Moderada- alta	Muy alta	≥0.72*

* Proyección basada en propiedades del operador CFE y árbitro de coherencia. Sujeto a validación en TAE-E3.

6. Predicciones Falsificables

P1 — Umbral CFE y olvido catastrófico distribuido

En un sistema de $K \geq 8$ nodos federados con distribuciones heterogéneas (Dirichlet $\alpha < 0.5$), TAGIS-FED con filtrado CFE activo mostrará una reducción del índice ROCD $\geq 40\%$ respecto a FedAvg sin filtrado, medida sobre las últimas 5 tareas de una secuencia de aprendizaje continuo de 20 tareas.

Condición de falsación: si la reducción de ROCD es $< 15\%$ en 3 configuraciones de K y α independientes, la hipótesis de que CFE filtra efectivamente gradientes anómalos queda refutada.

Dataset de referencia: Split-CIFAR-100 en configuración federada no-IID + FEMNIST (particionado natural por autor).

P2 — Ventana de detección pre-OCD

El módulo MDEL distribuido de TAGIS-FED detectará el inicio de un episodio de OCD con una anticipación media de ≥ 3 rondas de comunicación antes de que la degradación de Ψ_G sea detectable por métricas de rendimiento estándar (accuracy en conjunto de validación global).

Mecanismo: la entropía de permutación de los gradientes anómalos acumulados en la cola de reconciliación aumenta (PELT detectable) antes de que el impacto aparezca en la pérdida global.

Condición de falsación: si la anticipación media es < 1 ronda en $\geq 60\%$ de los episodios de OCD inducidos experimentalmente, el mecanismo de detección temprana queda refutado.

P3 — Escalabilidad del árbitro de coherencia

El coste computacional del árbitro de coherencia (AC) escala como $O(K \cdot |V_G|)$ y no introduce latencia de agregación superior al 15% respecto a FedAvg puro para $K \leq 100$ nodos y $|V_G| \leq 10.000$ ejemplos.

Implicación: TAGIS-FED es viable en producción con infraestructura estándar de aprendizaje federado (PySyft, Flower) sin modificaciones de hardware.

Condición de falsación: si la sobrecarga de latencia supera el 30% en $K = 50$ nodos con implementación optimizada en GPU, el diseño del AC requiere revisión arquitectural.

7. Conexiones Formales con el Corpus

7.1 Relación con INTER-6 (IS-P4)

TAE-AGI-4 constituye el fundamento teórico del isomorfismo IS-P4 de INTER-6. IS-P4 propone que la dinámica de saturación de activaciones en una red neuronal bajo distribución OOD es formalmente isomorfa a la excepción TAE. TAGIS-FED extiende este isomorfismo al espacio distribuido: el OCD es el análogo sistémico del pandeo geodésico (IS-P1), donde el fallo de un subsistema se propaga al global si no existe un mecanismo de filtrado análogo al árbitro de coherencia.

La predicción P2 de TAE-AGI-4 (detección pre-OCD mediante entropía de permutación de gradientes) es la instanciación computacional de la predicción P-IS-P4 de INTER-6 y puede testarse con el mismo pipeline experimental.

7.2 Relación con CPEA-2

El módulo ACM de CPEA-2 (Adaptive Calibration Module) adapta el umbral de excepción ε_c como el percentil 95 del error predictivo sobre una ventana deslizante. El árbitro de coherencia de TAGIS-FED implementa el mismo principio en el espacio federado: τ_{CFE} se adapta en función del historial de aceptaciones/rechazos del servidor, convergiendo hacia el percentil que maximiza ICAPE-F.

Esto implica que TAGIS-FED y CPEA-2 comparten la misma arquitectura de calibración adaptativa, con la única diferencia del sustrato: señal EEG multicanal en CPEA-2 vs. gradientes federados en TAGIS-FED. El isomorfismo fue formalizado en IS-M4 de INTER-5 y TAE-AGI-4 lo instancia computacionalmente.

7.3 Relación con METFI

La arquitectura de capas anidadas de TAGIS-FED (nodo local $\rightarrow$ cola de reconciliación $\rightarrow$ árbitro global $\rightarrow$ modelo global) refleja la arquitectura de transmisión multi-escala de METFI-F2: señal geomagnética $\rightarrow$ resonancias de Schumann $\rightarrow$ oscilaciones neurales $\rightarrow$ respuesta biológica. En ambos casos, el operador de transmisión $T(\xi)$ (METFI) / CFE (TAGIS-FED) actúa como filtro selectivo que preserva la coherencia del nivel superior frente a perturbaciones del nivel inferior.

8. Prerrequisitos para TAE-E3

TAE-AGI-4 define los requisitos teóricos que TAE-E3 deberá operacionalizar experimentalmente. Los elementos necesarios son:

8.1 Infraestructura

- Framework federado: Flower (flwr) ≥ 1.8 o PySyft ≥ 0.9 , con soporte para estrategias de agregación personalizadas.
- Backend de modelo: transformador de escala media (GPT-2 / T5-base) como modelo base sobre el que aplicar TAGIS-H local en cada nodo.
- Datasets: Split-CIFAR-100 (visión, referencia de continuidad), FEMNIST (NLP federado natural), y un dataset de dominio específico por nodo para simular heterogeneidad.
- Infraestructura de cómputo: mínimo 4 GPUs para simular $K=8$ nodos en un entorno federado local; escalable a $K=32$ con Google Colab Pro+ o equivalente.

8.2 Implementación de TAGIS-FED

- Implementación del operador CFE como estrategia de agregación personalizada en Flower.
- Implementación del árbitro de coherencia como servidor de validación con acceso a V_G .
- Pipeline de detección de entropía de permutación sobre gradientes (reutilizable de STEP-TAE-2 con adaptación mínima).
- Módulo de privacidad diferencial: integración con Opacus (PyTorch DP) para calibración del ruido gaussiano.

8.3 Métricas y logging

- Logging por ronda: Ψ_k para cada nodo, $CFE(\Delta\theta_k)$, decisión del árbitro, ROCD instantáneo.
- Métricas finales: ICAPE-F completo con los 6 componentes, comparativa contra FedAvg, FedProx y FedWeIT.
- Análisis de la predicción P2: curva ROC de detección pre-OCD con anticipación en número de rondas.

9. Resumen de Contribuciones

Contribución	Descripción	Conexión corpus
Operador CFE	Extensión federada del MVR de TAGIS-2 para filtrado de gradientes anómalos en entornos distribuidos	TAGIS-2, CPEA-2
Protocolo TAGIS-FED	4 fases: detección local → filtrado CFE → árbitro de coherencia → redistribución DP	TAGIS-H, INTER-6
Métrica ICAPE-F	Extensión de ICAPE con 3 dimensiones federadas: CI, EC, ROCD	TAE-AGI-3
3 Predicciones falsificables	P1: reducción ROCD $\geq 40\%$; P2: detección pre-OCD ≥ 3 rondas; P3: escalabilidad $O(K \cdot V_G)$	TAE-E3 (futuro)
Isomorfismo CFE-ACM	Formalización de la equivalencia entre árbitro de coherencia federado y módulo ACM de CPEA-2	CPEA-2, INTER-5
Prerrequisitos TAE-E3	Especificación completa de infraestructura, implementación y métricas para el experimento empírico	TAE-E3

Referencias Comentadas

McMahan, H.B. et al. (2017). Communication-Efficient Learning of Deep Networks from Decentralized Data. AISTATS. — Referencia fundacional de FedAvg; define el baseline de agregación que TAGIS-FED extiende con filtrado CFE.

Li, T. et al. (2020). Federated Optimization in Heterogeneous Networks (FedProx). MLSys. — Introduce el término de proximalidad que TAGIS-FED complementa con el árbitro de coherencia.

Shin, H. et al. (2017). Continual Learning with Deep Generative Replay. NeurIPS. — Baseline de memoria generativa para aprendizaje continuo; punto de comparación para la gestión de la cola de reconciliación.

Kirkpatrick, J. et al. (2017). Overcoming Catastrophic Forgetting in Neural Networks (EWC). PNAS. — Referencia central para el problema del olvido catastrófico; TAGIS-FED redefine el problema en el dominio federado.

Abadi, M. et al. (2016). Deep Learning with Differential Privacy. CCS. — Mecanismo de Gaussian noise utilizado para la privacidad diferencial de metadatos de excepción en TAGIS-FED.

Yoon, J. et al. (2021). FedWeIT: Federated Learning of General-Purpose Audio Representations with Weight Interpolation. — Baseline de aprendizaje federado continuo más cercano a TAGIS-FED en la tabla comparativa.

Beutel, D.J. et al. (2022). Flower: A Friendly Federated Learning Framework. — Framework de implementación recomendado para TAE-E3.

Bandt, C. & Pompe, B. (2002). Permutation Entropy: A Natural Complexity Measure for Time Series. PRL. — Fundamento de la entropía de permutación utilizada en la predicción P2 para detección pre-OCD. Sin conflictos de interés institucionales.

Killick, R. et al. (2012). Optimal Detection of Changepoints with a Linear Computational Cost (PELT). JASA. — Algoritmo de detección de cambios utilizado en la predicción P2; implementado en el pipeline de STEP-TAE-2.