



PAPAYAYKWARE

Estudios científicos comprensibles

· INICIO

ARCHIVOS DEL BLOG



junio 23, 2026

FORMALIZACIÓN DE $\Lambda(T)$ — CONTROLADOR HOMEOSTÁTICO DE COHERENCIA

—

Formalización de $\lambda(t)$ — Controlador homeostático de coherencia

Documento: CPEA-G- λ -1 *Corpus Papayaykware* · Autor conceptual: Claude · Director: Javi Cíborro

El problema que resuelve

Un λ fijo en $L_{\text{total}} = L_{\text{pred}} + \lambda \cdot L_{\text{coh}}$ es un compromiso estático entre dos objetivos que no son estáticos. Durante fases de aprendizaje estable, el sistema no necesita regularización fuerte: la coherencia se mantiene sola. Durante transiciones —nuevos dominios, distributional shift, eventos TAE— la coherencia colapsa y un λ fijo es demasiado débil para protegerla o demasiado fuerte para permitir la reorganización necesaria.

Lo que el sistema necesita es un regulador que observe $\Gamma_G(t)$ en tiempo real y ajuste la presión de coherencia en función del estado actual. Eso es exactamente lo que hace un controlador homeostático biológico: no mantiene un valor fijo de presión reguladora, sino que responde a la desviación respecto al punto de equilibrio.

Definición formal

Controlador sigmoidal:

$$\lambda(t) = \lambda_{\text{max}} \cdot \sigma(\alpha \cdot (\Gamma_{\text{thr}} - \Gamma_G(t)))$$

donde $\sigma(x) = 1 / (1 + e^{-x})$ es la función logística estándar, y:

- $\Gamma_{\text{thr}} \in (0,1)$ es el umbral de coherencia objetivo, calibrado empíricamente sobre el dataset de referencia. Valor inicial recomendado: 0.65

- $\alpha > 0$ es la sensibilidad del controlador: α alto produce respuesta binaria (λ salta de 0 a $\lambda_{\max}$ abruptamente), α bajo produce respuesta gradual. Rango operativo: $\alpha \in [2, 10]$
- $\lambda_{\max}$ es el techo de regularización, que limita la presión máxima sobre L_{coh} para evitar que el sistema entre en régimen de rigidez donde L_{pred} queda subordinada. Rango recomendado: $\lambda_{\max} \in [0.5, 2.0]$

Comportamiento resultante:

Cuando $\Gamma_G(t) \gg \Gamma_{\text{thr}} \rightarrow$ el argumento de σ es negativo y grande $\rightarrow \lambda(t) \approx 0$. El sistema optimiza casi exclusivamente L_{pred} . La coherencia está alta, no necesita presión.

Cuando $\Gamma_G(t) \ll \Gamma_{\text{thr}} \rightarrow$ el argumento es positivo y grande $\rightarrow \lambda(t) \approx \lambda_{\max}$. La regularización de coherencia domina. El sistema entra en modo protección.

Cuando $\Gamma_G(t) \approx \Gamma_{\text{thr}} \rightarrow \lambda(t) \approx \lambda_{\max}/2$. Régimen de transición, sensibilidad máxima a pequeñas variaciones de coherencia.

Extensión: controlador con memoria (λ con inercia)

La versión básica responde instante a instante. En presencia de ruido en $\Gamma_G(t)$ —inevitable con EEG real— esto produce oscilaciones de λ que desestabilizan el entrenamiento. Se introduce inercia mediante un filtro exponencial:

$$\tilde{\lambda}(t) = \beta \cdot \tilde{\lambda}(t-1) + (1-\beta) \cdot \lambda(t)$$

donde $\beta \in [0.8, 0.95]$ es el factor de suavizado. El λ efectivo en el backward pass es $\tilde{\lambda}(t)$, no $\lambda(t)$. Esto es análogo al momentum en optimización de gradiente: reduce la varianza sin introducir sesgo sistemático.

Conexión con TAE

El controlador $\lambda(t)$ no es solo un mecanismo de regularización. Es un detector implícito de excepción en el sentido TAE. Cuando $\lambda(t)$ supera un umbral secundario λ_{TAE} —definible como $\lambda(t) > 0.8 \cdot \lambda_{\max}$ durante una ventana temporal T_{TAE} — el sistema puede inferir que Γ_G ha colapsado de forma sostenida: señal de que el sistema ha abandonado su atractor habitual y está en proceso de reorganización.

En ese momento, según la lógica TAE, la respuesta correcta no es forzar el retorno al estado anterior sino permitir la exploración del nuevo régimen. El controlador $\lambda(t)$ puede implementar esto mediante una válvula de alivio:

Si $\tilde{\lambda}(t) > \lambda_{\text{TAE}}$ durante T_{TAE} segundos consecutivos: $\rightarrow$ activar modo TAE: reducir α temporalmente (suavizar la presión) $\rightarrow$ registrar el evento en el log de excepciones $\rightarrow$ permitir que $\Gamma_G(t)$ explore valores por debajo de Γ_{thr} sin penalización máxima

Este mecanismo convierte $\lambda(t)$ en algo más que un hiperparámetro adaptativo: es la interfaz entre el optimizador y la dinámica de aprendizaje excepcional del sistema.

Implementación en SIGMA-T

El controlador se inserta entre la capa de cálculo de $\Gamma_G(t)$ y la función de coste. En pseudocódigo:

```
def compute_loss(L_pred, gamma_G, t, state):
    # Controlador homeostático
    lambda_inst = LAMBDA_MAX * sigmoid(ALPHA * (GAMMA_THR - gamma_G))

    # Inercia
    state['lambda_smooth'] = BETA * state['lambda_smooth'] + (1 - BETA) * lambda_inst
    lambda_eff = state['lambda_smooth']

    # Detección de excepción TAE
    if lambda_eff > TAE_THRESHOLD:
        state['tae_counter'] += 1
        if state['tae_counter'] >= TAE_WINDOW:
            lambda_eff *= TAE_RELIEF_FACTOR # suaviza presión
            log_tae_event(t, gamma_G, lambda_eff)
    else:
        state['tae_counter'] = 0

    # Función de coste compuesta
    L_coh = 1.0 - gamma_G
    L_total = L_pred + lambda_eff * L_coh

    return L_total, lambda_eff, state

# Hiperparámetros por defecto
LAMBDA_MAX    = 1.0
ALPHA         = 5.0
GAMMA_THR     = 0.65
BETA          = 0.90
TAE_THRESHOLD = 0.80 # fracción de LAMBDA_MAX
TAE_WINDOW    = 50   # pasos de entrenamiento
TAE_RELIEF_FACTOR = 0.4
```

Protocolo de calibración

Los tres hiperparámetros críticos — Γ_{thr} , α , λ_{max} — no son universales. Dependen de la topología del grafo $G(t)$ y del dominio de aplicación. El protocolo de calibración es:

Paso 1 — Caracterizar la distribución base de Γ_G . Correr NEXUS-EEG sobre el conjunto de validación sin función de coste modificada y registrar la distribución empírica de $\Gamma_G(t)$. El percentil

25 de esa distribución es el candidato natural para Γ_{thr} : por debajo de ese punto, el sistema ya está en régimen de baja coherencia.

Paso 2 — Barrido de α . Para cada valor $\alpha \in \{2, 4, 6, 8, 10\}$, entrenar durante 500 pasos y medir la varianza de $\tilde{\lambda}(t)$. Seleccionar el α que produce varianza de $\tilde{\lambda} < 0.05$ sin aplanar la curva de respuesta.

Paso 3 — Calibrar λ_{max} . Fijar α calibrado y barrer $\lambda_{max} \in \{0.3, 0.5, 1.0, 1.5, 2.0\}$. La métrica de selección es el tradeoff entre backward transfer (pérdida catastrófica) y rendimiento en la tarea actual. El punto de inflexión de esa curva es λ_{max} óptimo.

Paso 4 — Validación cruzada con datos EEG reales. Aplicar los hiperparámetros calibrados sobre los 12 registros anonimizados del corpus NEXUS-EEG v1.0 y verificar que $\tilde{\lambda}(t)$ responde correctamente a transiciones cognitivas conocidas (etiquetadas por anotación conductual).

Compartir

COMENTARIOS



Escribe tu comentario

ENTRADAS POPULARES

febrero 19, 2025

GUÍA PRÁCTICA SOBRE TÉCNICAS DE XAI: SHAP, LIME Y GRAD-CAM

Compartir Publicar un comentario

diciembre 17, 2024


N-ACETILCISTEÍNA (NAC): FUENTES ALIMENTARIAS NATURALES

[Compartir](#) [Publicar un comentario](#)

Con la tecnología de Blogger



Puedes tener un doctorado y seguir siendo un idiota: Richard Feynman



Papayaykware

—
SANTA CRUZ DE
TENERIFE, SANTA
CRUZ DE TENERIFE,
Spain

[VISITAR PERFIL](#)

[Denunciar abuso](#)

Buscar
Buscar este blog

Translate

Con la tecnología de  Traductor de Goo