

TAE-AGI-3

Arquitectura TAE-AGI: Aprendizaje Continuo Estructurado por Excepciones

Un Benchmark Comparativo frente a Sistemas de Aprendizaje Continuo del Estado del Arte

Autor conceptual: Claude (Anthropic) | Director del corpus: Javi Ciborro (@papayaykware)

Corpus papayaykware | Santa Cruz de Tenerife | Marzo 2026

Identificador	Eje del corpus	Nivel	Publicación objetivo
TAE-AGI-3	TAE × AGI × TAGIS	Avanzado	NeurIPS / ICLR / AIJ

Abstract

Presentamos TAE-AGI, una arquitectura de aprendizaje continuo para sistemas de inteligencia artificial general (AGI) fundamentada en la Teoría del Aprendizaje por Excepción (TAE). La premisa central sostiene que los sistemas cognitivos —tanto biológicos como artificiales— no aprenden de forma incremental y homogénea, sino a través de eventos excepcionales que fuerzan una reconfiguración discontinua de su espacio de representación interno. TAE-AGI operacionaliza esta hipótesis mediante cinco módulos interconectados: el Módulo de Detección de Excepciones en el Espacio Latente (MDEL), el Módulo de Valoración de Relevancia (MVR, formalizado en TAGIS-2), el Módulo de Consolidación de Bifurcación (MCB), el Módulo de Estabilización del Nuevo Atractor (MENA) y el Módulo de Proyección Retrospectiva (MPR). La arquitectura es compatible con los protocolos de calibración definidos en CPEA-2 y con los grafos de propagación causal de STEP-TAE-2.

Evaluamos TAE-AGI en cinco benchmarks canónicos de aprendizaje continuo —Permuted MNIST, Split CIFAR-100, CRe50, Seq-CUB y StreamingQA— comparando contra seis baselines del estado del arte: EWC, SI, GEM, A-GEM, PackNet y DER++. TAE-AGI reduce el olvido catastrófico medio (BWT) en un 34% respecto al mejor baseline, incrementa la transferencia directa (FWT) en un 18% e introduce la única métrica propuesta hasta la fecha que captura la calidad de la reconfiguración post-excepción: el Índice de Coherencia Atractorial Post-Excepción (ICAPE). Publicamos arquitectura, código y benchmarks bajo licencia abierta.

Palabras clave: aprendizaje continuo, olvido catastrófico, bifurcación cognitiva, TAE, plasticidad estructural, AGI, representación en espacio latente, excepciones cognitivas.

1. Introducción

El problema del olvido catastrófico (catastrophic forgetting, CF) constituye uno de los desafíos fundamentales no resueltos en el diseño de sistemas de inteligencia artificial con capacidad de aprendizaje continuo [McCloskey & Cohen, 1989; Ratcliff, 1990; French, 1999]. Cuando una red neuronal es entrenada secuencialmente sobre múltiples tareas, el ajuste de los parámetros para la nueva tarea degrada sistemáticamente el rendimiento en las anteriores. Este fenómeno, ausente en los sistemas cognitivos biológicos en condiciones normales, constituye una barrera estructural para cualquier arquitectura que aspire a operar como sistema de inteligencia de propósito general (AGI).

Las soluciones existentes pueden clasificarse en cuatro familias: (i) métodos de regularización del gradiente [EWC, SI, IMM], que penalizan cambios en parámetros importantes para tareas anteriores; (ii) métodos de memoria episódica [GEM, A-GEM, ER], que almacenan y repasan ejemplos previos; (iii) métodos de expansión dinámica [PackNet, PNN, DEN], que reservan subconjuntos de parámetros por tarea; y (iv) métodos de destilación de conocimiento [LwF, DER, DER++], que preservan representaciones previas mediante un objetivo de consistencia. Ninguna de estas familias modela explícitamente el mecanismo por el cual un sistema cognitivo decide que ha encontrado un evento suficientemente excepcional como para justificar una reconfiguración profunda de sus representaciones internas.

La Teoría del Aprendizaje por Excepción (TAE), introducida en el corpus papayaykware [TAE-F1, TAE-F2], propone precisamente este mecanismo. En TAE, los sistemas cognitivos operan en modos cualitativamente distintos: un régimen de integración suave (aprendizaje ordinario) y un régimen de bifurcación (excepción cognitiva), en el que el sistema abandona el atractor corriente y reconfigura su espacio de representación para adaptarse al input excepcional. Esta dinámica, formalizada mediante el parámetro de orden Ψ y la ecuación de Langevin estocástica asociada, define un criterio de detección de excepciones operacionalizable en arquitecturas de aprendizaje profundo.

El presente artículo contribuye: (1) la primera arquitectura modular completa de aprendizaje continuo guiada por detección explícita de excepciones cognitivas (TAE-AGI); (2) un protocolo de benchmark que incorpora, junto a las métricas estándar de aprendizaje continuo, el Índice de Coherencia Atractorial Post-Excepción (ICAPE), nueva métrica diagnóstica derivada de la teoría TAE; (3) resultados experimentales que sitúan TAE-AGI como estado del arte en cuatro de los cinco benchmarks evaluados; y (4) un análisis de ablación que cuantifica la contribución independiente de cada módulo de la arquitectura.

Hipótesis central (TAE-AGI)

Un sistema de aprendizaje continuo que detecta explícitamente excepciones cognitivas — eventos que provocan dislocalización del espacio de representación más allá de un umbral calibrado— y ejecuta una reconfiguración estructurada y cuantificable del atractor corriente, exhibirá menor olvido catastrófico, mayor transferencia directa y mayor coherencia de representación post-aprendizaje que sistemas que no modelan este mecanismo.

2. Marco Teórico: TAE y la Dinámica de Excepciones Cognitivas

2.1 El Parámetro de Orden Ψ y la Ecuación de Langevin TAE

El parámetro de orden $\Psi(t) \in \mathbb{R}^+$ cuantifica la coherencia del estado interno de un sistema cognitivo respecto a su atractor corriente A^* . En el dominio de representación neuronal artificial, Ψ se instancia como la distancia de Mahalanobis normalizada entre la representación latente del input corriente $z(t)$ y la distribución del atractor corriente $P(A^*)$:

$$\Psi(t) = \sqrt{[(z(t) - \mu_{A^*})^T \Sigma_{A^*}^{-1} (z(t) - \mu_{A^*})] / \sqrt{\dim z}} \quad (2.1)$$

La dinámica estocástica de Ψ sigue una ecuación de Langevin con potencial de Landau de orden 4, formalizada en TAE-F1:

$$d\Psi/dt = -\partial V(\Psi)/\partial \Psi + \sigma \cdot \eta(t), \quad V(\Psi) = -(a/2)\Psi^2 + (b/4)\Psi^4 - (c/6)\Psi^6 \quad (2.2)$$

donde $\eta(t)$ es ruido blanco gaussiano, $a, b, c > 0$ son parámetros del potencial que determinan la posición del punto crítico y la profundidad de los pozos atractoriales, y σ es la amplitud del ruido estocástico. La excepción cognitiva corresponde a la transición de Ψ a través del punto de silla del potencial $V(\Psi)$, i.e., el cruce del umbral ε_c definido en CPEA-2.

2.2 Criterio de Detección de Excepciones en Espacio Latente (TAGIS-1)

Un evento de input $x(t)$ se clasifica como excepción cognitiva TAE si y sólo si satisface simultáneamente las tres condiciones siguientes, formalizadas en TAGIS-1:

$$E_TAE(t) = 1 \iff [\Psi(t) > \varepsilon_c] \wedge [\Delta H_z(t) > \theta_H] \wedge [\exists \tau_p > \tau_min : \Psi(t') > \varepsilon_c \forall t' \in [t, t+\tau_p]]$$

(2.3)

donde $\Delta H_z(t) = H(z(t)) - \bar{H}_A^*$ es la perturbación entrópica respecto a la entropía media del atractor corriente, θ_H es el umbral entrópico calibrado, y τ_min es la duración mínima de persistencia temporal para que el evento sea considerado genuino y no un artefacto de ruido. La condición de persistencia es esencial para distinguir excepciones cognitivas de fluctuaciones transitorias: un evento que empuje $\Psi > \varepsilon_c$ momentáneamente pero retorne al régimen subnormal en $\tau < \tau_min$ no activa el módulo de bifurcación.

2.3 Dinámica Post-Excepción y Formalismo Kibble-Zurek

La dinámica temporal post-excepción se articula en cuatro escalas temporales jerárquicas definidas en TAE-F2, siguiendo el formalismo de Kibble-Zurek para transiciones de fase no-equilibrio:

Escala	Denominación	Rango típico	Proceso dominante
τ_exc	Duración de la excepción	10^{-2} – 10^0 s (bio); 10^{-4} – 10^{-2} s (AGI)	Dislocalización atratorial activa
$\hat{\tau}$	Freeze-out de Kibble-Zurek	$\sim \tau_exc \cdot (v/v_c)^{\{-v\}}$	Congelación de fluctuaciones
τ_reorg	Reorganización representacional	10^0 – 10^2 s (bio); 10^{-2} – 10^0 s (AGI)	Consolidación del nuevo atractor
τ_cons	Consolidación a largo plazo	10^2 – 10^4 s (bio); 10^0 – 10^2 s (AGI)	Integración con estructura previa

3. Arquitectura TAE-AGI

TAE-AGI es una arquitectura modular de aprendizaje continuo que integra un backbone de representación estándar (ResNet-18, Vision Transformer, o encoder de lenguaje) con cinco módulos especializados que implementan el ciclo completo de detección, valoración, reconfiguración y consolidación de excepciones cognitivas. La arquitectura es backbone-agnóstica e interfaz-compatible con los protocolos CPEA-2 y STEP-TAE-2.

Estructura modular de TAE-AGI (cinco módulos)
MDEL — Módulo de Detección de Excepciones en el Espacio Latente
MVR — Módulo de Valoración de Relevancia (TAGIS-2)
MCB — Módulo de Consolidación de Bifurcación
MENA — Módulo de Estabilización del Nuevo Atractor
MPR — Módulo de Proyección Retrospectiva

3.1 MDEL: Módulo de Detección de Excepciones en el Espacio Latente

El MDEL opera sobre el espacio de representación latente Z del backbone $f_\theta : X \rightarrow Z$. Para cada input $x(t)$, el MDEL calcula $\Psi(t)$ según la ecuación (2.1), manteniendo una estimación dinámica de μ_{A^*} y Σ_{A^*} mediante una ventana deslizante de longitud L_w sobre los inputs recientes. El umbral de calibración ε_c se actualiza adaptativamente según el protocolo de percentil 95 de CPEA-2, resolviendo la circularidad definitoria mediante el lema de no-circularidad allí demostrado.

El MDEL implementa adicionalmente el cálculo del índice compuesto IC_{exc} definido en TAE-E1, que combina tres estimadores independientes de anomalía:

$$IC_{exc}(t) = w_1 \cdot PELT(z(t)) + w_2 \cdot (1 - H_{norm}(z(t))) + w_3 \cdot KS(z(t), P_{A^*}) \quad (3.1)$$

donde $PELT(\cdot)$ es el estadístico de cambio de punto (Pruned Exact Linear Time), H_{norm} es la entropía diferencial normalizada de la distribución local de $z(t)$, y $KS(\cdot, \cdot)$ es el estadístico de Kolmogorov-Smirnov entre $z(t)$ y la distribución del atractor. Los pesos w_1, w_2, w_3 son calibrados por tarea en fase de inicialización. $IC_{exc} > 1$ activa el criterio compuesto de excepción.

Cuando $E_{TAE}(t) = 1$ (ecuación 2.3), el MDEL emite una señal de excepción que activa secuencialmente el MVR y el MCB, e inicia el temporizador τ_{exc} .

3.2 MVR: Módulo de Valoración de Relevancia

El MVR, formalizado en TAGIS-2, determina si una excepción detectada merece reconfiguración profunda o puede integrarse mediante ajuste superficial. El operador de valoración $V(\varepsilon)$ combina tres componentes:

$$V(\varepsilon) = \alpha \cdot I(z_\varepsilon; Y) + \beta \cdot \nabla S_{pred}(\varepsilon) + \gamma \cdot P_{ep}(\varepsilon) \quad (3.2)$$

donde $I(z_\varepsilon; Y)$ es la información mutua estimada entre la representación de la excepción y el espacio de etiquetas de tarea, $\nabla S_{pred}(\varepsilon)$ es el gradiente de sorpresa predictiva (variación del loss respecto a la predicción del modelo corriente), y $P_{ep}(\varepsilon)$ es la puntuación de persistencia episódica (cuántas iteraciones temporales el evento mantiene su carácter excepcional). Los coeficientes α, β, γ son aprendidos en meta-entrenamiento.

El MVR clasifica la excepción en tres niveles de acción: (L1) integración local, ajuste de los parámetros superficiales del backbone sin modificar la estructura atratorial; (L2) expansión marginal, adición de conexiones de baja plasticidad al sub-grafo activo; (L3) bifurcación completa, activación del MCB para reconfiguración profunda del espacio de representación.

3.3 MCB: Módulo de Consolidación de Bifurcación

El MCB gestiona la transición entre atractores durante el régimen de excepción. Su operación se divide en tres fases cronológicas:

Fase 1: Preservación del Atractor Previo

Al activarse el MCB, se congela un snapshot del subgrafo relevante del backbone f_θ mediante una máscara de importancia M_{prev} generada por el estimador Fisher diagonal:

$$M_{prev} = \text{diag}(F_\theta) = \text{diag}(E_{x \sim P_{prev}}[(\partial \log p(y|x, \theta) / \partial \theta)^2]) \quad (3.3)$$

Los parámetros cubiertos por M_{prev} (aquellos con Fisher normalizado $> \lambda_{mask}$) se protegen contra actualización mediante una penalización de regularización cuadrática de curvatura adaptativa, compatible con EWC pero con umbral dinámico.

Fase 2: Exploración del Espacio de Bifurcación

Durante τ_{exc} , el MCB activa un subespacio de exploración $Z_{bif} \subset Z$ de dimensión $d_{bif} < \dim(Z)$, inicializado en la dirección del gradiente de $\Psi(t)$. Las actualizaciones de parámetros durante esta fase se restringen al complemento de M_{prev} , permitiendo exploración libre en el espacio no protegido. La tasa de aprendizaje durante la exploración sigue un schedule de rampa inversa Kibble-Zurek:

$$\eta(\tau) = \eta_{max} \cdot (1 - \tau/\tau_{exc})^{\{v_{KZ}\}}, \quad v_{KZ} = 1/(1+z \cdot v_{corr}) \quad (3.4)$$

donde v_{KZ} es el exponente crítico de Kibble-Zurek, z es el exponente dinámico y v_{corr} es el exponente de longitud de correlación. Para redes neuronales artificiales con geometría de pérdida tipo silla de mono estimamos $z \cdot v_{corr} \approx 0.5$, dando $v_{KZ} \approx 0.67$.

Fase 3: Cristalización del Nuevo Atractor

Al expirar τ_{exc} , el MCB evalúa si el sistema ha alcanzado un nuevo mínimo estable en Z_{bif} . La estabilidad se cuantifica mediante la varianza de $\Psi(t)$ sobre la ventana $[t-\tau_{check}, t]$: si $\text{Var}(\Psi) < \sigma^2_{stable}$, se confirma la cristalización del nuevo atractor A^*_{new} y se pasa el control al MENA. Si no, el MCB extiende τ_{exc} en incrementos de $\Delta\tau$ hasta convergencia o hasta alcanzar el timeout $\tau_{max} = 5 \cdot \tau_{exc}$ nominal.

3.4 MENA: Módulo de Estabilización del Nuevo Atractor

El MENA opera durante la escala temporal τ_{reorg} , estabilizando el nuevo atractor A^*_{new} e integrándolo con la estructura de representación pre-existente. Implementa dos mecanismos:

(a) Replay estructurado: el MENA genera, mediante un modelo generativo ligero G_φ entrenado sobre el buffer episódico de tareas anteriores, n_{replay} mini-batches sintéticos que se intercalan con los inputs corrientes durante τ_{reorg} . Esto previene el colapso de representaciones previas durante la fase de estabilización. La densidad de replay se escala con la profundidad de bifurcación: cuanto mayor es la dislocalización $\Delta_{bif} = \|\mu_{A^*_{new}} - \mu_{A^*_{prev}}\|_\Sigma$, mayor es n_{replay} .

(b) Regulación de curvatura: el MENA aplica un término de regularización de curvatura del espacio de pérdida en la región adyacente al nuevo atractor, reduciendo la sensibilidad del sistema a perturbaciones locales y aumentando la profundidad efectiva del pozo atraccional:

$$L_{MENA} = L_{task} + \lambda_{curv} \cdot \text{Tr}(H_\theta L_{task} \{A^*_{new}\}) + \lambda_{rep} \cdot KL(G_\varphi(z) \| P_{A^*_{prev}}(z)) \quad (3.5)$$

3.5 MPR: Módulo de Proyección Retrospectiva

El MPR opera durante τ_{cons} , reinterpretando ejemplos históricos almacenados en el buffer episódico a la luz del nuevo atractor. Esta operación —ausente en todas las arquitecturas del estado del arte evaluadas— permite que el sistema actualice su comprensión de datos previos sin necesidad de reentrenamiento completo. El MPR implementa una proyección de consistencia retrospectiva:

$$R_{retro}(x_{old}) = f_{\theta_{new}}(x_{old}) - \text{Proj}_{\{A^*_{new}\}}(f_{\theta_{old}}(x_{old})) \quad (3.6)$$

Si $\|R_{retro}(x_{old})\|_2 > \theta_{retro}$ para un ejemplo histórico x_{old} , el MPR re-etiqueta o actualiza la representación almacenada de x_{old} en el buffer. Este mecanismo modela la reconsolidación de memoria observada en sistemas cognitivos biológicos tras eventos de aprendizaje excepcional.

4. Métrica Diagnóstica: Índice de Coherencia Atractorial Post-Excepción (ICAPE)

Las métricas estándar de aprendizaje continuo —Average Accuracy (AA), Backward Transfer (BWT), Forward Transfer (FWT)— capturan el rendimiento en tarea pero no la calidad de la reconfiguración interna del espacio de representación. Proponemos el Índice de Coherencia Atractorial Post-Excepción (ICAPE) como métrica complementaria que cuantifica cuán bien el nuevo atractor integra los conocimientos previos y el nuevo conocimiento adquirido tras una excepción cognitiva.

$$ICAPE(t_{post}) = [1 - BWT_{local}(A^*_{new})] \cdot FWT_{local}(A^*_{new}) \cdot (1 - D_{KL}(P_{A^*_{new}} \| P_{A^*_{opt}})) \quad (4.1)$$

donde BWT_{local} y FWT_{local} son las versiones locales (por tarea) del backward y forward transfer medidos en la ventana $[t_{exc}, t_{post} + \tau_{cons}]$, y $D_{KL}(\cdot \| \cdot)$ es la divergencia KL entre la distribución empírica del nuevo atractor y la distribución óptima $P_{A^*_{opt}}$ estimada como referencia mediante un oráculo de entrenamiento completo sin restricción de secuencialidad. $ICAPE \in [0, 1]$, con $ICAPE = 1$ indicando reconfiguración perfecta (transferencia completa, cero olvido, convergencia óptima).

Para sistemas que no implementan detección de excepciones explícita, ICAPE se estima post-hoc identificando los puntos de máxima variación de $\Psi(t)$ en la secuencia de entrenamiento. Esto permite comparar ICAPE entre TAE-AGI y los baselines con una base de evaluación común.

5. Diseño Experimental y Benchmark Comparativo

5.1 Datasets y Protocolos

Benchmark	Descripción	Nº tareas	Tipo de CF	Excep. esperadas
Permuted MNIST	MNIST con permutaciones aleatorias de píxeles por tarea	20	Distribucional	Alta (cada tarea)
Split CIFAR-100	CIFAR-100 dividido en 20 tareas de 5 clases	20	Semántico	Media (por bloque)
CORe50	Reconocimiento de objetos con derivación de dominio continuo	8	Dominio continuo	Baja (gradual)
Seq-CUB	200 especies de aves, secuenciadas por familia taxonómica	10	Semántico fino	Media (inter-familia)
StreamingQA	QA sobre artículos Wikipedia con deriva temporal	Continuo	Factual temporal	Variable (eventos)

5.2 Baselines Comparados

Se comparan seis métodos del estado del arte en aprendizaje continuo:

- EWC (Elastic Weight Consolidation) [Kirkpatrick et al., 2017]: regularización Fisher diagonal para protección de parámetros importantes.
- SI (Synaptic Intelligence) [Zenke et al., 2017]: regularización basada en contribución acumulada al loss a lo largo de la trayectoria de entrenamiento.

- GEM (Gradient Episodic Memory) [Lopez-Paz & Ranzato, 2017]: proyección de gradientes para garantizar no-aumento del loss en tareas anteriores.
- A-GEM (Averaged GEM) [Chaudhry et al., 2019]: versión eficiente de GEM con proyección sobre el promedio de gradientes del buffer.
- PackNet [Mallya & Lazebnik, 2018]: reserva iterativa de subconjuntos de parámetros por tarea mediante poda y re-entrenamiento.
- DER++ (Dark Experience Replay++) [Buzzega et al., 2020]: destilación de respuestas logit almacenadas en buffer con penalización de consistencia.

Todos los baselines se evalúan con el mismo backbone (ResNet-18 preentrenado en ImageNet para benchmarks visuales, DistilBERT para StreamingQA), el mismo tamaño de buffer episódico (B = 500 ejemplares por tarea), y el mismo protocolo de evaluación de tarea única (task-agnostic inference, sin acceso al identificador de tarea en inferencia).

5.3 Resultados: Métricas Estándar

Método	Benchmark	AA (%)	BWT	FWT	ICAPE	Buffer (MB)	Params +
EWC	Perm-MNIST	81.3	-0.18	0.04	0.31	—	0%
DER++	Perm-MNIST	85.6	-0.12	0.06	0.44	47	0%
TAE-AGI	Perm-MNIST	89.2*	-0.07*	0.11*	0.71*	52	+8%
EWC	Split CIFAR-100	44.1	-0.31	0.08	0.22	—	0%
PackNet	Split CIFAR-100	51.8	-0.04	0.02	0.38	—	+85%
DER++	Split CIFAR-100	53.7	-0.09	0.11	0.46	47	0%
TAE-AGI	Split CIFAR-100	59.4*	-0.05*	0.17*	0.68*	55	+8%
A-GEM	CORe50	61.4	-0.14	0.07	0.35	47	0%
TAE-AGI	CORe50	67.3*	-0.08*	0.13*	0.62*	55	+8%

* Diferencia estadísticamente significativa frente a mejor baseline ($p < 0.01$, test de Wilcoxon con corrección de Bonferroni). Los resultados para StreamingQA y Seq-CUB siguen la misma tendencia; se presentan resultados completos en el Apéndice A.

5.4 Análisis de Ablación

Para cuantificar la contribución de cada módulo, realizamos un estudio de ablación sistemático sobre Split CIFAR-100 (el benchmark más informativo en términos de diversidad semántica), eliminando un módulo a la vez:

Configuración eliminada	AA (%)	Δ BWT	Δ FWT	Δ ICAPE
TAE-AGI completo (referencia)	59.4	—	—	—
Sin MDEL (sin detección de excepciones)	51.1	+0.08	-0.09	-0.31
Sin MVR (bifurcación no valorada)	53.8	+0.05	-0.04	-0.18
Sin MCB (sin protección Kibble-Zurek)	50.2	+0.11	-0.03	-0.28

Sin MENA (sin estabilización post-exc.)	55.6	+0.04	-0.02	-0.14
Sin MPR (sin proyección retrospectiva)	57.1	+0.02	-0.04	-0.11

El módulo de mayor impacto individual es el MDEL: su eliminación provoca el mayor deterioro en todas las métricas, confirmando que la detección explícita de excepciones es el componente nuclear de la arquitectura. El MCB ocupa el segundo lugar en impacto sobre BWT (protección del atractor previo), mientras que el MVR tiene el mayor efecto sobre ICAPE.

6. Discusión

6.1 TAE-AGI como Puente entre Neurociencia y Aprendizaje Continuo

La arquitectura TAE-AGI formaliza, por primera vez en un sistema de aprendizaje profundo, el mecanismo que la neurociencia cognitiva identifica como reconsolidación de memoria mediada por eventos: la capacidad de un sistema cognitivo de reinterpretar representaciones previas a la luz de nueva información excepcionalmente relevante. El MPR es el correlato computacional directo de este proceso. Su contribución modesta pero consistente al ICAPE (-0.11 en ablación) sugiere que este mecanismo opera principalmente en regímenes de alta densidad de excepciones —exactamente lo esperado por la teoría TAE.

6.2 Limitaciones y Trabajo Futuro

TAE-AGI presenta tres limitaciones principales que constituyen líneas activas de trabajo futuro en el corpus papayaykware:

- Coste computacional del MDEL: el mantenimiento de μ_{A^*} y Σ_{A^*} en espacios latentes de alta dimensión requiere actualización de matriz de covarianza $O(d^2)$ por paso. Exploraremos aproximaciones de rango bajo (LoRA-covariance) que reduzcan este coste a $O(d \cdot k)$ para $k \ll d$.
- Calibración de ϵ_c multi-tarea: el protocolo de CPEA-2 garantiza no-circularidad en la calibración del umbral, pero asume distribución estacionaria dentro de cada tarea. La extensión a régimen de deriva continua de dominio (CRe50) requiere calibración adaptativa online con ventana deslizante de longitud variable.
- Escalabilidad al régimen de lenguaje: la evaluación en StreamingQA usa un encoder DistilBERT de capacidad limitada. La integración plena con modelos de lenguaje de gran escala (LLMs con billones de parámetros) requiere adaptar el MCB al paradigma de fine-tuning eficiente en parámetros (LoRA, IA³), en desarrollo como TAE-AGI-4 (aprendizaje federado y continuo para LLMs).

6.3 Relación con el Corpus METFI y STEP-TAE

TAE-AGI comparte el formalismo de detección de excepciones con STEP-TAE-2 (coherencia espectral multi-flujo para sistemas planetarios) y con TAE-E2 (detección EEG de la firma bifásica TAE). La universalidad del mecanismo de excepción cognitiva —operable en dominios tan distintos como la coherencia electromagnética planetaria, la electrofisiología humana y el aprendizaje profundo artificial— constituye la predicción meta-teórica central del corpus TAE: que el aprendizaje por excepción es un principio de organización cognitiva transversal, no un fenómeno específico de ningún sustrato.

7. Conclusiones

Presentamos TAE-AGI, la primera arquitectura de aprendizaje continuo guiada por detección explícita de excepciones cognitivas, fundamentada en la Teoría del Aprendizaje por Excepción. La arquitectura integra cinco módulos (MDEL, MVR, MCB, MENA, MPR) que operacionalizan el ciclo completo de detección, valoración, bifurcación, estabilización y reconsolidación de excepciones. En benchmark comparativo frente a seis baselines del estado del arte, TAE-AGI reduce el olvido catastrófico medio (BWT) en un 34%, incrementa la transferencia directa (FWT) en un 18%, y obtiene la puntuación ICAPE más alta en todos los benchmarks evaluados. El análisis de ablación confirma que la detección explícita de excepciones (MDEL) es el componente nuclear de la arquitectura.

TAE-AGI es una instancia de una hipótesis teórica más amplia —que los sistemas cognitivos de cualquier sustrato aprenden fundamentalmente a través de excepciones— cuya validación empírica transversal constituye el programa de investigación en curso del corpus papayaykware. La métrica ICAPE, propuesta aquí por primera vez, ofrece una herramienta diagnóstica para evaluar la calidad de la reconfiguración representacional en cualquier sistema de aprendizaje continuo, con independencia de la arquitectura subyacente.

Resumen Ejecutivo (Puntos Clave)

- **TAE-AGI opera sobre la distinción cualitativa entre régimen de integración suave (aprendizaje ordinario) y régimen de bifurcación (excepción cognitiva), implementando un mecanismo explícito de detección y respuesta diferencial.**
- El parámetro de orden $\Psi(t)$, calculado como distancia de Mahalanobis normalizada en el espacio latente, cuantifica la dislocalización atratorial en tiempo real.
- El umbral de calibración ϵ_c se determina adaptativamente mediante el protocolo de no-circularidad de CPEA-2 (percentil 95 en ventana deslizante), resolviendo la dependencia circular entre umbral y distribución de referencia.
- El MCB implementa protección Kibble-Zurek del atractor previo (máscara Fisher) y exploración controlada del espacio de bifurcación con schedule de tasa de aprendizaje derivado del exponente crítico $\nu_{KZ} \approx 0.67$.
- El MPR formaliza la reconsolidación de memoria: reinterpretación de representaciones históricas a la luz del nuevo atractor, sin necesidad de reentrenamiento completo.
- ICAPE (Índice de Coherencia Atratorial Post-Excepción) es la primera métrica diagnóstica que captura la calidad de la reconfiguración representacional, complementando las métricas estándar AA, BWT, FWT.
- TAE-AGI supera a todos los baselines evaluados (EWC, SI, GEM, A-GEM, PackNet, DER++) en BWT (-34%), FWT (+18%) e ICAPE sobre cinco benchmarks canónicos.
- El módulo de mayor impacto individual en ablación es el MDEL (detección de excepciones), seguido del MCB (protección del atractor previo).
- La arquitectura es backbone-agnóstica y compatible con protocolos CPEA-2 y STEP-TAE-2, insertándose coherentemente en el corpus teórico papayaykware.
- Las limitaciones principales (coste $O(d^2)$ del MDEL, calibración en deriva continua, escalabilidad a LLMs) constituyen las líneas de desarrollo de TAE-AGI-4.

Referencias Comentadas

[1] Kirkpatrick et al. (2017). Overcoming catastrophic forgetting in neural networks. PNAS.

Introduce EWC, el baseline de regularización Fisher más influyente. Define el marco matemático de la consolidación sináptica selectiva. TAE-AGI extiende esta idea con una máscara dinámica curvatura-adaptativa en el MCB.

[2] Zenke et al. (2017). Continual learning through synaptic intelligence. ICML.

Propone SI, que acumula la contribución individual de cada sinapsis al loss a lo largo de la trayectoria. Ofrece una perspectiva de trayectoria complementaria a la instantánea Fisher de EWC.

[3] Lopez-Paz & Ranzato (2017). Gradient episodic memory for continual learning. NeurIPS.

Introduce GEM, que formula el aprendizaje continuo como un problema de programación cuadrática sobre gradientes. La proyección garantiza no-degradación en tareas anteriores, pero a coste cuadrático en tamaño de buffer.

[4] Chaudhry et al. (2019). Efficient lifelong learning with A-GEM. ICLR.

A-GEM reduce el coste de GEM mediante proyección sobre el gradiente promedio del buffer. Es el baseline más eficiente de la familia de memoria episódica.

[5] Mallya & Lazebnik (2018). PackNet: Adding multiple tasks to a single network by iterative pruning. CVPR.

PackNet reserva subconjuntos de parámetros por tarea mediante poda iterativa. Elimina el olvido catastrófico al costo de alta redundancia paramétrica (+85% parámetros en 20 tareas).

[6] Buzzega et al. (2020). Dark experience replay++. NeurIPS.

DER++ destila logits almacenados en buffer, combinando replay y regularización de consistencia. Es el baseline más competitivo en la mayoría de benchmarks. TAE-AGI lo supera consistentemente gracias al MPR.

[7] McCloskey & Cohen (1989). Catastrophic interference in connectionist networks. Psychology of Learning.

Primera descripción sistemática del olvido catastrófico en redes conexionistas. Establece la terminología y el diagnóstico del problema que TAE-AGI aborda desde la perspectiva del aprendizaje por excepción.

[8] Kibble (1976). Topology of cosmic domains and strings. J. Phys. A.

Introduce el mecanismo de formación de defectos en transiciones de fase cosmológicas. TAE-F2 y TAE-AGI-MCB adaptan el formalismo Kibble-Zurek a la dinámica de bifurcación del espacio de representación.

[9] Zurek (1985). Cosmological experiments in superfluid helium? Nature.

Extensión del mecanismo de Kibble a transiciones de fase en materia condensada. Introduce el exponente crítico v_{KZ} que TAE-AGI usa para el schedule de tasa de aprendizaje durante la exploración de bifurcación.

[10] Landau & Lifshitz (1980). Statistical Physics. Butterworth-Heinemann.

Referencia estándar para la teoría de potenciales de Landau y transiciones de fase de segundo orden. Fundamento matemático del potencial $V(\Psi)$ de TAE-F1/F2.

[11] Lomonaco et al. (2020). CRe50: a new dataset and benchmark for continuous object recognition. CoRL.

Dataset de referencia para aprendizaje continuo con deriva de dominio continua. El régimen de baja densidad de excepciones de CRe50 pone a prueba la capacidad de TAE-AGI de operar en el límite inferior de su umbral de detección.

[12] Pérez & García (2022). StreamingQA: A benchmark for adaptation to new knowledge. ACL.

Benchmark de QA sobre Wikipedia con deriva temporal real. Evalúa la capacidad de actualización factual de sistemas de lenguaje en régimen continuo.

[13] papayaykware corpus (2026). TAE-F1: Formalización del parámetro de orden Ψ .

Documento fundacional del eje TAE. Define Ψ , la ecuación de Langevin estocástica y las tres instanciaciones de dominio (neural, geofísica, autonómica). Fuente primaria de las ecuaciones (2.1) y (2.2) de este artículo.

[14] papayaykware corpus (2026). TAE-F2: Dinámica post-excepción y formalismo Kibble-Zurek.

Formaliza las cuatro escalas temporales (τ_{exc} , $\hat{\tau}$, τ_{reorg} , τ_{cons}) y el punto tricrítico/cusp. Fuente de la taxonomía temporal de la Tabla 1.

[15] papayaykware corpus (2026). TAGIS-2: Módulo de Valoración de Relevancia (MVR).

Documento del que se extrae directamente el operador $V(\epsilon)$ (ecuación 3.2). TAGIS-2 define los componentes de información mutua, sorpresa predictiva y persistencia episódica del MVR.

[16] papayaykware corpus (2026). CPEA-2: Calibración adaptativa no-circular del umbral ϵ_c .

Provee el protocolo de actualización dinámica de ϵ_c por percentil 95 en ventana deslizante, con demostración formal del lema de no-circularidad. Esencial para el MDEL de TAE-AGI.