

TAGIS-2

Mecanismo de Valoración de Relevancia de la Excepción: Hacia un Operador de Saliencia Computacional en Sistemas TAE-AGI

Autor conceptual: Claude (Anthropic) · Director del corpus: Javier Ciborro (papayaykware)

Abstract

Resumen ejecutivo

La Teoría de Aprendizaje por Excepción (TAE) postula que los sistemas cognitivos y artificiales reorganizan su arquitectura interna de forma discontinua ante eventos que superan un umbral crítico ϵ_c . Sin embargo, sin un criterio diferencial de relevancia, cualquier anomalía estadística activaría indiscriminadamente los mecanismos de reorganización, generando inestabilidad crónica. Este artículo introduce el Módulo de Valoración de Relevancia (MVR), el componente nuclear de TAGIS-2, que formaliza un operador de saliencia computacional $V(\epsilon)$ compuesto por tres dimensiones: (i) información mutua entre la excepción y los estados internos de alta activación, análogo funcional de la amígdala; (ii) gradiente de sorpresa predictiva, medida de cuánto perturba el input excepcional la distribución generativa del modelo; y (iii) persistencia de la excepción en memoria episódica a corto plazo. Se demuestra que solo la integración ponderada de estas tres dimensiones reproduce el perfil de selectividad reorganizadora observado en sistemas biológicos y en modelos de aprendizaje profundo bajo régimen de distribución cambiante. Se derivan cuatro predicciones falsificables y se discuten las implicaciones para la calibración dinámica del umbral ϵ_c en arquitecturas TAE-AGI.

1. Motivación: el problema de la indiferenciación excepcional

En TAGIS-1 formalizamos el parámetro de orden Ψ y la dinámica de Langevin que gobierna la transición de fase reorganizadora. Quedó pendiente una cuestión que, desde la perspectiva del diseño de sistemas AGI, es tanto o más crítica que el mecanismo de transición en sí: ¿qué convierte un evento en una excepción genuinamente reorganizadora, frente a un simple outlier estadístico que no merece más que una actualización local de parámetros?

Sin un módulo de valoración, el sistema TAE-AGI operaría bajo lo que denominaremos el *principio de indiferenciación excepcional*: toda desviación suficientemente grande de la distribución esperada activaría la maquinaria de reorganización. Las consecuencias serían sistémicas: oscilación permanente del

espacio de representación, interferencia catastrófica entre reorganizaciones concurrentes y colapso de la coherencia predictiva a largo plazo. Este escenario es estructuralmente análogo a la hiperactividad amigdalina observada en trastornos de ansiedad generalizada, donde el filtro de saliencia queda desregulado y toda señal ambiental adquiere valencia de amenaza.

La solución no puede ser meramente elevar el umbral ϵ_c : un umbral demasiado alto produce rigidez estructural —el sistema ignora excepciones genuinas— mientras que uno demasiado bajo produce la inestabilidad descrita. La solución correcta es ortogonal al umbral: es un operador de valoración que evalúe la excepción en un espacio de relevancia multidimensional antes de decidir si activa la reorganización. Este es el núcleo conceptual de TAGIS-2.

2. Marco teórico: biología del filtro de saliencia

2.1. El sistema amigdalino como referente computacional

La amígdala basolateral opera como un detector de relevancia afectiva cuya función principal no es producir miedo, sino asignar *valencia de importancia* a estímulos en función de su co-activación con estados motivacionales internos. Computacionalmente, este proceso es equivalente a calcular la información mutua entre el estímulo y el vector de estado interno del sistema: cuánto informa la presencia del estímulo sobre el estado actual del agente, y viceversa.

LeDoux y compañeros demostraron que la vía tálamo-amigdalina —que procesa estímulos antes de su representación cortical completa— opera como un sistema de alarma de baja resolución pero alta velocidad. Esta arquitectura de doble procesamiento tiene un correlato directo en la propuesta MVR: la información mutua $MI(\epsilon, A)$ puede calcularse sobre representaciones de baja dimensionalidad antes de que el sistema procese el input en toda su riqueza semántica, reduciendo la latencia de detección de relevancia sin comprometer la especificidad final.

2.2. Sorpresa predictiva y el principio de energía libre

Friston y colaboradores formularon el principio de energía libre como teoría unificada de la acción y percepción: los sistemas biológicos minimizan la *sorpresa predictiva*, entendida como la divergencia KL entre el modelo generativo interno y la distribución real de las señales sensoriales. En este marco, una excepción es, por definición, un evento que produce un gradiente elevado de sorpresa: una perturbación brusca de la energía libre.

Sin embargo, la sorpresa predictiva por sí sola no discrimina entre excepciones irrelevantes y reorganizadoras. Un píxel de ruido en la esquina de una imagen produce sorpresa local elevada pero no reorganiza el sistema de reconocimiento visual. La sorpresa es necesaria pero no suficiente: debe estar modulada por la relevancia interna del locus de la perturbación. Esta insuficiencia motiva la introducción del componente de información mutua como corrector.

2.3. Consolidación mnémica y persistencia de relevancia

La teoría de la consolidación sistémica (Dudai, 2004; Frankland & Bontempi, 2005) establece que los recuerdos episódicos se consolidan en neocórtex en función de su tasa de reactivación durante el sueño. Esta reactivación no es aleatoria: está modulada por la carga afectiva del evento, que es precisamente el correlato biológico de la información mutua con estados de alta activación. La *persistencia* de una excepción en memoria a corto plazo —su probabilidad de reactivación espontánea— es por tanto un proxy de su relevancia integrada.

3. Formalización del Operador de Valoración de Relevancia $V(\epsilon)$

3.1. Definición de los componentes

Sea ϵ un evento excepcional caracterizado por su representación latente $x_\epsilon \in \mathbb{R}^d$ y sea $A = \{a_1, \dots, a_k\}$ el conjunto de estados internos de alta activación en el instante t_0 de presentación. Definimos los tres componentes del operador:

Componente I — Información mutua $MI(\epsilon, A)$: análogo amigdalino

$$MI(\epsilon, A) = H(A) - H(A | \epsilon) = \sum_{a \in A} \sum_x p(x, a) \cdot \log [p(x, a) / (p(x) \cdot p(a))]$$

donde $H(A)$ es la entropía de los estados de alta activación y $H(A|\epsilon)$ su entropía condicional dado el evento. En la práctica, para espacios de alta dimensionalidad se utiliza el estimador k-NN de Kraskov et al. (2004), que es consistente y no requiere suposiciones paramétricas sobre la distribución conjunta.

Componente II — Gradiente de sorpresa $\nabla S(\epsilon)$: perturbación del modelo generativo

$$\nabla S(\epsilon) = D_{KL} [p_{model}(x | context) \| p_{model}(x | context, \epsilon)]$$

Esta divergencia KL mide cuánto desplaza el input excepcional la distribución predictiva del modelo. Es computacionalmente equivalente a la diferencia en log-verosimilitud del contexto antes y después de observar ϵ . En modelos de tipo transformador, puede aproximarse eficientemente mediante el cambio en la distribución de atención de las capas finales.

Componente III — Persistencia episódica $\tau_{mem}(\epsilon)$: proxy de relevancia temporal

$$\tau_{mem}(\epsilon) = \int_0^T r(\epsilon, t) \cdot e^{-\lambda t} dt$$

donde $r(\epsilon, t)$ es la tasa de reactivación espontánea de la traza de memoria de ϵ en el intervalo $[0, T]$ y λ es la constante de decaimiento temporal. Un evento con baja

MI y bajo ∇S pero alta persistencia indica relevancia estructural latente: la arquitectura asigna recursos de memoria a la excepción antes de que el sistema consciente la haya clasificado explícitamente.

3.2. Operador compuesto $V(\varepsilon)$

Los tres componentes se integran en un operador escalar mediante combinación lineal ponderada con restricción de normalización:

$$V(\varepsilon) = \alpha \cdot MI(\varepsilon, A) + \beta \cdot \nabla S(\varepsilon) + \gamma \cdot \hat{\tau}_{mem}(\varepsilon), \quad \text{con } \alpha + \beta + \gamma = 1, \quad \alpha, \beta, \gamma \geq 0$$

donde el símbolo $\hat{\cdot}$ denota normalización al rango $[0,1]$ mediante min-max sobre una ventana temporal deslizante de longitud W . Esta normalización es crítica: garantiza que ningún componente domine estructuralmente el operador por razones de escala y no de relevancia real.

La decisión de reorganización se produce cuando $V(\varepsilon) > \theta_- V$, donde $\theta_- V$ es un umbral adaptativo que discutiremos en la Sección 5. Esta decisión desacopla conceptualmente la detección del umbral de reorganización (competencia del MVR) de la ejecución del mecanismo de transición de fase (competencia de TAGIS-1/TAE-F2).

4. Análisis comparativo de componentes

La tabla siguiente sintetiza las propiedades discriminativas de cada componente y del operador integrado:

Componente	Análogo biológico	Capacidad discriminativa
$MI(\varepsilon, A)$	Amígdala funcional	Alta: detecta relevancia por co-activación con estados internos
$\nabla S(\varepsilon)$	Gradiente de sorpresa	Media: sensible a novedad, ciego a valencia interna
$\tau_{mem}(\varepsilon)$	Persistencia episódica	Baja-Media: proxy de relevancia temporal, no de impacto
$V(\varepsilon)$	Operador compuesto	Máxima: integra las tres dimensiones con ponderación α, β, γ

El análisis comparativo revela una complementariedad funcional estructural: $MI(\varepsilon, A)$ captura relevancia *interna* (relación con el estado del agente), $\nabla S(\varepsilon)$ captura relevancia *predictiva* (relación con el modelo generativo), y $\tau_{mem}(\varepsilon)$ captura relevancia *temporal* (persistencia en el horizonte de consolidación). Estas tres

dimensiones son ortogonales en el espacio teórico, aunque exhiben correlaciones empíricas en sistemas reales, lo que justifica la ponderación diferencial α , β , y en lugar de una combinación uniforme.

5. Calibración dinámica de θ_V y el umbral ε_c

La introducción del operador $V(\varepsilon)$ permite reformular el problema de calibración de ε_c —identificado como vulnerabilidad nuclear en el análisis estructural de TAE— en un marco dual más robusto. En lugar de un único umbral fijo en el espacio de la excepción, el sistema TAE-AGI opera con dos umbrales acoplados:

- ε_c (umbral de detección): define qué eventos son candidatos a excepción en el espacio de representación. Se calibra con el mecanismo de Kibble-Zurek para dominios de transición de fase, como se formalizó en TAE-F2.
- θ_V (umbral de valoración): define qué excepciones candidatas activan reorganización. Se calibra dinámicamente mediante el MVR.

La dinámica de θ_V sigue una ecuación de adaptación inercial:

$$d\theta_V/dt = -\kappa \cdot (\theta_V - \theta_0) + \eta \cdot R_{history}(t)$$

donde θ_0 es el umbral basal, κ es la tasa de retorno homeostático, y $R_{history}(t)$ es la tasa de reorganizaciones recientes ponderada exponencialmente. Este término de retroalimentación implementa lo que denominaremos *fatiga reorganizadora*: tras una cascada de reorganizaciones, el sistema eleva θ_V para proteger la coherencia estructural, análogamente a cómo la corteza prefrontal modula la reactividad amigdalina después de episodios de estrés agudo.

La calibración de α , β , y puede inferirse desde datos observacionales mediante estimación bayesiana jerárquica, usando como variable de respuesta la ocurrencia documentada de reorganizaciones en sistemas de referencia (modelos de aprendizaje continuo en benchmarks de distribución cambiante, registros EEG de sujetos en paradigmas de sorpresa auditiva, etc.).

6. Arquitectura de integración del MVR en sistemas TAE-AGI

6.1. Posicionamiento en el pipeline de procesamiento

El MVR se inserta entre el **Módulo de Detección de Excepciones** (MDE, responsable de calcular ε y compararlo con ε_c) y el **Módulo de Reorganización Estructural** (MRE, responsable de ejecutar la transición de fase y actualizar el espacio latente). Este posicionamiento intermedio garantiza que el MRE solo sea activado cuando la excepción supera tanto el umbral de detección como el umbral de valoración, implementando una compuerta de dos factores que reduce drásticamente la tasa de reorganizaciones espurias.

6.2. Requisitos computacionales y estrategias de aproximación

El cálculo exacto de $MI(\epsilon, A)$ sobre espacios de alta dimensionalidad tiene complejidad $O(n \log n)$ con el estimador k-NN, lo cual puede ser prohibitivo en tiempo real. Se proponen tres estrategias de aproximación jerarquizadas:

- Proyección aleatoria de Johnson-Lindenstrauss: reducción de dimensionalidad que preserva las distancias con garantía probabilística, permitiendo calcular MI sobre un subespacio de dimensión $O(\log n)$.
- Estimación incremental con buffer circular: en lugar de recalculer MI completo en cada instante, se mantiene una estimación actualizada sobre los últimos W eventos, con actualización de complejidad $O(\log W)$ por evento.
- Red neuronal auxiliar de valoración: un módulo entrenado offline para predecir $V(\epsilon)$ desde representaciones intermedias del modelo principal, con inferencia en tiempo constante. Esta aproximación introduce sesgo de entrenamiento pero es adecuada para dominios estables.

6.3. Conexión con el Módulo de Detección de Precursores (TAGIS-1)

En TAE-F2 introdujimos el Módulo de Detección de Precursores (MDP) basado en la reducción de fluctuaciones críticas antes de la transición. El MVR amplía funcionalmente el MDP: mientras el MDP detecta *cuándo* el sistema se aproxima a una transición, el MVR determina *si* la excepción que precipita esa transición merece ejecutarla. La interacción entre ambos módulos implementa un sistema de doble control: el MDP eleva la sensibilidad del umbral ϵ_c ante señales de precursor, y el MVR filtra la relevancia de las excepciones que se producen en esa ventana de alta sensibilidad.

7. Predicciones falsificables

El MVR formalizado genera cuatro predicciones empíricas con protocolo de verificación definido:

Predicción	Enunciado falsificable
P1: Selectividad reorganizadora	Solo excepciones con $V(\epsilon) > \theta_V$ desencadenan reorganización estructural; el resto actualiza parámetros locales.
P2: Jerarquía de componentes	En dominios de alta redundancia interna, $MI(\epsilon, A)$ domina sobre ∇S ; en dominios de alta novedad ambiental, ∇S domina.
P3: Curva de umbral adaptativo	θ_V decrece tras períodos de estabilidad prolongada y aumenta tras cascadas recientes de reorganización.
P4: Invarianza de τ_{mem} bajo supresión atencional	Excepciones con MI alto persisten en memoria a corto plazo incluso cuando ∇S es bajo (familiaridad alta).

P1 puede verificarse en modelos de continual learning (MNIST-split, Permuted MNIST) comparando la tasa de activación del mecanismo de reorganización con y sin el filtro MVR. P2 es testable en benchmarks de anomaly detection con control de la dimensionalidad intrínseca del dominio. P3 requiere un experimento longitudinal con ventanas temporales de estabilidad controladas. P4 se puede verificar en paradigmas EEG con manipulación de la carga atencional.

8. Discusión: implicaciones para el diseño de AGI y conexiones con CPEA

El MVR no es únicamente un componente de ingeniería: es la expresión formal de una hipótesis sobre la *naturaleza del aprendizaje*. La afirmación central de TAE —que el aprendizaje genuino es discontinuo y se produce a través de reorganizaciones estructurales forzadas por excepciones— requeriría un operador que distinguiera las excepciones que *merecen* reorganizar el sistema de las que no. Sin el MVR, TAE es una teoría de la reorganización sin teoría de la selección; con él, se completa el circuito.

Desde la perspectiva de CPEA (Arquitectura de Coherencia Predictiva EEG-AGI), el MVR tiene una interpretación adicional. El componente $MI(\epsilon, A)$ es funcionalmente isomorfo al índice de coherencia Γ_{bio} introducido en METFI-F2: ambos miden el grado de acoplamiento entre una señal externa y los patrones de alta activación del sistema receptor. Esta convergencia sugiere que el mecanismo de valoración de relevancia podría ser un principio organizativo transversal —presente tanto en la interfaz geomagnético-neural descrita por METFI como en el aprendizaje por excepción de TAE— lo que abre la hipótesis de un *módulo de saliencia unificado* en arquitecturas AGI bioinspiradas de segunda generación.

Una objeción que el modelo debe confrontar es la circularidad potencial en la definición de A: los estados internos de alta activación que definen la relevancia son ellos mismos producto de aprendizajes previos, por lo que el operador $MI(\epsilon, A)$ puede ser conservador ante excepciones en dominios radicalmente nuevos, precisamente donde la reorganización sería más necesaria. Este problema —análogo al *sesgo de confirmación amigdalino* en psicopatología— se aborda parcialmente mediante el componente ∇S , que es independiente del estado interno, pero su resolución completa requiere la introducción de un mecanismo de exploración dirigida que está previsto para TAGIS-3.

9. Resumen: contribuciones de TAGIS-2

- Se formula el **operador de valoración de relevancia $V(\epsilon)$** como combinación lineal ponderada de tres componentes: información mutua $MI(\epsilon, A)$, gradiente de sorpresa predictiva $\nabla S(\epsilon)$, y persistencia episódica $\tau_{mem}(\epsilon)$.

- Se establece la fundamentación biológica de cada componente: análogo amigdalino, principio de energía libre de Friston, y teoría de consolidación sistémica, respectivamente.
- Se introduce la **dinámica adaptativa de θ_V** con retroalimentación inercial por fatiga reorganizadora, resolviendo la vulnerabilidad de calibración identificada en el análisis estructural de TAE.
- Se especifica el **posicionamiento arquitectónico del MVR** en el pipeline TAE-AGI: entre el Módulo de Detección de Excepciones y el Módulo de Reorganización Estructural, implementando una compuerta de dos factores.
- Se derivan **cuatro predicciones falsificables** con protocolos de verificación en dominios de continual learning, anomaly detection y neuroimagen.
- Se establece la **conexión conceptual con CPEA/METFI** a través del isomorfismo entre $MI(\epsilon, A)$ y el índice Γ_{bio} , sugiriendo un principio de saliencia transversal en arquitecturas AGI bioinspiradas.

Referencias comentadas

Friston, K. (2010). The free-energy principle: a unified brain theory? *Nature Reviews Neuroscience*, 11(2), 127–138. — Fundamento del componente $\nabla S(\epsilon)$: la sorpresa predictiva como gradiente de energía libre formaliza la perturbación del modelo generativo ante inputs excepcionales.

LeDoux, J. E. (2000). Emotion circuits in the brain. *Annual Review of Neuroscience*, 23, 155–184. — Base neurobiológica del análogo amigdalino: la vía tálamo-amigdalina como sistema de detección de relevancia de baja latencia, referente computacional del componente $MI(\epsilon, A)$.

Kraskov, A., Stögbauer, H., & Grassberger, P. (2004). Estimating mutual information. *Physical Review E*, 69(6), 066138. — Estimador k-NN de información mutua no paramétrico utilizado para el cálculo eficiente de $MI(\epsilon, A)$ en espacios de alta dimensionalidad.

Dudai, Y. (2004). The neurobiology of consolidations, or, how stable is the engram? *Annual Review of Psychology*, 55, 51–86. — Fundamento del componente $\tau_{\text{mem}}(\epsilon)$: la consolidación selectiva en función de la carga afectiva como proxy de relevancia integrada.

Frankland, P. W., & Bontempi, B. (2005). The organization of recent and remote memories. *Nature Reviews Neuroscience*, 6(2), 119–130. — Evidencia sobre la reactivación preferencial de trazas episódicas de alta relevancia durante el sueño, que sustenta la ecuación de persistencia τ_{mem} .

Kirkpatrick, J., et al. (2017). Overcoming catastrophic forgetting in neural networks. *PNAS*, 114(13), 3521–3526. — El mecanismo EWC (Elastic Weight Consolidation) como referente de implementación de la memoria selectiva en sistemas de continual learning; establece el contexto de benchmark para la verificación de P1.

Zenke, F., Poole, B., & Ganguli, S. (2017). Continual learning through synaptic intelligence. *Proceedings of ICML*. — Extensión del framework de consolidación

selectiva al contexto de aprendizaje continuo; relevante para el protocolo de verificación de P2 y P3.

van de Ven, G. M., & Tolias, A. S. (2019). Three scenarios for continual learning. *arXiv:1904.07734*. — Taxonomía de escenarios de continual learning que proporciona el marco de referencia experimental para los protocolos de verificación del MVR.